

Osnove statistike za društvene znanosti

Udžbenik za studente koji moraju razumjeti istraživanje



Luka Šikić

Doc. dr. sc. · Sveučilišni odjel za komunikologiju



Petra Palić

Izv. prof. dr. sc. · Sveučilišni odjel za sociologiju

POGLAVLJE 0

Osnove statistike za društvene znanosti

Udžbenik

Osnove statistike za društvene znanosti

Za studente koji moraju razumjeti istraživanje, a ne postati analitičari. Bez matematike iznad srednje škole i bez pretpostavljenog programiranja. Svaka ideja najprije se vidi kroz simulaciju, pa tek onda dobiva ime i formulu.

Počni čitati Interakcije Uči uz AI

Autori

Doc. dr. sc.

Luka Šikić

Docent, Sveučilišni odjel za komunikologiju, Hrvatsko katoličko sveučilište.

Izv. prof. dr. sc.

Petra Palić

Izvanredna profesorica, Sveučilišni odjel za sociologiju, Hrvatsko katoličko sveučilište.

18 poglavlja

5 dijelova

17 interakcija

6 dodataka

Što knjiga obećava

Nakon čitanja student može kritički prosuditi statističku tvrdnju na koju naiđe u medijima, izvještaju ili odgovoru umjetne inteligencije. Može pošteno opisati i prikazati skup podataka. Može pročitati, protumačiti i skromno reproducirati zaključne analize koje prevladavaju u objavljenim društvenim znanostima. I može s AI asistentom raditi disciplinirano, prepuštajući mu računanje, a zadržavajući prosudbu, provjeru i odgovornost.

Dio I

Statističko mišljenje

Signal i šum, mjerenje i dizajn, i kako brojke zavode.

Dio II

Opisivanje podataka

Sažimanje, vizualizacija kao argument, povezanost.

Dio III

Od uzorka do populacije

Vjerojatnost koliko treba, uzorkovanje, procjena.

Dio IV

Zaključivanje

Logika testiranja, veličina učinka i snaga, kriza i obnova.

Dio V

Modeli

Kategorički podaci, usporedbe grupa, regresija, doba algoritama.

Završnica

Vaše prvo istraživanje

Jedno cjelovito vođeno istraživanje, od pitanja do izvještaja.

Predgovor

VINJETA

Američko statističko udruženje moralo je objaviti posebno pojašnjenje jednog od najčešćih brojeva u znanstvenim radovima jer je p -vrijednost postala zamjena za širi sud o dokazima (Wasserstein i Lazar 2016.). Problem nije pripadao samo specijalistima. Isti skok od broja prema presudi pojavljuje se u novinskim naslovima, izvještajima ustanova i odgovorima generativnih modela.

Čitatelj društvenih istraživanja svakodnevno susreće postotke, intervale, grafove i predikcije. Ne mora sam graditi svaki složeni model, ali mora znati koje pitanje rezultat odgovara, odakle dolazi i gdje prestaje njegova dokazna snaga.

Koji minimum statističkog znanja pretvara pasivnog primatelja brojki u odgovornog čitatelja istraživanja?

Knjiga za čitatelja istraživanja

Ova je knjiga namijenjena studentima društvenih znanosti koji moraju razumjeti istraživanje, a ne postati profesionalni analitičari. Ne pretpostavlja programiranje ni matematiku izvan srednjoškolskog gradiva. Pretpostavlja spremnost da se svaka tvrdnja uspori dovoljno dugo kako bismo vidjeli podatke, usporedbu i neizvjesnost.

Gradivo slijedi put od statističkog mišljenja preko opisivanja i uzorkovanja do zaključivanja, modela i algoritamskih sustava. Simulacija dolazi prije formule. Procjena i interval dolaze prije testa. Čitanje tuđih brojki ravnopravan je sadržaj, a ne motivacijska digresija.

Nakon knjige čitatelj bi trebao moći kritički prosuditi statističku tvrdnju, pošteno opisati podatke, pratiti temeljne inferencijalne analize i surađivati s AI asistentom bez predaje odgovornosti. Račun se može delegirati. Izbor pitanja, provjera izvora i potpis pod zaključkom ostaju ljudski posao.

Granice i putovi čitanja

Knjiga ne obuhvaća vremenske nizove, faktorsku analizu, psihometriju, višerazinske modele ni punu Bayesovsku inferenciju. Strojno učenje pojavljuje se kroz ideje i društvene posljedice, a ne kroz matematičku izgradnju algoritama. Granica nije tvrdnja da te teme nisu važne, nego odluka da se obećani put može završiti.

Digitalno izdanje nosi interaktivne prikaze, a tiskano njihove statične blizance. Dodatci nude R praktikum, put bez koda, katalog podataka, odabir postupka, rječnik i protokol za rad s asistentom.

Kod se u poglavljima pojavljuje kao dokaz, a ne kao zadatak. Nijedna vježba ne traži da čitatelj napiše program. Razrađeni primjer svakog poglavlja pokazuje postupak kojim su dobivene brojke iz proze, jer

tvrdnja koju nije moguće provjeriti nije tvrdnja. Za čitanje tih blokova dovoljna su tri znaka. Znak $|>$ znači „pa onda” i vodi podatke iz jednog koraka u sljedeći, znak $+$ dodaje još jedan sloj grafu, a `aes` ime-
nuje pridruživanje varijabli vizualnim kanalima. Sve ostalo su imena
glagola koja kažu što rade. Tko poželi i sam pisati, kroz R ga od insta-
lacije vodi praktikum, a tko to ne želi, put bez koda ostaje potpun.

Poglavlja se mogu čitati redom, ali i koristiti kao referenca. Pojmovi
se namjerno vraćaju. Simpsonov paradoks najprije gradi statističku
sumnju, zatim se pojavljuje u povezanosti i kategoričkim podacima.
Uzročnost se sadi u dizajnu i vraća u regresiji. Predikcija se odvaja
od objašnjenja prije nego što uđe u svijet algoritama.

STATISTIKA U DIVLJINI

Jedan broj ne nosi cijeli dokaz. Izjava Američkog statističkog udru-
ženja upozorila je da p-vrijednost sama ne mjeri veličinu učinka ni važ-
nost rezultata (Wasserstein i Lazar 2016.).

To načelo određuje ton knjige. Nijedan rezultat ne odbacujemo zbog
jednog broja i nijedan ne prihvaćamo zbog njega. Vraćamo se pitanju,
dizajnu, procjeni, neizvjesnosti i posljedicama.

PITAJTE MODEL

Asistent u ovoj knjizi služi kao instrument za račun, objašnjenje i pro-
vjeru. Svaki njegov rezultat mora ostaviti vidljiv trag do podataka, koda
ili izvora. Model ne dobiva osobne podatke ispitanika i ne navodi se kao
dokaz za empirijsku tvrdnju.

Objasni postupak korak po korak, prikaži račun ili kod i
navedi što trebam ručno provjeriti. Ne izmišljaj izvore ni
podatke koji nisu priloženi.

NADITE GREŠKU

Asistent je dao jasan postupak, reproducibilan kod i ograničio zaključak na opažajni dizajn. Budući da tekst zvuči uvjerljivo, navedeni izvor nije potrebno otvoriti i provjeriti.

Razrađeni primjer

Svako poglavlje slijedi isti mali ugovor. Stvarna vinjeta otvara pitanje. Proza i simulacija grade pojam. Interakcija omogućuje promjenu uvjeta, a „Statistika u divljini” rastavlja objavljenu tvrdnju. Dva okvira o asistentu pokazuju koristan postupak i jednu realističnu pogrešku.

Razrađeni primjer zatim vodi analizu od pitanja do ograničenog zaključka. Kod ostaje dostupan, ali proza mora stajati samostalno. Sažetak, dvojezični pojmovi i četiri vrste zadataka zatvaraju poglavlje. Taj ponovljeni oblik oslobađa čitatelja da pažnju usmjeri na ono što se u statističkom argumentu mijenja.

Sažetak

Knjiga uči statistiku kao disciplinu povezivanja pitanja, podataka, postupka i ograničenog zaključka. Simulacija, procjena, provjera izvora i transparentan rad s asistentom njezine su stalne metode. Opseg je namjerno ograničen kako bi čitatelj završio put od osnovnog brojanja do kritičkog čitanja modela. Prvo poglavlje započinje tamo gdje broj prestaje biti dovoljan odgovor.

Pojmovi

statistička pismenost (*statistical literacy*), simulacija (*simulation*), procjena (*estimation*), reproducibilnost (*reproducibility*), provjera izvora (*source verification*)

Zadaci

Konceptualni

Opišite razliku između razumijevanja istraživanja i profesionalnog izvođenja analize. Predajte jedan odlomak.

Računski

Otvorite presavijeni blok koda u razrađenom primjeru poglavlja o sažimanju podataka i povežite svaki njegov korak s rečenicom iz proze. Predajte kratku mapu postupka, bez pisanja vlastitoga koda.

Kritički

Pročitajte izjavu o p-vrijednostima i izdvojite načelo koje biste primijenili na novinski naslov (Wasserstein i Lazar 2016.). Predajte naslov prije i nakon revizije.

Revizija modela

Ocijenite modelsku analizu iz okvira. Imenujte tri dobre prakse, jednu pogrešku i točan postupak provjere izvora.

DIO I: STATISTIČKO MIŠLJENJE

Zašto statistika

Zašto kontekst odlučuje što brojke znače

Vrijeme čitanja	Widget	Podaci	Preduvjet
18 min	Simpsonov paradoks	UCBAmissions	bez preduvjeta

VINJETA

Podaci o upisima na Sveučilište Kalifornije u Berkeleyju 1973. godine otvorili su ozbiljno pitanje. Jesu li njegovi poslijediplomski programi pri upisu diskriminirali žene (Bickel i sur. 1975.)? Zbirni podaci upućivali su upravo na to. Među prijavama u šest najvećih odjela stopa prijma iznosila je 44,5 % za muškarce i 30,4 % za žene (Bickel i sur. 1975.).

Istraživački tim zatim je iste prijave razdvojio prema odjelu. Slika se promijenila. U 4 od šest odjela stopa prijma za žene bila je barem jednaka stopi za muškarce, dok su se žene češće prijavljivale na odjele na kojima je prijam bio teži za sve kandidate (Bickel i sur. 1975.). Zbirni jaz nije nestao iz tablice, ali njegovo se značenje više nije moglo čitati na isti način.

Oba su prikaza nastala iz istih prijava i oba su računski točna. Jedan sugerira veliku razliku, a drugi pokazuje da sastav prijava tu razliku snažno oblikuje. Kojoj slici treba vjerovati kada ispravan izračun vodi prema pogrešnom zaključku?

Broj nije zaključak

Berkeleyjski slučaj ne pokazuje da su podaci nepouzdana. Pokazuje nešto zahtjevnije. Podaci ne donose zaključak bez pitanja koje im postavljamo i bez usporedbe kojom na to pitanje odgovaramo. Zbirna stopa odgovara na pitanje tko je češće primljen u promatranoj skupini prijava. Stope po odjelima odgovaraju na pitanje kako su prolazili kandidati koji su se prijavili na isti odjel. Ta su pitanja povezana, ali nisu ista.

Statistika počinje upravo na mjestu na kojem prestaje jednostavno prebrojavanje. Njezina zadaća nije proizvesti broj, nego odrediti što taj broj može poduprijeti. Pritom mora sačuvati vezu između pitanja, načina mjerenja, usporedbe i zaključka. Izračun može biti besprijekoran, a tvrdnja izgrađena na njemu ipak pogrešna jer broj odgovara na drugo pitanje od onoga koje nas zanima.

Zbog toga podatke nije korisno zamišljati kao suprotnost ljudskom iskustvu. Anegdota može otkriti problem, predložiti mehanizam ili pokazati posljedicu koju tablica skriva. Ne može nam sama reći koliko je pojava raširena ni što bi se dogodilo u drugim okolnostima. Podaci proširuju pogled preko pojedinačnog slučaja, ali zauzvrat traže odluke o tome koga smo promatrali, što smo mjerili i s čime rezultat uspoređujemo.

Podjela posla među njima prilično je jasna. Pojedinačan slučaj dobro odgovara na pitanje kako se nešto uopće događa, jer opisuje redoslijed, okolnosti i iskustvo koje brojka izostavlja. Ispitanica koja objašnjava zašto je prestala čitati vijesti daje mehanizam koji nijedna stopa ne sadrži. Podaci na razini skupine odgovaraju na pitanje koliko je često i koliko različito, jer jedino oni pokazuju kako se slučajevi raspoređuju. Nesporazum nastaje kada odgovor na jedno pitanje uzmemo kao odgovor na drugo, pa iz jednog uvjerljivog svjedočenja izvedemo raširenost ili iz prosjeka izvedemo iskustvo pojedinca.

Kvantitativna analiza time ne zamjenjuje poznavanje područja nego o njemu ovisi. Odluka o tome koje su skupine usporedive, koje objašnjenje zasluđuje provjeru i koja je razlika dovoljno velika da bi bila važna dolazi iz teorije i iz poznavanja slučaja. Račun te odluke provodi, ali ih ne donosi.

Broj zato ne govori sam za sebe. Govori unutar postupka koji možemo pregledati, ponoviti i osporiti. Strogost statističkog pristupa ne sastoji se u tome da svakom dojmu suprotstavimo izračun. Sastoji se u tome da učinimo vidljivima korake između opažanja i tvrdnje.

Odluka koja se donosi bez dokaza

Berkeleyjski slučaj završio je u znanstvenom časopisu, ali oblik problema svakodnevno je i izvan istraživanja. Zamislimo uredništvo portala u kojem posjećenost pada. Urednik smatra da su naslovi predosadni i traži drukčiji stil. Prijedlog zvuči uvjerljivo i moguće je da je točan. Jednako su moguća i druga objašnjenja, od vremena objave

i duljine tekstova do konkurentske aplikacije koja je upravo izašla ili godišnjeg doba u kojem publika radi nešto drugo.

Bez podataka takva se rasprava ne može razriješiti. Svaki sudionik ima svoju teoriju, svaka teorija ima primjer koji joj ide u prilog, a odluka na kraju pripadne osobi koja je najuvjerljivije govorila. Isti se raspored ponavlja u ministarstvu koje procjenjuje je li mjera djelovala, u udruzi koja mjeri doseg kampanje i u stranačkom stožeru koji tumači pomak u anketi. Statistika ne obećava da će uvijek dati odgovor. Obećava postupak u kojem se neslaganje premješta s uvjerljivosti govornika na provjerljivost tvrdnje.

Društvene znanosti taj zahtjev nose u vlastitoj definiciji. Sociologija, politologija, psihologija, komunikologija i ekonomija empirijske su discipline, pa se njihove tvrdnje moraju moći suočiti s opažanjima. Kada istraživač tvrdi da je povjerenje u medije palo, da negativne vijesti privlače više pozornosti ili da neki oblik sudjelovanja slabi s dohotkom, ta tvrdnja mora imati podatke iza sebe. Podaci pak bez postupka koji ih pretvara u usporedbu ostaju zaliha brojki koja podupire gotovo svaki zaključak.

Okolnosti su usto takve da se podacima više ne bavi samo istraživač. Svaki klik, otvorena poruka i sekunda gledanja negdje se bilježe, a odluke o sadržaju, oglasima i dosegu donose se iz tih zapisa. Tko ne razumije kako takvi podaci nastaju i što njihovi rezultati ne pokazuju, ne može ravnopravno sudjelovati u raspravi koju oni oblikuju. Statistička pismenost time postaje uvjet sudjelovanja, a ne dodatna vještina.

Navarro učenje statistike uspoređuje s kuharskim receptom, gdje niz mehaničkih uputa najprije izgleda proizvoljno, a razumijevanje počinje kada postane jasno zašto svaki korak postoji (Navarro 2019.). Recept se tada prestaje slijediti i počinje se kuhati. Ista razlika dijeli izračun od statističkog mišljenja. Formula se može primijeniti bez razumijevanja, ali odluka o tome koju usporedbu uopće treba napraviti ne može.

Vrijedi odmah reći i što statistika ne obećava. Ona ne pretvara nepotpune podatke u potpune i ne nadoknađuje ono što nije izmjereno.

Ne odlučuje umjesto istraživača koja je usporedba važna, jer taj izbor pripada području o kojem se raspravlja, a ne računu. Ne uklanja nesigurnost, nego je izražava, pa je pošten statistički nalaz gotovo uvijek uži i oprezniji od tvrdnje koja mu prethodi. Očekivanje da će analiza donijeti konačan sud najčešće završava razočaranjem ili pretjeranom tvrdnjom, a knjiga na oboje pokušava odgovoriti ranije nego kasnije.

Gdje intuicija popušta

Protiv takvog postupka govori jedan uporan prigovor. Ako je zaključak dovoljno očit, čemu formalna provjera. Odgovor je da naša prosudba promjenjivosti i vjerojatnosti sustavno griješi, i to na predvidljive načine. Ljudska sklonost prepoznavanju obrazaca izvanredno je korisna, ali radi i kada obrasca nema.

Slučajnost je prvo mjesto na kojem intuicija popušta. Niz od 10 bacanja novčića u kojem se pismo i glava savršeno izmjenjuju većini ljudi ne izgleda slučajno. Neuredan niz s tri uzastopna pisma izgleda mnogo prirodnije. Kod poštenog novčića svaki od 1024 moguća niza jednako je vjerojatan, pa ni jedan od njih nije manje slučajan od drugoga. Mi zapravo ne uspoređujemo niz s vjerojatnošću nego s mentalnom slikom slučajnosti koja je previše uredna. Stvarna je slučajnost grudasta, pa nizovi, gomilanja i naizgled značajni obrasci nastaju i kada iza njih ne stoji nikakav uzrok.

Drugo mjesto je pojedinačan slučaj. Ako susjed hvali novu aplikaciju za vijesti i dvoje kolega kaže isto, dojam dokaza nastaje gotovo automatski. Troje ljudi ipak ne opisuje populaciju, a ni njihov izbor nije slučajan, jer su za novu aplikaciju vjerojatno posegnuli oni koji se vijestima ionako više bave. Tversky i Kahneman opisali su sklonost da učestalost pojave procjenjujemo prema tome koliko nam lako pada na pamet njezin primjer, što su nazvali heuristikom dostupnosti (Tversky i Kahneman 1973.). Živopisan i nedavan slučaj time dobiva težinu koju mu njegova stvarna zastupljenost ne daje.

Treće mjesto je povezanost. Portali koji objavljuju više tekstova imaju više ukupnih posjeta, iz čega se lako izvodi savjet da treba objavljivati više. Veći portali istodobno imaju više novinara, veći proračun i stariju publiku, pa broj tekstova može biti popratna pojava, a ne uzrok. Odnos među dvjema pojavama može nastati zato što prva utječe na drugu, zato što druga utječe na prvu ili zato što obje ovise o nečem trećem. Tvrdnja da povezanost nije uzročnost zvuči kao opće mjesto, ali koraci kojima se ona provjerava predmet su poglavlja o dizajnu istraživanja i poglavlja o regresiji.

Ta tri promatranja imaju zajednički oblik. U svakome nam nedostaje usporedba. Ne znamo kako izgledaju ostali nizovi, ne znamo za one koji aplikaciju nisu pohvalili i ne znamo što bi se dogodilo pri istom broju tekstova na portalu druge veličine. Statistika popravlja upravo to, tako da usporedbu učini izričitom umjesto da je prepusti dojamu.

Zbog toga ni količina podataka sama po sebi ne rješava problem. Analitika velikog portala bilježi milijune interakcija, ali ako bilježi samo one koji su došli, o onima koji nisu ne govori ništa, koliko god zapisa bilo. Veći skup smanjuje rasipanje oko procjene, a sustavan propust u tome što je uopće promatrano ostaje jednako velik u malom i u golemom skupu. Pogreška izbora ne razrjeđuje se količinom, što je razlika koju poglavlje o uzorkovanju razrađuje brojčano.

Prigovor da ovakav oprez vodi u nemoć ipak ne stoji. Nesigurno znanje nije isto što i neznanje, a razlika među njima je upravo ono što statistički postupak mjeri. Ista disciplina koja zabranjuje preširok zaključak dopušta da uži zaključak izrečemo s razlogom i da kažemo koliko čvrsto stoji.

Signal u promjenjivom svijetu

Društvene pojave rijetko se ponavljaju na potpuno isti način. Dvije osobe izložene istoj poruci ne moraju joj jednako vjerovati. Ista anketa provedena na drugom uzorku neće vratiti potpuno jednake postotke. Čak se i ponašanje iste osobe mijenja s vremenom i okolnostima. Ta

promjenjivost nije kvar podataka. Ona je razlog zbog kojeg nam statistika treba.

U takvoj promjenjivosti pokušavamo razlučiti **signal** od **šuma**. Signal je obrazac koji nas zanima, poput razlike među skupinama ili povezanosti dviju pojava. Šum obuhvaća ostale izvore varijacije zbog kojih opažanja ne pristaju savršeno uz obrazac. Granica među njima nije zadana unaprijed. Ono što je šum za jedno pitanje može postati signal za drugo.

Ako proučavamo razlikuje li se povjerenje u institucije među dobnim skupinama, pojedinačne razlike unutar svake skupine otežavaju nam da vidimo opći obrazac. Ako zatim pitamo zašto se ljudi iste dobi razlikuju, upravo te pojedinačne razlike postaju predmet istraživanja. Statističko mišljenje zato ne uklanja varijabilnost. Ono je raspoređuje prema pitanju koje pokušavamo razjasniti.

Ta pokretljiva granica objašnjava zašto se u društvenim znanostima toliko raspravlja o tome što je u nekom nalazu zapravo objašnjeno. Ista razlika u sudjelovanju može se pripisati dobi, obrazovanju, dohotku ili mjestu stanovanja, ovisno o tome koje smo od tih obilježja uvrstili u usporedbu. Nijedan od tih izbora nije pogrešan sam po sebi, ali svaki proizvodi drukčiju podjelu na obrazac i ostatak. Zbog toga se rezultati različitih istraživanja o istoj pojavi razilaze i onda kada su svi izračuni ispravni.

Iz promjenjivosti slijedi ograničenje koje vrijedi za cijelu knjigu. Jedno opažanje ne može razriješiti pitanje o obrascu, ma koliko bilo uvjerljivo. Student koji se puno koristi mrežama i slabo prati vijesti ne pokazuje da veza postoji, kao što ni student koji je iznimka ne pokazuje da veze nema. Obojica su podaci, ali obrazac postoji na razini skupine, a ne pojedinca, pa se i provjeriti može samo na skupini.

Broj promatranih slučajeva zato ulazi u tumačenje rezultata jednako kao i sam rezultat. Razlika izmjerena na desetak ljudi lako nastaje istom promjenjivošću koja bi se pri sljedećem prikupljanju podataka okrenula na drugu stranu. Ista razlika izmjerena na tisućama ljudi mnogo je teže objašnjiva pukim rasipanjem. Koliko točno uzorak sužava taj prostor, pitanje je poglavlja o uzorkovanju.

Usporedba je pritom važnija od samog velikog ili malog broja. Pad, rast ili razlika dobivaju značenje tek kada znamo prema čemu ih mjerimo. Ponekad je usporedba druga skupina, ponekad ranije razdoblje, a ponekad raspon rezultata koji bi mogli nastati običnom promjenjivošću. Kasnija poglavlja izgradit će računske postupke za te usporedbe. Za sada je važan njihov zajednički temelj. Tvrdnja postaje statistička tek kada jasno kaže što se s čim uspoređuje.

Razlika koju čini postupak

Prijelaz s dojma na postupak najlakše se opiše kroz ono što postupak od nas traži da napišemo. Dojam može ostati neodređen i time neoboriv. Zapisana analiza mora odgovoriti na četiri pitanja, a svako od njih otvara mjesto na kojem je moguće pogriješiti i na kojem je pogrešku moguće naći.

Prvo pitanje glasi koga smo promatrali. Berkeleyjska tablica ne govori o svim sveučilištima ni o svim prijavama, nego o šest odjela u jednoj godini (Bickel i sur. 1975.). Doseg tvrdnje nikada nije širi od skupa koji je ušao u izračun, a najčešća pogreška pri čitanju statistike jest tiho proširenje tog dosega. Drugo pitanje glasi što smo izmjerili. Stopa prijma bilježi ishod postupka, ne namjeru onih koji su odlučivali, pa ista brojka podupire tvrdnju o ishodima i ne podupire tvrdnju o motivima.

Treće pitanje glasi s čime rezultat uspoređujemo. Ono je najzahtjevnije jer usporedbu obično biramo nesvjesno, a upravo je izbor usporedbe ono što je u Berkeleyju preokrenulo zaključak. Isti postotak podupire različite tvrdnje ovisno o tome stoji li uz drugu skupinu, uz prošlu godinu ili uz vrijednost koju bismo očekivali da nikakve razlike nema. Objava koja navodi samo jedan broj tu je odluku već donijela umjesto čitatelja, obično prešutno.

Četvrto pitanje glasi koliko bi se rezultat mogao pomaknuti da smo prikupili druge podatke iste vrste. Nijedno mjerenje ne pogađa istu vrijednost dvaput, pa svaka procjena ima raspon unutar kojeg se razumno može kretati. Tvrdnja bez ikakve mjere nesigurnosti zato obe-

ćava više nego što podaci nose, a upravo se takve tvrdnje najlakše šire. Kako se taj raspon računa i kako se pošteno izriče, predmet je poglavlja o procjeni.

Postupak, dakle, ne jamči točan zaključak. On jamči nešto skromnije i korisnije. Čini tvrdnju provjerljivom, tako da neslaganje postane rasprava o podacima, mjerenju i usporedbi umjesto rasprave o tome tko je uvjerljiviji. Kada dvoje ljudi tvrde suprotno na temelju istog skupa, razlika među njima mora se moći pokazati u jednom od ta četiri koraka, jer drugih mjesta nema. Ostatak ove knjige razrađuje upravo ta pitanja, jedno po jedno, i svakom od njih posvećuje vlastite postupke.

Zbirna slika i skrivena struktura

Zbirni rezultat često izgleda kao najpotpuniji prikaz jer obuhvaća sva opažanja. Ipak, ukupni prosjek ili stopa uvijek su mješavina rezultata podskupina i zastupljenosti tih podskupina. Skupina koja je brojnija snažnije povlači ukupni rezultat prema sebi. Promjena sastava stoga može promijeniti zbirnu stopu čak i kada se ništa nije promijenilo unutar pojedinih podskupina.

U Berkeleyju su se odjeli znatno razlikovali po težini upisa, a prijave muškaraca i žena nisu bile jednako raspoređene među njima. Žene su se češće prijavljivale na selektivnije odjele, pa je njihova zbirna stopa snažnije odražavala upravo te odjele. Usporedba unutar odjela uklonila je taj učinak sastava iz neposredne usporedbe, zbog čega se obrazac vidljiv u ukupnim podacima oslabio ili preokrenuo (Bickel i sur. 1975.).

Takav se obrat naziva **Simpsonov paradoks**. Riječ je o obrascu u kojem se povezanost vidljiva u združenim podacima promijeni ili preokrene kada podatke razdvojimo prema relevantnoj trećoj varijabli (Simpson 1951.). Paradoks nije u aritmetici. Svaka stopa ostaje točna. Neobičnost nastaje zato što iste brojke opisuju različite usporedbe, a naš se zaključak promijeni kada to napokon primijetimo.

Mehanizam se najlakše vidi na konstruiranom primjeru u kojem sve brojke stanu u jednu rečenicu. Neka portal A objavi 100 videozapisa s prosječnim angažmanom od 200 reakcija i 10 tekstova s prosjekom od 50, a portal B neka objavi 10 videozapisa s prosjekom od 220 i 100 tekstova s prosjekom od 60. Portal B je uspješniji u obama formatima. Njegov je zbirni prosjek ipak znatno niži i iznosi 75 naprema 186 reakcija po objavi.

Razlika nastaje zato što zbirni prosjek nije prosjek dvaju formata nego prosjek svih objava. Video kod portala A čini 91 % objava, a kod portala B samo 9 %. Format s višim angažmanom time u jednom zbroju sudjeluje s velikom težinom, a u drugom s malom. Zbirna mjera tako mjeri i uspješnost i sastav proizvodnje, a čitatelj koji vidi samo nju ne može znati koliko je koji sastojak pridonio.


Razdvajanje podataka ipak nije čarobni postupak koji uvijek otkriva konačnu istinu. Podskupine moraju imati sadržajno opravdanje. Ako podatke dijelimo na dovoljno mnogo proizvoljnih načina, prije ili poslije pronaći ćemo privlačan obrazac koji nema stabilno značenje. Statistička disciplina traži da objasnimo zašto je određena podjela važna prije nego što njezin rezultat proglasimo odgovorom.

Ostaje pitanje kojem prikazu vjerovati kada se dva razilaze. Odgovor nije statistički, i to je možda najvažnija pouka ovog poglavlja. Sama aritmetika ne može odlučiti treba li odjel ući u usporedbu, jer su obje tablice jednako točne. Odluka ovisi o tome kakvu tvrdnju želimo provjeriti. Za tvrdnju o odlučivanju unutar odjela usporedba mora biti unutar odjela. Za tvrdnju o ukupnom ishodu prijava zbirna je stopa upravo ono što treba. Tek kad je pitanje jasno postavljeno, brojke postaju dokaz, a poglavlje o mjerenju i istraživačkom dizajnu bavi se time kako se to pitanje postavlja.

Simpsonov paradoks zato nije tek neobičan trik s tablicama. On sažima razlog postojanja statistike. Promatrani broj moramo povezati sa strukturom podataka koja ga je proizvela, a zaključak ograničiti na usporedbu koju smo doista napravili.

Interakcija — Simpsonov paradoks

Interaktivni prikaz gradi transparentan primjer s dvjema skupinama i dvjema podskupinama. Stope unutar podskupina ostaju jednake, dok klizači mijenjaju njihovu zastupljenost u svakoj skupini. Prebacivanje pogleda pokazuje kako različiti utezi mogu proizvesti zbirni rezultat suprotan obrascu unutar obje podskupine.



Slika 1: Isti obrazac prikazan združeno i unutar dviju podskupina.

Što isprobati.

1. Najprije usporedite samo zbirne stope i zapišite koja skupina izgleda uspješnije.
2. Uključite prikaz podskupina i provjerite ostaje li smjer razlike jednak.
3. Promijenite zastupljenost podskupina bez mijenjanja njihovih stopa i promatrajte kada se zbirni zaključak preokrene.
4. Postavite obje zastupljenosti na istu vrijednost i provjerite je li obrat tada uopće moguć.

Posljednji korak pokazuje granicu pojave. Dok su obje skupine jednako raspoređene po podskupinama, zbirna usporedba slijedi uspo-

redbu unutar podskupina i obrata nema. Obrat traži da se skupine razlikuju i po tome gdje su mjerene, a ne samo po tome kako su prošle. Zbirna razlika zato uvijek sadrži dva sastojka, uspješnost i sastav, koje bez razdvajanja podataka ne možemo razlučiti.

STATISTIKA U DIVLJINI

Privid pristranosti u zbirnoj stopi. Tvrdnja da su muškarci u Berkeleyju 1973. primani češće od žena aritmetički je točna za šest najvećih odjela (Bickel i sur. 1975.). Problem nastaje tek kada tu zbirnu razliku pretvorimo u objašnjenje postupka upisa. Ukupna stopa istodobno spaja odluke različitih odjela i različitu raspodjelu prijava među njima.

Odgovorno čitanje zato ne odbacuje zbirnu stopu, ali od nje traži pomoćne informacije. Potrebni su brojevi prijava i primljenih kandidata unutar svakog odjela te objašnjenje zbog čega je odjel relevantna podjela. Tek tada vidimo koji dio razlike nastaje unutar usporedivih skupina, a koji zbog njihova različitog sastava.

PITAJTE MODEL

Asistent može brzo izračunati zbirne stope i ponoviti izračun po podskupinama, ali mu treba dati stvarne brojnike i nazivnike. Nakon odgovora valja provjeriti daju li zbrojevi ćelija objavljene ukupne vrijednosti i je li svaka stopa izračunata s odgovarajućim nazivnikom. Modeli osobito lako nadopune ćeliju koja nedostaje ili svaku razliku između zbirnog i grupiranog prikaza proglase Simpsonovim paradoksom.

Usporedi zbirne stope prijma sa stopama po odjelima. Prikaži broj prijava, broj primljenih i nazivnik svake stope. Opiši kako sastav prijava mijenja zbirni rezultat, ali nemoj iz tih tablica izvoditi kauzalni zaključak.

NADITE GREŠKU

Zbirna stopa prijma bila je viša za muškarce, dok je u četiri od šest odjela stopa za žene bila barem jednaka stopi za muškarce (Bickel i sur. 1975.). Žene su se češće prijavljivale na selektivnije odjele (Bickel i sur. 1975.). Stoga je izbor odjela uzrokovao cijeli zbirni jaz.

Razrađeni primjer


Berkeleyjski podaci omogućuju da cijeli problem pratimo bez složenog modela. Svaki redak izvorne tablice govori o ishodu prijave, spolu kandidata i odjelu. Prvi korak združuje odjele te za svaku skupinu dijeli broj primljenih s ukupnim brojem prijava.

Tablica 1: Zbirne stope prijma u šest najvećih odjela. Izrada autora prema Bickel i sur. (1975.).

Mjera	Muškarci	Žene
Prijave	2 691	1 835
Primljeni	1 198	557
Stopa prijma	44,5 %	30,4 %

Zbirna tablica pokazuje velik jaz. Primljeno je 44,5 % muškaraca i 30,4 % žena među prijavama obuhvaćenim ovim podacima (Bickel i sur. 1975.). Kada bismo ovdje stali, bilo bi razumljivo posumnjati da je ista razlika prisutna u odlukama svakog odjela. Ta pretpostavka ipak nije sadržana u zbirnoj stopi.

Sljedeći korak ne mijenja nijednu prijavu. Mijenja samo razinu na kojoj ih uspoređujemo. Stope sada računamo zasebno u svakom odjelu, čime kandidati iz selektivnog odjela više ne utječu izravno na usporedbu kandidata u odjelu s višom prolaznošću.



Slika 2: Stope prijma prema odjelu i spolu. Izrada autora prema Bickel i sur. (1975.).

Stope po odjelima više ne podržavaju jednostavnu priču prema kojoj se isti jaz ponavlja posvuda. U četiri od šest odjela stopa za žene barem je jednaka stopi za muškarce, dok je u preostala dva niža (Bickel i sur. 1975.). Presudan je i raspored prijava. Velik dio prijava žena završio je u odjelima s niskim stopama prijma, pa su ti odjeli dobili veću težinu u njihovoj zbirnoj stopi (Bickel i sur. 1975.).

Zbirna stopa može se zamisliti kao prosjek odjelnih stopa u kojem odjeli nemaju jednaku težinu. Njihova težina ovisi o broju prijava iz svake skupine. Zato dvije skupine mogu imati sličan ili obrnut odnos unutar odjela, a ipak vrlo različite ukupne stope. Obrat ne proizvodi pogrešan račun. Proizvode ga različiti utezi u dvama zbirnim prosjecima.

Ti se utezi mogu i izmjeriti. Odjeli se u ovim podacima razlikuju znatno više međusobno nego što se unutar njih razlikuju muškarci i žene, jer ukupna prolaznost pada s 64 % u najpristupačnijem odjelu na 6 % u najselektivnijem (Bickel i sur. 1975.). Na dva najpristupačnija

odjela otpada 51 % svih prijava muškaraca i tek 7 % prijava žena, dok na dva najselektivnija otpada 21 % prijava muškaraca i 40 % prijava žena (Bickel i sur. 1975.). Dvije skupine zapravo nisu prolazile kroz isti postupak odabira, nego kroz različite mješavine postupaka.

Tek s tim brojevima obrat prestaje biti neobičnost i postaje očekivan. Skupina čije se prijave gomilaju ondje gdje su svi rijetko primani mora imati nižu zbirnu stopu, čak i kada je u većini odjela prolazila jednako dobro ili bolje. Zbirna razlika u tom smislu vjerno mjeri nešto stvarno, samo ne ono što se na prvi pogled čini. Ona mjeri raspored prijava barem koliko i strogost odlučivanja.

Ova analiza još ne daje konačan sud o pravednosti upisa. Odjelne tablice ne govore zašto su prijave raspoređene upravo tako, kako su kandidati usmjeravani ni jesu li kriteriji unutar odjela bili primijenjeni jednako. One postižu nešto uže i nužno. Pokazuju da zbirnu razliku ne smijemo tumačiti kao izravnu sliku odluka unutar svakog odjela. Statistički postupak nije zatvorio pitanje, nego ga je napokon postavio dovoljno precizno.

Sažetak

Statistika povezuje podatke s usporedbom koja određenom zaključku daje značenje. Bez postupka odluku preuzima najuvjerljiviji govornik, a intuicija na tom mjestu griješi predvidljivo, jer slučajnost tumači kao obrazac i pojedinačan slučaj kao raširenost. Promjenjivost nije smetnja koju uklanjamo, nego građa iz koje razlučujemo signal i šum. Simpsonov paradoks pokazuje da točan zbirni rezultat može zavesti kada skriva sastav podskupina, i da izbor između dvaju točnih prikaza ovisi o pitanju, a ne o računu. Strog pristup zato ne završava izračunom, nego provjerava koga smo promatrali, što smo izmjerili, s čime smo usporedili i koliko bi se rezultat mogao pomaknuti. Sljedeći korak vodi prema mjerenju i istraživačkom dizajnu, gdje se odlučuje što će uopće postati podatak.

Pojmovi

statistika (*statistics*), signal (*signal*), šum (*noise*), heuristika dostupnosti (*availability heuristic*), zbirni podaci (*aggregate data*), podskupina (*subgroup*), Simpsonov paradoks (*Simpson's paradox*)

Zadaci

Konceptualni

Objasnite kako dvije računski točne stope mogu poduprijeti različite zaključke. U odgovoru razlikujte zbirnu usporedbu od usporedbe unutar podskupina.

Zatim opišite situaciju iz vlastitog područja u kojoj bi pojedinačan slučaj bio bolji izvor od podataka o skupini, i situaciju u kojoj bi bilo obrnuto. Predajte dva kratka odlomka i u svakome imenujte pitanje na koje odabrani izvor odgovara.

Računski

Upotrijebite konstruirani primjer dvaju portala iz odjeljka o zbirnoj slici. Izračunajte ručno zbirni prosjek angažmana za svaki portal i provjerite da odgovara brojkama u tekstu. Zatim portalu B zamijenite broj videozapisa i broj tekstova, ostavite sve prosjeke unutar formata nepromijenjenima i ponovno izračunajte oba zbirna prosjeka. Predajte četiri broja i jednu rečenicu o tome koji se zbirni prosjek promijenio i zašto, iako se nijedan prosjek unutar formata nije promijenio.

Zatim se vratite na tablicu zbirnih stopa prijma i na sliku stopa po odjelima iz razrađenog primjera. Pročitajte s njih u koliko odjela žene imaju barem jednaku stopu prijma i zapišite u jednoj rečenici zašto to ne proturječi nižoj zbirnoj stopi. Postupak za isti izračun nad cijelim skupom podataka nalazi se u praktikumu.

Kritički

Prosudite tvrdnju da zbirni jaz u stopama prijma sam po sebi dokazuje pristranost svakog odjela u Berkeleyju (Bickel i sur. 1975.). Navedite koju dodatnu usporedbu tvrdnja preskače i što ni ta dodatna usporedba ne može dokazati.

Pronađite zatim u medijima jednu tvrdnju koja uspoređuje dvije skupine pomoću jednog zbirnog broja. Za nju odgovorite na četiri pitanja iz odjeljka o postupku, koja se odnose na promatrani skup, izmjerenu veličinu, usporedbu i nesigurnost. Predajte tvrdnju, njezin izvor i po jednu rečenicu o svakom pitanju, uključujući pitanja na koja objava ne daje odgovor.

Revizija modela

Ocijenite analizu modela iz okvira iznad. Imenujte točne korake, izdvojite jednu neopravdanu tvrdnju i napišite njezinu oprezniju zamjenu. U obrazloženju navedite koji bi podatak trebalo imati da bi izvorna tvrdnja postala opravdana.

Mjerenje i istraživački dizajn

Od društvene pojave do opravdanog zaključka

Vrijeme čitanja	Widget	Podaci	Preduvjet
22 min	Prikaz konfundera	konstruirani primjeri	pogl. 1

VINJETA

Berkeleyjski podaci iz prethodnog poglavlja bilježili su prijave, ishode upisa, spol kandidata i odjel. Nisu bilježili kvalitetu prijave, savjet koji je kandidat dobio prije prijave ni način na koji su pojedini odjeli donosili odluke (Bickel i sur. 1975.). Tablica je zato mogla pokazati raspored ishoda, ali nije mogla izravno izmjeriti svaki postupak koji je do tih ishoda doveo.

Istraživači su se morali vratiti korak unatrag. Prije pitanja o razlici trebalo je utvrditi što pojedini redak predstavlja, koje su usporedbe opravdane i koje alternativne priče podaci još dopuštaju. Više računanja nije moglo nadomjestiti ono što nije bilo izmjereno.

Kako društvenu pojavu pretvaramo u podatke, a da pritom ne zamijenimo mjeru za pojavu koju želimo razumjeti?

Od pojma do podatka

Društvene znanosti najčešće proučavaju pojave koje ne možemo položiti na vagu. Povjerenje, politička otuđenost, osjećaj sigurnosti i izloženost medijima postoje kao pojmovi prije nego što postoje kao brojke, pa se moraju prevesti u opažanja.

Definicija 1. Operacionalizacija je postupak kojim se teorijski pojam pretvara u određeni način mjerenja, tako da se navede što će se opažati i po kojem pravilu će se opažanju pridružiti vrijednost.

Isto teorijsko pitanje može postati jedno anketno pitanje, skup tvrdnji, ponašajni trag ili procjena promatrača. Svaki izbor zahvaća dio pojave i istodobno nešto izostavlja.

Rijetko se pritom oslanjamo na jedno pitanje. Uobičajen je postupak da se isti pojam zahvati s nekoliko tvrdnji koje se potom sažimaju u jedan rezultat. Razlog nije temeljitost nego to što svaka pojedina tvrdnja uz zajednički pojam nosi i vlastite osobitosti, poput riječi koju dio ispitanika razumije drukčije. Kada se odgovori zbroje, zajednički se dio pojačava, a pojedinačne osobitosti djelomično poništavaju. Cijena je što izvedeni rezultat više ne odgovara nijednom stvarno postavljenom pitanju, pa se mora tumačiti kroz sadržaj svih tvrdnji koje su u nj ušle.

Razlika između pojma i njegove mjere temeljna je i ne nestaje boljim instrumentom. Povjerenje u medije mentalno je stanje. Odgovor na pitanje o tome koliko netko vjeruje određenom izvoru na ljestvici od 1 do 10 opažanje je koje to stanje odražava nesavršeno. Kvaliteta istraživanja ovisi upravo o veličini tog razmaka, a rasprava o nalazu koja ga previdi zapravo raspravlja o dvjema različitim stvarima pod istim imenom.

Posljedica je vidljiva u svakoj literaturi koja se čini proturječnom. Dva istraživanja o utjecaju društvenih mreža na političku polarizaciju mogu doći do suprotnih zaključaka i pritom oba biti korektno provedena, ako je jedno polarizaciju operacionaliziralo kao razliku u stavovima među pristašama stranaka, a drugo kao učestalost neprijateljskih izjava o protivnicima. Prva mjera bilježi udaljenost mišljenja, druga ton javne rasprave. Kada se nalazi razilaze, prvo pitanje nije tko je pogriješio nego jesu li mjerili isto.

Jedinica koju mjerimo naziva se opažanjem, a svojstvo koje se među opažanjima mijenja naziva se **varijablom**. Ako 300 ljudi upitamo koliko minuta dnevno provode na mrežama, imamo 300 opažanja jedne varijable. Ako svakome postavimo 10 pitanja, imamo 300 opažanja za svaku od 10 varijabli. Varijabla zato nije samo stupac s urednim imenom. Ona je trag odluke o tome što će se uopće računati kao razlika među jedinicama.

Ta odluka pada prije prikupljanja podataka i poslije se ne može popraviti. Ispitanik koji je odgovarao na ljestvici s pet stupnjeva ne može naknadno biti smješten na ljestvicu s deset. Anketa koja nije pitala za mjesto stanovanja ne može naknadno razlikovati grad i selo. Analiza radi s onim što je mjerenje propustilo kroz sebe, pa je operacionalizacija najutjecajniji korak istraživanja i istodobno onaj koji se u izvještajima najkraće opisuje.

Zbog toga se pri čitanju tuđeg istraživanja isplati zastati na tri pitanja prije nego što se pogleda ijedan rezultat. Kako je ključni pojam izmjeren, ne kako je nazvan. Koja je jedinica analize, jer ista riječ može označavati osobu, objavu, sat gledanja ili kućanstvo, a nalaz se mijenja s tim izborom. I što je mjerenje moralo izostaviti, jer svaki

instrument nešto ne vidi. Odgovori na ta tri pitanja obično stoje u dva odlomka metodologije koje je najlakše preskočiti i koji najviše određuju kako valja čitati sve ostalo.

Anketno pitanje pritom nije neutralan prozor prema stavu nego dio mjernog instrumenta. Formulacija određuje što ispitanik razumije, ponuđeni odgovori određuju što uopće može reći, a redoslijed pitanja može promijeniti okvir u kojem odgovara. Ispitanik koji je upravo odgovarao na niz pitanja o nesigurnosti drukčije će ocijeniti povjerenje u institucije nego onaj kojemu je isto pitanje postavljeno prvo. Ništa od toga nije razlog za odbacivanje anketa. Razlog je za to da se rezultat čita zajedno s upitnikom, a ne umjesto njega.

Razine mjerenja

Brojevi u podacima ne znače uvijek isto. Stevens je 1946. godine predložio podjelu na četiri razine mjerenja, koja se u društvenim znanostima koristi i danas jer određuje koje računske operacije na nekoj varijabli imaju sadržajno značenje (Stevens 1946.). Podjela ne govori o važnosti teme nego o tome što se smije izvesti iz zapisanih vrijednosti.

Na **nominalnoj razini** brojevi ili oznake samo imenuju kategorije i među njima nema poretka. Vrsta medija, država prebivališta, stranačka bliskost i status zaposlenosti pripadaju ovamo. S takvim se podacima može prebrojavati i računati udio, ali prosjek nema smisla, jer prosječna vrsta medija ne postoji. **Ordinalna razina** dodaje poredak bez jamstva da su razmaci jednaki. Odgovori na ljestvici slaganja imaju jasan smjer, a tvrdnja da je razlika između neslaganja i neutralnosti jednaka razlici između slaganja i potpunog slaganja ostaje pretpostavka. Medijan je ovdje smislen, dok je prosjek kompromis.

Intervalna razina ima jednake razmake, ali proizvoljno ishodište, pa dopušta zbrajanje i oduzimanje, a ne i omjere. **Omjerna razina** ima i apsolutnu nulu, zbog čega je izjava o dvostruko većoj vrijednosti opravdana. Vrijeme provedeno na platformi, broj dijeljenja i dohodak omjerne su varijable, jer nula ondje doista znači odsutnost pojave.

Praksa je pritom manje uredna od podjele. Ljestvice slaganja strogo su ordinalne, a u velikom se dijelu objavljene literature zbrajaju i prosječuju kao da su intervalne. Taj kompromis nije nemaran koliko se čini, jer zbroj više tvrdnji koje mjere isti pojam ponaša se stabilnije od svake pojedine, ali ostaje pretpostavka koju vrijedi izreći umjesto prešutjeti. Čitatelj koji zna da je prosjek ordinalne ljestvice pretpostavka, a ne činjenica, drukčije čita razliku od dvije desetine bodova između dviju skupina.

Uz razinu mjerenja ide i razlika između diskretnih i kontinuiranih varijabli. Diskretna varijabla poprima odvojene vrijednosti, poput broja komentara, koji ne može iznositi tri i pol. Kontinuirana može poprimiti bilo koju vrijednost unutar raspona, poput vremena na stranici. Razlika utječe na izbor grafičkog prikaza i na izbor postupka, a u praksi diskretne varijable s velikim rasponom tretiramo kao kontinuirane. Broj bodova na testu tehnički je diskretan, ali su susjedne vrijednosti toliko blizu da ga ništa ne priječi da se ponaša kontinuirano.

Praktična važnost svega toga leži u jednom svojstvu razina. Kretanje prema nižoj razini uvijek je moguće, a prema višoj nikada. Iz zabilježene dobi u godinama možemo napraviti dobne skupine kad god poželimo, dok iz zabilježenih skupina ne možemo vratiti godine. Iz izmjerenih minuta možemo izvesti podjelu na česte i rijetke korisnike, dok iz te podjele ne možemo izvesti minute. Anketa koja odmah nudi razrede umjesto broja štedi ispitaniku nekoliko sekundi i trajno oduzima analizi mogućnosti.

Iz toga slijedi savjet koji vrijedi za svako prikupljanje podataka. Razina se planira unaprijed, prema analizama koje namjeravamo provesti, a ne bira naknadno. Ako je cilj prosjek ili korelacija, potrebna je barem intervalna mjera. Ako je cilj samo raspodjela po kategorijama, nominalna je dovoljna. Odgovor na to pitanje pripada nacrtu istraživanja, a ne obradi podataka, i najjeftinije je pravilo u ovom poglavlju, jer se poštuje bez ikakva troška i krši uz trošak koji se ne može nadoknaditi.

Pouzdanost i valjanost

Dobra mjera mora zadovoljiti dva odvojena zahtjeva koja se lako brkaju. Prvi je postojanost. Vaga koja pri tri uzastopna vaganja pokaže tri različite težine beskorisna je iako mjeri pravu veličinu.

Definicija 2. Pouzdanost je stupanj u kojem instrument daje dosljedne rezultate pri ponovljenom mjerenju istog stanja u istim uvjetima.

Pouzdanost se u društvenim znanostima provjerava na tri načina koje ćete sretati u metodološkim odjeljcima objavljenih radova. Ponovljeno mjerenje uspoređuje rezultate istog instrumenta u dva trenutka, uz pretpostavku da se u međuvremenu nije promijenilo ono što se mjeri. Slaganje među procjenjivačima važno je svugdje gdje ljudi kodiraju građu, pa dva koderi koji isti tekst ocijene različito otkrivaju problem instrumenta, a ne razliku u građi. Interna konzistentnost pita slažu li se čestice istog upitnika međusobno, jer bi sve trebale zahvaćati isti pojam. Cronbachov alfa najčešća je mjera te treće vrste, dok se za slaganje među koderima najčešće navode Cohenova kappa i Krippendorffova alfa. Granice koje se u praksi spominju kao prihvatljive konvencija su o kojoj se i dalje raspravlja, pa ih ne treba čitati kao prag položenog ispita.

Za čitatelja iz toga slijedi konkretna provjera. Rad koji se oslanja na upitnik trebao bi za svaku ljestvicu navesti mjeru interne konzistentnosti, a rad koji kodira sadržaj trebao bi navesti mjeru slaganja među koderima i broj jedinica na kojima je izračunata. Izostanak tih podataka ne dokazuje da je mjerenje loše, ali uklanja jedini način na koji bi se to izvana moglo provjeriti, pa je razlog za oprez pri tumačenju.

Kod ponovljenog mjerenja krije se zamka koja je za društvene znanosti specifična. Stavovi se doista mijenjaju, pa razlika između dva termina može značiti da instrument nije pouzdan ili da se svijet u međuvremenu promijenio. Ako se između dvaju mjerenja povjerenja u medije dogodio velik skandal, pad rezultata nalaz je, a ne pogreška.

Razlikovanje nestabilnosti instrumenta od stvarne promjene predmeta ne rješava se računom nego poznavanjem razdoblja.

Drugi zahtjev odnosi se na sadržaj, a ne na postojanost.

Definicija 3. Valjanost je stupanj u kojem instrument mjeri upravo onaj pojam o kojem se namjerava zaključivati, a ne neki drugi s kojim je povezan.

Ta su dva svojstva neovisna, što je najlakše vidjeti na primjeru mjere koja ima jedno bez drugoga. Kvaliteta novinarstva mjerena brojem zarez u tekstu bila bi izvrsno pouzdana, jer bi svaka dva brojača došla do istog rezultata, i posve nevaljana. Pouzdanost je nužan uvjet, a ne dovoljan, i pouzdana mjera može svaki put jednako promašiti cilj.

Nepouzdanost pritom ne ostaje tehnička sitnica nego ulazi u same rezultate, i to na način koji je važno predvidjeti. Ako mjera uz stvarnu vrijednost bilježi i slučajnu pogrešku, dio razlika među ispitanicima nastao je od pogreške, a ne od pojave. Kada dvije takve mjere povežemo, njihova zajednička kretanja moraju se probiti kroz dva sloja šuma, pa izmjerena veza redovito izgleda slabijom nego što je veza među samim pojmovima. Loše mjerenje time obično ne izmišlja nalaz nego ga skriva.

Posljedica je protivna očekivanju, pa je vrijedi izreći izravno. Nalaz da veze nema slabiji je dokaz nego što se čini kada su mjere nepouzdanane, jer je izostanak veze mogao proizvesti sam instrument. Nalaz da veza postoji unatoč nepouzdanim mjerama u tom je smislu čvršći, jer je pogreška radila protiv njega. Zbog toga podatak o pouzdanosti mijenja tumačenje rezultata u oba smjera i ne služi samo kao potvrda da je posao obavljen uredno.

Valjanost se rastavlja na nekoliko pitanja. Pokriva li instrument sve važne dijelove pojma, pa upitnik o medijskoj pismenosti koji ne spominje digitalne sadržaje propušta bitan dio predmeta. Mjeri li instrument doista pojam koji imenuje, a ne nešto susjedno, jer klikovi, vrijeme na stranici i komentari svi nose ime angažmana, dok zapravo mjere početni interes, dubinu čitanja i motivaciju za javno očitovanje.

Vrijede li rezultati izvan uvjeta u kojima su dobiveni, što je pitanje koje se najoštrije postavlja kod laboratorijskih studija. Reakcija na neistinitu vijest prikazanu na praznom zaslonu ne mora odgovarati reakciji iste osobe koja isti sadržaj sretne među porukama prijatelja i obavijestima.

Treći čimbenik i logika eksperimenta

Varijable u istraživanju nisu ravnopravne. Ona za koju pretpostavljamo da djeluje naziva se nezavisnom varijablom, a ona koja bilježi ishod zavisnom. U opažачkim se studijama ista razlika češće izriče kao odnos prediktora i ishoda, jer ondje istraživač ničim ne manipulira i terminologija manipulacije zavarava. Nitko ne dodjeljuje ispitanicima dob ni obrazovanje.

Opasnost koja iz toga slijedi glavna je tema ovog poglavlja. Varijabla povezana i s pretpostavljenim uzrokom i s ishodom može proizvesti privid veze između njih ili prikriti vezu koja postoji.

Definicija 4. Konfundirajuća varijabla je varijabla koja je povezana i s pretpostavljenim uzrokom i s ishodom, pa dio opažene veze među njima potječe od nje, a ne od djelovanja uzroka na ishod.

Ako podaci pokazuju da adolescenti koji više koriste Instagram imaju niže samopoštovanje, moguće je da korištenje snižava samopoštovanje, da niže samopoštovanje potiče korištenje ili da društvena izoliranost povećava oboje. Navarro tu pojavu naziva problemom treće varijable i drži je razlogom zbog kojeg povezanost ne dokazuje uzročnost (Navarro 2019.).

Konfundiranje je pritom samo jedno od nekoliko objašnjenja koja opažena veza dopušta, i vrijedi ih držati odvojenima jer se različito rješavaju. Obrnuti smjer djelovanja tvrdi da ishod djeluje na pretpostavljeni uzrok, pa bi niže samopoštovanje vodilo većem korištenju umjesto obrnuto. Protiv njega pomaže vremenski razmak među mjerenjima, a ne dodavanje varijabli u model. Pristranost odabira tvrdi da je u uzorak ušla posebna skupina ljudi, pa veza vrijedi za nju, a ne za

populaciju. Protiv nje pomaže način prikupljanja podataka. Konfundiranje u užem smislu tvrdi da postoji zajednički uzrok obiju veličina, i jedino se protiv njega može nešto učiniti prilagodbom u analizi, i to samo ako je taj uzrok izmjeren.

Prepoznavanje konfundera počinje sadržajnim znanjem, a ne naredbom u programu. Nijedan postupak ne može iz same tablice pročitati koje varijable pripadaju objašnjenju, jer se odnosi među stupcima ne razlikuju po tome je li stupac uzrok ili posljedica. Program može prilagoditi model za dob, obrazovanje ili prethodno ponašanje tek nakon što netko obrazloži zašto su baš te varijable važne i kako su izmjerene. Poglavlje o regresiji tu prilagodbu razrađuje računski, ali odluku o njezinu sadržaju ostavlja ondje gdje je i sada.

Eksperiment je dizajn koji taj problem rješava u korijenu. Istraživač sam određuje vrijednost nezavisne varijable, jedinice raspoređuje nasumično i sve ostalo drži jednakim. Nasumična dodjela najvažniji je od ta tri elementa, jer ne izjednačava skupine samo po obilježjima kojih se istraživač sjetio nego i po onima koje nije izmjerio ni zamislio. Ako se skupine razlikuju samo po uvjetu koji smo mi postavili, razlika u ishodu ima samo jedno raspoloživo objašnjenje. To je jedini dizajn koji kauzalni zaključak nosi po svojoj konstrukciji.

Kako to izgleda u praksi, najlakše je vidjeti na pokusu s dvjema inačicama poruke. Isti se tekst opremi dvama naslovima, jednim suzdržanim i jednim zaoštrenim, a čitatelji se nasumično razdijele tako da svaka polovica vidi samo jedan. Nakon nekog vremena uspoređuje se udio onih koji su tekst otvorili. Manipulacija je ovdje u tome što naslov dodjeljuje istraživač, a ne čitatelj. Nasumičnost je u tome što nitko ne bira koju će inačicu vidjeti. Kontrola je u tome što su tekst, vrijeme objave i položaj na stranici jednaki u obje skupine.

Vrijedi razmisliti što bi se dogodilo da nasumičnosti nema. Ako bi čitatelji sami birali koji naslov otvaraju, skupina koja bira zaoštrene naslove bila bi sastavljena od ljudi koji su ionako skloniji takvim sadržajima. Razlika u otvaranju tada bi mjerila i naslov i sklonost čitatelja, bez ikakva načina da ih razdvojimo. Upravo je to razlika između po-

kusa i naizgled sličnog prikupljanja podataka o tome što ljudi već rade, i ona ne ovisi o količini podataka nego o načinu na koji su nastali.

Isti nacrt istodobno pokazuje granicu eksperimenta. Mnogo toga što društvene znanosti zanima ne može se dodijeliti. Nitko ne može nasumično odrediti kome će pripasti niže obrazovanje, tko će odrastati u siromaštvu ni koliko će godina netko provoditi uz određenu platformu. Pitanja koja se najviše tiču društvenih nejednakosti time su sustavno ona na koja najjači dizajn ne može odgovoriti, zbog čega su opažачke studije u ovim disciplinama pravilo, a ne ustupak.

Stupanj u kojem u to možemo biti sigurni naziva se internom valjanošću, a prijetnje njoj su sve situacije u kojima se među skupine uvuče neplanirana sustavna razlika. Vanjski događaj između prvog i drugog mjerenja može promijeniti ishod neovisno o intervenciji. Nejednako osipanje sudionika po skupinama iskrivljuje usporedbu, jer preostali sudionici više nisu ono što je nasumična dodjela stvorila. Sudionici koji naslute svrhu istraživanja mogu se ponašati u skladu s pretpostavljenim očekivanjem, pa u ispitivanju medijske pismenosti odgovaraju kritičnije nego što doista jesu.

Opažачke studije i doseg zaključka

Većina istraživanja u društvenim znanostima nije eksperimentalna, i to iz razloga koji nije lijenost. Mnoge varijable koje nas zanimaju ne mogu se dodijeliti. Nikome se ne može nasumično odrediti dohodak, razina obrazovanja, izloženost siromaštvu ni količina vremena provedena na mrežama tijekom odrastanja. Ondje gdje bi dodjela bila moguća, često ne bi bila etična.

U opažачkoj studiji istraživač mjeri varijable onakve kakve jesu i analizira veze među njima. Cijena je poznata i sastoji se u tome da se suparnička objašnjenja ne mogu razlučiti samim podacima. Negativna veza između korištenja mreža i političke informiranosti dopušta tri čitanja koja podaci ne razdvajaju, jer mreže mogu smanjivati informiranost, slabije informirani mogu više posezati za mrežama, a obrazovanje ili dob mogu oblikovati oboje. Zauzvrat takva studija promatra pojavu

u njezinim prirodnim okolnostima, na velikim i raznolikim uzorcima, bez ograničenja koja laboratorij nameće.

Između tih krajnosti stoji kvazieksperiment, u kojem se uspoređuju skupine koje su se razlikovale bez istraživačeva zahvata. Usporedba korisnika koji su doživjeli curenje podataka s onima koji nisu koristi razliku koju je proizveo svijet, a ne nacrt istraživanja. Takav dizajn dopušta oprezniju formulaciju, u kojoj se govori o povezanosti koja opstaje i nakon uzimanja u obzir niza izmjerenih čimbenika, uz izričito priznanje da neizmjereni čimbenici ostaju mogući. Na trećem se kraju nalaze studije slučaja i kvalitativni pristupi, koji daju dubinu i mehanizam, ali ne procjenjuju raširenost. Oni su izvor hipoteza koje kvantitativni dizajni potom provjeravaju, pa im je odnos komplementaran, a ne natjecateljski.

Anketa dodaje još jednu razinu dizajna. Formulacija pitanja određuje što ispitanik razumije, ponuđeni odgovori određuju što smije reći, a **okvir uzorkovanja** određuje tko uopće može biti izabran. Velik broj odgovora ne popravljajući sustavno izostavljanje dijela populacije. Precizno mjerenje pogrešne skupine ostaje precizno mjerenje pogrešne skupine, a poglavlje o uzorkovanju pokazuje zašto se ta pogreška povećanjem uzorka ne smanjuje.

Uz okvir dolazi i pitanje tko je pozvan, a nije odgovorio. Ljudi koji odbijaju sudjelovanje obično se od sudionika razlikuju upravo po onome što se ispituje, pa istraživanje o povjerenju u institucije teže dopire do onih koji institucijama najmanje vjeruju. Ta pojava ne pogađa uzorak nasumično nego pristrano, i zato je opasnija od običnog smanjenja broja odgovora. Naknadno vaganje odgovora prema dobi, spolu i obrazovanju popravljajući razlike u obilježjima koja su zabilježena, a razliku u sklonosti odgovaranju ostavlja netaknutom. Podatak o stopi odgovora zbog toga pripada svakom poštenom izvještaju o anketi jednako kao i sam rezultat.

Preostaje pitanje koje vrijedi i za najbolje izveden eksperiment. Vrijede li rezultati izvan okolnosti u kojima su dobiveni. To je pitanje eksterne valjanosti i postavlja se u tri smjera. Prema populaciji, jer nalaz na studentima jednog fakulteta ne mora vrijediti za druge dobne

skupine ni za druge sredine. Prema kontekstu, jer se ponašanje u nadziranom uvjetima razlikuje od ponašanja u svakodnevnoj upotrebi. Prema vremenu, jer se platforme, norme i navike mijenjaju dovoljno brzo da nalaz od prije nekoliko godina opisuje svijet kojeg više nema.


Interna i eksterna valjanost pritom su u napetosti. Što je situacija kontroliranja, to je zaključak o uzroku čvršći i to je manje nalik prilikama u kojima pojava inače nastaje. Nijedan pojedinačan dizajn ne postiže oboje, pa najuvjerljiviji nalazi u društvenim znanostima obično dolaze iz niza studija različitih dizajna koje pokazuju u istom smjeru. Kada čitate jedno istraživanje, korisnije je pitati koju je od dviju valjanosti platilo nego ga ocjenjivati kao dobro ili loše u cjelini.

Dizajni se zato najbolje zamišljaju kao raspon, a ne kao ljestvica kvalitete. Na jednom kraju stoje pokusi, s najviše kontrole i najslabijom sličnošću svakodnevnici. U sredini su kvazieksperimenti i opažачke studije s uzimanjem drugih čimbenika u obzir, koje kupuju prirodnost po cijenu slabijeg kauzalnog zaključka. Na drugom su kraju studije slučaja i kvalitativni pristupi, koji daju mehanizam i jezik za pojavu koju još ne znamo dobro opisati. Pitanje nije koji je dizajn najbolji nego koji odgovara na pitanje koje smo postavili.

Praksa se u novije vrijeme sve češće oslanja na kombinaciju. Razgovori s manjim brojem sudionika mogu otkriti koje varijable uopće treba mjeriti, anketa na velikom uzorku može utvrditi koliko su te veze raširene, a pokus na kraju može provjeriti smjer djelovanja za nalaz koji se pokazao najvažnijim. Takav redoslijed ne miješa metode nego ih raspoređuje prema onome što svaka može, i najbliži je odgovor koji ova disciplina ima na to što ni jedan dizajn ne može sve.

Interakcija — Prikaz konfundera

Prikaz pokazuje odnos dviju varijabli prije i nakon razlikovanja jedinica prema trećoj varijabli. Opažanja ostaju ista, ali se mijenja usporedba. Pomak ishoda povezan s trećom varijablom može zbirnu vezu preokrenuti iako je odnos unutar obiju podskupina stabilan.



Slika 1: Ista opažanja prikazana zbirno i odvojeno prema trećoj varijabli.

Što isprobati.

1. Promatrajte početnu vezu bez treće varijable.
2. Uključite konfundirajuću varijablu i usporedite smjer veze.
3. Promijenite njezinu povezanost s ishodom i pronadite slučaj u kojem se početni zaključak preokreće.
4. Postavite tu povezanost na nulu i provjerite razlikuju li se tada dva prikaza uopće.

Posljednji korak imenuje uvjet. Dok treća varijabla ne pomiče ishod, oba prikaza govore isto i njezino uključivanje ništa ne mijenja. Konfundiranje traži da varijabla bude povezana s objema promatranim veličinama istodobno, a ne samo da postoji u podacima. Odatle slijedi i praktična posljedica. Popis mogućih konfundera nije popis svega što je izmjereno, nego kratak popis onoga za što imamo razlog vjerovati da djeluje na obje strane, i taj razlog dolazi iz teorije, a ne iz tablice.

STATISTIKA U DIVLJINI

Što mjeri stopa prijma. Zbirna stopa u Berkeleyju opisivala je ishod prijava, ali nije sama mjerila namjeru, kriterije odlučivanja ni iskustvo kandidata (Bickel i sur. 1975.). Pretvaranje te stope u potpunu ocjenu pravednosti preskače operacionalizaciju pojma pravednosti. Pravednost se može operacionalizirati kao jednak ishod među skupinama, kao jednak postupak prema jednako kvalificiranim kandidatima ili kao jednaka dostupnost samog odjela, i te tri mjere u ovim podacima ne daju isti odgovor.

Odgovorno čitanje zato najprije pita koja je jedinica analize i koje su varijable dostupne. Jedinica su ovdje prijave, a ne osobe, pa kandidat koji se prijavio na dva odjela ulazi dvaput. Dostupne su varijable ishod, spol i odjel, dok kvaliteta prijave i savjet primljen prije prijave nisu izmjereni. Tek nakon toga ima smisla procjenjivati koji dizajn može razlikovati suparnička objašnjenja, a ovaj skup podataka nastao je bez ikakva dizajna, jer su ga proizveli sami upisni postupci.

PITAJTE MODEL

Asistent može pretvoriti istraživačko pitanje u nacrt varijabli i upozoriti na moguće konfundere. Njegov popis nije dokaz da su mjere valjane. Treba provjeriti odgovara li svaka predložena varijabla stvarnom instrumentu, tko nedostaje iz okvira uzorkovanja i dopušta li dizajn kauzalni zaključak.

Dva su promašaja ovdje osobito česta. Modeli redovito predlažu popis konfundera koji je dug i uvjerljiv, a pritom ne razlikuju varijable koje prethode pretpostavljenom uzroku od onih koje su njegova posljedica, iako se prilagodba za posljedicu ne smije provesti. Uz to skloni su kauzalnom jeziku i za nacрте koji ga ne podnose, pa opažačku studiju opisuju glagolima poput utječe ili smanjuje. Provjerite svaku predloženu varijablu prema tome kada nastaje i preformulirajte svaku rečenicu koja tvrdi djelovanje.

Za ovo istraživačko pitanje predloži jedinicu analize, način mjerenja ishoda, mogući konfundirajući čimbenik i dizajn. Za svaku predloženu varijablu navedi nastaje li prije ili poslije pretpostavljenog uzroka. Za svaku odluku navedi što se iz prikupljenih podataka neće moći zaključiti.

NADITE GREŠKU

U opažачkoj anketi studenti koji dulje koriste društvene mreže prijavili su niže povjerenje u institucije. Obje su varijable izmjerene istim upitnikom i analiza je uključila dob. Rezultat zato dokazuje da dulje korištenje društvenih mreža smanjuje povjerenje.

Razrađeni primjer

Zamislimo istraživanje povjerenja u lokalne institucije. Pojam je apstraktan i nijedno pitanje ga ne zahvaća samo, pa ga operacionaliziramo s četiri tvrdnje na istoj ljestvici od 1 do 5. Tri su tvrdnje formulirane potvrdno, tako da viši odgovor znači više povjerenja. Četvrta je namjerno formulirana niječno, jer se tako u anketama razbija navika da ispitanik mehanički zaokružuje isti stupac. Ta odluka o formulaciji vratit će se kao problem u računu.

Prije nego što četiri odgovora spojimo u jedan rezultat, provjeravamo ponašaju li se doista kao mjere istog pojma. Najjednostavnija provjera uspoređuje svaku tvrdnju sa zbrojem preostalih. Ako sve mjere isto, svaka bi se trebala kretati u istom smjeru kao ostatak instrumenta.

Tablica 1: Povezanost svake tvrdnje s ostatkom instrumenta, prije i nakon okretanja niječne tvrdnje. Izrada autora.

Tvrdnja	Prije okretanja	Nakon okretanja
1 — potvrдна	0,75	0,95
2 — potvrдна	0,60	0,85
3 — potvrдна	0,76	0,83
4 — niječna	-0,95	0,95

Tablica odmah pokazuje nepravilnost. Prve tri tvrdnje snažno se slažu s ostatkom instrumenta, dok četvrta ide u suprotnom smjeru i s ostatkom je povezana negativno, na razini od -0,95. To nije znak da je tvrdnja loša. To je posljedica njezine niječne formulacije, zbog koje visok odgovor na njoj znači nisko povjerenje. Ista brojka koja u prve tri tvrdnje znači povjerenje u četvrtoj znači njegovu odsutnost.

Popravlak je jednostavan i sastoji se u okretanju ljestvice te jedne tvrdnje, tako da od najveće moguće vrijednosti uvećane za jedan oduzmemo dani odgovor. Nakon tog zahvata četvrta se tvrdnja slaže s ostatkom jednako kao i ostale, na razini od 0,95, i sve četiri mjere idu u istu stranu. Tek sada zbrajanje ima smisla.

Tablica 2: Odgovori nakon okretanja niječne tvrdnje i izvedena mjera povjerenja. Izrada autora.

Ispitanik	Odgovori na tvrdnje 1 do 4	Povjerenje
I01	4 · 5 · 4 · 4	4,25
I02	5 · 4 · 5 · 5	4,75
I03	3 · 3 · 3 · 3	3,00
I04	2 · 1 · 2 · 1	1,50
I05	1 · 2 · 1 · 2	1,50
I06	3 · 4 · 3 · 3	3,25

Cijena propuštenog koraka nije mala. Da smo sve četiri tvrdnje zbrojili bez okretanja, rezultati ispitanika razlikovali bi se za najviše 1,75 boda, dok se nakon ispravka razlikuju za 3,50. Niječna tvrdnja poništavala bi ono što ostale mjere, pa bi instrument izgledao kao da su svi ispitanici slični. Zaključak takve analize bio bi da se povjerenje među ljudima jedva razlikuje, i to bez ijedne pogreške u samom računu.

Nalaz iz ove dijagnostike vrijedi zapamtiti kao obrazac, jer se sreće i u tuđim podacima. Stavka koja je s ostatkom instrumenta povezana negativno gotovo je uvijek niječno formulirana stavka koju je netko zaboravio okrenuti. Prije nego što se takva tvrdnja proglasi lošom i izbací, treba pogledati njezin puni tekst. Ako je tvrdnja niječna, popravak je okretanje, a ne izbacivanje, i instrument ostaje potpun. Ako tvrdnja nije niječna, a ipak ide protiv ostatka, tada doista mjeri nešto drugo i pitanje postaje sadržajno.

Ono što je ovim postupkom postignuto ipak treba precizno imenovati. Pokazali smo da se četiri tvrdnje kreću zajedno, što je dokaz o unutarnjoj dosljednosti instrumenta. Nismo pokazali da mjere povjerenje. Četiri tvrdnje koje bi sve mjerile opću sklonost slaganju s bilo čime slagale bi se jednako lijepo i dale bi jednako urednu tablicu. Dosljednost je nužan uvjet, a valjanost se brani sadržajem tvrdnji, načinom na koji ih ispitanici razumiju i usporedbom s mjerama za koje već znamo što znače.

Doseg zaključka na kraju određuje ono što ovdje nije prikazano. Ne znamo tko je ušao u uzorak ni tko je odbio sudjelovati, ne znamo kako je pitanje glasilo u punom tekstu i mjerili smo u jednom trenutku. Ta tri podatka ne mijenjaju nijedan broj u tablici, a mijenjaju sve što o njima smijemo reći. Zbog toga metodološki odjeljak objavljenog rada nije formalnost nego mjesto na kojem se odlučuje koliko njegovi rezultati vrijede.

Sažetak

Mjerenje prevodi teorijske pojave u opažanja, a istraživački dizajn određuje dokle zaključak smije dosegnuti. Pouzdanost, valjanost i

razina mjerenja nisu tehnički dodatci nakon prikupljanja podataka, nego svojstva odluka donesenih prije njega, a razrađeni primjer pokazao je da jedna previđena formulacija može prepoloviti razlike među ispitanicima bez ijedne pogreške u računu. Konfundirajuća varijabla objašnjava zašto povezanost sama ne nosi uzrok, a nasumična dodjela zašto pokus taj problem rješava ondje gdje je uopće izvediva. Kako se ta prilagodba za treće čimbenike provodi računski, pokazuje poglavlje o regresiji. Sljedeće poglavlje okreće pogled prema tvrdnjama koje sve te odluke skrivaju.

Pojmovi

operacionalizacija (*operationalization*), varijabla (*variable*), razina mjerenja (*level of measurement*), pouzdanost (*reliability*), valjanost (*validity*), konfundirajuća varijabla (*confounder*), interna valjanost (*internal validity*), eksterna valjanost (*external validity*), okvir uzorkovanja (*sampling frame*)

Zadaci

Konceptualni

Razlikujte pouzdanu mjeru od valjane mjere na vlastitom primjeru. Predajte objašnjenje u kojem ista mjera može biti pouzdana, ali nevaljana.

Odaberite zatim jedan pojam iz svojeg područja i predložite dvije različite operacionalizacije istog pojma. Za svaku navedite što zahvaća i što izostavlja te opišite nalaz koji bi jedna proizvela, a druga ne bi.

Računski

Upotrijebite tablicu povezanosti stavki iz razrađenog primjera. Za četvrtu tvrdnju ručno provjerite kako se odgovor mijenja pri okretanju ljestvice, tako da za odgovore od 1 do 5 zapišete okrenute vrijednosti.

Zatim za prva tri ispitanika iz tablice s odgovorima izračunajte prosjek četiriju tvrdnji prije i nakon okretanja i predajte šest brojeva.

Iz dobivenih brojeva odgovorite u jednoj rečenici zašto propušteno okretanje smanjuje razlike među ispitanicima umjesto da ih poveća. Postupak za istu provjeru nad cijelim skupom podataka nalazi se u praktikumu.

Kritički

Prosudite što se iz Berkeleyjskih podataka može zaključiti o ishodima, a što ne može o postupku odlučivanja (Bickel i sur. 1975.). Predajte dva stupca s dopuštenim i nedopuštenim zaključcima.

Pronađite zatim objavljeno istraživanje iz svojeg područja i utvrdite kojem dizajnu pripada. Predajte odlomak u kojem imenujete dizajn, navodite jedan zaključak koji taj dizajn nosi i jedan koji autori izvode šire nego što dizajn dopušta.

Revizija modela

Ocijenite analizu modela iz okvira iznad. Imenujte dizajn, prepoznajte jednu neopravdanu tvrdnju i napišite inačicu koja poštuje ograničenja dizajna. Uz ispravak navedite koji bi dizajn bio potreban da izvorna tvrdnja postane opravdana i zašto taj dizajn ovdje vjerojatno nije izvediv.

Kako brojke zavode

Četiri provjere prije nego povjerujemo broji

Vrijeme čitanja	Widget	Podaci	Preduvjet
4 min	Istraživač margine pogreške	simulacija	pogl. 1 i 2

VINJETA

Američko statističko udruženje objavilo je izjavu o p-vrijednostima nakon desetljeća u kojima se jedan prag često koristio kao zamjena za znanstveni sud (Wasserstein i Lazar 2016.). Problem nije bio u tome što su istraživači zaboravili računati. Problem je nastajao kada je jedan broj preuzimao značenje koje mu postupak nije davao.

Sličan prijenos značenja događa se u naslovima anketa, postocima bez nazivnika i grafovima kojima odabrani

raspon osi pretvara malu promjenu u dramatičan lom. Broj može biti točan, a prikaz ipak voditi prema zaključku koji podaci ne nose.

Kako razlikovati računsku pogrešku od mnogo češće pogreške u okviru, usporedbi i jeziku?

Četiri provjere jedne tvrdnje

Prva provjera traži izvor. Tvrdnja koja navodi istraživanje mora omogućiti pronalaženje izvornog izvještaja, tablice ili skupa podataka. Poveznica na drugi članak nije podrijetlo brojke, a navođenje ustanove bez godine i istraživanja nije dovoljno da bi se nalaz provjerio.

Druga provjera traži nazivnik. Porast od pedeset posto može značiti prijelaz s dva slučaja na tri ili s dva milijuna na tri milijuna. Postotak opisuje omjer, dok **postotni bod** opisuje razliku između dvaju postotaka. Njihova zamjena može višestruko povećati dojam promjene iako je aritmetika pojedinačnih brojeva točna.

Treća provjera traži usporedbu. Graf bez zajedničke nule nije automatski nepošten, ali skraćena os mora biti vidljiva i opravdana. Odbir početnog razdoblja, izostavljanje jedne skupine ili isticanje samo povoljnog ishoda mijenja priču. Čitatelj zato pita koje bi razumno drugačije uokvirivanje pokazalo isti podatak.

Četvrta provjera traži neizvjesnost. Rezultat ankete nije svojstvo uzorka koje će se bez promjene ponoviti u populaciji. Margina pogreške opisuje samo uzoračku promjenjivost pod određenim pretpostavkama. Ne obuhvaća pristran okvir, neodaziv, loše pitanje ni naknadno biranje najzanimljivijeg rezultata.


Protokol skeptičnog čitanja

Skeptičnost nije automatsko odbacivanje. Ona usporava prijelaz od podatka prema tvrdnji. Najprije utvrđujemo tko je proizveo broj i za koju svrhu. Zatim provjeravamo jedinicu analize, nazivnik, vremenski okvir i usporednu skupinu. Tek tada procjenjujemo koliko neizvjesnost i dizajn dopuštaju zaključak.

Isti protokol vrijedi za ljudski i strojno proizveden tekst. Asistent može izmisliti izvor, popuniti ćeliju koja nedostaje ili zaokružiti rezultat do lažne preciznosti. Uvjerljiv stil nije dokaz podrijetla. Svaka brojka mora ostaviti trag do podataka ili postupka iz kojeg je nastala.

Interakcija — Istraživač margine pogreške

Istraživač prikazuje približnu marginu pogreške uzorka pri različitim veličinama i procijenjenim udjelima. Zaseban klizač uvodi poznatu sustavnu pristranost. Interval se tada može sužavati oko precizno procijenjene pogrešne vrijednosti.



Slika 1: Tri stanja pokazuju učinak veličine uzorka i sustavne pristranosti.

Što isprobati.

1. Povećavajte uzorak i promatrajte brzinu sužavanja margine.
2. Zadržite uzorak jednakim, a promijenite procijenjeni udio.
3. Uključite sustavnu pristranost i provjerite zašto uži interval ne mora biti bliži istini.

STATISTIKA U DIVLJINI

Prag koji nije presuda. Izjava Američkog statističkog udruženja naglasila je da p-vrijednost sama ne mjeri veličinu ni važnost učinka i ne određuje treba li rezultat smatrati znanstveno vrijednim (Wasserstein i Lazar 2016.).

Naslov koji istraživanje svodi na „dokazano” ili „nije dokazano” uklanja procjenu, neizvjesnost i dizajn. Broj ostaje vidljiv, a upravo informacije potrebne za njegovo tumačenje nestaju.

PITAJTE MODEL

Asistent je koristan kao strogi čitatelj ako dobije izvornu tablicu i jasnu zabranu nadopunjavanja nedostajućih podataka. Treba tražiti da odvoji provjeru aritmetike od procjene dizajna i jezika. Nakon odgovora ručno se otvara svaki navedeni izvor i provjerava postoji li broj u njemu.

Rastavi ovu statističku tvrdnju na izvor, brojnik, nazivnik, usporedbu, neizvjesnost i dopušten zaključak. Ne dopunjuj podatke koji nisu priloženi i jasno označi što nije moguće provjeriti.

NADITE GREŠKU

Anketa pokazuje vodstvo jedne opcije, ali se intervali procjena dviju opcija preklapaju. Zbog preklapanja možemo zaključiti da među njima sigurno nema razlike. Uzorak je opisan, a postoci se zbrajaju do cjeline.

Razrađeni primjer

Simuliramo dvije ankete o istoj podršci, jednu s manjim i jednu s većim uzorkom. Obje su pošteno uzorkovane iz iste zamišljene populacije. Cilj nije dobiti stvarni izborni rezultat, nego vidjeti što se mijenja kada povećamo broj opažanja.

Tablica 1: Simulirane procjene pri dvjema veličinama uzorka. Izrada autora.

Uzorak	Veličina uzorka	Margina pogreške
manji	250	$\pm 6,2 \%$
veći	1000	$\pm 3,1 \%$

Veći uzorak daje užu marginu, ali obje ankete dijele pretpostavku da je uzorkovanje nepristrano. Kada bi okvir isključio dio populacije, tablica bi i dalje mogla pokazivati veliku računsku preciznost. Strog prikaz zato uz marginu navodi način odabira ispitanika, datum, formulaciju pitanja i naručitelja.

Sažetak

Brojke zavode kada izgube izvor, nazivnik, usporedbu ili neizvjesnost. Pogreška ne mora biti u računu jer često nastaje u izboru prikaza i jezika kojim se rezultat pretvara u tvrdnju. Skeptični protokol jednak je za novinski naslov, znanstveni sažetak i odgovor modela. U sljedećem dijelu knjige isti se zahtjev primjenjuje na sažimanje i vizualizaciju vlastitih podataka.

Pojmovi

nazivnik (*denominator*), postotni bod (*percentage point*), margina pogreške (*margin of error*), pristranost (*bias*), lažna preciznost (*false precision*), podrijetlo podatka (*data provenance*)

Zadaci

Konceptualni

Objasnite razliku između pedesetpostotnog rasta i rasta od pedeset postotnih bodova. Predajte vlastiti primjer bez stvarnih empirijskih tvrdnji.

Računski

Upotrijebite simulirane podatke `sim_ankete`. Dodajte treću veličinu uzorka i predajte tablicu s pripadajućom marginom pogreške.

Kritički

Pročitajte izjavu o p-vrijednostima i izdvojite jednu tvrdnju koju ona dopušta te jednu koju izričito ne dopušta (Wasserstein i Lazar 2016.). Predajte dvije rečenice i citat izvora.

Revizija modela

Ocijenite analizu modela iz okvira iznad. Odvojite točne provjere od jedne pogrešne interpretacije i napišite provjerljiviju zamjenu.

DIO II: OPISIVANJE PODATAKA

Sažimanje podataka

Što sredina otkriva, a što raspodjela skriva

Vrijeme čitanja	Widget	Podaci	Preduvjet
21 min	Oblikovanje distribucije	simulirana anketa	pogl. 1 do 3

VINJETA

Tukey je istraživačku analizu podataka postavio kao postupak u kojem sažetak otvara pitanja umjesto da ih zatvara (Tukey 1977.). Isti prosjek može pripadati zbijenoj skupini sličnih opažanja ili raspodjeli u kojoj se većina nalazi daleko od nekoliko ekstremnih vrijednosti. Broj je u oba slučaja pravilno izračunat, ali iskustvo tipičnog opažanja nije isto.

U društvenim podacima takva razlika mijenja zaključak. Prosječno vrijeme, prihod ili broj dijeljenja može snažno povući mala skupina iznimnih slučajeva. Medijan će ostati stabilniji, ali će zauzvrat zanemariti koliko su ti slučajevi daleko od sredine.

Koji sažetak čuva ono što je važno u raspodjeli, a što pritom skriva?

Mjere središta

Ostatak poglavlja radi na simuliranoj anketi o korištenju društvenih mreža sa 300 ispitanika, koja bilježi dob, dnevno vrijeme korištenja u minutama i povjerenje u sadržaj na ljestvici od 1 do 10. Uzorak je proizveden kodom uz fiksno sjeme i ne opisuje nijednu stvarnu populaciju. Koristan je zato što ima oblik koji mjere medijskog angažmana redovito imaju, pa se na njemu vidi kako se sažeci ponašaju kada raspodjela nije simetrična.

Prosjek raspoređuje ukupno izmjereno vrijeme ravnomjerno na sve ispitanike. Ako svakome pripišemo jednak dio zajedničkog zbroja, svaki dobiva upravo aritmetičku sredinu. Zapis te operacije koristi n za broj opažanja u uzorku i x_i za vrijednost izmjerenu kod pojedinog ispitanika, a crta nad slovom kaže da je riječ o sredini tih vrijednosti.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Definicija 5. Aritmetička sredina je zbroj svih izmjerenih vrijednosti podijeljen njihovim brojem.

Sredina našeg uzorka iznosi 50,1 minuta dnevno. Brojka zvuči kao opis tipičnog ispitanika, a nije, jer više vremena od nje provodi samo

40 % ljudi u uzorku. Sredina koristi svaku vrijednost i zato je najinformativnija mjera središta, ali ta joj osjetljivost istodobno dopušta da je nekoliko krajnjih slučajeva odvuče iznad gotovo svih opažanja.

Kompromis između pune sredine i mjere koja krajnosti ignorira nudi **skraćena sredina** (*trimmed mean*), koja odbacuje zadani postotak najmanjih i najvećih vrijednosti pa prosjek računa iz ostatka. Uz odbacivanje po 5 % sa svake strane naš prosjek pada na 46,1 minuta, a uz 10 % na 44,1. Navarro upozorava da se ta mjera u objavljenim istraživanjima pojavljuje iznenađujuće rijetko iako je u mnogim situacijama primjerenija od obične sredine (Navarro 2019.).

Skraćivanje dovedeno do kraja daje medijan. Ono što medijan čini drukčijim nije samo otpornost, nego pitanje na koje odgovara. Sredina je vrijednost koja minimizira zbroj kvadriranih odstupanja i zato velikim odstupanjima daje veliku težinu, dok medijan minimizira zbroj apsolutnih odstupanja i sva odstupanja tretira jednako.

Definicija 6. Medijan je vrijednost koja poredani niz opažanja dijeli na dvije jednako velike polovine.

Medijan našeg uzorka iznosi 39 minuta i time za sredinom zaostaje 11,1 minuta. Razlika između dviju mjera time postaje brza dijagnostika oblika, jer sredina veća od medijana upućuje na rep prema većim vrijednostima. Mod opisuje najčešću vrijednost i za neprekinuto vrijeme korištenja nije koristan, ali za povjerenje mjereno cijelim brojevima jest, gdje najčešći odgovor iznosi 5. Za kategorije poput dobne skupine mod je jedina mjera središta koja ima značenje, jer prosjek kategorija ne postoji.

Mjere raspršenosti

Znati gdje se opažanja grupiraju tek je pola opisa. Dva medijska portala mogu imati jednak prosječan broj komentara po članku, a na prvome svaki članak dobiva između 45 i 55 komentara dok na drugome neki prolaze bez ijednoga, a poneki skupe 200. Prosjek ne razlikuje te dvije situacije, a čitatelju su potpuno različite.

Najjednostavniji odgovor je raspon, razlika između najveće i najmanje izmjerene vrijednosti. U našem uzorku vrijeme korištenja ide od 3 do 248 minuta, pa raspon iznosi 245 minuta. Ta brojka ima istu slabost kao sredina, samo izraženiju, jer ovisi isključivo o dva najekstremnija opažanja i sve ostale zanemaruje.

Sadržajnija mjera polazi od udaljenosti pojedinog opažanja od sredine. Tu udaljenost nazivamo odstupanjem, a njezinu veličinu bez obzira na smjer daje apsolutna vrijednost. Prosječno apsolutno odstupanje zato ima izravno čitljivo značenje, jer kaže koliko se tipičan ispitanik razlikuje od sredine.

$$\text{PAO} = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

Za naše podatke ta mjera iznosi 29,4 minuta. Statistika je ipak krenula drugim putem, jer apsolutna vrijednost nije diferencijabilna u nuli i otežava izvođenje svega što na raspršenosti počiva. Kvadriranje odstupanja daje matematički ugodniju veličinu po cijeni izgubljene neposrednosti, a rezultat te zamjene je varijanca.

Definicija 7. Varijanca je prosjek kvadriranih odstupanja opažanja od aritmetičke sredine, uz djelitelj umanjen za jedan.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Umanjeni djelitelj u tom izrazu nije sitnica i naziva se Besselovom korekcijom. Slijedi iz toga što odstupanja mjerimo od sredine izračunane iz istih tih podataka. Sredina uzorka po definiciji leži najbliže vlastitim opažanjima, bliže nego što bi im ležala prava sredina populacije, pa su odstupanja od nje sustavno premala. Dijeljenje s n zato bi dalo procjenu koja u prosjeku podcjenjuje raspršenost u populaciji, a umanjeni djelitelj tu pristranost uklanja.

Razlika između uzorka i populacije od ovog mjesta ulazi i u zapis. Statistike izračunane iz uzorka nose latinična slova, pa je sredina uzorka $\bar{x}$

a njegova varijanca s^2 . Nepoznate vrijednosti koje opisuju populaciju nose grčka slova, pa je populacijska sredina μ a populacijska varijanca σ^2 . Broj opažanja u uzorku ostaje n , a slovo N knjiga zadržava za veličinu populacije.

Navarro otvoreno kaže da je upravo ovaj korak jedno od najtežih mjesta uvodnog kolegija (Navarro 2019.). Puni se argument ne može izvesti prije nego što postoji pojam raspodjele uzorkovanja, pa procjena koja u prosjeku pogađa pravu vrijednost ovdje ostaje tvrdnja, a ne pokazana činjenica. Poglavlje o uzorkovanju vraća se na nju i pokazuje je simulacijom.

Varijanca našeg uzorka iznosi 1 533,3. Broj je velik i gotovo neupotrebljiv u izvještaju, jer kvadriranje nosi i mjernu jedinicu, pa je rezultat izražen u kvadriranim minutama. Kvadriranje istodobno objašnjava zašto je varijanca osjetljiva na krajnje slučajeve, budući da odstupanje dvostruko veće od drugoga u zbroj ulazi četverostruko.

Standardna devijacija i kvartili

Korijen varijance vraća mjeru u jedinice u kojima su podaci izmjereni i time je čini čitljivom.

Definicija 8. Standardna devijacija je korijen varijance, pa raspršenost izražava u istim jedinicama kao izmjerene vrijednosti.

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Standardna devijacija našeg uzorka iznosi 39,2 minuta, dakle nešto više od prosječnog apsolutnog odstupanja od 29,4 minuta. Taj je odnos pravilo, ne slučajnost, jer kvadriranje pojačava velika odstupanja pa ih standardna devijacija nosi teže. Zbog toga se standardna devijacija čita kao tipična udaljenost od sredine samo približno.

Za približno normalnu raspodjelu vrijedi korisno pravilo palca po kojem oko 68 % opažanja leži unutar jedne standardne devijacije od

sredine, oko 95 % unutar dviju i oko 99,7 % unutar triju. Naši podaci pokazuju što se dogodi kada se pravilo primijeni bez provjere pretpostavke. Unutar jedne standardne devijacije nalazi se 79,3 % ispitanika, a ne 68 %, a raspon dviju devijacija proteže se od minus 28,3 do 128,4 minuta. Negativno trajanje ne postoji, pa donja granica sama pokazuje da pretpostavka ne stoji.

Zanimljiviji je drugi dio provjere. Unutar dviju standardnih devijacija nalazi se 95,0 % ispitanika, što se s pravilom poklapa gotovo točno. Jedna brojka koja izađe kako smo očekivali ne potvrđuje pretpostavku na kojoj očekivanje počiva, a upravo takva poklapanja najčešće zaustave provjeru prerano.

Kada sredina i standardna devijacija zataje, opis se prenosi na položaje u poredanom nizu. **Percentil** je vrijednost ispod koje leži zadani postotak opažanja, pa je medijan pedeseti percentil. Prvi i treći kvartil odsijecaju donjih i gornjih 25 %, a razlika između njih opisuje širinu središnje polovine raspodjele.

Tablica 1: Percentili dnevnog vremena korištenja u simuliranoj anketi. Izrada autora.

Percentil	Minuta
5.	9,0
10.	12,0
25.	22,0
50.	39,0
75.	68,2
90.	103,1
95.	127,3

Interkvartilni raspon našeg uzorka iznosi 46,2 minuta i proteže se od 22,0 do 68,2 minuta. Ta mjera ne reagira na to koliko je krajnje opažanje daleko, nego samo na to koliko ih je, pa se s medijanom uparuje jednako prirodno kao standardna devijacija sa sredinom. Izvještaj koji

navodi medijan uz standardnu devijaciju miješa dva različita opisa iste raspodjele.

Oblik raspodjele i položaj opažanja

Središte i raspršenost ne kazuju je li raspodjela simetrična. Kada lijeva i desna strana izgledaju kao zrcalne slike, sredina i medijan padaju na isto mjesto. Dugi rep prema većim vrijednostima povlači sredinu za sobom i ostavlja medijan gdje je bio, pa razlika između njih mjeri koliko je raspodjela nagnuta.


Definicija 9. Asimetrija je mjera nesimetričnosti raspodjele, pozitivna kada je rep raspodjele okrenut prema većim vrijednostima.

Formalna mjera polazi od standardiziranih odstupanja i diže ih na treću potenciju. Neparna potencija čuva predznak, pa velika pozitivna odstupanja zbroj vuku prema pozitivnome, a velika negativna prema negativnome.

$$\text{asimetrija} = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3$$

Asimetrija našeg uzorka iznosi 1,61. Takav oblik u podacima o medijskoj uporabi nije iznimka nego očekivanje, i to iz strukturnog razloga. Vrijeme, dijeljenja i pratitelji imaju prirodnu donju granicu na nuli a nikakvu gornju, pa se većina opažanja skuplja pri dnu dok pojedinci mogu otići vrlo visoko. Isti izraz s eksponentom četiri mjeri zaobljenost (*kurtosis*) i opisuje težinu repova, a naš višak nad vrijednošću očekivanom za normalnu raspodjelu iznosi 3,36, što znači da krajnjih slučajeva ima više nego što bi zvonasta krivulja predviđela.

Kada raspodjela ima takav oblik, promjena ljestvice često pomaže više od promjene mjere. Logaritam sabija velike vrijednosti i razmake pretvara u omjere, pa razlika između 10 i 20 minuta postaje jednako velika kao razlika između 60 i 120.



Slika 1: Dnevno vrijeme korištenja u izvornim jedinicama i na logaritamskoj ljestvici, sa sredinom i medijanom.

Na logaritamskoj ljestvici asimetrija pada na -0,44, a sredina i medijan gotovo se poklapaju na 3,61 i 3,66. Transformacija time nije popravila podatke, nego je promijenila pitanje. Rezultati na toj ljestvici govore o razmjernim razlikama, pa svaka tvrdnja izvedena iz njih mora reći da je razlika višekratnik, a ne broj minuta.

Oblik odlučuje i o tome kada je pojedino opažanje neobično. Dnevnih 100 minuta znači jedno u skupini koja se u prosjeku zadržava 15 minuta, a nešto posve drugo u skupini koja se zadržava 80. Položaj postaje čitljiv kada udaljenost od sredine izrazimo u standardnim devijacijama.

Definicija 10. Standardizirana vrijednost kaže koliko standardnih devijacija pojedino opažanje leži iznad ili ispod aritmetičke sredine.

$$z_i = \frac{x_i - \bar{x}}{s}$$

Standardizirana varijabla uvijek ima sredinu nula i standardnu devijaciju jedan, pa vrijednosti izmjerene u minutama i vrijednosti izmjerene

na ljestvici povjerenja od 1 do 10 postaju usporedive. Prevođenje na zajednički jezik položaja ipak ne uklanja oblik raspodjele. U desno nagnutim podacima ostaje nemoguće da neko opažanje bude tri standardne devijacije ispod sredine, dok ih iznad nje može biti pet.

Odluka koja se lako preskoči jest odluka o skupini prema kojoj se položaj mjeri. Standardizacija u cijelom uzorku i standardizacija unutar dobne skupine odgovaraju na različita pitanja, a njihovi se odgovori mogu razlikovati i u predznaku.


Tablica 2: Tri ispitanika iz najstarije skupine, standardizirani u cijelom uzorku i unutar vlastite skupine. Izrada autora.

Ispitanik	Minuta	U uzorku	U skupini
I288	39	-0,28	2,40
I251	37	-0,33	2,19
I280	37	-0,33	2,19

Ispitanici u tablici provode manje vremena od prosjeka cijelog uzorka i unutar svoje dobne skupine pripadaju najintenzivnijim korisnicima. Obje su tvrdnje istinite i opisuju isti podatak, pa izvještaj mora reći prema čemu je položaj mjeren. Kada referentna skupina ostane neimenovana, čitatelj joj pridaje onu koja mu je bliža i zaključak se tiho mijenja.

Interakcija — Oblikovanje distribucije

Oblikovatelj raspodjele pomiče jedno krajnje opažanje i širi preostalih devet oko njihova zajedničkog središta. Sredina, medijan i dvije mjere raspršenosti mijenjaju se pred čitateljem. Tako postaje vidljivo koje mjere slušaju svaku vrijednost, a koje prvenstveno čuvaju redoslijed.



Slika 2: Tri raspodjele pokazuju odvojene učinke krajnjeg opažanja i raspršenosti.

Što isprobati.

1. Spustite krajnje opažanje sa 70 na 14 i usporedite sredinu s medijanom.
2. Vratite ga na 70 i provjerite koja se mjera središta više pomaknula.
3. Postavite krajnje opažanje na 11 pa povećajte faktor raspršenosti i usporedite dvije raspodjele iste sredine.

STATISTIKA U DIVLJINI

Prosjeak kao početak pregleda. Tukey je zagovarao istraživački pristup u kojem se podaci pregledavaju iz više kutova prije konačnog modeliranja (Tukey 1977.). Izvještaj koji navodi samo prosjek uklanja upravo oblik koji bi mogao objasniti zašto taj prosjek nije tipičan. Odgovorna tablica zato uparuje mjeru središta s mjerom raspršenosti i brojem opažanja. Graf zatim pokazuje asimetriju, praznine i krajnje slučajeve koje tri sažetka ne mogu nositi.

PITAJTE MODEL

Asistent lako izradi tablicu sažetaka i pritom obično pretpostavi simetriju koju nije provjerio. Vrijedi zatražiti broj valjanih opažanja, postupanje s nedostajućim vrijednostima i medijan uz svaku sredinu, a zatim provjeriti je li za nagnutu raspodjelu ponudio mjeru koja opisuje tipično opažanje. Dvije provjere hvataju većinu grešaka. Zbroj opažanja po skupinama mora dati ukupan broj, a granica raspona izvedena iz sredine i standardne devijacije ne smije pasti izvan mogućih vrijednosti mjere.

Sažmi svaku skupinu brojem opažanja, prikladnom mjerom središta i prikladnom mjerom raspršenosti. Obrazloži izbor nakon pregleda oblika raspodjele i prikaži koliko vrijednosti nedostaje.

NADITE GREŠKU

Prosječno dnevno korištenje u uzorku iznosi 50,1 minuta uz standardnu devijaciju od 39,2 minuta. Tipičan ispitanik dakle provodi oko 50 minuta dnevno na društvenim mrežama, a polovina uzorka nalazi se iznad te vrijednosti. Raspršenost je znatna, pa razlike među dobnim skupinama treba dodatno ispitati.

Razrađeni primjer

Zadatak je opisati koliko se vremena u anketi provodi na društvenim mrežama i razlikuju li se dobne skupine. Prvi je korak odluka o mjerama, a oblik raspodjele tu odluku već je donio. Zbirna raspodjela nagnuta je prema većim vrijednostima, pa uz sredinu treba stajati medijan, a uz standardnu devijaciju interkvartilni raspon.

```
s4_po_skupini <- anketa_mreze |>
  group_by(dobna_skupina) |>
  summarise(
```

```

opazanja = n(),
sredina = mean(minute_dnevno),
medijan = median(minute_dnevno),
sd = sd(minute_dnevno),
iqr = IQR(minute_dnevno),
.groups = "drop"
)

```

Blok dijeli uzorak po dobnoj skupini i za svaku ponavlja isti niz mjera. Znak `|>` vodi podatke iz jednog koraka u sljedeći, `group_by` određuje po čemu se uzorak dijeli, a `summarise` svakoj skupini vraća jedan red. Taj se obrazac vraća u svakom kasnijem poglavlju koje sažima podatke po skupinama.

Tablica 3: Dnevno vrijeme korištenja prema dobnoj skupini u simuliranoj anketi. Izrada autora.

Dobna skupina	Opazanja	Sredina	Medijan	Standardna devijacija	Interkvartilni raspon
18 do 24	90	81,5	68,5	44,6	46,2
25 do 34	84	54,4	46,0	29,0	41,8
35 do 44	66	32,4	26,0	20,3	26,2
45 i više	60	16,2	15,0	9,5	15,5

Tablica pokazuje uređen pad kroz dobne skupine, od 68 minuta u najmlađoj do 15 minuta u najstarijoj po medijanu. Zbirna sredina od 50,1 minuta ne opisuje nijednu od tih skupina, jer leži između njih i istodobno je povučena repom najintenzivnijih korisnika. Sažetak cijelog uzorka ovdje opisuje mješavinu, a ne populaciju.

Raspršenost pada zajedno sa središtem, i to je nalaz sam za sebe. Standardna devijacija u najmlađoj skupini iznosi 44,6 minuta, a u najstarijoj 9,5, pa se skupine ne razlikuju samo po tome koliko koriste mreže nego i po tome koliko su međusobno slične. Skupina s najvišim medijanom ujedno je najmanje homogena.

Ono što tablica ne može pokazati jest odakle raspršenost dolazi. Interkvartilni raspon u najmlađoj skupini iznosi 46,2 minuta, dok standardna devijacija govori o širini koja uključuje i krajnje slučajeve. Razlika između tih dviju brojki mjeri koliko opis skupine ovisi o nekolicini najintenzivnijih korisnika, a odgovor na pitanje jesu li ti korisnici pogreška mjerenja, legitimna manjina ili sam predmet istraživanja ne daje nijedan sažetak.

Sažetak

Sažetak je odluka o tome koji dio raspodjele čuvamo u malom broju vrijednosti. Mjera središta bez raspršenosti ostavlja pola priče neispričanom, a obje zajedno još ne pokazuju oblik, pa nagnuta raspodjela svaku od njih čini podložnom pogrešnom čitanju. Standardizacija opisuje položaj i time uvodi pitanje prema kojoj se skupini položaj mjeri, dok transformacija ljestvice mijenja jedinicu tvrdnje. Razlika između uzorka i populacije ovdje je ušla u zapis i čeka poglavlje o uzorkovanju da je opravda. Sljedeće poglavlje podatke vraća u prostor i pokazuje kako graf postaje dio argumenta.

Pojmovi

aritmetička sredina (*mean*), skraćena sredina (*trimmed mean*), medijan (*median*), mod (*mode*), varijanca (*variance*), standardna devijacija (*standard deviation*), interkvartilni raspon (*interquartile range*), standardizirana vrijednost (*z-score*), asimetrija (*skewness*), zaobljenost (*kurtosis*)

Zadaci

Konceptualni

Predvidite kako će se sredina, medijan, standardna devijacija i interkvartilni raspon promijeniti kada jedno najveće opažanje dodatno po-

raste. Predajte obrazloženje bez računanja, s izričitim razlikovanjem mjera koje reagiraju na veličinu odstupanja od onih koje reagiraju samo na njegovo postojanje.

Računski

Upotrijebite interakciju poglavlja. Pri početnim postavkama pročitajte s prikaza svih deset vrijednosti, ručno izračunajte sredinu i medijan i usporedite ih s brojkama koje prikaz ispisuje. Zatim krajnje opažanje spustite na najmanju dopuštenu vrijednost i oba izračuna ponovite. Predajte četiri broja i dvije rečenice o tome koja se mjera promijenila više i zašto joj je promjena veća.

S prikaza oblika raspodjele potom pročitajte položaj sredine i medijana u izvornim jedinicama i na logaritamskoj ljestvici te u jednoj rečenici objasnite zašto se razlika među njima mijenja. Postupak za isti izračun nad cijelim skupom podataka nalazi se u praktikumu.

Kritički

Objasnite zašto istraživačka analiza ne završava jednom mjerom središta (Tukey 1977.). Predajte popis triju dodatnih provjera u punim rečenicama, uz navod što bi svaka od njih otkrila na podacima iz ovog poglavlja.

Revizija modela

Ocijenite modelsku analizu iz okvira. Imenujte jedan opravdan izbor, jednu neopravdanu tvrdnju i izračun kojim biste je provjerili u tri koraka.

Vizualizacija kao argument

Graf pokazuje ono što brojčani sažetak ne može

Vrijeme čitanja	Widget	Podaci	Preduvjet
22 min	Isti podaci, četiri grafa	Anscombeov kvartet, simulirana anketa	pogl. 4

VINJETA

Anscombe je sastavio četiri skupa podataka s gotovo jednakim uobičajenim brojčanim sažecima, uključujući isti linearni odnos, ali s posve različitim grafičkim oblicima (Anscombe 1973.). Jedan je pokazivao približno linearan obrazac, drugi zakrivljenost, treći utjecajnu točku, a četvrti gotovo okomiti oblak s jednim izdvojenim opažanjem.

Tablica sažetaka nije sadržavala računsku pogrešku. Upravo je zato primjer bio uvjerljiv. Četiri različite priče stale su u iste brojke jer sažeci nisu mogli sačuvati položaj svakog opažanja.

Kada graf razjašnjava podatke, a kada ih pretvara u argument koji prikriva vlastite odluke?

Gramatika grafike

Graf nije slika dodana nakon analize. On bira što će se uspoređivati položajem, duljinom, površinom ili bojom, pa je izbor prikaza ujedno izbor načina na koji će čitatelj vidjeti razliku. Dobra vizualizacija zato počinje tvrdnjom. Raspodjela jedne brojčane varijable traži prikaz koji čuva oblik, usporedba kategorija zajedničku početnu točku, a odnos dviju brojčanih varijabli sačuvana pojedinačna opažanja. Graf koji ne odgovara pitanju može biti uredan i potpuno neinformativan.

Uobičajeni popis vrsta grafova, u kojem stupčani dijagram stoji uz kružni i raspršeni, pritom skriva jednu važnu činjenicu. Vrsta grafa nije osnovna jedinica. Svaki je prikaz skup odvojenih odluka koje se u praksi tako često pojavljuju zajedno da je njihova kombinacija dobila ime.

Definicija 11. Gramatika grafike je opis prikaza kao skupa zasebnih odluka o tome što jedna oznaka predstavlja, koja je varijabla pridružena kojem vizualnom kanalu, što je izračunato prije crtanja i kako se vrijednost pretvara u vizualnu veličinu.

Razlaganje na odluke svaku od njih izlaže zasebnoj provjeri. Ideju je kao sustav postavio Wilkinson (Wilkinson 2005.), a paket ggplot2

postao je njezina najraširenija izvedba (Wickham 2016.). Sama gramatika ne pripada nijednom programu i primjenjuje se pred tiskanom grafikom, bez pisanja koda.

Najprije treba znati što predstavlja jedna oznaka na grafu. Točka može stajati za ispitanika, državu, godinu ili stranku, a prikazi tu jedinicu mijenjaju bez najave. Kada agregat zamijeni pojedinca, mijenja se i pitanje na koje graf odgovara, što je ista opasnost koju opisuje poglavlje o mjerenju i dizajnu.

Sljedeći korak pridružuje varijable vizualnim kanalima, položaju na dvjema osima, boji, veličini i obliku.

Definicija 12. Pridruživanje (*aesthetic mapping*) je odluka koja varijabla ulazi u koji vizualni kanal, čime se određuje koja usporedba čitatelju postaje neposredno dostupna.

Pridruživanje je tvrdnja o tome što zaslužuje usporedbu. Kada skupinu nosi boja, graf poziva na neposrednu usporedbu skupina. Kada je skupina razdvojena u zasebna polja, graf traži da se obrazac čita unutar svake od njih. Podaci ostaju isti, argument se mijenja, a obmane nije bilo.

Najtiša odluka dolazi prije crtanja. Graf redovito nešto izračuna prije nego što postavi prvu oznaku. Stupac visine prosjeka odbacio je raspodjelu, okvir s brkovima izgubio je informaciju o broju vrhova, a izgladnena linija dodala je model koji nitko nije zatražio. Poglavlje o sažimanju pokazalo je koji sažetak što gubi, a gramatika tome dodaje da je i sam graf redovito sažetak, samo neoznačen. Anscombeov kvartet poseban je slučaj upravo tog pravila (Anscombe 1973.).

Ljestvica je pravilo kojim vrijednost postaje vizualna veličina. Raspon osi, njezin prekid, logaritamska transformacija i položaj sredine u ljestvici boja mijenjaju koliko promjena zauzima prostora, a podatke pritom ne mijenjaju. Koordinatni sustav zatvara popis i najčešće služi kao opomena, jer polarne koordinate duljinu pretvaraju u kut i time istu usporedbu čine težom.

Iz tih odluka slijedi postupak za čitanje tuđega grafa. Što predstavlja jedna oznaka, što je pridruženo kojem kanalu, što je izračunato prije crtanja i što dopušta ljestvica jesu pitanja koja se pred novinskom grafikom postavljaju bez ikakva programa. Knjiga taj postupak dalje koristi pri svakom rastavljanju objavljene tvrdnje.

Što oko može očitati

Gramatika kaže da oznaka nosi usporedbu, ali ne kaže koliko dobro. To pitanje nije stvar ukusa i ima izmjeren odgovor. Cleveland i McGill zadavali su sudionicima parove vrijednosti prikazane različitim kanalima i mjerili koliko im omjer promaši (Cleveland i McGill 1984.). Iz tih pokusa slijedi poredak elementarnih zadataka po pogrešci koju proizvode, u kojem je očitavanje položaja na zajedničkoj osi najtočnije, zatim slijede položaj na odvojenim osima s usklađenom ljestvicom, duljina, nagib, površina, te na kraju obujam, zakrivljenost i zasićenost boje (Cleveland i McGill 1984.).

Poredak nije popis zabrana nego pravilo raspodjele. Kanal na vrhu poretka dodjeljuje se veličini koja nosi zaključak, a kanali s dna sekundarnim razlikama, gdje je gruba procjena dovoljna. Kružni dijagram udio kodira kutom, a kut leži nisko u poretku, pa isti podaci u stupcima na zajedničkoj osi proizvode točnije očitavanje (Cleveland i McGill 1984.). Kada nekoliko udjela treba samo prepoznati, a ne rangirati, ta razlika prestaje biti važna.

Iz istog poretka slijedi i zašto trodimenzionalni prikaz ravnih podataka pogoršava očitavanje. Perspektiva duljinu pretvara u obujam, a obujam se u pokusima nalazi među najlošije očitanim kanalima (Cleveland i McGill 1984.). Ukras se dodaje kanalu koji nosi zaključak, i to je ista obitelj postupaka kojoj pripada skraćena os iz poglavlja o zavaravanju brojkama.

Tufte je isti problem postavio kao pitanje raspodjele tinte na stranicama, gdje se svaki element grafa mjeri time nosi li podatak ili ne nosi (Tufte 2001.). Sjena ispod stupca, rešetka u pozadini, obrub oko svake

oznake i preljev boje troše prostor i pažnju, a ne dodaju nijednu vrijednost, pa ih Tufte skupno naziva grafičkim otpadom. Njegovo je pravilo da se takav element ukloni i da se provjeri je li se išta izgubilo, jer ako nije, nije ni trebao biti ondje.

Postoji i oštiji oblik istog mjerenja. Tufte uspoređuje veličinu učinka koji graf pokazuje s veličinom učinka koji u podacima postoji, a omjer tih dviju veličina naziva faktorom laži (Tufte 2001.). Pošten graf ima taj omjer blizu jedinice. Kada ga skraćena os, površina umjesto duljine ili perspektiva podignu, graf tvrdi više nego što podaci nose, i to bez ijedne netočne brojke. Vrijednost te mjere nije u tome što se često računa nego u tome što obmanu premješta iz područja ukusa u područje provjere.

Prikaz prema tvrdnji

Pitanje kojim graf počinje nije koji je prikaz lijep nego koju tvrdnju treba provjeriti. Broj i vrsta varijabli tu odluku gotovo određuju, pa je vrijedi imati pri ruci.

Tablica 1: Prikaz prema vrsti podataka i prema onome što svaki izbor žrtvuje. Izrada autora.

Što se prikazuje	Uobičajeni izbor	Što prikaz čuva, a što odbacuje
jedna brojčana varijabla	histogram, krivulja gustoće	čuva oblik cijele raspodjele, gubi pojedinačno opažanje
jedna kategorijalna varijabla	stupci na zajedničkoj osi	čuva učestalost, ne kaže ništa o raspršenosti unutar kategorije

Što se prikazuje	Uobičajeni izbor	Što prikaz čuva, a što odbacuje
brojčana po skupinama	okvir s brkovima, violina	čuva položaj i raspon, odbacuje broj vrhova i pojedinačna opažanja
dvije brojčane varijable	raspršeni dijagram	čuva svako opažanje, teško podnosi velik broj točaka
dvije kategorijalne varijable	grupirani ili složeni stupci	čuva odnos udjela, otežava usporedbu unutar složenih stupaca


Desni stupac tablice nosi cijeli argument. Svaki prikaz nešto sačuva i nešto odbaci, pa se izbor donosi prema tome što tvrdnja treba, a ne prema tome što izgleda uredno. Okvir s brkovima izračunava medijan i kvartile prije crtanja, pa raspodjela s dva vrha i raspodjela s jednim mogu proizvesti isti okvir. Histogram ne računa ništa osim razreda, pa taj oblik čuva, ali skupine uspoređuje teže.

Posljednji redak tablice krije odluku koja se rijetko izriče. Kada se dvije kategorijalne varijable prikazuju stupcima, stupci se mogu poređati jedan uz drugi ili složiti jedan na drugi, a treća mogućnost svaki stupac rastegne na punu visinu i time prikaže udjele. Prvi izbor čuva apsolutne brojeve i omogućuje usporedbu veličine skupina. Treći ih odbacuje i pokazuje samo sastav, zbog čega skupina od dvadeset ispitanika izgleda jednako pouzdano kao skupina od dvjesto. Nijedan izbor nije pogrešan, ali izvještaj koji tvrdi da je neka skupina brojnija, a prikazuje udjele, tvrdi nešto što njegov graf ne pokazuje.

Složeni stupac uz to skriva zamku koju je lako previdjeti. Samo najdonji segment u nizu počinje od zajedničke crte, dok svi ostali počinju ondje gdje je prethodni završio. Duljina im ostaje točna, ali položaj

im je pomaknut za vrijednost koja se mijenja od stupca do stupca, pa se usporedba srednjih segmenata svodi na očitavanje duljine bez zajedničke početne točke, što je prema poretku iz prethodnog odjeljka osjetno teži zadatak (Cleveland i McGill 1984.). Kada usporedba jednog segmenta nosi zaključak, on dobiva vlastiti prikaz.

Ono što je odbačeno vidi se tek kada se vrati na graf. Simulirana anketa `anketa_mreze` sadrži 300 ispitanika s dnevnim vremenom korištenja društvenih mreža, i nije mjerenje nego nastavni skup proizveden kodom. Kada se uz okvire nacrtaju i opažanja iz kojih su izračunati, razlika između sažetka i podatka prestaje biti apstraktna.




Slika 1: Okvir s brkovima i opažanja iz kojih je nastao. Kutija stoji na kvartilima, a točke pokazuju raspored koji kvartili ne mogu prenijeti.

Kutija sažima svaku skupinu u pet brojeva. U najmlađoj skupini polovina ispitanika leži između 53 i 99 minuta, a u najstarijoj između 9 i 24. Točke iza kutije pokazuju što je taj sažetak potrošio, jer se iz njih vidi koliko je opažanja stisnuto uz donji rub i koliko rijetko rep doseže svoje najveće vrijednosti. Kutija bi bila ista i da su opažanja unutar nje raspoređena posve drukčije, što je isti nalaz koji poglavlje o sažimanju podataka izvodi brojčano.

Dvije varijable u istom prostoru

Kada obje varijable nose brojeve, raspršeni dijagram jedini je prikaz koji ne mora ništa izračunati. Svaka točka je jedno opažanje na svojem mjestu, pa se iz oblaka čita smjer veze, njezina zakrivljenost, postojanje podskupina i položaj opažanja koja odudaraju. Zbog toga je to prikaz s najvećom informacijskom gustoćom u knjizi i prikaz kojim počinje svaka provjera odnosa.

Njegova slabost je vlastiti uspjeh. Kada opažanja ima mnogo, točke se preklapaju, a gustoća prestaje biti vidljiva, jer sto opažanja na istom mjestu izgleda kao jedno. Uobičajeni popravak je djelomična prozirnost oznake, čime preklapljen područja postaju tamnija, pa gustoća opet nosi značenje. Drugi je popravak lagano razmicanje oznaka, koje se koristi kada je jedna varijabla zapravo diskretna, a treći prelazak na prikaz koji gustoću računa izravno.




Slika 2: Dob i dnevno vrijeme korištenja u simuliranoj anketi. Lijevo su neprozirne oznake, desno prozirne, a razlika je u tome što se vidi gdje je opažanja mnogo.

Oba polja sadrže istih 300 opažanja i oba pokazuju da vrijeme korištenja opada s dobi. Desno polje uz to pokazuje gdje ih je mnogo, a gdje malo, i time odgovara na pitanje koliko je obrazac tipičan, a ne samo postoji li. Prozirnost ovdje nije ukras nego pridruživanje gustoće tami oznake, dakle odluka gramatike kao i svaka druga.

Na raspršeni se dijagram redovito dodaje izgladena linija koja kroz oblak provlači procijenjeni prosječni odnos. Ta linija nije podatak nego model, i to je najvažnija stvar koju o njoj treba znati. Ona pretpostavlja oblik veze, zaglađuje ono što joj ne odgovara i ostaje uvjerljiva i onda kada oblak ispod nje nema nikakav stabilan obrazac. Poglavlje o regresiji pokazuje kako se takva linija dobiva i pod kojim je uvjetima opravdana, a do tada vrijedi pravilo da se linija čita zajedno s oblakom iz kojega je izvučena, nikada umjesto njega.

Poštena ljestvica

Ljestvica je mjesto na kojem se najlakše pogriješi i najlakše prevari, jer je mijenja jedan broj, a mijenja se cijeli dojam. Prosjeci dnevnih minuta po dobnim skupinama razlikuju se za 65 minuta, što je 80 % najvećeg među njima. Koliko će ta razlika zauzeti prostora ne ovisi o podacima nego o rasponu osi.



Slika 3: Isti prosjeci na dvjema osima. Lijevi prikaz počinje od nule, desni od najmanje vrijednosti, a razlika među skupinama nije se promijenila.

Desni prikaz nije izmislio nijedan broj. Sve četiri vrijednosti stoje ondje gdje i lijevo, a promijenio se samo raspon koji im je dodijeljen. Kod stupaca je to ozbiljna pogreška, jer duljina stupca nosi značenje,

pa odsječena os duljinu pretvara u veličinu koja više ne odgovara vrijednosti. Kod linijskog grafa i raspršenog dijagrama, gdje značenje nosi položaj a ne duljina, raspon smije slijediti podatke, uz obavezu da os bude označena tako da čitatelj vidi odakle počinje.

Odatle slijedi pravilo koje vrijedi i za tuđi i za vlastiti graf. Odsječena os dopuštena je kada je razlika koju treba vidjeti manja od šuma na osi od nule, a uvjet je da odsjecanje bude vidljivo. Sakriveno odsjecanje čitatelju oduzima podatak koji mu treba da bi prosudio tvrdnju, a to je isti postupak koji poglavlje o zavaravanju brojkama opisuje kao odabir prikaza prema željenom zaključku.


Ista logika vrijedi za logaritamsku ljestvicu, koja dugi desni rep raspodjele stišće i time pokazuje strukturu koja se na izvornoj ljestvici zbila u jedan stupac. Ona ne krivotvori ništa, ali mijenja što znači jednaki razmak, pa graf koji je koristi mora to reći u oznaci osi. Poglavlje o sažimanju podataka istu je pretvorbu uvelo brojčano, i graf od nje ne traži ništa novo.

Mala višestruka polja

Kada skupina ima više od tri ili četiri, boja prestaje raditi. Krivulje se preklapaju, legenda traži stalno vraćanje pogleda, a čitatelj usporedbu provodi po sjećanju. Alternativa je da se isti graf ponovi za svaku skupinu.

Definicija 13. Mala višestruka polja (*small multiples*) niz su prikaza istoga oblika i iste ljestvice, po jedan za svaku skupinu, tako da se razlike među skupinama očitavaju usporedbom položaja između polja.

Zajednička ljestvica je uvjet bez kojega postupak gubi smisao. Kada svako polje dobije vlastiti raspon, panel s malim razlikama izgleda jednako dramatično kao panel s velikima, pa se usporedba koja je bila svrha prikaza više ne može provesti. Slobodne osi imaju svoje mjesto tamo gdje se uspoređuje oblik, a ne razina, ali to je iznimka koja se izriče, a ne zadana postavka.



Slika 4: Ista raspodjela u zbirnom polju i u četirima skupinskim poljima uz zajedničku os. Zbirni oblik nastaje preklapanjem raspodjela različitih položaja.

Gornji prikaz ima jedan vrh i dugi rep. Donji pokazuje da taj oblik nije svojstvo nijedne skupine nego posljedica njihova zbrajanja, jer se vrh pomiče prema manjim vrijednostima kako dob raste. Zbirna raspodjela postoji, uredno je izračunata i ne opisuje nijednog stvarnog ispitanika osobito dobro.

To je vizualni oblik pojave koju je Simpson opisao brojačano na tablicama frekvencija (Simpson 1951.), i razlog zbog kojeg poglavlje o povezanosti tom pitanju vraća s koeficijentom u ruci. Prikaz koji skupine zbraja nije pogrešan, nego odgovara na drugo pitanje od prikaza koji ih razdvaja. Nevolja nastaje kada se odgovor na prvo pitanje objavi kao odgovor na drugo.

Graf pred čitateljem

Graf mora raditi u tri okolnosti koje autor pri crtanju obično ne vidi. Netko ga čita u crno-bijelom tisku, netko preko čitača zaslona, a netko razlikuje boje drukčije od autora.

Prva obveza je da boja nikada ne bude jedini nosač značenja. Kada se skupine razlikuju samo tinkturom, uklanjanje boje uklanja podatak, pa graf koji je u digitalnom izdanju čitljiv u tiskanom prestaje biti graf. Rješenje je da kanal koji nosi razliku bude udvostručen, dakle da uz

boju stoji i oblik oznake, vrsta linije ili izravna oznaka uz krivulju. Paleta ove knjige zbog istog je razloga poredana po svjetlini, a ne po tonu, pa u tisku daje razlučive sive razine.

Druga obveza je opis. Svaki graf u knjizi nosi alternativni tekst koji kaže što se na njemu vidi, a ne kako je nastao. Dobar opis imenuje varijable, smjer i najizrazitiju osobinu obrasca, i piše se tako da čitatelj koji sliku ne vidi dobije isti nalaz, a ne popis elemenata. Opis koji glasi „graf prikazuje odnos dviju varijabli” nije ispunio obvezu, jer ne prenosi ništa što naslov već ne kaže.

Treća obveza je izravno označavanje. Legenda traži da čitatelj pamti par boje i imena dok pogled putuje između legende i grafa, a oznaka postavljena uz krivulju taj put uklanja. Isto vrijedi za redoslijed kategorija, koji abecedni poredak gotovo nikada ne pogađa. Kategorije poredane po veličini čitaju se bez napora, a poredane po abecedi traže da čitatelj sam obavi rangiranje koje je graf mogao obaviti umjesto njega.

Tri obveze vrijede za graf koji sami crtamo. Pred tuđim grafom iste odluke postaju pitanja, i tada gramatika iz prvog odjeljka radi kao popis provjere. Vrijedi ga provesti do kraja na primjeru koji je već pred nama, dakle na desnom polju s odsječenom osi.


Prvo pitanje glasi što predstavlja jedna oznaka. Ondje jedan stupac stoji za jednu dobnu skupinu, dakle za agregat, a ne za ispitanika, pa se iz njega ne smije zaključivati ništa o pojedincu. Drugo pitanje traži pridruživanja, a ona su dva, jer kategorija određuje vodoravni položaj, a prosjek duljinu stupca. Boja i širina ne nose ništa, što je uredno, budući da bi svaka razlika u njima sugerirala razliku koje u podacima nema.

Treće pitanje je najtiše i ovdje najvažnije. Prije crtanja izračunata je aritmetička sredina po skupini, čime su odbačene sve raspodjele, a s njima i dugi desni rep koji je histogram pokazao. Stupac visok 82 minuta postoji, ali ne postoji ispitanik kojemu ta vrijednost pripada, jer je medijan iste skupine 68 minuta. Četvrto pitanje odnosi se na ljestvicu i otkriva ono zbog čega je prikaz uopće sporan, dakle da os ne počinje od nule i da to nije označeno.

Iz četiri odgovora slijedi presuda koja je preciznija od dojma. Prikaz nije netočan, nego kombinira odbačenu raspodjelu s neoznačenim od-sjecanjem, pa duljina stupca ne odgovara ni vrijednosti ni tipičnom ispitaniku. Isti se popis primjenjuje na novinsku grafiku, na sliku iz izvještaja i na graf koji je proizveo asistent, i traži manje vremena nego čitanje teksta koji uz njega stoji.

Interakcija — Isti podaci, četiri grafa

Interakcija prikazuje iste simulirane podatke četirima geometrijama. Promjena grafa ne mijenja opažanja, ali mijenja usporedbu koja postaje laka ili teška. Čitatelj tako bira prikaz prema tvrdnji, a ne prema dojmu atraktivnosti.



Slika 5: Sva simulirana opažanja i samo dvije skupinske sredine. Drugi prikaz skriva raspršenost koju prvi čuva.

Što isprobati.

1. Odaberite raspršeni dijagram i opišite odnos varijabli bez sažimanja po skupinama.

2. Prijedite na histogram i utvrdite koja je prethodna informacija nestala.
3. Usporedite raspodjelu po skupinama s prikazom njihovih sredina.
4. Odaberite graf za tvrdnju o razlikama među tipičnim ishodima i obrazložite izbor.

STATISTIKA U DIVLJINI

Kružni dijagram nikada. Zabrana kruži uredništvima i priručnicima kao utvrđena činjenica, a redovito se poziva na jedan izvor. Cleveland i McGill doista su izmjerili da sudionici točnije očitavaju položaj na zajedničkoj osi nego kut, i taj nalaz stoji (Cleveland i McGill 1984.). Iz njega slijedi da udio koji nosi zaključak ne treba kodirati kutom. Ne slijedi zabrana. Pokusi su mjerili točnost očitavanja omjera dviju istaknutih vrijednosti, a ne razumijevanje prikaza u kontekstu, pamćenje ni brzinu prepoznavanja (Cleveland i McGill 1984.). Prikaz u kojem treba vidjeti da jedna kategorija drži otprilike polovinu, a ne rangirati sedam bliskih udjela, ne pada pod izmjereni nedostatak. Kratki oblik tvrdnje sadrži pravi nalaz i izgubljen uvjet pod kojim vrijedi, što je najčešći način na koji izmjeren rezultat postane pravilo.

PITAJTE MODEL

Asistent može predložiti geometriju i napisati alt-tekst, ali treba dobiti pitanje koje graf mora odgovoriti. Nakon izrade provjeravamo zajedničke osi, nazive jedinica, redoslijed kategorija i nosi li boja značenje koje nestaje u tisku.

Dva promašaja ponavljaju se dovoljno često da ih vrijedi tražiti unaprijed. Asistent rado dodaje izgladenu liniju kroz raspršeni dijagram, čime u prikaz uvodi model koji nitko nije zatražio i koji poglavlje o regresiji tek uvodi. I rado veže boju uz kategoriju bez drugoga nosača razlike, pa graf koji je na zaslonu čitljiv u tisku ostaje bez jednog stupca podataka.

Predloži najjednostavniji graf za ovu tvrdnju. Obrazloži koja usporedba nosi zaključak, navedi potrebnu ljestvicu i napiši alt-tekst bez tumačenja koje podaci ne podupiru.

NADITE GREŠKU

Za usporedbu udjela triju kategorija asistent je predložio ovaj poziv.

```
ggplot(udjeli, aes(kategorija, udio)) +
  geom_col(width = c(0.6, 0.6, 0.9)) +
  geom_text(aes(label = udio), vjust = -0.5) +
  scale_y_continuous(limits = c(0, 1))
```

Os počinje od nule, kategorije su označene, a vrijednosti stoje uz stupce. Šira treća kategorija, prema obrazloženju, samo popravljala optičku ravnotežu prikaza.

Razrađeni primjer

Zadatak je provjeriti koliko brojčani sažetak sam po sebi jamči o strukturi podataka. Anscombeovi su skupovi za to izabrani zato što su im sažeci gotovo jednaki po konstrukciji (Anscombe 1973.), pa ostaje samo pitanje što prikaz dodaje. Podaci `anscombe` ugrađeni su u R i reproduciraju objavljeni kvartet.

Prije crtanja vrijedi vidjeti koliko je sličnost bliska. Aritmetičke sredine ishoda u četirima skupovima iznose 7,50, 7,50, 7,50 i 7,50, a standardne devijacije 2,03, 2,03, 2,03 i 2,03. Tablica sastavljena od tih osam brojeva ne bi imala što reći, jer se skupovi po njoj ne razlikuju.


```

anscombe_dugo <- bind_rows(
  tibble(skup = "Skup I", x = anscombe$x1, y = anscombe$y1),
  tibble(skup = "Skup II", x = anscombe$x2, y = anscombe$y2),
  tibble(skup = "Skup III", x = anscombe$x3, y = anscombe$y3),
  tibble(skup = "Skup IV", x = anscombe$x4, y = anscombe$y4)
)

p_anscombe <- ggplot(anscombe_dugo, aes(x, y)) +
  geom_point() +
  geom_smooth(method = "lm", se = FALSE) +
  facet_wrap(~ skup, ncol = 1)

```

Prvi blok slaže četiri skupa u jednu tablicu s jednim opažanjem u svakom redu. Drugi ispisuje odluke gramatike u redoslijedu u kojem smo ih izgradili. Poziv `aes` pridružuje varijable osima, `geom_point` bira oznaku, `geom_smooth` dodaje izračun koji nastaje prije crtanja, a `facet_wrap` razdvaja skupove u ponovljena polja. Dodani pravac je onaj najmanjih kvadrata, u izvornom radu jednak u sva četiri skupa (Anscombe 1973.), a poglavlje o regresiji pokazuje kako se dobiva. Nakon ovog imenovanja svaki se graf u knjizi može pročitati bez novoga objašnjenja, jer se iste četiri odluke vraćaju u svakom pozivu.



Slika 6: Anscombeov kvartet s jednakim sažecima i različitim oblicima. Izrada autora prema Anscombe (1973.).

Prvi skup približno odgovara linearnoj priči. Drugi traži zakrivljeni opis. Treći i četvrti pokazuju koliko jedno opažanje može određivati pravac. Zaključak zato ne glasi da je korelacija beskorisna. Glasi da se brojčani sažetak čita uz prikaz strukture iz koje je nastao.

Sažetak

Graf je skup odluka o tome što jedna oznaka predstavlja, koja varijabla ulazi u koji kanal, što je izračunato prije crtanja i kako se vrijednost pretvara u vizualnu veličinu. Te se odluke provjeravaju pojedinačno, a njihov redoslijed nije stvar ukusa, jer je izmjereno da kanali nose usporedbu različito točno (Cleveland i McGill 1984.). Svaki prikaz nešto čuva i nešto odbaci, pa se bira prema tvrdnji koju treba provjeriti, a ne prema izgledu. Raspon osi, razdvajanje u mala polja i oslanjanje na boju mijenjaju što će čitatelj vidjeti bez ijedne promjene u podacima, što graf čini argumentom koji podliježe istoj provjeri kao brojka. Sljedeće poglavlje uzima jedan od tih prikaza, raspršeni dijagram, sažima ga u jedan koeficijent i pita što je pritom izgubljeno.

Pojmovi

gramatika grafike (*grammar of graphics*), pridruživanje (*aesthetic mapping*), geometrija grafa (*geom*), ljestvica (*scale*), grafička percepcija (*graphical perception*), mala višestruka polja (*small multiples*), pristupačnost (*accessibility*), alt-tekst (*alternative text*), utjecajno opažanje (*influential observation*)

Zadaci

Konceptualni

Odaberite graf za raspodjelu jedne varijable, usporedbu kategorija i odnos dviju brojčanih varijabli. Za svaki izbor navedite što prikaz odbacuje. Predajte tri izbora s obrazloženjem.

Računski

Upotrijebite interakciju poglavlja. Za svaki od četiriju prikaza zapišite što čuva, što izračunava prije crtanja i koju usporedbu olakšava, a zatim iste odluke pročitajte s Anscombeovih prikaza iz razrađenog primjera (Anscombe 1973.). Predajte tablicu s četirima redovima i jednom rečenicom obrazloženja u svakom. Postupak za ponavljanje izračuna nad cijelim skupom nalazi se u praktikumu.

Kritički

Pronađite objavljeni graf sa skraćenom osi i prosudite je li odsjecanje opravdano. Odredite koliko bi razlika zauzela prostora na osi od nule, je li prekid vidljivo označen i mijenja li se zaključak teksta uz graf. Predajte odlomak s presudom i s uvjetom pod kojim bi presuda bila suprotna.

Revizija modela

Ocijenite prijedlog modela iz okvira. Imenujte odluke gramatike koje su ispravno odgovorene, jednu koja obmanjuje, redak koda u kojem ta odluka stoji i način njezina popravka.

Povezanost

Koeficijent sažima odnos, ali ne čuva cijelu sliku

Vrijeme čitanja	Widget	Podaci	Preduvjet
20 min	Pogodi korelaciju	simulirana anketa, Anscombeov kvartet	pogl. 4, 5

VINJETA

Anscombeova četiri skupa imaju gotovo jednaku Pearsonovu korelaciju, iako njihovi grafovi prikazuju različite odnose (Anscombe 1973.). Analitičar koji je dobio samo koeficijent mogao je uredno izvijestiti o smjeru i jačini linearne veze, a ipak propustiti zakrivljenost ili jedno opažanje koje određuje cijeli rezultat.

Korelacija je bila točno izračunata. Nije pogriješila u računu, nego je sažela samo jedan aspekt odnosa. Poteškoća je nastala kada je taj sažetak pročitao kao potpuna slika.

Što koeficijent povezanosti čuva, a koje odnose ostavlja izvan kadra?

Zajedničko kretanje

Dvije su varijable povezane kada se njihov raspored mijenja zajedno. Pozitivna veza znači da se veće vrijednosti jedne češće pojavljuju uz veće vrijednosti druge. Negativna veza spaja veće vrijednosti jedne s manjimima druge. Slaba linearna veza ne znači da odnosa nema, jer zakrivljeni obrazac može imati koeficijent blizu nule.

Do mjere se dolazi pitanjem koje se može postaviti za svakog pojedinog ispitanika. Je li iznad prosjeka u obje varijable, ispod prosjeka u obje, ili iznad u jednoj i ispod u drugoj. U simuliranoj anketi `anketa_mreze`, koja ima 300 ispitanika i nije mjerenje nego nastavni skup proizveden kodom, na istu stranu prosjeka u dobi i u dnevnim minutama odstupa 27 % ispitanika. Kada varijable ne bi bile povezane, taj bi udio bio blizu polovine, jer bi predznaci dvaju odstupanja bili neovisni. Udio znatno ispod polovine znak je da odstupanja redovito idu na suprotne strane, dakle da je veza negativna. Sam udio ipak ne kaže koliko je veza jaka, jer ne razlikuje jedva prijedeni prosjek od krajnje vrijednosti.

Odgovor na to daje umnožak. Za svakog se ispitanika pomnože njegova odstupanja od dviju sredina, čime se veliko slaganje nagrađuje jače od malog, a neslaganje ulazi s negativnim predznakom. Prosjek tih umnožaka po cijelom uzorku mjera je zajedničkog kretanja.

Definicija 14. Kovarijanca je prosjek umnožaka odstupanja dviju varijabli od njihovih sredina, uz djelitelj umanjen za jedan, pa je po-

zitivna kada opažanja odstupaju na istu stranu i negativna kada odstupaju na suprotne.

Zapisano simbolima, gdje x_i i y_i označavaju vrijednosti izmjerene kod istog opažanja, $\bar{x}$ i $\bar{y}$ njihove sredine, a n broj opažanja, kovarijanca glasi

$$\text{Cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

Djelitelj $n-1$ isti je onaj iz poglavlja o sažimanju podataka, a formula je poopćenje varijance, jer varijanca nastaje kada se ista varijabla stavi na oba mjesta.

Jedna osobina kovarijancu čini neupotrebljivom za izvještavanje. Ona nosi jedinice obiju varijabli pomnožene jedna s drugom. Kovarijanca dobi i dnevnih minuta u anketi iznosi -293,1, a kovarijanca dobi i istog vremena izraženog u satima -4,9. Odnos se nije promijenio, promijenila se jedinica, a broj se promijenio šezdeset puta. Vrijednost kovarijance zato ne govori ništa dok se ne zna u čemu je mjereno, i nijedan se par varijabli po njoj ne može usporediti s drugim parom.

Zajedničko kretanje bez jedinica

Rješenje je već napisano u poglavlju o sažimanju podataka. Standardizirana vrijednost pretvara opažanje u broj standardnih devijacija od sredine i time odbacuje jedinicu. Ako se prije množenja obje varijable standardiziraju, umnožak više ne ovisi o tome mjeri li se vrijeme u minutama ili satima.

Definicija 15. Pearsonova korelacija je prosjek umnožaka standardiziranih vrijednosti dviju varijabli, pa mjeri smjer i jačinu njihove linearne veze na ljestvici od -1 do $+1$, neovisno o mjernim jedinicama.

Uzoračku korelaciju označavamo slovom r , a odgovarajuću vrijednost cijele populacije grčkim slovom ρ , po istom pravilu po kojem su u

poglavlju o sažimanju podataka uzorak nosio latinicu, a populacija grčka slova. Definicija se zapisuje kao

$$r = \frac{1}{n-1} \sum_{i=1}^n z_{x_i} z_{y_i} = \frac{\text{Cov}(x, y)}{s_x s_y},$$

gdje su z_{x_i} i z_{y_i} standardizirane vrijednosti dviju varijabli kod istog opažanja, a s_x i s_y njihove standardne devijacije. Dva zapisa daju isti broj, jer dijeljenje kovarijance standardnim devijacijama i standardiziranje prije množenja isti su postupak izveden različitim redom.

Da to nije samo tvrdnja, provjerava se izravno. Prosjek umnožaka standardiziranih vrijednosti dobi i dnevnih minuta u anketi iznosi -0,559, a ugrađeni izračun korelacije daje -0,559. Ista korelacija izračunata na satima umjesto minuta iznosi -0,559, dakle nepromijenjeno, dok se kovarijanca u istoj zamjeni pomaknula šezdeset puta. Standardizacija je učinila upravo ono zbog čega je uvedena.

Krajnje vrijednosti ljestvice imaju geometrijsko značenje. Vrijednost +1 znači da sve točke leže na jednom uzlaznom pravcu, -1 da leže na silaznom, a nula da linearne veze nema. Sve između mjeri koliko se oblak približio pravcu, i to je cijeli sadržaj koeficijenta. Ono što on ne mjeri jest nagib tog pravca, pa korelacija od -0,56 ne govori za koliko se minuta mijenja vrijeme korištenja po godini dobi. Taj broj daje tek regresija, i to je razlika koju poglavlje o regresiji razrađuje.

Koliko znači jedan koeficijent

Nakon izračuna redovito slijedi pitanje je li dobiveni broj velik. Cohen je za društvene znanosti ponudio orijentacijske vrijednosti, po kojima se korelacija oko 0,10 opisuje kao mala, oko 0,30 kao srednja, a oko 0,50 kao velika (Cohen 1988.). Te se vrijednosti citiraju toliko često da su stekle status ljestvice za očitavanje, što nisu.

Uvjet stoji već kod izvora. Vrijednosti su ponudene za polja u kojima ne postoji bolja osnova za prosudbu i izričito ustupaju mjesto

poznavanju područja (Cohen 1988.). U predviđanju pojedinačnog ponašanja korelacija od 0,30 ozbiljan je nalaz, a u provjeri pouzdanosti mjernog instrumenta 0,50 je razlog za odbacivanje instrumenta. Isti broj u dvama kontekstima nosi suprotne prosudbe, pa se veličina ne očitava iz tablice nego iz literature koja mjeri isto što i mi.

Jedna preinaka koeficijenta ipak pomaže prosudbi, jer ga stavlja na ljestvicu koja se lakše tumači. Kvadrirana korelacija kaže koliki je udio varijance jedne varijable zajednički s drugom, pa korelacija od -0,56 znači da dvije varijable dijele 31 % varijance, dok preostalih 69 % ostaje neobjašnjeno. Kvadriranje je pritom nemilosrdno prema srednjim vrijednostima, jer korelacija od 0,30, koju bi mnogi opisali kao osrednju, dijeli devet posto varijance. Poglavlje o regresiji istu veličinu koristi kao mjeru prilagodbe modela.

Druga polovina odgovora nema veze s veličinom. Koeficijent izračunat na uzorku procjena je, pa nosi vlastitu nesigurnost, koja opada s brojem opažanja. Korelacija od 0,40 na trideset ispitanika i ista korelacija na tri tisuće ispitanika dva su vrlo različita nalaza, iako je broj jednak. Dio knjige o uzorkovanju i procjeni tu nesigurnost izračunava, a do tada vrijedi da se korelacija bez broja opažanja uz sebe ne može prosuditi.

Kada se varijabli nakupi, korelacije svih parova slažu se u matricu, koja je simetrična i na dijagonali nosi jedinice, jer je svaka varijabla savršeno povezana sama sa sobom.

Tablica 1: Korelacije triju brojčanih varijabli simulirane ankete. Izrada autora.

	dob	minute_dnevno	povjerenje
dob	1,00	-0,56	-0,33
minute_dnevno	-0,56	1,00	0,18
povjerenje	-0,33	0,18	1,00


Matrica je ekonomična i opasna u istoj mjeri. Tri varijable daju tri para, deset varijabli daje četrdeset pet, a pregled u kojem se traži najveći broj prestaje biti provjera hipoteze i postaje njezino izmišljanje.

Poglavlje o krizi i obnovi pokazuje što se s takvim pretraživanjem dogodi kada mu se doda testiranje. Ovdje je dovoljno pravilo da matrica služi za pregled, a da svaki par koji ulazi u zaključak dobije vlastiti raspršeni dijagram.

Rangovi umjesto vrijednosti

Pearsonova korelacija mjeri koliko se oblak približio pravcu, pa je zakrivljena veza za nju djelomično nevidljiva. Odnos u kojem jedna varijabla stalno raste s drugom, ali sve sporije, postoji i uredan je, a mjeren pravcem izgleda slabije nego što jest.

Za takve slučajeve podaci se prije računanja zamjenjuju rangovima. Najmanja vrijednost dobiva prvi rang, sljedeća drugi, i tako redom, nakon čega se na rangove primijeni isti Pearsonov izračun. Rangiranje čuva poredak i odbacuje razmake, pa rezultat mjeri je li kretanje dosljedno u jednom smjeru bez zahtjeva da bude pravocrtno. Tako dobivena **Spearmanova korelacija**, koja se označava sa r_s , mjeri monotonu vezu.



Slika 1: Dob i dnevno vrijeme korištenja u simuliranoj anketi. Veza je dosljedno silazna, ali nije pravocrtna, pa je mjera koja traži pravac strože kažnjava.

Oblak pada strmo u mlađim godinama i izravna se poslije, što je oblik koji pravac ne može pratiti. Pearsonova korelacija dobi i dnevnih minuta iznosi -0,56, a Spearmanova -0,68. Razlika u istom smjeru redovit je znak da je veza monotona, ali zakrivljena. Potvrda dolazi odmah, jer korelacija dobi s logaritmom minuta, koja zakrivljenost uklanja, iznosi -0,68 i približila se Spearmanovoj vrijednosti.

Iz toga slijedi jednostavna dijagnostika. Kada se dva koeficijenta slažu, veza je približno pravocrtna i Pearsonov je izbor u redu. Kada se razilaze, zakrivljenost je vjerojatna i graf će je pokazati. Spearmanova mjera uz to slabije reagira na pojedinačno krajnje opažanje, jer krajnja vrijednost dobiva samo sljedeći rang umjesto vlastite udaljenosti, pa se koristi i kada podaci sadrže malo opažanja koja izrazito odudaraju.

Nijedna od dviju mjera ne vidi vezu koja nije monotona. Kada je zadovoljstvo niže i pri vrlo malom i pri vrlo velikom opterećenju, oba koeficijenta mogu ispasti blizu nule, jer se uzlazni i silazni dio međusobno ponište. To nije znak da odnosa nema nego znak da nijedan jedan broj taj odnos ne može nositi.

Kada koeficijent zavarava

Prvi način na koji koeficijent zavara nije pogreška računanja nego izbor onoga tko je birao uzorak. Korelacija mjeri koliko varijacije jedne varijable prati varijaciju druge, pa uklanjanje varijacije uklanja i mjeru.

Definicija 16. Ograničenje raspona (*range restriction*) je smanjenje izmjerene povezanosti do kojeg dolazi kada uzorak pokriva samo dio raspona jedne varijable, pa unutar njega ostaje premalo varijacije da bi se odnos vidio.

Anketa to pokazuje na sebi. U cijelom uzorku korelacija dobi i dnevnih minuta iznosi -0,56. Ograničimo li se na najmlađu dobnu skupinu, u kojoj je 90 ispitanika unutar raspona od sedam godina, ista korelacija iznosi 0,18, dakle slabo i k tome u suprotnom smjeru. Vrijedi znati odakle taj drugi broj dolazi. Generator koji je skup proizveo razlikuje

dobne skupine, a unutar skupine svim ispitanicima dodjeljuje istu raspodjelu, pa je prava vrijednost unutar te skupine nula. Dobivenih 0,18 cijelim je iznosom ono što promjenjivost uzorka proizvede na 90 opažanja.


Veza između dobi i vremena korištenja time nije opovrgnuta. Nestao je raspon dobi unutar kojeg se mogla očitati, i to je razlog zbog kojeg se studija provedena na studentima jedne generacije ne može uzeti kao dokaz da dob nije važna. Isto vrijedi za svaku selekciju koja prethodi mjerenju, dakle za uzorke sastavljene od primljenih kandidata, zaposlenih radnika ili preživjelih poduzeća. Poglavlje o mjerenju i dizajnu isti postupak opisuje kao pitanje o tome tko je ušao u skup.

Isti izračun pokazao je i drugi način na koji koeficijent zavara, jer je broj različit od nule ovdje nastao iz uzorka u kojem veze nema. Što je opažanja manje, to je takav ishod vjerojatniji, pa koeficijent bez broja opažanja uz sebe ne nosi dovoljno da bi se prosudio. Treći je način osjetljivost na pojedinačno opažanje, jer jedna vrijednost daleko od ostalih pomiče oba prosjeka i obje standardne devijacije, a s njima i sam koeficijent. Sva tri načina nose isti simptom, dakle broj koji izgleda uvjerljivo, i sva tri otkriva isti postupak, dakle pogled na raspršeni dijagram prije nego što se broj negdje zapiše.

Kada se predznak preokrene

Najteži slučaj nije oslabljen nego preokrenut koeficijent. On nastaje kada uzorak sadrži podskupine koje se razlikuju po razini obiju varijabli, a promatraju se zbirno.

Zamislimo tri odjela jedne organizacije, koji se razlikuju po tome koliko su njihovi zaposlenici iskusni i koliko su zadovoljni poslom. Podaci koji slijede konstruirani su za ovu svrhu i nisu mjerenje. Unutar svakog odjela zadovoljstvo blago opada s godinama staža, dok su odjeli s iskusnijim zaposlenicima ujedno oni s višim zadovoljstvom.



Slika 2: Konstruirani podaci u kojima zbirna veza raste, a veza unutar svakog odjela pada. Isti su podaci prikazani jednom bez oznake odjela i jednom s njom.

Zbirna korelacija staža i zadovoljstva iznosi 0,76, dakle jasno pozitivna. Unutar odjela ona iznosi -0,77, -0,66 i -0,71, dakle negativna u sva tri. Nijedan broj nije pogrešno izračunat i nijedan ne proturječi drugome, jer odgovaraju na različita pitanja. Zbirni koeficijent mjeri i razliku među odjelima i odnos unutar njih odjednom, a razlika među odjelima ovdje je toliko veća da određuje predznak.

Ista je pojava koju je Simpson opisao na tablicama frekvencija (Simpson 1951.), a poglavlje o statističkom mišljenju pokazalo je na stvarnom slučaju prijamnog postupka u Berkeleyju, gdje se zbirna razlika u stopama prijma raspala čim su odjeli razdvojeni (Bickel i sur. 1975.). Vizualni oblik iste pojave nose mala višestruka polja iz poglavlja o vizualizaciji. Zajedničko im je da razlika među skupinama i odnos unutar skupina nisu ista veličina, i da ih zbirni broj spaja u jedan.

Društvene znanosti taj problem susreću u obliku koji nema ni jednu podskupinu nego samo pogrešnu jedinicu analize. Korelacije se često računaju na zemljama, županijama ili školama, dakle na prosjecima, jer su podaci u tom obliku dostupni. Prosjeci su glatkiji od pojedinaca, pa su korelacije među njima redovito znatno jače, a njihov smjer ne mora vrijediti unutar tih jedinica. Zaključak o pojedincu izveden iz veze među skupinama naziva se **ekološkom pogreškom** (*ecological fallacy*), i ne otklanja se boljim izračunom nego samo podacima o


pojedincima. Tvrdnja izračunata na razini zemalja legitiman je nalaz o zemljama, i ništa više od toga.

Odatle slijedi ono što se o uzroku smije reći. Varijabla koja je povezana i s pretpostavljenim uzrokom i s ishodom prisvaja dio veze koja se pripisuje uzroku, i to je konfundirajuća varijabla iz poglavlja o mjerenju i dizajnu. Odjel je ovdje takva varijabla, jer određuje i staž i zadovoljstvo. Kada je poznata i izmjerena, razdvajanje je popravljiva. Kada nije izmjerena, ona i dalje djeluje, a koeficijent o njoj ne javlja ništa.

Zbog toga povezanost sama ne određuje uzrok. Veza između dviju varijabli podnosi četiri objašnjenja, jer prva može djelovati na drugu, druga na prvu, obje može oblikovati treća, ili je obrazac nastao pukom promjenjivošću uzorka. Koeficijent je jednak u sva četiri slučaja i ne razlikuje ih. Razlikuje ih dizajn istraživanja, o kojem je poglavlje o mjerenju i dizajnu već govorilo, pa je smjer tvrdnje koju o povezanosti smijemo iznijeti određen prije nego što je izračunata.

Interakcija — Pogodi korelaciju

Igra prikazuje četiri raspršena oblaka bez koeficijenta i traži procjenu smjera i jačine. Rezultat se mijenja sa svakom procjenom, pa se vidljivi oblik može izravno usporediti s veličinom Pearsonove korelacije.



Slika 3: Četiri simulirana oblaka i njihove Pearsonove korelacije. Statični prikaz otkriva vrijednosti koje digitalna igra skriva.

Što isprobati.

1. Procijenite samo znak svake povezanosti i provjerite jesu li kli-
zači na pravoj strani nule.
2. Usporedite oblake A i D te procijenite koji je odnos bliže savr-
šenoj povezanosti.
3. Fino namjestite procjene za slabije oblake B i C bez mijenjanja
prvih dviju.
4. Pokušajte ostvariti četiri pogotka, zatim opišite koji je oblak
bilo najteže procijeniti.

STATISTIKA U DIVLJINI

Dinosaur s urednim sažetkom. Anscombeove je skupove trebalo sastaviti ručno, pa je dugo ostajalo otvoreno koliko je takvih slučajeva uopće moguće. Matejka i Fitzmaurice odgovorili su postupkom koji polazi od zadanog skupa i sitnim pomacima točaka mijenja njegov oblik, a pritom sredine, standardne devijacije i korelaciju drži nepromijenjenima do druge decimalne (Matejka i Fitzmaurice 2017.). Iz istog sažetka tako su izveli niz oblika, među njima zvijezde, križeve i obris dinosaura. Dohvat nalaza vrijedi izmjeriti. Rad ne pokazuje da je korelacija nestabilna niti da je pogrešno izračunata, jer je u svim tim skupovima ista i točna. Ono što pokazuje jest da sažetak od nekoliko brojeva ne određuje skup podataka, pa put od podataka do sažetka ide samo u jednom smjeru. Iz toga slijedi obveza koja je skromnija od pouke koja se uz rad obično navodi, dakle da se uz koeficijent prikaže i oblik iz kojeg je nastao, a ne da se koeficijent napusti.

PITAJTE MODEL

Asistent može izračunati Pearsonovu i Spearmanovu korelaciju i opisati graf. Treba mu zatražiti provjeru linearnosti, krajnjih vrijednosti, podskupina i ograničenja raspona. Nakon odgovora valja provjeriti jesu li redovi u dvjema varijablama ispravno upareni i je li iz povezanosti izveden nedopušten uzrok.

Tri promašaja ponavljaju se dovoljno često da ih vrijedi tražiti unaprijed. Asistent rado veličinu koeficijenta očitava s Cohenove ljestvice bez uvjeta koji uz nju ide (Cohen 1988.). Rado navodi korelaciju bez broja opažanja, pa se nesigurnost procjene ne može prosuditi. I rado prelazi s opisa veze na jezik učinka, u kojem jedna varijabla „dovodi do” druge, iako je izračunao samo zajedničko kretanje.

Usporedi Pearsonovu i Spearmanovu korelaciju, opiši oblik raspršenog dijagrama i provjeri utjecaj krajnjih opažanja. Zaključak ograniči na povezanost koju dizajn podupire.

NADITE GREŠKU

Na pitanje o odnosu dobi i vremena korištenja asistent je napisao ovu analizu.

```
anketa_mreze |>
  filter(dobna_skupina == "18 do 24") |>
  summarise(
    r = cor(dob, minute_dnevno),
    n = n()
  )
```

Uz ispis je dodao obrazloženje. Korelacija u toj skupini iznosi 0,18 uz 90 ispitanika, dakle slaba je i pozitivna. Budući da je skupina dobno homogena i bez krajnjih vrijednosti, procjena je čista od miješanja naraštaja, pa zaključuje da dob i vrijeme korištenja praktički nisu povezani.

Razrađeni primjer

Zadatak je ispravno izvijestiti o povezanosti dviju varijabli iz simulirane ankete, dakle dobi i dnevnog vremena korištenja društvenih mreža. Postupak ima tri koraka i svaki od njih odgovara jednoj provjeri iz ovog poglavlja. Najprije se pogleda oblik, zatim se izračunaju obje mjere, i tek se onda piše rečenica.

```
sazetak <- anketa_mreze |>
  summarise(
    n = n(),
    pearson = cor(dob, minute_dnevno),
    spearman = cor(dob, minute_dnevno, method = "spearman")
  )

sazetak
```

```
# A tibble: 1 x 3
      n pearson spearman
  <int>   <dbl>   <dbl>
1   300 -0.559   -0.680
```

Poziv `summarise` i njegov niz glagola dolaze iz poglavlja o sažimanju podataka, a funkcija `cor` jedina je novost i računa korelaciju dvaju stupaca, po zadanom Pearsonovu. Argument `method` mijenja mjeru u Spearmanovu. Ovo poglavlje ne uvodi nijedan novi obrazac čitanja koda, što je i njegova svrha, jer se ista tri elementa pojavljuju od poglavlja o sažimanju nadalje.

Raspršeni dijagram iz odjeljka o rangovima pokazao je da veza pada strmo u mlađim godinama i izravna se poslije. Uz taj oblik dva koeficijenta imaju smisla zajedno, jer Pearsonova vrijednost od -0,56 mjeri koliko je oblak blizu pravca, a Spearmanova od -0,68 koliko je kretanje dosljedno silazno. Razlika među njima nije neslaganje nego opis zakrivljenosti.

Iz toga slijedi rečenica koju je dopušteno napisati. U ovom simuliranom uzorku od 300 ispitanika dob i dnevno vrijeme korištenja povezani su negativno i dosljedno, uz Spearmanovu korelaciju od -0,68, dok je veza zakrivljena, pa je Pearsonova vrijednost od -0,56 niža. Rečenica navodi mjeru, njezinu veličinu, broj opažanja i oblik odnosa, a ne navodi uzrok, jer podaci dolaze iz jednokratnog mjerenja bez ikakve intervencije.

Sažetak

Kovarijanca mjeri zajedničko odstupanje od sredina, a korelacija je ista mjera očišćena od jedinica, pa se kreće između minus jedan i plus jedan i mjeri koliko je oblak blizu pravca. Spearmanova inačica radi s rangovima, pa mjeri dosljednost smjera bez zahtjeva da veza bude pravocrtna, a njihovo je razilaženje najjeftinija dijagnostika zakrivljenosti u knjizi. Jedan broj ne može nositi ni oblik odnosa, ni širinu raspona iz kojeg je izračunat, ni podskupine koje ga mogu preokrenuti,

i sve troje otkriva prikaz iz prethodnog poglavlja. Iz povezanosti se ne izvodi uzrok, jer četiri različita objašnjenja proizvode isti koeficijent, a razlikuje ih dizajn a ne izračun. Sve dosad izračunato odnosilo se na uzorak pred nama, pa sljedeći dio knjige uvodi vjerojatnost i pita koliko se od takvog obrasca može očekivati i kad veze nema.

Pojmovi

kovarijanca (*covariance*), Pearsonova korelacija (*Pearson correlation*), Spearmanova korelacija (*Spearman correlation*), monotona veza (*monotonic relationship*), linearnost (*linearity*), matrica korelacija (*correlation matrix*), ograničenje raspona (*range restriction*), utjecajno opažanje (*influential observation*), konfundirajuća varijabla (*confounder*), ekološka pogreška (*ecological fallacy*)

Zadaci

Konceptualni

Nacrtajte dva različita odnosa koja mogu imati sličnu Pearsonovu korelaciju, i uz svaki napišite što bi izvještaj koji navodi samo koeficijent propustio. Predajte skicu i objašnjenje.

Računski

Upotrijebite tablicu korelacija koju poglavlje ispisuje za tri varijable simulirane ankete. Za svaki od triju parova zapišite smjer veze i procijenite, prema onome što ste vidjeli na raspršenom dijagramu dobi i minuta, bi li se Spearmanova vrijednost razlikovala od Pearsonove i u kojem smjeru. Zatim upotrijebite interakciju poglavlja i za svaki od četiriju oblaka zabilježite koliko je vaša procjena promašila. Predajte tablicu sa sedam redaka i jednom rečenicom obrazloženja u svakom. Postupak za ponavljanje izračuna nad cijelim skupom nalazi se u praktikumu.

Kritički

Pronađite objavljenu tvrdnju u kojoj se iz povezanosti dviju društvenih pojava izvodi preporuka za djelovanje. Odredite koje od četiriju objašnjenja veze tekst pretpostavlja, koju bi treću varijablu trebalo isključiti i kakav bi dizajn to mogao učiniti. Predajte odlomak s presudom i s uvjetom pod kojim bi preporuka bila opravdana.

Revizija modela

Ocijenite analizu iz okvira o pogrešci. Imenujte što je u pozivu ispravno izvedeno, redak koda koji proizvodi pogrešan zaključak, mehanizam zbog kojeg koeficijent pada, i napišite ispravljenu rečenicu izvještaja.

DIO III: OD UZORKA DO POPULACIJE

Vjerojatnost koliko treba

Vjerojatnost opisuje obrasce ponovljene slučajnosti

Vrijeme čitanja	Widget	Podaci	Preduvjet
24 min	Simulator novčića i A/B kampanje	simulirana populacija	pogl. 4

VINJETA

Igrači, treneri i navijači godinama su tvrdili isto. Košarkaš koji je pogodio nekoliko puta zaredom u tom je trenutku „vruć”, pa mu sljedeći pokušaj ima veće izgleda nego inače. Gilovich, Vallone i Tversky uzeli su tu tvrdnju ozbiljno i provedli je kroz zapise stvarnih utakmica, a zaključili su da je riječ o krivom čitanju slučajnih nizova (Gilovich i sur. 1985.).

Nalaz nije rekao da se ljudi zanose. Rekao je nešto neugodnije, da niz koji izgleda kao obrazac slučajnost proizvodi sama od sebe, pa oko njega nema što objašnjavati. Trideset godina kasnije pokazalo se da ni sam postupak mjerenja nije bio bezazlen, o čemu ovo poglavlje govori pred kraj.

Kako razlikovati obrazac od onoga što slučajnost proizvodi bez ijednog razloga?


Što vjerojatnost broji

Pošten novčić bacimo dvadeset puta i prebrojimo glave. Sljedećih dvadeset puta broj će gotovo sigurno biti drugačiji, a nakon nekoliko takvih serija postaje jasno da jedan rezultat nije obećanje nego uzorak iz nečega većega. To veće opisuje vjerojatnost.

Definicija 17. Vjerojatnost je broj između nule i jedinice koji događaju pridružuje udio ishoda u kojima se on pojavljuje, pri čemu nula znači da se događaj ne može dogoditi, a jedinica da se mora dogoditi.

Taj se broj čita na dva načina i oba su u knjizi u upotrebi. U postupku koji se može ponoviti mnogo puta vjerojatnost je dugoročna učestalost, dakle udio ponavljanja u kojima se događaj pojavi. U situaciji koja se neće ponoviti isti broj izražava stupanj uvjerenja pod jasno navedenim informacijama, i tada je važno reći na temelju čega je postavljen. Vjerojatnost da nogometna reprezentacija osvoji sljedeće prvenstvo nije udio ničega, jer se to prvenstvo igra jednom.

Prvo čitanje ima svojstvo koje se može vidjeti. Kratki nizovi kolebaju se snažno, dugi se smiruju, i to bez ikakve sile koja bi ih smirivala.



Slika 1: Kumulativni udio glava u trima neovisnim nizovima bacanja poštenog novčića. Vodoravna crta označuje vrijednost pola.

Nakon dvadeset bacanja tri se niza razilaze od 0,25 do 0,65, dakle dovoljno da bi netko od njih zaključio kako novčić nije pošten. Nakon dvije tisuće bacanja svi leže između 0,498 i 0,502. Ta pravilnost ima ime i zove se zakon velikih brojeva, a kaže da se relativna učestalost s brojem ponavljanja primiče vjerojatnosti.

Ono što zakon ne kaže važnije je od onoga što kaže. Nijedno pojedinačno bacanje ne zna što se prije dogodilo i ništa ne nadoknađuje. Udio se ne primiče polovici zato što se višak glava kompenzira viškom pisama, nego zato što svaki novi rezultat ulazi u sve veći nazivnik i time sve manje pomiče omjer. Rani je višak i dalje tu, samo je u dvije tisuće bacanja prestao biti vidljiv.

Očekivanje da se ravnoteža mora vratiti dovoljno je rašireno da ima vlastito ime i zove se kockarska zabluda. Igrač koji je četiri puta zaredom izgubio drži da mu je peti put dužan, a analitičar koji je imao tri slaba tjedna očekuje jak. Ista pogreška u obrnutom smjeru stoji iza vjerovanja iz vinjete, gdje niz pogodaka ne najavljuje pismo nego novi pogodak. Obje verzije pretpostavljaju da nizovi imaju pamćenje,

a ono što stvarno postoji jest raspon ishoda koji slučajnost proizvodi i koji je u kratkim nizovima mnogo širi nego što se očekuje.

Tri pravila i jedna pretpostavka

Računanje s vjerojatnostima oslanja se na tri pravila koja se pamte u jednom odlomku. Vjerojatnost da se događaj ne dogodi jednaka je jedinici umanjenoj za vjerojatnost da se dogodi, što je često najbrži put do odgovora. Vjerojatnosti dvaju ishoda koji se ne mogu dogoditi istovremeno zbrajaju se, a ako se mogu preklopiti, od zbroja treba oduzeti preklap kako ne bi bio brojen dvaput. Za vjerojatnost da se dva događaja dogode zajedno pravilo množenja vrijedi samo uz dodatnu pretpostavku.

Preklap iz drugog pravila lako se previdi, a razlika koju čini vidljiva je na podacima. U populaciji na kojoj poglavlje radi portal bira 30,2 % ljudi, a osoba do dvadeset devete godine ima 24,7 %. Zbroj ta dva udjela iznosi 54,9 %, dok je stvarni udio onih koji su mladi ili biraju portal 47,0 %. Razlika je točno onih 7,9 % koji su oboje i koje je zbrajanje izbrojilo dvaput.

Treće pravilo nosi pretpostavku i jedino je od navedenih sadržajno.

Definicija 18. Neovisnost dvaju događaja znači da saznanje o tome je li se jedan dogodio ne mijenja vjerojatnost drugoga.

Poglavlje radi na simuliranoj populaciji od pedeset tisuća odraslih osoba, istoj koju koriste poglavlja o uzorkovanju i procjeni, i ta je populacija u cijelosti poznata. U njoj društvene mreže kao primarni izvor vijesti bira 26,8 % ljudi, a osoba do dvadeset devete godine ima 24,7 %. Kad bi te dvije okolnosti bile neovisne, pravilo množenja dalo bi 6,6 % ljudi koji su i mladi i biraju mreže. Stvarni udio iznosi 11,3 %, dakle gotovo dvostruko više.

Račun je ispravan, a pogrešna je pretpostavka koju je koristio. Neovisnost je tvrdnja o svijetu i provjerava se u podacima, a ne bira zato što pojednostavljuje množenje. Kad ne vrijedi, potreban je pojam koji razlikuje ukupnu vjerojatnost od vjerojatnosti unutar neke skupine.

Definicija 19. Uvjetna vjerojatnost je vjerojatnost događaja izračunata unutar skupine u kojoj je neki drugi događaj već nastupio.

Među osobama do dvadeset devete godine društvene mreže bira 45,9 %, a među starijima 20,5 %. Televizija ide obrnuto, s 21,7 % u cijeloj populaciji i 41,2 % među osobama od šezdeset godina naviše. Razlika između ukupne i uvjetne vrijednosti upravo je mjera ovisnosti, i kad je nema, dva se broja poklapaju.

Isto se pitanje u svakodnevnim izvještajima postavlja stalno, iako se rijetko tako zove. Udio konverzija među posjetiteljima koji su kliknuli na oglas i udio otvaranja među poslanim porukama uvjetne su vjerojatnosti, i svaka od njih vrijedi samo za skupinu u čijem je nazivniku. Analiza po segmentima nije ništa drugo nego niz uvjetnih vjerojatnosti, pa se čita s istim oprezom prema nazivniku koji je poglavlje o kategoričkim podacima kasnije stavlja u središte.

Ponovljeni pokušaji s dva ishoda

Mnoga pitanja u društvenim istraživanjima imaju isti oblik. Fiksna je broj pokušaja, svaki završava na jedan od dva načina, i zanima nas koliko ih je završilo na prvi. Glasanje, klik, odgovor na poziv i otvaranje poruke stanu u taj kalup.

Definicija 20. Binomna raspodjela opisuje broj uspjeha u zadanom broju pokušaja kad svaki pokušaj ima samo dva ishoda, jednaku vjerojatnost uspjeha i nikakvu vezu s ostalim pokušajima.

Uz dvadeset objava i vjerojatnost od dva posto da pojedina postane viralna, raspodjela kaže da nijedna neće biti viralna u 66,8 % mjeseci. To nije prognoza za jedan mjesec nego opis onoga što niz mjeseci proizvodi, i upravo takav opis nedostaje kad se jedan loš mjesec tumači kao promjena u kvaliteti sadržaja.

Tri uvjeta iz definicije rijetko vrijede svi odjednom, i njihovo je propadanje poučnije od samog računa. Vjerojatnost uspjeha nije jednaka kroz pokušaje ako se objave razlikuju po doseg, a pokušaji nisu


neovisni ako jedno dijeljenje poveća vidljivost i time izazove sljedeće. Viralnost je ime za točno to kršenje neovisnosti, pa je binomna raspodjela za nju loš model, koliko god račun bio uredan. Isto vrijedi za anketu u kojoj se ispituju dvije osobe iz istog kućanstva.

Kad uvjeti drže, raspodjela daje dvije korisne stvari odjednom. Očekivani broj uspjeha jednak je umnošku broja pokušaja i vjerojatnosti uspjeha, pa se lako pamti i lako provjerava. Raspršenost oko tog broja raste sporije od samog broja pokušaja, što znači da udio uspjeha postaje sve stabilniji što je kampanja veća, premda apsolutni broj uspjeha varira sve više. Ta dva smjera stalno se brkaju u izvještajima, u kojima veći apsolutni raspon prolazi kao znak nestabilnosti, iako je udio zapravo precizniji nego prije.

Model zato nije opis svijeta nego kontrolirana slika jednog dijela procesa. Ono što ga čini korisnim jest da se u njemu točno zna što proizvodi slučajnost, pa opaženi rezultat ima s čime biti uspoređen.

Interakcija — Simulator novčića i A/B kampanje

Sljedeći prikaz drži stvarnu vjerojatnost uspjeha nepromijenjenom i mijenja samo duljinu niza. Vidljivo postaje ono zbog čega se kratki nizovi tako lako pogrešno čitaju, a to je da raspon njihovih ishoda ostaje širok i onda kad se proces uopće ne mijenja.



Slika 2: Simulirane stope uspjeha pri dvjema duljinama niza i istoj stvarnoj vjerojatnosti. Dulji niz daje užu raspodjelu.

Što isprobati.

1. Postavite pošten novčić i dvadeset pokušaja pa opišite raspon simuliranih udjela glava.
2. Povećajte niz na dvjesto pokušaja bez promjene vjerojatnosti.
3. Prebacite scenarij na A/B kampanju i postavite stvarnu stopu uspjeha na trideset posto.
4. Usporedite jednu krajnju simuliranu stopu s cijelom raspodjelom ponovljenih kampanja.

Posljednji korak pokazuje odnos koji stoji iza svega u ovom dijelu knjige. Jedna kampanja ne može biti neobična sama po sebi, jer se neobičnost mjeri prema rasponu ishoda koji isti postupak proizvodi.

Kad je taj raspon širok, krajnji rezultat nije dokaz ni o čemu osim o širini raspona.

Zvonasta krivulja i njezino područje


Raspodjela mnogih ponavljanja iz widgeta ima prepoznatljiv oblik. Simetrična je, najgušća je u sredini, i prema objema stranama se proužduje sve brže. Taj oblik u statistici ima posebno mjesto, i ne zato što ga priroda posebno voli.

Definicija 21. Normalna raspodjela je simetrična zvonasta raspodjela koju u cijelosti određuju njezino središte i njezina standardna devijacija.

Razlog njezine povlaštenosti nije u tome što je česta u prirodi, nego u tome što nastaje kad se mnogo malih i međusobno neovisnih doprinosa zbroji. Visina, mjerna pogreška i rezultat na testu takvi su zbrojevi, a to je i svaki prosjek. Zbog toga se ista krivulja pojavljuje i tamo gdje pojedinačna opažanja nisu ni blizu zvonastog oblika, pod uvjetom da ih se dovoljno zbroji. Widget je tu tvrdnju već pokazao, jer je raspodjela stopa uspjeha zvonasta iako pojedini pokušaj ima samo dva ishoda. Poglavlje o uzorkovanju od te činjenice gradi cijeli svoj argument.

Dva parametra znače da je oblik uvijek isti, a mijenja se samo gdje leži i koliko je širok. Iz toga slijedi svojstvo korisno za brzu orijentaciju. Unutar jedne standardne devijacije od sredine leži oko 68 % vrijednosti, unutar dvije oko 95 %, a unutar tri oko 99,7 %.

Umjesto da se to pravilo primi na vjeru, izmjerimo ga na dvjema varijablama iste poznate populacije. Prva je dnevno vrijeme provedeno uz medije, druga je iznos koji je osoba spremna platiti za pristup sadržaju.



Slika 3: Dnevne minute uz medije i spremnost na plaćanje u simuliranoj populaciji, s isprekidanim crtama na jednoj i dvjema standardnim devijacijama od sredine.


Za dnevne minute pravilo drži. Unutar jedne standardne devijacije nalazi se 70,1 % populacije, unutar dviju 95,9 %, a unutar triju 99,1 %. Odstupanja od 68, 95 i 99,7 postoje i posljedica su blage nagnutosti udesno, ali su dovoljno mala da orijentacija ostane upotrebljiva.

Za spremnost na plaćanje pravilo se raspada. Unutar jedne standardne devijacije leži 87,7 % populacije umjesto oko 68 %, a unutar triju samo 97,6 % umjesto oko 99,7 %. Razlog je vidljiv na grafu. Ništa ne plaća 76,1 % ljudi, pa se raspodjela nagomilala na nuli i ima dugi rep udesno. Donja granica od jedne standardne devijacije ispod sredine pada u negativne iznose, koje nitko ne može imati, pa ispod nje nema nijedne osobe.

Promjena ljestvice vraća oblik. Ako se pogledaju samo oni koji nešto plaćaju i njihovi se iznosi logaritmira, kako je poglavlje o sažimanju podataka već pokazalo na vremenu korištenja, pravilo se vraća gotovo točno, s 68,0 %, 94,8 % i 99,7 %. Zvonasti oblik dakle nije bio svojstvo tih ljudi nego svojstvo ljestvice na kojoj su mjereni.

Kad podaci ne pristaju krivulji

Postotci unutar područja govore o cjelini i mogu prikriti gdje točno raspodjela odstupa. Prikaz koji odgovara na to pitanje poreda opažene vrijednosti po veličini i svaku od njih stavi nasuprot vrijednosti koja bi na tom mjestu bila očekivana da raspodjela jest normalna. Kad se oblici poklapaju, točke leže na pravcu.



Slika 4: Poredane vrijednosti triju varijabli nasuprot vrijednostima očekivanima pod normalnom raspodjelom. Pravac označuje savršeno poklapanje.

Svaki oblik odstupanja nosi svoju poruku. Dnevne minute prate pravac gotovo cijelim rasponom i odižu se tek na desnom kraju, što je potpis blagog repa prema većim vrijednostima. Spremnost na plaćanje leži vodoravno dok traju nule i zatim naglo skreće uvis, jer normalna raspodjela na tom mjestu očekuje postupan prijelaz, a podaci ga nemaju. Logaritmirani iznosi vraćaju se na pravac.

Prikaz ne izriče presudu o tome je li analiza dopuštena. On pokazuje gdje pretpostavka pristaje, a gdje se lomi, i time razdvaja dvije vrste odstupanja koje se lako izjednače. Blago odizanje repa uz veliki uzorak rijetko išta mijenja, dok raspodjela s gomilom na nuli traži drugu ljestvicu ili drugi model.

Nizovi koje slučajnost proizvodi

Vratimo se pitanju iz vinjete, jer ono ima odgovor koji se može izmjeriti. Postavimo postupak koji sigurno nema nikakvu memoriju, dakle bacanje poštenog novčića, i u svakom nizu izdvojimo one pokušaje koji dolaze neposredno iza tri uzastopna pogotka. Ako su pokušaji neovisni, među izdvojenima bi pogodaka trebalo biti pola.

Tablica 1: Prosječan udio pogodaka na pokušajima koji slijede zadani niz pogodaka, u simulaciji poštenog novčića bez ikakve memorije. Izrada autora.

Duljina niza pokušaja	Nakon jednog pogotka	Nakon tri pogotka
20	0,476	0,356
50	0,491	0,418
100	0,496	0,459

Pola ih nije. U nizu od stotinu pokušaja prosječan udio iza tri pogotka iznosi 0,459, a u nizu od dvadeset pokušaja pada na 0,356. Postupak pritom nema nikakvu memoriju, jer smo ga sami napravili takvim. Odstupanje ne dolazi iz procesa nego iz odabira.

Razlog je u konačnosti niza. Kad iz jednog niza izdvojimo upravo ona mjesta koja dolaze iza tri pogotka, sam uvjet troši pogotke. Niz s malo pogodaka rijetko uopće nudi takvo mjesto, a u nizu koji ga nudi tri su pogotka već potrošena na uvjet, pa ih je za promatrano mjesto ostalo manje nego što ih niz prosječno ima. Prosjek takvih udjela zato leži ispod stvarne vjerojatnosti, i to više što je niz kraći i uvjet dulji. Uz uvjet od samo jednog pogotka u nizu od stotinu pokušaja odstupanje pada na 0,496 i jedva se primjećuje.

Veličina tog odstupanja nije akademska sitnica. U nizu od stotinu pokušaja ono iznosi oko četiri postotna boda, što je istog reda kao razlika koju bi netko tražio da pokaže postojanje forme. Postupak mjerenja time proizvodi pomak u smjeru zaključka koji se donosi.

Pouka nadilazi košarku i nije o tome tko je bio u pravu. Analiza koja iz podataka izdvoji jedinice po nekom svojstvu tih istih podataka

nije više neutralan pogled na njih, jer je odabir dio postupka jednako kao i račun koji slijedi. Jedini pouzdan način da se to provjeri jest pustiti cijeli postupak, s odabirom uključenim, na podatke u kojima se odgovor unaprijed zna. Upravo to knjiga radi otkad je populacija poznata, i to je razlog zbog kojeg simulacija u ovim poglavljima dolazi prije formule.

STATISTIKA U DIVLJINI

Vruća ruka i njezin ispravak. Zaključak da je vjerovanje u vruću ruku krivo čitanje slučajnih nizova ušao je u udžbenike i u popularne prikaze kao gotova činjenica o ljudskoj pameti (Gilovich i sur. 1985.). Miller i Sanjurjo pokazali su poslije da mjera koja se u toj literaturi koristi nosi suptilnu ali znatnu pristranost, da je izvorna studija na nju osjetljiva i da se nakon ispravka dugogodišnji zaključak obrće (Miller i Sanjurjo 2018.).

Ono što se u ovoj epizodi promijenilo nije bio podatak nego postupak njegova čitanja, i to je razlog zbog kojeg okvir stoji u poglavlju o vjerojatnosti. Pristranost koju simulacija u prethodnom odjeljku mjeri ista je ona koja je tridesetak godina ostala neopažena u nizu recenziranih radova. Iz toga ne slijedi da je vruća ruka dokazana, nego da izvorni nalaz nije bio ono za što je uzet, i da tvrdnja o odsutnosti učinka traži jednako pažljivo mjerenje kao tvrdnja o njegovu postojanju.

PITAJTE MODEL

Asistent lako izračuna vjerojatnost pod zadanim modelom i obično točno pogodi funkciju. Provjeravamo ono što ne pogađa pouzdano. Prvo je pretpostavka neovisnosti, koju redovito uzima prešutno, pa množi vjerojatnosti i tamo gdje jedinice dijele kućanstvo, razred ili algoritamski doseg. Drugo je nazivnik, jer ukupnu i uvjetnu vjerojatnost u odgovoru zna zamijeniti. Treće je smjer zaključka, jer vjerojatnost jednog ishoda pod modelom lako predstavi kao vjerojatnost samog modela.

Navedi koje pretpostavke o neovisnosti i jednakoj vjerojatnosti koristiš prije nego što bilo što izračunaš, a zatim isti rezultat dobij i simulacijom pa usporedi dva broja.

NADITE GREŠKU

Na pitanje koliko je vjerojatno da barem jedna od pet objava iste kampanje postane viralna asistent je napisao ovu analizu.

```
p_viral <- 0.02
p_barem_jedna <- 1 - (1 - p_viral)^5
```

Uz ispis je dodao obrazloženje. Vjerojatnost da pojedina objava ne postane viralna iznosi 0,98, vjerojatnost da nijedna od pet ne postane viralna je 0,98 na petu potenciju, a komplement toga daje 9,6 %. Budući da su objave zasebne jedinice iste kampanje, zaključuje da je račun potpun.

Razrađeni primjer

Novi naslov newslettera poslan je na pedeset adresa i otvoren je četrnaest puta. Dosadašnja stopa otvaranja iznosi dvadeset dva posto, pa pitanje glasi je li četrnaest otvaranja dovoljno neobično da bi se o novom naslovu smjelo tvrditi išta. Račun ispod daje istu vjerojatnost na dva načina, prvo iz binomne raspodjele, a zatim brojanjem u dvadeset tisuća simuliranih kampanja.

```
1 - pbinom(13, size = 50, prob = 0.22)
```

```
[1] 0,1941652
```

```
kampanje <- rbinom(20000, size = 50, prob = 0.22)
mean(kampanje >= 14)
```

```
[1] 0,1937
```

Funkcija `pbinom` vraća vjerojatnost da uspjeha bude najviše onoliko koliko je zadano, pa je komplement te vrijednosti pri trinaest upravo vjerojatnost od četrnaest naviše. Funkcija `rbinom` izvlači slučajne ishode iz iste raspodjele, pa udio među njima mora dati približno isti broj.

Oba puta daju istu vrijednost, 19,4 % iz raspodjele i 19,3 % iz simulacije. Podudaranje nije iznenađenje nego provjera, jer je raspodjela sažetak upravo onoga što simulacija radi jedan po jedan slučaj.

Odgovor uredništvu zato nije ohrabrujući. Kampanja koja ne bi bila ni po čemu posebna proizvela bi četrnaest ili više otvaranja u otprilike jednom od pet slučajeva, pa opaženi rezultat nije neobičan i sam ne nosi nikakvu tvrdnju o novom naslovu. Odluka koja iz toga slijedi jest poslati više poruka, a ne donijeti zaključak iz ovih.

Postupak kojim smo došli do te rečenice ima ime i cijelo poglavlje. Pretpostavili smo da se ništa nije promijenilo, izračunali koliko je opaženi ishod vjerojatan pod tom pretpostavkom, i tek onda odlučili što nam taj broj dopušta reći.

Sažetak

Vjerojatnost opisuje što ponovljena slučajnost proizvodi, i ta se tvrdnja u kratkim nizovima ne vidi. Tri pravila računanja su jednostavna, a jedina sadržajna odluka u njima jest pretpostavka neovisnosti, koja se u podacima provjerava i u ovoj populaciji ne vrijedi. Binomna raspodjela pokriva ponovljene pokušaje s dva ishoda dok ta pretpostavka drži, a normalna raspodjela opisuje oblik koji se pojavljuje u zbroju mnogih ishoda, s pravilom područja koje na asimetričnim varijablama otkazuje. Odabir pokušaja koji slijede niz uspjeha pokazao je da i sam

postupak mjerenja može proizvesti pomak veličine koju tražimo. Poglavlje o uzorkovanju tu logiku prenosi na statistike koje se mijenjaju od uzorka do uzorka.

Pojmovi

vjerojatnost (*probability*), zakon velikih brojeva (*law of large numbers*), uvjetna vjerojatnost (*conditional probability*), neovisnost (*independence*), binomna raspodjela (*binomial distribution*), normalna raspodjela (*normal distribution*), QQ prikaz (*Q-Q plot*)

Zadaci

Konceptualni

Objasnite u jednom odlomku zašto niz od pet glava zaredom ne mijenja vjerojatnost sljedećeg bacanja, a niz od pet viralnih objava iste kampanje mijenja procjenu za sljedeću. Imenujte svojstvo po kojem se dva slučaja razlikuju.

Računski

U populaciji iz ovog poglavlja portal kao primarni izvor vijesti bira 30,2 % ljudi. Izračunajte vjerojatnost da nijedna od pet neovisno izabranih osoba ne bira portal, a zatim vjerojatnost da ga bira barem jedna. Zatim u widgetu poglavlja postavite stvarnu vjerojatnost na tu vrijednost i pet pokušaja pa opišite koliko se pojedinačni nizovi razlikuju od izračunatog prosjeka.

Kritički

Prosudite kako je nalaz o vrućoj ruci prešao put od mjerenja do općenite tvrdnje o ljudskoj procjeni slučajnosti, i što se u toj tvrdnji

promijenilo nakon ispravka mjere (Gilovich i sur. 1985.; Miller i Sanjurjo 2018.). Predajte jedan odlomak i imenujte rečenicu koju bi popularni prikaz smio zadržati.

Revizija modela

Ocijenite analizu iz okvira o pogrešci. Imenujte korake računa koji su ispravni, redak koda u kojem stoji pretpostavka koja ne vrijedi, i napišite rečenicu kojom bi izvještaj morao ograničiti svoj zaključak.

Uzorkovanje

Jedan uzorak skriva raspodjelu mogućih rezultata

Vrijeme čitanja	Widget	Podaci	Preduvjet
24 min	CLT stroj	simulirana populacija	pogl. 4, 7

VINJETA

Ismay i Kim zaključivanje predaju tako da čitatelj svaki postupak najprije vidi kao ponovljeno uzorkovanje, a tek ga zatim susretne kao formulu (Ismay i Kim 2019.).

Redosljed nije stvar ukusa. Formula za standardnu pogrešku zapisuje ishod postupka koji se može odvrtjeti pred očima, pa je onaj tko je vidio postupak čita kao sažetak, a onaj tko nije mora je primiti na vjeru.

Problem koji taj postupak rješava svakodnevan je. Istraživački tim treba reći nešto o svim odraslim stanovnicima jednoga grada, a razgovarao je s njih osamsto. Izračunata brojka točna je za tih osamsto ljudi i ni za koga drugoga.

Uzorak je pritom samo jedan ishod. Drugi uzorak iste veličine, izvučen istim postupkom istoga dana, dao bi drugu sredinu i drugi udio.

Kako iz jednoga uzorka doznati koliko bi se rezultat mijenjao da smo uzorkovali ponovno?

Populacija, uzorak i pogreška uzorkovanja

Statistika postoji zbog jednog nesrazmjera. Tvrdnja se odnosi na skup jedinica koji ne možemo izmjeriti u cijelosti, a podatak dolazi iz dijela koji smo uspjeli obuhvatiti. **Populacija** je skup jedinica o kojima želimo zaključivati, **uzorak** je dio jedinica koje smo stvarno promatrali, a razlika među njima nije samo u veličini. Uzorak nastaje postupkom odabira, i taj postupak određuje koje populacijske jedinice uopće imaju priliku postati podatak.

Mjere se razlikuju zajedno s time. Vrijednost izračunata na cijeloj populaciji naziva se **parametar** i piše se grčkim slovom, pa je μ populacijska sredina, a σ populacijska standardna devijacija. Vrijednost izračunata na uzorku naziva se **statistika** i piše se latinicom, kako je poglavlje o sažimanju podataka već koristilo $\bar{x}$ za uzoračku sredinu i s za uzoračku standardnu devijaciju. Slovo n i dalje označava broj opažanja u uzorku, a N veličinu populacije. Statistika je procjena parametra i gotovo nikada mu nije jednaka.

U stvarnom istraživanju to razlikovanje ostaje neprovjerljivo, jer parametar nije poznat. Kad bi bio poznat, uzorak ne bi ni trebao. Ovo poglavlje zato radi na simuliranoj populaciji od 50 000 odraslih osoba izmišljenoga grada, koju je proizveo kod uz fiksno sjeme i koja ne opisuje nijedno stvarno mjesto. Njezina je vrijednost upravo u tome što je izmišljena, jer se samo za izmišljenu populaciju smije reći koliki joj je prosjek prije nego što se izvuče ijedan uzorak. Prosječno povjerenje u medije u toj populaciji iznosi 4,88 na ljestvici od 1 do 10 uz standardnu devijaciju 1,98, prosječno se dnevno prati 174,5 minuta medijskog sadržaja, a udio onih kojima je portal primarni izvor vijesti iznosi 30,2 %.

Izvučemo li iz te populacije jedan uzorak od stotinu osoba, prosječno povjerenje u njemu iznosi 5,00, a udio korisnika portala 32,0 %. Obje su vrijednosti blizu populacijskih, ali nijedna nije jednaka. Razmak koji je pritom nastao ima ime, i to ime nije optužba.

Definicija 22. Pogreška uzorkovanja je razlika između vrijednosti izračunate na uzorku i vrijednosti koju ima cijela populacija, a nastaje zato što je izmjeren dio umjesto cjeline.

Riječ pogreška ovdje ne označava propust u radu. Nitko nije pogrešno prepisao odgovor ni krivo postavio pitanje. Kada bi cijeli postupak bio proveden besprijekorno, razmak bi i dalje postojao, jer stotinu ljudi nije pedeset tisuća ljudi. Razlikovanje te neizbježne promjenjivosti od pristranosti koja nastaje lošim odabirom nosi ostatak poglavlja, i vrijedi ga zadržati na umu od prve stranice.


Kad uzorkovanje ponovimo

Jedan uzorak ne govori koliko je njegova procjena stabilna. Da bismo to doznali, moramo napraviti ono što stvarno istraživanje nikada ne radi, a to je ponoviti cijeli postupak od početka. Tri neovisna uzorka od po stotinu osoba iz naše populacije daju prosječno povjerenje 4,57, 4,47 i 4,84. Sva tri broja opisuju istu populaciju, izračunata su istim postupkom i međusobno se razlikuju za 0,37 boda.

Ponovimo li to ne tri nego tri tisuće puta, dobiveni prosjeci prestaju biti niz pojedinačnih ishoda i postaju raspodjela s vlastitim oblikom, središtem i širinom. Ta raspodjela nije opis ljudi. Ona je opis onoga što bi se događalo s našom procjenom.

Definicija 23. Distribucija uzorkovanja je raspodjela vrijednosti koje bi neka statistika poprimila kroz mnogo ponovljenih uzoraka iste veličine iz iste populacije.

Razlika između te raspodjele i raspodjele samih opažanja najvažnije je razlikovanje u cijelom poglavlju, a lako se izgubi jer obje imaju sredinu i standardnu devijaciju. Raspodjela opažanja odgovara na pitanje koliko se ljudi međusobno razlikuju. Distribucija uzorkovanja odgovara na pitanje koliko bi se razlikovala naša procjena da smo imali sreće drugačije.



Slika 1: Raspodjela pojedinačnih ocjena povjerenja u simuliranoj populaciji i raspodjela sredina tri tisuće uzoraka od po sto osoba, na zajedničkoj osi.

Objе raspodjele leže oko iste vrijednosti, što znači da uzoračka sredina ne promašuje sustavno ni prema gore ni prema dolje. Procjenitelj koji ima to svojstvo naziva se **nepristranim**. Zbijenost donjeg panela nije,

međutim, svojstvo ljudi nego svojstvo postupka, i upravo je ona ono što nas zanima kad pitamo koliko smijemo vjerovati jednoj brojci.

Standardna pogreška

Širinu distribucije uzorkovanja mjerimo isto kao svaku drugu raspršenost, standardnom devijacijom. Da bi bilo jasno da je riječ o raspršenosti procjene, a ne o raspršenosti ljudi, ta mjera nosi vlastito ime.

Definicija 24. Standardna pogreška je standardna devijacija distribucije uzorkovanja, pa opisuje koliko bi tipično varirala procjena kroz ponovljene uzorke.

U našoj simulaciji standardna devijacija pojedinačnih ocjena iznosi 1,98, a standardna devijacija tri tisuće uzoračkih sredina 0,198. Omjer tih dviju brojki iznosi 10,0. Uzorci su imali po stotinu osoba, a korijen iz sto je deset, i to poklapanje nije slučajno.

Razlog se vidi bez računa. Sredina raspoređuje ukupno izmjereno na sve ispitanike, pa u uzorku od deset ljudi jedan neobičan odgovor nosi desetinu rezultata, a u uzorku od tisuću ljudi tisućinu. Kako uzorak raste, pojedinačna odstupanja imaju sve manju priliku pomaknuti zbroj, i to ne zato što bi odstupanja nestajala, nego zato što se u većem uzorku sve češće međusobno poništavaju. Dobitak zato ne raste s brojem ljudi nego sa svojim korijenom.

$$SE_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

U toj jednakosti $SE_{\bar{x}}$ označava standardnu pogrešku uzoračke sredine, σ standardnu devijaciju populacije, a n veličinu uzorka. Za naš slučaj formula daje 0,1984, dok je simulacija dala 0,1981. Dvije brojke dolaze iz dva potpuno različita smjera, jedna iz algebre i druga iz tri tisuće ponovljenih izvlačenja, a poklapaju se na tri decimale.

U stvarnom istraživanju σ nije poznata, pa se na njezino mjesto stavlja uzoračka standardna devijacija s . Time formula postaje procjena, a ne identitet. Tu zamjenu poglavlje o sažimanju podataka je pripremilo kada je varijancu uvelo s djeliteljem umanjenim za jedan i tu odluku ostavilo kao tvrdnju bez dokaza. Simulacija je sada može provjeriti. Izvučemo li četiri tisuće uzoraka od po deset osoba i u svakome izračunamo prosjek kvadriranih odstupanja s djeliteljem deset, prosječan rezultat iznosi 3,55, dok prava populacijska varijanca iznosi 3,94. Isti račun s djeliteljem devet daje 3,94. Djelitelj n podcjenjuje sustavno, i to zato što odstupanja mjeri od uzoračke sredine, koja je sama izračunata iz istih tih opažanja i zato im leži bliže nego prava populacijska sredina.

Praktična posljedica korijena vidljiva je čim se ispišu veličine uzorka jedna do druge. Preciznost raste, ali sve sporije, pa svako sljedeće poboljšanje košta nesrazmjerno više od prethodnoga.

Tablica 1: Standardna pogreška sredine povjerenja pri osam veličina uzorka, izračunata formulom i izmjerena na tisuću i petsto ponovljenih uzoraka. Izrada autora.


Veličina uzorka	Formula	Simulacija	Raspon $\pm 1,96$ SE
10	0,627	0,617	$\pm 1,23$
25	0,397	0,405	$\pm 0,78$
50	0,281	0,282	$\pm 0,55$
100	0,198	0,194	$\pm 0,39$
200	0,140	0,141	$\pm 0,27$
500	0,089	0,088	$\pm 0,17$
1 000	0,063	0,065	$\pm 0,12$
2 000	0,044	0,043	$\pm 0,09$

Prijelaz s deset na sto osoba prepolovljuje standardnu pogrešku dva puta. Prijelaz sa sto na tisuću, koji stoji desetostruko više, prepolovljuje je nešto više od jednom i pol puta. Da bi se preciznost udvostručila, uzorak se mora učetverostručiti, i ta aritmetika objašnjava zašto ankete rijetko rastu preko nekoliko tisuća ispitanika.

Oblik koji se pojavljuje

Zbijenost distribucije uzorkovanja objašnjena je. Njezin oblik nije, a upravo je oblik ono što omogućuje sve što slijedi. Pogledajmo varijablu koja je koliko god želimo daleko od zvonaste krivulje. Spremnost na plaćanje vijesti u našoj populaciji ima 76,1 % nula i dugi rep prema velikim iznosima, uz koeficijent asimetrije 3,2. Nijedan udžbenički postupak ne bi tu raspodjelu nazvao normalnom.

Izvučemo li iz nje uzorke od po pet osoba i pogledamo raspodjelu njihovih sredina, asimetrija ostaje visoka i iznosi 1,47. Pri uzorcima od petnaest osoba pada na 0,76, pri trideset na 0,52, a pri sto na 0,32. Raspodjela sredina ispravlja se sama od sebe, iako se izvorna raspodjela nije ni za što promijenila.



Slika 2: Izrazito asimetrična populacijska varijabla i raspodjele njezinih uzoračkih sredina pri četiri veličine uzorka. Svaki panel ima vlastitu os.


Ono što smo upravo vidjeli ima ime i status teorema. **Središnji granični teorem** (*central limit theorem*) tvrdi da se distribucija uzorkovanja sredine približava normalnoj raspodjeli kako uzorak raste, bez obzira na oblik raspodjele iz koje se uzorkuje. Uobičajeno pravilo

palca stavlja granicu oko trideset opažanja, ali naša simulacija pokazuje i zašto je to pravilo grubo. Kod izrazito asimetrične varijable trideset osoba nije bilo dovoljno da asimetrija nestane, dok bi kod raspodjele koja je već gotovo simetrična i deset osoba bilo dovoljno. Granica ovisi o tome koliko je izvorna raspodjela iskrivljena, a ne o okruglom broju.

Praktična vrijednost teorema je u tome što oslobađa gotovo cijelo zaključivanje od pretpostavke o obliku podataka. Postupci koji slijede ne traže da su pojedinačna opažanja normalno raspodijeljena, nego da je normalna raspodjela procjene, a to je nešto što uzorak proizvodi sam. Ta razlika objašnjava zašto se isti alati primjenjuju na dohotke, brojanja i ocjene na ljestvici od jedan do deset, iako nijedna od tih raspodjela nije zvonasta.

Interakcija — CLT stroj

Simulacija koja je upravo prošla kroz četiri veličine uzorka fiksirala je oblik populacije. Widget odvađa te dvije stvari, pa se oblik populacije, veličina uzorka i broj ponavljanja mijenjaju neovisno. Time postaje vidljivo koje je svojstvo posljedica čega, jer oblik raspodjele sredina ovisi o obojemu, a njezina širina samo o veličini uzorka.



Slika 3: Desno asimetrična simulirana populacija i raspodjele sredina pri dvjema veličinama uzorka. Veći uzorak daje pravilniju i užu raspodjelu sredina.

Što isprobati.

1. Odaberite simetričnu populaciju i uzorak veličine dva pa usporedite širine dvaju histograma.
2. Promijenite populaciju u desno asimetričnu bez povećanja uzorka.
3. Povećajte uzorak na četrdeset i odvojeno opišite promjenu oblika i širine raspodjele sredina.
4. Odaberite dvovršnu populaciju i pronađite veličinu uzorka pri kojoj se dvije populacijske skupine više ne vide u sredinama.

Zašto ankete od osamsto ljudi rade

Anketni rezultati rijetko su sredine. Češće su udjeli, pa se pitanje preciznosti postavlja za **uzorački udio**, koji označavamo s $\hat{p}$ i koji procjenjuje populacijski udio. Logika ostaje ista, jer je udio prosjek niza nula i jedinica, pa ga središnji granični teorem pokriva jednako kao svaku drugu sredinu. Mijenja se samo to što raspršenost udjela ne treba mjeriti posebno. Kod varijable koja poprima samo dvije vrijednosti raspršenost je određena samim udjelom, najveća je kada je populacija podijeljena napola i pada kako se udio primiće nuli ili jedinici.

$$SE_{\hat{p}} = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Polovica širine intervala oko procjene naziva se **marginu pogreške** (*margin of error*), i to je brojka koju medijski izvještaji navode uz anketu. Budući da je raspršenost najveća pri udjelu od 50 %, uvrštavanjem te vrijednosti dobiva se najgori slučaj, koji vrijedi bez obzira na to kakav će rezultat ispasti. Za uobičajenu razinu od 95 % margina se tada svodi na približno jedan podijeljen korijenom veličine uzorka.

Tablica 2: Najveća margina pogreške za udio pri razini od 95 % i uzorak potreban za zadanu marginu. Izrada autora.

Veličina uzorka	Margina pogreške	Ciljana margina	Potreban uzorak
400	±4,9 %	±5 %	385
800	±3,5 %	±4 %	601
1 000	±3,1 %	±3 %	1 068
2 000	±2,2 %	±2 %	2 401

Tablica objašnjava zašto se veličine anketnih uzoraka tako uporno grupiraju između pet stotina i dvije tisuće ispitanika. Ispod te granice margina postaje prevelika da bi se o razlikama uopće govorilo, a iznad

nje trošak raste brže od koristi. Anketa na osamsto ljudi daje marginu od približno $\pm 3,5$ %, i ta je preciznost dovoljna da se razaznaju razlike od desetak postotnih bodova, a nedovoljna za razlike od dva ili tri.

Odatle slijedi pravilo čitanja koje vrijedi više od svega ostaloga u ovom poglavlju. Kada izvještaj navodi da prva opcija ima 32 %, a druga 29 %, razlika od tri postotna boda manja je od margine pogreške tipične ankete, pa podaci ne podupiru tvrdnju da je prva opcija ispred druge. Uz to, margina se odnosi na svaku procjenu zasebno, a razlika dvaju udjela ima vlastitu, još veću nesigurnost.

U formuli za marginu pogreške nedostaje jedna veličina koju bi svatko očekivao da je ondje, a to je veličina populacije. Preciznost ovisi o tome koliko smo ljudi pitali i koliko su njihovi odgovori raspršeni, ne o tome koliko ih ima. Provjeriti se to može izravno. Uzorak od osamsto osoba izvučen iz cijele naše populacije daje standardnu pogrešku 0,0700, a isti takav uzorak izvučen iz njezina deset puta manjeg dijela daje 0,0640. Populacija veća za red veličine donijela je razliku u preciznosti manju od desetine. Zbog toga anketa na tisuću ljudi jednako dobro opisuje grad od pedeset tisuća stanovnika i državu od četiri milijuna, što je vjerojatno najmanje intuitivan rezultat u cijelom poglavlju i redovito zvuči kao pogreška onima koji ga prvi put čuju.

Preostaje reći što margina pogreške ne pokriva, jer se upravo o tome najčešće šuti. Ona mjeri isključivo promjenjivost koja dolazi od slučajnog izvlačenja ispitanika. Ne mjeri ljude koji nikada nisu bili u okviru iz kojega se uzorkovalo, ne mjeri one koji su bili pozvani ali nisu odgovorili, i ne mjeri učinak formulacije pitanja ni redoslijeda ponuđenih odgovora. Anketa uz koju piše da je margina ± 3 % nudi tri postotna boda opreza za jedan izvor pogreške i nijedan za ostale tri. Rečenica da je nešto „unutar margine pogreške” zato je tvrdnja o slučaju, a ne potvrda da je istraživanje dobro provedeno.

Kad slučajnost nije bila slučajna

Sve dosad rečeno počiva na jednoj pretpostavci koju je lako previdjeti jer se rijetko izgovara. Formula za standardnu pogrešku i središnji

granični teorem vrijede za **slučajni uzorak**, u kojem svaka jedinica populacije ima poznatu i različitu od nule vjerojatnost da bude odabrana. Kada ta pretpostavka padne, brojke se i dalje uredno izračunaju, ali više ne mjere ono što tvrde.

Prigodni uzorak najčešći je oblik takvog pada. Istraživač anketira one koji su mu dostupni, obično studente vlastitog kolegija. U našoj populaciji skupina mladih od dvadeset pet godina s višim obrazovanjem broji 1 915 osoba i njihovo prosječno povjerenje u medije iznosi 4,09, naspram 4,88 u cijeloj populaciji. Razmak je veći od cijele margine pogreške ankete na tisuću ljudi, a ne bi se smanjio ni da smo anketirali sve te mlade ljude do posljednjega.

Samoodabir djeluje suptilnije jer proizvodi velike uzorke. Zamislimo mrežnu anketu na koju odgovaraju oni koji su na internetu, koji su vidjeli poziv i koji su se odlučili javiti, pri čemu svaki od tih koraka propušta drugačiji dio populacije. Simulacija takvog postupka na našoj populaciji daje uzorak od 2 676 osoba, dakle mnogostruko veći od bilo koje telefonske ankete. Njegov prosjek dobi iznosi 32,1 godina naspram 42,2 u populaciji, udio korisnika društvenih mreža 47,8 % naspram 26,8 %, a prosječno povjerenje 4,42 naspram 4,88.

Treći oblik pogađa i istraživanja koja su sve napravila ispravno. Uzorak može biti izvučen savršeno slučajno iz besprijeckornog popisa, a onda dio odabranih ne odgovori. Ako oni koji ne odgovaraju nalikuju onima koji odgovaraju, gubi se samo veličina uzorka i s njom nešto preciznosti. Ako se razlikuju, a upravo se najčešće razlikuju po zauzetosti, zanimanju za temu i povjerenju u onoga tko pita, tada preostali dio uzorka više nije slučajan bez obzira na to kako je odabran. Postupak odabira i postupak odaziva dva su različita filtra, i drugi je izvan nadzora istraživača.

Kod tolikog uzorka standardna pogreška je sitna, pa bi izvještaj mogao objaviti vrlo uzak interval oko sustavno pogrešne vrijednosti. To je najvažnija asimetrija u poglavlju. Slučajna promjenjivost pada s veličinom uzorka i mjeri se standardnom pogreškom, dok pristranost odabira ne ovisi o veličini uzorka i standardna je pogreška uopće ne vidi. Velik pristran uzorak zato je opasniji od malog slučajnog, jer

nosi jednaku netočnost i uz nju uvjerljivost koju mala brojka nikada ne bi imala.

STATISTIKA U DIVLJINI

Deset milijuna listića i pogrešan pobjednik. Časopis *Literary Digest* razaslao je uoči američkih izbora 1936. milijune probnih listića i na temelju vraćenih odgovora objavio predviđanje koje je promašilo pobjednika, dok su istodobne ankete na uzorcima manjima za red veličine pogodile ishod (Squire 1988.).

Uzorak nije zakazao zbog veličine. Popisi iz kojih su adrese izvučene obuhvaćali su imućnija kućanstva sustavno češće od ostalih, a listić je vratio tek dio onih koji su ga primili, pa se skupina koja je odgovorila razlikovala od skupine koja nije (Squire 1988.). Oba filtra djeluju u istom smjeru i nijedan se ne popravljja slanjem još listića. Slučaj se često prepričava kao upozorenje da uzorci trebaju biti veliki, iako pokazuje upravo suprotno.

PITAJTE MODEL

Asistent može napisati simulaciju distribucije uzorkovanja u nekoliko sekundi, ali treba mu odvojeno zadati populaciju, postupak odabira, veličinu uzorka i statistiku koja se računa. Provjeravamo uzorkuje li s vraćanjem samo kada je to namjera, jer je zadana postavka mnogih funkcija suprotna od potrebne. Najčešća pogreška u odgovoru nije u kodu nego u rečenici koja ga prati, gdje se raspršenost pojedinaca predstavi kao standardna pogreška procjene.

Simuliraj mnogo neovisnih uzoraka iz zadane populacije.
Prikaži raspodjelu uzoračkih sredina i odvojeno navedi standardnu devijaciju opažanja te standardnu pogrešku sredine.

NADITE GREŠKU

Veći nasumični uzorak daje užu distribuciju uzoračkih sredina. Budući da je standardna pogreška manja, vrijednosti pojedinaca u većem uzorku također su međusobno sličnije.

Razrađeni primjer

Cijeli aparat zaključivanja koji slijedi u ostatku knjige svodi se na jednu petlju. Izvuci uzorak, izračunaj mjeru, ponovi mnogo puta i pogledaj što je nastalo. Sve ostalo su prečice do rezultata te petlje. Vrijedi je zato jednom vidjeti ispisanu u cijelosti, na najgoroj varijabli koju naša populacija ima.

Pitanje glasi koliko su prosjeci pouzdani kada se računaju na varijabli s mnoštvom nula i dugim repom, dakle u okolnostima u kojima bi se svaka pretpostavka o zvonastom obliku odmah raspala. Postavljamo ga tako da usporedimo dvije veličine uzorka i za obje pogledamo gdje se sredine skupljaju i koliko su raspršene.

```
uzmi_sredinu <- function(n) {
  mean(sample(populacija_medija$spremnost_platiti, n))
}

sredine_5 <- replicate(4000, uzmi_sredinu(5))
sredine_60 <- replicate(4000, uzmi_sredinu(60))

c(
  populacija = mean(populacija_medija$spremnost_platiti),
  sredina_5 = mean(sredine_5),
  sredina_60 = mean(sredine_60),
  se_5 = sd(sredine_5),
  se_60 = sd(sredine_60)
)
```

populacija	sredina_5	sredina_60	se_5	se_60
6,126660	6,100150	6,144362	6,185099	1,790483

Funkcija **replicate** ponavlja zadani izraz traženi broj puta i skuplja rezultate u vektor, pa je ona jedini novi glagol u ovom bloku. Prosjek četiri tisuće sredina iz uzoraka od pet osoba iznosi 6,10 kuna, a iz uzoraka od šezdeset osoba 6,14 kuna, dok prava populacijska vrijednost iznosi 6,13 kuna. Nijedna od dviju veličina uzorka ne promašuje cilj sustavno, što je nepristranost o kojoj je već bilo riječi.

Razlikuju se u nečemu drugome. Standardna pogreška pri pet osoba iznosi 6,19, a pri šezdeset 1,79, dakle 3,5 puta manje. Odnos je približno jednak korijenu iz dvanaest, koliko puta je veći uzorak, i time se algebra iz odjeljka o standardnoj pogrešci potvrđuje na varijabli za koju bi se očekivalo da je najviše izmiče. Vrijedi zapaziti i što petlja nije popravila. Uzorak od pet osoba i dalje daje raspodjelu sredina koja je vidljivo iskrivljena, pa nepristranost i normalnost nisu isto svojstvo i ne stižu u istom trenutku.

Vrijedi zapaziti i što je u ovom bloku bilo moguće samo zato što je populacija izmišljena. Prvi redak poziva **populacija_medija** i time čini nešto što nijedno stvarno istraživanje ne može, jer izvlači uzorke iz cjeline kojoj bi inače bilo nemoguće pristupiti. Istraživač koji radi s podacima ima jedan uzorak i nijednu mogućnost da petlju stvarno pokrene. Sve što slijedi u knjizi način je da se do rezultata te petlje dođe bez nje, a poglavlje o procjeni prvo je od tih zaobilaženja. Ono uzorku dopušta da nakratko preuzme ulogu populacije, i time istu petlju vrati u ruke nekome tko ima samo osamsto ispitanika.

Sažetak

Uzorak je jedan ishod postupka odabira, a distribucija uzorkovanja opisuje kako bi se procjena mijenjala kroz ponovljene izvlačenja. Njezinu širinu mjeri standardna pogreška, koja pripada procjeni, a ne pojedincima, i pada s korijenom veličine uzorka, pa preciznost postaje sve skuplja. Njezin oblik se s porastom uzorka približava normalnoj raspodjeli bez obzira na to iz čega se uzorkuje, i upravo to čini ostatak knjige mogućim. Ništa od toga ne popravljaju pristran odabir, jer

standardna pogreška mjeri samo ono što bi se mijenjalo kroz ponavljanja istoga postupka, a ne ono što je taj postupak sustavno izostavio. Poglavlje o procjeni uzet će tu raspodjelu i iz nje izgraditi raspon oko vrijednosti koju ne možemo izravno vidjeti.

Pojmovi

populacija (*population*), uzorak (*sample*), parametar (*parameter*), statistika (*statistic*), pogreška uzorkovanja (*sampling error*), distribucija uzorkovanja (*sampling distribution*), nepristranost (*unbiasedness*), standardna pogreška (*standard error*), središnji granični teorem (*central limit theorem*), uzorački udio (*sample proportion*), margina pogreške (*margin of error*), slučajni uzorak (*random sample*), prigodni uzorak (*convenience sample*), samoodabir (*self-selection*)

Zadaci

Konceptualni

Razlikujte raspodjelu pojedinačnih opažanja od distribucije uzoračkih sredina. Za svaku navedite što joj je jedinica, što mjeri njezina širina i što se s njom događa kada uzorak naraste. Predajte skicu obiju raspodjela i dva popratna objašnjenja.

Računski

Upotrijebite tablicu margine pogreške iz ovog poglavlja. Anketa na tisuću ispitanika izvještava da prva opcija ima 44 %, a druga 39 %. Izračunajte marginu pogreške te ankete, presudite je li razlika od pet postotnih bodova veća od margine i objasnite zašto usporedba dviju procjena traži više opreza od prosudbe svake zasebno. Zatim odredite koliki bi uzorak trebao da margina padne na polovicu i provjerite rezultat u istoj tablici. Postupak s cijelim skupom podataka opisan je u Dodatku A.

Kritički

Pročitajte slučaj časopisa *Literary Digest* iz okvira o statistici u divljini (Squire 1988.). Objasnite zašto povećanje broja poslanih listića ne bi ispravilo nijedan od dvaju opisanih problema i navedite koji bi podatak o toj anketi bio najkorisniji za prosudbu njezine vjerodostojnosti. Predajte jedan odlomak.

Revizija modela

Ocijenite analizu modela iz okvira o pogrešci. Izdvojite tvrdnju koja je točna, imenujte zamjenu dviju razina varijabilnosti i napišite ispravljenu verziju druge rečenice koja zadržava sve što je u njoj bilo točno.

Procjena

Interval pokazuje koliko je procjena precizna

Vrijeme čitanja	Widget	Podaci	Preduvjet
21 min	Hvatač intervala	simulirana populacija	pogl. 8

VINJETA

Cumming je zagovarao izvještavanje procjena i intervala kao središte statističkog zaključivanja, umjesto oslanjanja na samu odluku o značajnosti (Cumming 2014.). Pomak mijenja pitanje koje postavljamo podacima. Umjesto binarnog prolaza pitamo koliki je učinak i koliko je procjena precizna.

Poglavlje o uzorkovanju pokazalo je zašto takvo pitanje uopće ima smisla. Naša procjena samo je jedan ishod iz

raspodjele mogućih ishoda, a širina te raspodjele poznata je u simulaciji jer smo uzorkovanje ponovili tri tisuće puta.

Istraživač koji objavljuje rezultat nema tri tisuće uzoraka.

Ima jedan, i iz njega mora reći koliko je siguran.

Kako iz jednoga opaženog uzorka pošteno govoriti o vrijednosti koja ostaje nepoznata?

Od točke prema rasponu

Uzorak od 200 osoba iz naše populacije daje prosječno povjerenje u medije od 4,82. Ta jedna vrijednost naziva se **točkasta procjena** (*point estimate*) i najbolji je sažeti pogodak koji trenutačno imamo. Njezina je slabost u tome što ne nosi nikakav trag vlastite nesigurnosti. Ista brojka mogla je nastati iz uzorka od dvadeset ljudi i iz uzorka od dvadeset tisuća, a te dvije situacije ne zaslužuju jednako povjerenje.

Sve što nedostaje već je izračunato u prethodnom poglavlju. Standardna pogreška mjeri koliko bi procjena tipično varirala kroz ponovljena uzorkovanja, a za naš uzorak iznosi 0,148. Uz nju procjena prestaje biti gola brojka i postaje brojka s poznatom skalom vlastitog kolebanja.

Središnji granični teorem kazuje i kakav oblik to kolebanje ima. Raspodjela uzoračkih sredina približno je normalna, a za normalnu raspodjelu znamo koliki udio vrijednosti pada unutar zadanog broja standardnih devijacija od središta, što je pravilo koje je poglavlje o vjerojatnosti već postavilo. Približno 95 % vrijednosti leži unutar 1,96 standardnih devijacija.

Odatle slijedi konstrukcija koja se čini gotovo previše jednostavnom da bi radila. Ako je naša sredina u 95 % slučajeva unutar 1,96 standardnih pogrešaka od populacijske vrijednosti, tada je i populacijska vrijednost u 95 % slučajeva unutar te iste udaljenosti od naše sredine.

Razmak oko procjene dug 1,96 standardnih pogrešaka na svaku stranu zato će hvatati cilj u 95 % ponavljanja.

$$\bar{x} \pm z^* \cdot SE_{\bar{x}}$$

Slovo z^* označava koliko standardnih pogrešaka širimo na svaku stranu, i bira ga željena razina, pa je za 95 % ono jednako 1,96. Za naš uzorak taj račun daje raspon od 4,52 do 5,11, a prava populacijska vrijednost iznosi 4,88 i nalazi se unutra.

Definicija 25. Interval pouzdanosti je raspon oko procjene, izračunat postupkom koji kroz ponovljena uzorkovanja obuhvaća nepoznati parametar u unaprijed određenom udjelu slučajeva.

Vrijedi obratiti pozornost na to gdje u toj definiciji stoji obećanje. Ono ne stoji uz raspon nego uz postupak, i upravo se ta razlika u praksi najčešće gubi.

Što razina pouzdanosti obećava

Provjera je moguća jer populaciju poznajemo. Ponovimo cijeli postupak deset tisuća puta, svaki put izvučemo novi uzorak od dvjesto osoba, izračunamo njegovu sredinu i standardnu pogrešku, sastavimo interval i prebrojimo koliko ih je obuhvatilo pravu vrijednost. Cilj je obuhvaćen u 94,9 % slučajeva, a promašen u 506 od 10 000 ponavljanja.

Postupak dakle radi približno onako kako obećava, i vrijedi zadržati riječ približno. Zamjena nepoznate populacijske raspršenosti onom izmjerenom u uzorku unosi vlastitu nesigurnost, koja je pri dvjesto osoba mala, a pri dvadeset osoba ne bi bila. Ispravak koji to nadoknađuje širi interval za mali uzorak i knjiga ga uvodi u poglavlju o usporedbi dviju grupa, gdje ga postupak prvi put stvarno treba.

Ono što se u brojcima od 94,9 % ne vidi jest sudbina pojedinačnog intervala. Svaki od tih dvije tisuće raspona ili sadrži pravu vrijednost ili


je ne sadrži, i nakon što je izračunat, u njemu nema ničega slučajnog. Slučajan je bio uzorak koji ga je proizveo. Populacijska sredina fiksna je broj i ne kreće se, pa rečenica o vjerojatnosti da se ona nalazi unutar zadanih granica opisuje nešto što nema promjenjivosti koju bi ta vjerojatnost mjerila.

Analogija koja to drži na okupu jest bacanje obruča na fiksni kolac. Obruč je interval, kolac je parametar, a razina pouzdanosti opisuje koliko često obruč pada oko kolca kroz mnogo bacanja. Nakon jednoga bacanja obruč je pao ili nije, a mi ga gledamo zatvorenih očiju. Postotak opisuje ruku koja baca, ne ovaj pojedini obruč.

Zbog te razlike korisno je znati što čitatelj objavljenog intervala smije reći. Smije reći da su vrijednosti unutar granica uskladive s podacima, a one izvan njih slabo uskladive, i to pod pretpostavkama koje je postupak koristio. Smije reći da je istraživanje bilo dovoljno precizno da razluči razlike veće od širine raspona, i da za manje razlike nije. Ne smije reći koliko je vjerojatno da parametar leži unutra, niti da će se ponovljeno istraživanje smjestiti unutar tih istih granica, jer bi drugo istraživanje imalo vlastiti uzorak i vlastiti interval. Prve dvije rečenice pokrivaju gotovo sve što se u praksi treba zaključiti, i obje govore o rasponu vrijednosti, a nijedna o vjerojatnosti.

Interakcija — Hvatač intervala

Prebrojavanje iz prethodnog odjeljka dalo je jednu brojku i sakrilo postupak koji je do nje doveo. Widget taj postupak vraća na vidjelo, jer prikazuje same intervale, jedan ispod drugoga, oko iste nepomične ciljne crte. Veličina uzorka i razina pouzdanosti mijenjaju se odvojeno, pa se vidi da prva mijenja širinu intervala, a druga mijenja i širinu i učestalost promašaja.



Slika 1: Pedeset intervala iz ponovljenih simuliranih uzoraka i fiksna populacijska sredina. Križići označuju intervale koji promašuju cilj.

Što isprobati.

1. Zadržite pedeset intervala i prebrojite one koji ne sijeku okomitu ciljnu crtu.
2. Povećajte broj intervala na sto bez promjene veličine uzorka ili razine pouzdanosti.
3. Usporedite širinu intervala pri uzorcima veličine dvadeset i sto.
4. Promijenite razinu pouzdanosti s devedeset na devedeset i devet posto te opišite odnos širine i obuhvata.

Preciznost nasuprot pouzdanosti

Dva pomaka koja widget dopušta imaju vrlo različite učinke i lako ih je pobrkati jer oba mijenjaju širinu. Veći uzorak sužava interval time što smanjuje standardnu pogrešku, pa uz jednako obećanje o obuhvatu dobivamo precizniji odgovor. Prosječna širina intervala pri uzorku od pedeset osoba iznosi 1,09 boda, pri dvjesto 0,55, a pri osamsto 0,28.

Viša razina pouzdanosti također širi interval, ali ništa ne dobiva na preciznosti. Na istom našem uzorku raspon od 90 % širok je 0,49 boda, onaj od 95 % 0,58, a onaj od 99 % 0,76. Podaci se nisu promijenili, promijenio se zahtjev. Interval koji obuhvaća cilj u 100 % slučajeva postoji i proteže se od minus do plus beskonačno, čime savršena pouzdanost postaje savršeno beskorisna.

Preciznost je zato svojstvo koje se plaća podacima, a **pouzdanost** je svojstvo koje se bira i plaća širinom. Konvencija od 95 % nema dublje opravdanje od uobičajenosti, i to je razlog više da se uz svaki interval navede razina na kojoj je izračunat.


Širok interval ne znači loše obavljen posao. Češće znači mali uzorak ili podatke koji su stvarno raspršeni, i tada je široki raspon iskren opis stanja, a ne priznanje nesposobnosti. Suprotan je slučaj mnogo opasniji. Uzak interval oko procjene iz pristranog uzorka izgleda kao preciznost, a jest sigurnost u pogrešnu vrijednost, jer interval mjeri samo ono što bi se mijenjalo kroz ponavljanja istoga postupka.

Iz širine slijedi i način na koji se intervali čitaju kada ih je više na istoj slici, što je najčešći oblik u kojem ih društveni znanstvenik susreće. Grafovi koji uz svaku skupinu crtaju raspon umjesto samog stupca odmah pokazuju koje su procjene oslonjene na malo ljudi, a koje na mnogo, i time govore više od tablice prosjeka. Iskušenje je da se iz njih očita i zaključak o razlici.

Pravilo koje se pritom obično primjenjuje nije simetrično i vrijedi to znati. Kada se dva intervala uopće ne preklapaju, razlika među skupinama gotovo je sigurno stvarna. Kada se preklapaju, iz toga ne slijedi da razlike nema, jer umjereno preklapanje i dalje je uskladio s pravom razlikom. Preklapanje je zato slab dokaz u jednom smjeru

i jak u drugom, a pošten odgovor traži interval za samu razliku, a ne dva intervala jedan pokraj drugoga. Taj postupak knjiga uvodi u poglavlju o usporedbi dviju grupa.

Postoji i druga zamjena koja se često javlja u istom odlomku. Interval pouzdanosti govori gdje je prosjek, a ne gdje su ljudi. Za naš uzorak od dvjesto osoba raspon oko sredine dug je 0,58 boda, dok bi raspon unutar kojega leži otprilike 95 % pojedinačnih ocjena bio širok približno 8,2 boda. Prvi se odnosi na parametar i sužava se s uzorkom, drugi na buduće opažanje i ne sužava se gotovo nimalo.



Slika 2: Interval pouzdanosti za sredinu i raspon unutar kojega leži otprilike 95 % pojedinačnih ocjena, na istom uzorku i istoj osi.


Bootstrap kao vlastiti izum

Sve dosad počiva na jednoj formuli za standardnu pogrešku, a ta formula postoji samo za neke mjere. Za sredinu je poznata, za udio također, a za medijan, razliku percentila ili omjer dviju mjera nije jednostavna ili je uopće nema. Pitanje što učiniti kada formule nema ima odgovor koji se može smisliti bez ijedne nove ideje, uz uvjet da se prethodno poglavlje shvatilo ozbiljno.

Standardna pogreška bila je definirana kroz ponovljene uzorke iz populacije. Kad bismo populaciji imali pristup, izvukli bismo tisuću uzoraka, izračunali tisuću medijana i pogledali koliko se razilaze. Populaciji pristupa nemamo, imamo samo uzorak. Uzorak je pritom najbolja slika populacije kojom raspolažemo, jer je iz nje izvučen slučajno i njezine razmjere nosi u sebi. Ako mu dopustimo da privremeno glumi populaciju i iz njega izvlačimo nove uzorke jednake veličine, dobit ćemo raspodjelu koja oponaša onu koju bismo dobili iz prave populacije.

Izvlačenje mora biti s vraćanjem, i to nije tehnički detalj. Izvlačenjem bez vraćanja iz uzorka od šezdeset osoba dobili bismo šezdeset istih osoba u drugom poretku, pa bi svaki takav uzorak dao identičan medijan i raspodjela ne bi imala nikakvu širinu. Vraćanjem opažanja u posudu dopuštamo da neka uđu dvaput, a neka nijednom, i upravo ta promjena sastava oponaša promjenu sastava koja nastaje pri izvlačenju iz populacije. Postupak nosi ime **bootstrap** i uveden je kao način procjene nesigurnosti kada teorijski račun nije pri ruci (Efron 1979.).

Uzmimo uzorak od 60 osoba i pitajmo se koliko iznosi medijan dnevnih minuta praćenja medija. U uzorku on iznosi 173,5 minuta. Četiri tisuće bootstrap uzoraka daju raspon od 155,0 do 194,0 minuta, unutar kojega leži prava populacijska vrijednost od 165,0 minuta.



Slika 3: Raspodjela četiri tisuće bootstrap medijana iz jednog uzorka, s granicama središnjih 95 % vrijednosti i pravom populacijskom vrijednošću.

Histogram ima vidljiv stubast oblik jer medijan uzorka od šezdeset brojeva može poprimiti samo ograničen skup vrijednosti, što je svojstvo mjere, a ne mana postupka. Snaga bootstrapa upravo je u tome što ga takve neugodnosti ne zaustavljaju. Isti se postupak bez izmjene primjenjuje na sredinu, medijan, korelaciju ili razliku dviju skupina, jer nigdje ne pretpostavlja oblik raspodjele.

Njegova granica ostaje početni uzorak, i granica je stroga. Bootstrap ponovno koristi opažanja koja već imamo, pa ne može otkriti dio populacije koji u uzorak nikada nije mogao ući. Ako je uzorak prigodan, postupak će pouzdano opisati promjenjivost pogrešne procjene. Ako je premalen da zabilježi rijetke ali važne slučajeve, ta praznina ostaje u svakom od četiri tisuće ponavljanja.

STATISTIKA U DIVLJINI

Šest tvrdnji o jednom intervalu. Istraživači su studentima i aktivnim znanstvenicima predložili objavljeni interval pouzdanosti i uz njega šest tvrdnji o njegovu značenju, među kojima nijedna nije bila točna

(Hoekstra i sur. 2014.). Velik dio ispitanika u svim skupinama, uključujući iskusne istraživače, prihvatio je barem neke od njih.

Tvrđnje nisu bile besmislene, i u tome je poanta okvira. Sve su govorile o vjerojatnosti da se prava vrijednost nalazi unutar granica, ili o tome koliko je vjerojatno da bi se ponovljeno istraživanje unutar njih smjestilo. Postupak koji smo izgradili takva obećanja ne daje, jer se njegov postotak odnosi na udio intervala koje bi ponovljeno uzorkovanje proizvelo. Nalaz ne pokazuje da su intervali loš alat nego da je rečenica kojom ih opisujemo teža od računa koji ih proizvodi.

PITAJTE MODEL

Asistent može bootstrapirati gotovo svaku statistiku i obično to učini ispravno. Provjeravamo tri stvari koje redovito promakne. Uzorkuje li s vraćanjem i na punoj veličini uzorka, jer bez toga raspodjela nema smisla. Čuva li strukturu podataka, jer se kod uparenih ili grupiranih opažanja izvlače jedinice, a ne redovi. Ponavlja li dovoljno puta, jer nekoliko stotina ponavljanja daje granice koje se mijenjaju od pokretanja do pokretanja. Najčešća pogreška ipak nije u kodu nego u zaključnoj rečenici, gdje se već izračunatom intervalu pripiše vjerojatnost.

Izračunaj točkastu procjenu i bootstrap interval. Uzorkuj s vraćanjem na punoj veličini uzorka, sačuvaj strukturu podataka i interpretiraj razinu pouzdanosti kao svojstvo ponovljenog postupka.

NADITE GREŠKU

Bootstrap raspodjela je približno simetrična i interval je uredno izračunat iz njezinih krajeva. Postoji devedesetpetpostotna vjerojatnost da se fiksna populacijska vrijednost nalazi unutar upravo ovog opaženog intervala.

Razrađeni primjer

Pitanje je ono koje bi postavio naručitelj istraživanja. Koliko vremena dnevno stanovnici našega grada provode uz medije, i koliko je taj odgovor pouzdan ako je anketirano šezdeset ljudi.

Prvi izbor nije statistički nego opisni. Dnevne minute imaju rep prema velikim vrijednostima, a poglavlje o sažimanju podataka pokazalo je da prosjek takav rep povlači za sobom, dok medijan ostaje kod tipičnog ispitanika. Za pitanje o tome koliko medija prati uobičajena osoba medijan je pošteniji odgovor. Cijena tog izbora vidi se tek sada, jer za sredinu postoji formula za standardnu pogrešku, a za medijan ne postoji nijedna koja bi se dala napisati u jednom retku. Upravo zato ovaj primjer i postoji.

Cijeli bootstrap stane u istu petlju koju je poglavlje o uzorkovanju već pokazalo, uz jednu izmjenu. Umjesto iz populacije, izvlačimo iz uzorka, i to s vraćanjem.

```
set.seed(505)
uzorak <- slice_sample(populacija_medija, n = 60)

boot_medijan <- replicate(
  4000,
  median(sample(uzorak$minute_medija, replace = TRUE))
)

c(
  procjena = median(uzorak$minute_medija),
  donja = quantile(boot_medijan, 0.025),
  gornja = quantile(boot_medijan, 0.975)
)
```

procjena	donja.2,5%	gornja.97,5%
173,5	155,0	194,0

Poziv `sample` uz argument `replace` izvlači s vraćanjem i jedini je novi element u odnosu na prethodno poglavlje, dok `quantile` odsijeca zadani udio raspodjele s obje strane. Blok proizvodi upravo one tri brojke koje je odjeljak o bootstrapu već naveo, jer je riječ o istoj analizi ispisanoj u cijelosti.

Odgovor naručitelju glasi da tipičan stanovnik prati medije oko 173,5 minuta dnevno, uz raspon od 155,0 do 194,0 minuta koji opisuje koliko bi se ta procjena mijenjala kroz ponovljena istraživanja iste veličine. Raspon je širok gotovo 39 minuta, što je pošten opis onoga što šezdeset ljudi može reći, i ujedno najkorisnija brojka u cijelom izvještaju. Naručitelj koji je htio razlučiti promjenu od deset minuta iz ovih podataka odgovor neće dobiti bez većeg uzorka.

Budući da populaciju poznajemo, možemo napraviti i ono što stvarno istraživanje ne može. Prava vrijednost iznosi 165,0 minuta i nalazi se unutar granica. Iz toga ne slijedi da postupak radi, jer bi i loš postupak pogodio pokoji put. Ono što o postupku govori jest prebrojavanje deset tisuća ponavljanja iz ranijeg odjeljka, a ovaj pojedinačni podatak samo je jedan od njih, viđen iznutra kako ga vidi istraživač.

Redosljed kojim su tri brojke ispisane isti je onaj kojim se rezultat i izvještava. Najprije dolazi procjena, jer je ona odgovor na postavljeno pitanje. Zatim dolazi raspon, jer bez njega procjena tvrdi više nego što zna. Tek na kraju dolazi ograda, koja ovdje kaže da su podaci simulirani, da je mjera medijan, a ne prosjek, i da šezdeset ljudi nije mnogo. Ista tri koraka vrijede za nalaz čija je populacija stvarna, s tom razlikom da se ondje srednji korak mora izvesti bez ikakve mogućnosti provjere, i upravo zato mora biti izveden pažljivo.

Sažetak

Procjena počinje jednom vrijednošću, ali ne završava njome. Interval pouzdanosti uzima standardnu pogrešku i oblik koji je dao središnji granični teorem te oko procjene gradi raspon čije obećanje pripada postupku, a ne pojedinačnom rasponu koji imamo pred sobom. Preciznost se kupuje podacima, a pouzdanost se bira i plaća širinom, pa

uz svaki raspon mora stajati razina na kojoj je izračunat. Bootstrap istu ideju oslobađa formule tako što uzorku dopušta da privremeno glumi populaciju, i time otvara mjere za koje račun ne postoji, ne popravljajući pritom nijednu slabost samoga uzorka. Sljedeće poglavlje uzima isti aparat i mijenja mu pitanje, jer umjesto raspona usklađenog s podacima traži koliko su podaci neobični pod jednom određenom pretpostavkom.

Pojmovi

točkasta procjena (*point estimate*), interval pouzdanosti (*confidence interval*), razina pouzdanosti (*confidence level*), preciznost (*precision*), bootstrap (*bootstrap*), uzorkovanje s vraćanjem (*sampling with replacement*), parametar (*parameter*)

Zadaci

Konceptualni

Objasnite zašto razina pouzdanosti pripada postupku, a ne nepoznatom parametru nakon izračuna intervala. U objašnjenju navedite što je u postupku slučajno, a što fiksno, i zašto ta podjela isključuje rečenicu o vjerojatnosti da parametar leži unutar zadanih granica. Predajte jedan odlomak.

Računski

Upotrijebite widget Hvatač intervala. Postavite pedeset intervala pri uzorku od četrdeset osoba i razini od 95 % pa zabilježite koliko ih promašuje cilj. Ponovite mjerenje pri razini od 99 % i pri uzorku od sto šezdeset osoba, mijenjajući svaki put samo jednu postavku. Predajte tablicu s tri retka u kojoj su navedeni postavka, širina tipičnog intervala i broj promašaja te jednu rečenicu o tome koja postavka mijenja preciznost, a koja učestalost promašaja.

Kritički

Pronađite u medijskom izvještaju ili sažetku rada rečenicu koja tumači interval pouzdanosti. Prosudite pripisuje li vjerojatnost parametru, brka li raspon sredine s rasponom pojedinačnih opažanja ili je ispravna, i napišite verziju koja je vjerna postupku bez gubitka informacije (Hoekstra i sur. 2014.). Predajte izvornu rečenicu, prosudbu i ispravak.

Revizija modela

Ocijenite modelsku interpretaciju iz okvira o pogrešci. Imenujte što je u njoj točno, izdvojite jednu pogrešnu rečenicu i napišite frekventistički ispravnu zamjenu koja zadržava razinu od 95 % i ne uvodi nove tvrdnje o podacima.

DIO IV: ZAKLJUČIVANJE

Logika testiranja

Što p-vrijednost govori — i što ne govori

Vrijeme čitanja	Widget	Podaci	Preduvjet
24 min	Simulator p-vrijednosti	simulirana populacija	pogl. 7–9

VINJETA

Američko statističko udruženje moralo je 2016. javno razjasniti p-vrijednost jer je jedan računski izlaz prečesto služio kao automatska odluka o postojanju učinka (Wasserstein i Lazar 2016.). Udruženje se u svojoj povijesti dotad nije oglasilo o pojedinačnom statističkom postupku, pa je sama izjava bila priznanje da problem nije u računu nego u tome što se s njim radi.

Izveštaji su prag pretvarali u granicu između rezultata koji „postoje” i onih koji „ne postoje”. Postupak takvu podjelu ne može nositi, jer ne uspoređuje dvije tvrdnje o svijetu nego jednu tvrdnju s onim što bi slučajnost proizvela.

Što mala p-vrijednost govori o podacima, a što ne može reći o hipotezi?

Sudnica i njezina asimetrija

Testiranje počinje pretpostavkom u koju nitko ne vjeruje. Postupak najprije opiše svijet u kojem učinka koji tražimo nema, izračuna što bi taj svijet proizveo, i tek onda pogleda podatke. Ako podaci u takvom svijetu izgledaju neobično, pretpostavka postaje neodrživa.

Definicija 26. Nulta hipoteza je precizan model postupka koji je proizveo podatke, sastavljen tako da u njemu nema razlike ni veze koju istražujemo.

Alternativna hipoteza opisuje odstupanje koje bi nas zanimalo i namjerno je neodređena, jer obuhvaća sve razlike osim nulte. Te dvije tvrdnje nisu ravnopravne suparnice. Samo nulta hipoteza dovoljno je precizna da se iz nje može izračunati što će se dogoditi, i zbog toga cijeli postupak stoji na njoj.

Analogija sa suđenjem tu asimetriju objašnjava bolje od bilo koje formule. Sud polazi od pretpostavke nevinosti, a tužiteljstvo iznosi dokaze protiv nje. Presuda kojom optužba nije dokazana nije utvrđenje nevinosti nego izjava da dokazi nisu bili dovoljni. Statistički postupak radi isto, pa neodbacivanje nulte hipoteze nikada ne znači da je ona istinita.

Analogija ima i granicu koju vrijedi navesti odmah. Sud presuđuje o jednom događaju, a test opisuje ponašanje postupka kroz mnogo

ponavljanja. Sve što slijedi vrijedi za postupak, a ne za pojedini rezultat, i upravo se to u izvještajima gubi.

Zbog toga se dio odluka mora donijeti prije podataka. Nulti model treba biti zapisan tako da se iz njega može računati, mjera odstupanja odabrana, a prag uz koji će se rezultat čitati postavljen dok se još ne zna kako će podaci ispasti. Ništa od toga nije tehnička priprema. Postupak čije se komponente biraju nakon pogleda na podatke više nema stopu pogreške koju obećava, jer je obećanje dano za postupak koji se ponavlja jednak, a ne za onaj koji se dotjeruje. Koliko se tim putem može doći dokazuje poglavlje o krizi i obnovi.

Kako se gradi svijet bez učinka

Poglavlje radi na istoj simuliranoj populaciji kao poglavlja o uzorkovanju i procjeni. Iz nje je izvučeno 300 osoba koje se primarno informiraju preko portala ili preko tiska, i pitanje glasi razlikuju li se te dvije skupine po povjerenju u medije.


Prvo dolazi ono što odgovara na postavljeno pitanje. Razlika između sredina iznosi 0,64 boda u korist tiska, uz interval pouzdanosti od 0,17 do 1,11. Test dolazi tek poslije, jer odgovara na uže pitanje, na to je li s podacima uskladiva i nula.

Nulti model za ovo pitanje ne treba izvoditi računom. Ako izvor vijesti nema nikakve veze s povjerenjem, onda su oznake skupina samo naljepnice koje su jednako mogle biti razdijeljene bilo kako. Promiješamo ih dakle nasumično, izračunamo razliku sredina, i to ponovimo mnogo puta. Dobiveni raspon razlika točno je ono što nulti model dopušta.

Definicija 27. Testna statistika je jedan broj izračunat iz podataka koji sažima odstupanje od nultog modela u obliku usporedivom s odstupanjima koja taj model proizvodi.

Ovdje je ta statistika sama razlika sredina, jer je upravo ona ono o čemu se odlučuje. Sljedeći graf prikazuje što nulti model s njome radi

kroz četiri tisuće premještanja, a uz njega stoji razlika koju je dao stvarni raspored oznaka.



Slika 1: Razlike sredina kroz četiri tisuće nasumičnih premještanja oznaka skupine, uz okomitu crtu na razlici opaženoj u uzorku.

Nulta raspodjela ima sredinu u nuli i standardnu devijaciju od 0,26 boda. Devedeset pet posto premještanja daje razliku manju od 0,50 boda po apsolutnoj vrijednosti, dakle sve unutar tog raspona nulti model proizvodi bez ikakve pomoći. Opažena razlika od 0,64 boda leži izvan njega.


Preostaje prebrojati koliko je premještanja dalo odstupanje barem toliko veliko kao opaženo. Taj udio ima ime.

Definicija 28. P-vrijednost je udio rezultata koje nulti model proizvodi, a koji su s njime u najmanju ruku jednako neusklađeni kao opaženi rezultat.

U našem uzorku iznosi 0,016. Rečenica koja iz toga slijedi ima oblik koji vrijedi zapamtiti doslovno. Kad izvor vijesti ne bi imao nikakve veze s povjerenjem, razliku ovoliku ili veću vidjeli bismo u otprilike 1,6 % uzoraka. Sve što p-vrijednost kaže stoji u toj rečenici, i svaka tvrdnja koja iz nje izlazi mora biti opravdana posebno.

Interakcija — Simulator p-vrijednosti

Sljedeći prikaz radi ono što jedan uzorak ne može. Postupak ponavlja mnogo puta, odvojeno u svijetu u kojem učinka nema i u svijetu u kojem ga ima, i prikazuje kako se p-vrijednosti raspoređuju u jednom i u drugom. Radi preglednosti koristi normalne ishode s poznatom varijabilnošću i obostrani test.



Slika 2: Raspodjele p-vrijednosti pod nultim modelom i uz standardiziranu razliku 0,35.

Što isprobati.

1. Postavite stvarnu razliku na nulu i opišite oblik gornje raspodjele.
2. Podignite stvarnu razliku na 0,35 uz nepromijenjen uzorak.
3. Povećajte uzorak bez promjene razlike i usporedite udio rezultata ispod praga.
4. Spustite prag s 0,05 na 0,01 i pogledajte obje raspodjele.

Prvi korak otkriva svojstvo koje iznenađuje gotovo svakoga. Kad učinka nema, p-vrijednosti su ravnomjerno raspoređene po cijelom rasponu od nule do jedinice, pa je vrijednost od 0,03 pod nultim modelom jednako vjerojatna kao vrijednost od 0,53. Prag ne odvađa obično od neobičnog nego odsijeca unaprijed određen udio te ravnomjerne raspodjele, i taj udio je sve što prag jamči.

Dvije vrste pogreške

Postupak može pogriješiti na dva načina i nijedan se ne može ukloniti. Kad se odbaci nulta hipoteza koja je istinita, radi se o pogrešci prve vrste. Kad se ne odbaci nulta hipoteza koja je lažna, radi se o pogrešci druge vrste.

Definicija 29. Pogreška prve vrste je odbacivanje nulte hipoteze koja je istinita, a udio takvih odbacivanja u dugom nizu ponavljanja postupka jednak je odabranom pragu.

Ta se tvrdnja obično iznosi kao definicija, a u ovoj se knjizi može izmjeriti, jer je populacija poznata. Postavimo pitanje na koje unaprijed znamo odgovor. Razlikuju li se žene i muškarci po povjerenju u medije? U populaciji ta razlika iznosi 0,018 boda, dakle nule nema samo zato što je populacija konačna. Nulta hipoteza je za to pitanje praktički istinita.

Provedemo li isti permutacijski postupak na osamsto novih uzoraka od 300 osoba, prag od 0,05 prijeđe ih 5,0 %. Prag je dakle održao obećanje, i to je jedino obećanje koje daje.


Tablica 1: Udio uzoraka u kojima permutacijski postupak prelazi prag od 0,05, za dva pitanja s poznatim odgovorom. Osamsto uzoraka po pitanju, u svakome tristo premještanja. Izrada autora.

Pitanje	Stvarna razlika u populaciji	Udio odbacivanja
Razlika po spolu	0,02	5,0 %

Tablica 1: Udio uzoraka u kojima permutacijski postupak prelazi prag od 0,05, za dva pitanja s poznatim odgovorom. Osamsto uzoraka po pitanju, u svakome tristo premještanja. Izrada autora.

Pitanje	Stvarna razlika u populaciji	Udio odbacivanja
Razlika po izvoru vijesti	0,74	79,5 %

Drugi redak tablice nosi drugu vrstu pogreške. Razlika po izvoru vijesti u populaciji doista postoji i iznosi 0,74 boda, a postupak je pronalazi u 79,5 % uzoraka. U preostalih 20,5 % istraživač bi zaključio da nema dovoljno dokaza, i pritom bi se pridržavao svih pravila.



Slika 3: Raspodjela procijenjene razlike kad učinka nema i kad postoji, uz isprekidane crte na graničnim vrijednostima postupka.

Slika pokazuje zašto se dvije pogreške ne mogu istovremeno smanjivati. Granične crte određene su gornjom raspodjelom, a odsijecaju i donju. Pomaknemo li ih prema van kako bismo rjeđe pogriješili na prvi način, veći dio donje raspodjele ostaje između njih i postupak češće promašuje stvarnu razliku. Jedini način da oba udjela padnu jest

razmaknuti dvije raspodjele, a to se postiže većim uzorkom ili preciznijim mjerenjem, dakle odlukama iz dizajna, a ne izborom praga.

Koliki je uzorak za to potreban i kako se planira unaprijed, tema je sljedećeg poglavlja. Ovdje je dovoljno vidjeti da udio promašaja nije svojstvo testa nego posljedica dizajna, i da se o njemu odlučuje prije prikupljanja podataka.

Prag je konvencija, a ne mjera

Prag od 0,05 pojavljuje se u ovom poglavlju kao zadana vrijednost, a postupak ga ničim ne zahtijeva. Widget dopušta da se pomakne na 0,01 ili na 0,10 i ništa se u računu ne buni, jer prag samo određuje koliki udio nultog modela pristajemo odsjeći. Odabir je stvar dogovora struke i posljedica koje pogreška nosi, pa u području u kojem je lažni nalaz skup ima smisla biti stroži nego u području u kojem je propušten nalaz skuplji.

Iz toga slijedi da razlika između rezultata tik ispod praga i onoga tik iznad nije razlika u dokazu. Vrijednosti 0,048 i 0,052 gotovo su isti broj, a izvještaj koji jednu naziva nalazom, a drugu odsutnošću nalaza uvodi razliku koje u podacima nema. Upravo to je razlog zbog kojeg izjava Američkog statističkog udruženja traži da znanstveni zaključak ne ovisi samo o tome prelazi li p-vrijednost određeni prag (Wasserstein i Lazar 2016.).

Postoji i drugi razlog, koji se rijetko spominje, a lako se izmjeri. Ponovali smo pitanje o izvoru vijesti na osamsto uzoraka iz iste populacije, u kojoj razlika stvarno postoji i uvijek je jednaka. U polovici uzoraka p-vrijednost je bila ispod 0,003, u četvrtini iznad 0,033, a u desetini iznad 0,134. Ista populacija, isti postupak i ista veličina uzorka daju p-vrijednosti raspoređene preko dva reda veličine, pa je u 12,5 % uzoraka rezultat prešao i granicu od 0,10.

P-vrijednost je dakle i sama statistika koja se mijenja od uzorka do uzorka, i to snažnije od gotovo svake druge veličine u knjizi. Izvještaj koji je navodi na tri decimale sugerira preciznost koju ona nema, a

ponovljeno istraživanje s istim dizajnom lako proizvede vrijednost desetostruko drugačiju. Procjena i njezin interval pod ponavljanjem se ponašaju mnogo mirnije, i to je jedan od razloga zbog kojih u izvještaju stoje prvi.

Što p-vrijednost nije

Vratimo se pitanju o spolu, gdje odgovor unaprijed znamo. U našem uzorku razlika iznosi 0,15 boda uz interval od -0,30 do 0,60, a p-vrijednost je 0,53. Postupak je ovdje postupio ispravno, jer razlike doista nema.

Izvještaj koji bi iz toga zaključio da razlike nema rekao bi ipak previše. Interval dopušta razlike do gotovo pola boda u oba smjera, a to je raspon unutar kojeg bi se uredničke odluke razlikovale. Da je razlika u populaciji iznosila trećinu boda, ovaj bi uzorak jednako izgledao. Velika p-vrijednost znači da podaci nisu neusklađeni s nultim modelom, a ne da su s njime posebno usklađeni.

Najčešća pogreška ide u suprotnom smjeru i tiče se malih p-vrijednosti. Za naše pitanje o izvoru vjerojatnost od 0,016 odnosi se na podatke pod pretpostavljenim modelom, a ne na model pod opaženim podacima. To su dvije različite uvjetne vjerojatnosti, upravo one koje je poglavlje o vjerojatnosti razdvojilo, i njihova zamjena mijenja tvrdnju iz temelja.

Iz iste zamjene slijede još dvije rečenice koje treba prepoznati. P-vrijednost nije vjerojatnost da je nalaz nastao slučajno, jer se već računa pod pretpostavkom da jest. I nije mjera veličine učinka, jer ovisi o uzorku jednako koliko i o razlici, pa dovoljno velik uzorak proizvodi male vrijednosti i za razlike koje nikoga ne zanimaju.

Drugo pitanje i drugi račun

Pitanje koje istraživači zapravo imaju obično glasi koliko je vjerojatno da učinak postoji. Postupak iz ovog poglavlja na njega ne odgovara i

nije za njega ni napravljen. Odgovor na to pitanje traži nešto što test nigdje ne traži, a to je izjava o tome što se držalo vjerojatnim prije podataka.

Bayesovski pristup upravo tu izjavu zahtijeva. Istraživač unaprijed navodi koliko su mu koje vrijednosti učinka vjerojatne, podaci tu raspodjelu mijenjaju, i rezultat je nova raspodjela vjerojatnosti nad mogućim učincima. Iz nje se može očitati vjerojatnost da je učinak veći od nule ili veći od neke granice koja je sadržajno važna, dakle upravo ono što se od p-vrijednosti pogrešno očekuje.

Cijena je vidljiva i nije skrivena. Početnu raspodjelu netko mora postaviti i obrazložiti, a različiti izbori daju različite zaključke iz istih podataka. Za pristup koji se često predstavlja kao izlaz iz proizvoljnosti to je neugodna osobina, no ona je barem eksplicitna. U testiranju su pretpostavke jednako prisutne, samo se ne moraju izgovoriti.

Knjiga ostaje na frekvencijskom putu jer je to jezik kojim je napisana golema većina istraživanja koja čitatelj mora znati pročitati. Bayesovski račun ovdje ostaje pogled kroz prozor, s napomenom da odgovara na drugo pitanje i da mu za to treba dodatan ulaz. Poglavlje o regresiji na tu razliku se vraća u zaključnom pogledu unaprijed.

STATISTIKA U DIVLJINI

Popis od dvadeset pet. Sedmorica statističara objavila su u recenziranom časopisu popis od dvadeset pet pogrešnih tumačenja p-vrijednosti, intervala pouzdanosti i snage, uz obrazloženje svakoga (Greenland i sur. 2016.). Autori u istom radu tvrde da pogrešna tumačenja tih pojmova ostaju raširena unatoč desetljećima upozorenja i da ne postoji tumačenje koje bi istovremeno bilo jednostavno, intuitivno, ispravno i otporno na pogrešku.

Iz postojanja takvog popisa slijedi zaključak koji nije o nemaru. Pogreške se ponavljaju jer postupak odgovara na jedno pitanje, a čitatelju treba drugo, pa prijevod između njih mora obaviti netko drugi i najčešće ga nitko ne obavi. Isti rad upozorava i na to da mala p-vrijednost

može nastati i kad je nulti model točan, ako je analiza birana prema rezultatima koje daje, čime pomiče krivnju s pojedinačnog čitanja na cijeli postupak istraživanja. Popis dakle ne služi da bi se provjerila tuđa rečenica, nego da bi se prepoznalo koje pitanje analiza uopće može zatvoriti.

PITAJTE MODEL

Asistent pouzdano provede test i ispiše p-vrijednost, a rijetko sam postavi ono što mu prethodi. Prije poziva treba mu reći koja je jedinica opažanja i što nulti model tvrdi, jer iz tablice ne može zaključiti smiju li se oznake premještati slobodno. Provjeravamo tri stvari u odgovoru. Prva je redoslijed, jer procjena i interval moraju stajati ispred testa. Druga je rečenica kojom tumači p-vrijednost, koju vrlo često napiše kao vjerojatnost hipoteze. Treća je zaključak iz velike p-vrijednosti, koji redovito pretvara u tvrdnju da razlike nema.

Imenuj nulti model i jedinicu premještanja, izgradi nultu raspodjelu simulacijom i usporedi je s opaženom statistikom. Izvijesti procjenu s intervalom prije p-vrijednosti i napiši što bi rezultat značio da je stvarna razlika upola manja.

NADITE GREŠKU

Na pitanje razlikuju li se čitatelji tiska i portala po povjerenju u medije asistent je napisao ovu analizu.

```
razlika <- mean(tisak) - mean(portal)

nulte <- replicate(4000, {
  promijesano <- sample(skupina)
  mean(ishod[promijesano == "tisak"]) - mean(ishod[promijesano == "portal"])
})
```

```
mean(abs(nulte) >= abs(razlika))
```

Uz ispis je dodao obrazloženje. Oznake skupina premještene su četiri tisuće puta, a razlika ovoliku ili veću daje 1,6 % premještanja. Budući da je taj udio ispod praga, zaključuje da vjerojatnost da između dviju skupina nema razlike iznosi 1,6 %.

Razrađeni primjer

Cijeli se postupak može ispisati u nekoliko redaka, i vrijedi ga jednom vidjeti u cjelini. Analiza najprije računa opaženu razliku, zatim gradi nultu raspodjelu premještanjem oznaka, i na kraju prebrojava koliko je premještanja dalo barem toliko veliko odstupanje.

```
razlika <- mean(s10_ishod[s10_skupina == "tisak"]) -
  mean(s10_ishod[s10_skupina == "portal"])

nulte <- replicate(4000, {
  promijesano <- sample(s10_skupina)
  mean(s10_ishod[promijesano == "tisak"]) -
    mean(s10_ishod[promijesano == "portal"])
})

razlika
```

```
[1] 0,640939
```

```
mean(abs(nulte) >= abs(razlika))
```

```
[1] 0,01375
```

Funkcija `sample` bez dodatnih argumenata vraća isti niz oznaka u nasumičnom poretku, a `replicate` ponavlja izraz zadani broj puta

i skuplja rezultate. Cijeli nulti model stane u te dvije funkcije, bez ijedne pretpostavke o obliku raspodjele.

Izvještaj koji iz ovoga slijedi ima tri rečenice i njihov je redoslijed obvezan. Čitatelji tiska imaju u prosjeku 0,64 boda više povjerenja od čitatelja portala, uz interval od 0,17 do 1,11. Razliku ovoliku ili veću nulti model proizvodi u 1,6 % uzoraka. Podaci su promatrački i ljudi svoj izvor biraju sami, pa razlika opisuje dvije skupine, a ne učinak čitanja tiska.

Posljednja rečenica nije opreznost nego točnost. Test je odgovorio na pitanje o usklađenosti podataka s jednim modelom i ništa više od toga nije ni mogao. Ono što razlika znači, koliko je velika i vrijedi li na nju reagirati, ostaje otvoreno i vodi u sljedeće poglavlje.

Sažetak

Testiranje uspoređuje opaženi rezultat s onim što proizvodi precizno opisan svijet bez učinka, a nulta raspodjela za tu usporedbu gradi se premještanjem oznaka umjesto formulom. P-vrijednost je udio takvih rezultata barem toliko neusklađenih s nultim modelom kao opaženi, i ne kaže ni kolika je vjerojatnost hipoteze ni koliko je učinak važan. Dvije vrste pogreške povezane su tako da pomicanje praga jednu smanjuje, a drugu povećava, pa se obje snižavaju samo boljim dizajnom. Na poznatoj populaciji obje su stope izmjerene, i postupak je uz istinitu nultu hipotezu održao prag od pet posto, ali je stvarnu razliku od 0,74 boda propustio u svakom petom uzorku. Sljedeće poglavlje stavlja veličinu učinka i snagu ispred rituala značajnosti.

Pojmovi

nulta hipoteza (*null hypothesis*), alternativna hipoteza (*alternative hypothesis*), permutacijski test (*permutation test*), testna statistika (*test statistic*), p-vrijednost (*p-value*), pogreška prve vrste (*Type I error*), pogreška druge vrste (*Type II error*)

Zadaci

Konceptualni

Objasnite u jednom odlomku zašto p-vrijednost nije vjerojatnost nulte hipoteze, tako da napišete dvije rečenice koje se razlikuju samo po tome što je uvjet, a što zaključak. Imenujte podatak koji bi bio potreban da se od prve dođe do druge.

Računski

Nulta raspodjela iz ovog poglavlja ima sredinu nula i standardnu devijaciju 0,26 boda. Koristeći pravilo područja iz poglavlja o vjerojatnosti, procijenite koje bi razlike prelazile granicu od dviju standardnih devijacija, i usporedite svoju procjenu s graničnom vrijednošću 0,50 koju poglavlje navodi. Zatim u widgetu poglavlja postavite stvarnu razliku na nulu i opišite koliko uzoraka prelazi prag.

Kritički

Prosudite zašto je jednom strukovnom udruženju trebalo objaviti izjavu o pojedinačnom statističkom postupku, a skupini statističara popis od dvadeset pet pogrešnih tumačenja (Wasserstein i Lazar 2016.; Greenland i sur. 2016.). Predajte kratku uredničku bilješku i navedite jedno pravilo izvještavanja koje bi uklonilo najviše pogrešaka odjednom.

Revizija modela

Ocijenite analizu iz okvira o pogrešci. Imenujte korake koji su provedeni ispravno, redak koda iz kojeg izlazi izvještajna brojka, rečenicu koja iz nje ne slijedi i njezinu ispravljenu inačicu.

Veličina učinka i snaga

Koliki je učinak i koliko ga pouzdano vidimo

Vrijeme čitanja	Widget	Podaci	Preduvjet
22 min	Istraživač snage	simulirana populacija	pogl. 9, 10

VINJETA

Cohen je 1994. objavio kritiku prakse u kojoj je statistička značajnost zamijenila razmišljanje o veličini i važnosti učinka, pod naslovom koji je podsjećao da neke tvrdnje ne trebaju test (Cohen 1994.). Nije prigovarao računu. Prigovarao je tome što je jedan broj preuzeo posao prosudbe.

Prigovor je imao vrlo konkretan oblik. Recenzent koji pročita da je razlika značajna ne doznaje je li riječ o

pomaku koji bi promijenio nečiju odluku ili o razlici koju je otkrio samo dovoljno velik uzorak. Autor mu tu informaciju nije uskratio namjerno, nego zato što obrazac izvještavanja nije tražio da je napiše.

Koliko podataka trebamo da bismo pouzdano uočili učinak koji je vrijedan uočavanja?

Razlika koja nešto znači

Poglavlje nastavlja usporedbu iz prethodnog. Isti simulirani stanovnici, isto pitanje o povjerenju u medije među čitateljima tiska i portala, ali sada s punom populacijom umjesto uzorka, jer nas zanima što je istina, a ne kako je pogađamo.

Razlika iznosi 0,74 boda na ljestvici od jedan do deset. Ta brojka je najvažniji rezultat cijele usporedbe i mora stajati u izvornim jedinicama, jer se samo tako o njoj može odlučivati. Uredništvo koje razmišlja o preraspodjeli sadržaja treba znati govori li se o tri četvrtine boda ili o tri boda.

Sama razlika ipak ne kaže koliko je velika u odnosu na to kako su ljudi raspoređeni. Bod razlike znači jedno kad su svi odgovori zbijeni oko sredine, a nešto posve drugo kad se protežu preko cijele ljestvice. Standardizirana mjera tu usporedbu ugrađuje u sam broj.

Definicija 30. Standardizirana razlika je razlika dviju sredina podijeljena združenom standardnom devijacijom skupina, pa se izražava u standardnim devijacijama umjesto u izvornim jedinicama.

$$d = \frac{\bar{x}_2 - \bar{x}_1}{s_{\text{zdr}}}$$

Oznaka s_{zdr} stoji za združenu standardnu devijaciju, dakle za zajedničku mjeru raspršenosti unutar obje skupine.

Povjerenje se u ovoj populaciji raspršuje sa združenom standardnom devijacijom od 1,91 boda, pa razlika od 0,74 boda daje standardiziranu razliku od 0,39. Dvije skupine dakle dijeli nešto više od trećine standardne devijacije, što znači da se njihove raspodjele u najvećem dijelu preklapaju i da po jednom ispitaniku ne bi bilo moguće pogoditi odakle se informira.

Standardna devijacija kao mjerna jedinica ipak ostaje apstraktna, pa isti učinak vrijedi izraziti i na način koji se može zamisliti. Izvučemo li nasumce jednog čitatelja tiska i jednog čitatelja portala, prvi ima više povjerenja u 60,7 % slučajeva. Kad razlike ne bi bilo, taj bi udio iznosio pedeset posto, pa je učinak veličine kakvu ovdje gledamo pomak od desetak postotnih bodova u tako postavljenom pitanju. Rečenica tog oblika prolazi kroz uredničku raspravu bolje od bilo koje standardizirane mjere, jer nitko ne mora znati što je standardna devijacija da bi razumio ishod.

Orijentacijske vrijednosti za takve mjere postoje i najčešće se navode prema Cohenu, koji ih je ponudio kao pomoć u odsutnosti boljeg oslonca, a ne kao ljestvicu za očitavanje (Cohen 1988.). Što je učinak ove veličine sadržajno, odlučuje usporedba s drugim učincima u istom području i cijena postupanja, a ne tablica pragova. Standardizacija služi tome da se ta usporedba uopće može napraviti, jer razlike izmjerene u minutama, bodovima i postocima inače nemaju zajednički jezik.

Kad je značajno, a nije važno

Test odgovara na pitanje je li s podacima uskladiva i nula. To pitanje s veličinom učinka ima manje veze nego što se pretpostavlja, i najlakše se to vidi kad je uzorak vrlo velik.

Zamislimo portal koji uspoređuje dvije naslovnice. Prva ima stvarnu stopu klika od 2,00 %, druga od 2,05 %, a svaka je prikazana pola milijuna puta. Podaci ispod su konstruirani za ovu svrhu i nisu nalazni o kojoj stvarnoj kampanji.

U simuliranom pokusu prva je naslovnica postigla 1,976 %, a druga 2,076 %. Razlika iznosi 0,101 postotnog boda uz interval od 0,045 do 0,156, a p-vrijednost je 0,00036. Po svakom kriteriju iz prethodnog poglavlja rezultat je jasan, jer nulti model ovakvu razliku gotovo nikada ne proizvodi.

Prevedeno natrag u odluku, dobitak je jedan dodatni klik na otprilike tisuću prikaza. Isplati li se zbog toga mijenjati naslovnicu, ovisi o trošku promjene i o tome što jedan klik vrijedi, a ni jedno ni drugo nije u podacima. Statistička značajnost ovdje govori samo to da je uzorak bio dovoljno velik da razliku ove veličine odvoji od nule.

Ista logika radi i u suprotnom smjeru. Razlika koja bi promijenila uredničku odluku može ostati neznčajna ako je uzorak malen, i tada izostanak značajnosti ne govori o svijetu nego o količini prikupljenih podataka. Zbog toga se značajnost i važnost izvještavaju odvojeno, i zbog toga procjena s intervalom uvijek stoji ispred testa.

Snaga kao svojstvo plana

Vjerojatnost da postupak pronađe učinak koji postoji nije svojstvo testa nego kombinacije nekoliko odluka, od kojih se većina donosi prije podataka.

Definicija 31. Statistička snaga je vjerojatnost da postupak odbaci nultu hipotezu kad je ona lažna, dakle udio ponavljanja u kojima bi učinak zadane veličine bio otkriven.

Prethodno je poglavlje na ovoj populaciji izmjerilo da postupak stvarnu razliku pronalazi u otprilike četiri od pet uzoraka od tristo osoba. Ta brojka upravo je snaga, i sada je vrijedi izmjeriti na više veličina uzorka.

Tablica 1: Udio uzoraka u kojima permutacijski postupak prelazi prag od 0,05 pri stvarnoj razlici od 0,74 boda. Tristo simuliranih studija po retku. Izrada autora.

Jedinica u uzorku	Snaga
60	22,7 %
100	35,7 %
200	56,7 %
300	79,7 %
500	93,7 %
800	99,7 %


Rast nije ravnomjeran i to je najvažnije u tablici. Podizanje uzorka sa šezdeset na tristo osoba snagu diže s 22,7 % na 79,7 %, a svako daljnje ulaganje kupuje sve manje, jer je udio ograničen odozgo. Studija sa šezdeset osoba nije upola lošija od studije s tristo, nego je gotovo beskorisna za ovo pitanje.

Četiri stvari određuju gdje se na toj krivulji nalazimo. Veći stvarni učinak lakše se otkriva, veći uzorak daje precizniju procjenu, manja raspršenost ishoda čisti signal, a blaži prag propušta više rezultata. Prve dvije obično su jedine koje istraživač može mijenjati, i samo je druga u njegovim rukama nakon što je pitanje postavljeno.

Konvencija traži barem 80 %, i kao svaka konvencija služi kao polazište, a ne kao dokaz. Ako propuštena razlika nosi ozbiljnu posljedicu, osamdeset posto je premalo, a ako je istraživanje prvo u nizu i služi kao provjera izvedivosti, može biti previše.

Interakcija — Istraživač snage

Sljedeći prikaz odvađa tri odluke koje se u praksi donose zajedno. Čitatelj mijenja stvarnu veličinu učinka, broj jedinica i prag, svaki put samo jedno, i prati kako se pomiče udio uzoraka u kojima bi postupak nešto našao.



Slika 1: Simulirana snaga kroz veličine uzorka pri trima standardiziranim razlikama.

Što isprobati.


1. Zadržite učinak jednakim i povećavajte uzorak.
2. Zadržite uzorak jednakim i smanjujte učinak.
3. Spustite prag odluke i provjerite koliko je jedinica potrebno za istu snagu.
4. Postavite standardiziranu razliku na 0,10 i pokušajte dosegnuti 80 %.

Posljednji korak ne uspijeva unutar ponuđenog raspona, i to je poanta. Za male učinke potreban uzorak raste brže nego što većina istraživanja može podnijeti, pa odluka o tome koji je učinak vrijedan traženja mora doći prije odluke o uzorku.

Podsnažene studije pretjeruju

Uobičajena pouka o slaboj snazi glasi da se stvarni učinci propuštaju. To je točno, a nije najgori dio. Studija sa slabom snagom kvari i one nalaze koje proizvede, i to se na poznatoj populaciji može izmjeriti.

Ponovili smo isto pitanje na tri tisuće studija sa šezdeset osoba. Prosjek svih procjena iznosi 0,74 boda i praktički se poklapa sa stvarnom razlikom od 0,74, dakle postupak sam po sebi nije pristran.



Slika 2: Procijenjena razlika u tri tisuće studija sa šezdeset osoba, sve zajedno i samo one koje su prešle prag. Okomita crta označuje stvarnu razliku u populaciji.

Donji panel prikazuje ono što bi se objavilo. Među studijama koje su prešle prag prosječna procjena iznosi 1,50 boda, dakle 2,0 puta više od istine. Razlog je mehanički i nema veze s poštenjem istraživača. Uz slabu snagu prag prelaze samo uzorci u kojima je slučajnost razliku slučajno uvećala, jer manja procjena s ovako malim uzorkom prag ne može prijeći. Najmanja značajna procjena u ovoj simulaciji iznosi 0,84 boda.

Drugi smjer rjeđi je, ali nije nemoguć. Među značajnim nalazima 0,15 % ima suprotan predznak od stvarne razlike, dakle tvrdi da čitatelji portala imaju više povjerenja. Takav bi rad prošao recenziju jednako lako kao svaki drugi, jer je iznutra besprijekoran.

Ista simulacija s pet stotina osoba daje procjene koje istinu premašuju za faktor 1,03, dakle iskrivljenja praktički nema. Pretjerivanje nije svojstvo područja ni teme, nego posljedica toga što se prag primjenjuje na procjene koje su preraspršene za veličinu učinka koji se traži.

Za čitatelja objavljenih radova iz toga slijedi konkretan postupak. Kad rad na malom uzorku izvještava o velikom učinku uz p-vrijednost tik ispod praga, najvjerojatnije objašnjenje nije da je učinak zaista toliko nego da je uzorak propustio samo one procjene koje su slučajno ispale velike. Interval to obično odaje, jer se u takvim radovima proteže od jedva zamjetne do nevjerojatno velike vrijednosti. Zato se prvo gleda koliko je jedinica bilo i koliko je interval širok, a tek onda što piše u zaključku.

Planiranje unatrag

Iz svega prethodnog slijedi da uzorak nije stvar raspoloživosti nego odluke, i da ta odluka počinje na kraju.

Definicija 32. Najmanji važan učinak je najmanja razlika koja bi promijenila zaključak, odluku ili postupanje, određena sadržajno i prije prikupljanja podataka.

Postavlja ga istraživač, a ne račun, i obrazlaže se troškom postupanja, ozbiljnošću ishoda i onim što je u istom području već izmjereno. Tek kad je zapisan, pitanje o veličini uzorka ima odgovor, jer se snaga uvijek računa za neku određenu veličinu učinka.

Redoslijed je time obrnut od uobičajenog. Ne pita se koliko se ispitanika može prikupiti pa se nada da će biti dovoljno, nego se kreće od razlike koja bi nešto značila, dodaje se željena snaga, i iz toga izlazi broj jedinica. Ako je taj broj neizvediv, to je nalaz sam po sebi i treba ga znati prije istraživanja, a ne poslije.

Postoji i drugi način planiranja, bliži načelu po kojem je ova knjiga napisana. Umjesto da se pita koliko je jedinica potrebno da bi se prešao prag, pita se koliko ih je potrebno da bi procjena bila dovoljno precizna. Uz raspršenost iz ove populacije interval razlike širok je 1,06 boda pri stotinu ljudi po skupini, 0,61 pri tristo i 0,37 pri osamsto. Istraživač koji zna da mu je za odluku potrebna procjena unutar pola boda odatle čita odgovor izravno, bez ijedne pretpostavke o tome koliki je stvarni učinak.

Ta je razlika u pristupu važnija nego što izgleda. Planiranje prema snazi zahtijeva da se pogodi veličina učinka koji se traži, a upravo je ta veličina ono što se ne zna i zbog čega se istraživanje provodi. Planiranje prema preciznosti tu pretpostavku ne treba, jer širina intervala ovisi samo o raspršenosti i broju jedinica. Studija planirana na taj način ne obećava da će nešto naći, nego da će, što god nađe, biti dovoljno precizno da se o tome može odlučivati.

Razrađeni primjer

Pretpostavimo da bi uredništvo reagiralo na razliku od pola boda i da očekuje raspršenost sličnu onoj u ovoj populaciji. Analiza ispod za nekoliko veličina uzorka broji u kolikom udjelu simuliranih studija bi takva razlika bila otkrivena.

```
najmanji_ucinak <- 0.5
rasprsenost <- 1.9

snaga_za <- function(n) {
  mean(replicate(2000, {
    prva <- rnorm(n, 0, rasprsenost)
    druga <- rnorm(n, najmanji_ucinak, rasprsenost)
    razlika <- mean(druga) - mean(prva)
    abs(razlika) / sqrt(2 * rasprsenost^2 / n) >= 1.96
  })))
}

plan <- sapply(c(100, 150, 200, 250), snaga_za)
plan
```

```
[1] 0,4620 0,6350 0,7505 0,8325
```

Funkcija `replicate` ponavlja cijelu zamišljenu studiju dvije tisuće puta, a `sapply` isti račun provodi za svaku ponuđenu veličinu uzorka.

Granica 1,96 dolazi iz pravila područja koje uvodi poglavlje o vjerojatnosti, pa se ovdje ništa novo ne pretpostavlja.

Tablica 2: Udio simuliranih studija u kojima bi razlika od pola boda bila otkrivena, pri četirima veličinama uzorka po skupini. Izrada autora.

Jedinica po skupini	Snaga
100	46,2 %
150	63,5 %
200	75,0 %
250	83,2 %

Za razliku od pola boda treba između dvjesto i dvjesto pedeset ljudi po skupini da bi se dosegla uobičajena granica od osamdeset posto. Ako uredništvo može prikupiti stotinu, plan je i dalje moguć, ali izvještaj mora unaprijed reći da će studija razliku te veličine propustiti u više od polovice slučajeva.

Račun ne odlučuje ništa od onoga što je važno. Pola boda kao granicu postavio je netko tko zna što se s tom razlikom radi, raspršenost je procijenjena iz ranijih mjerenja, a odustajanje ispitanika i kvaliteta mjerenja nisu ni ušli u simulaciju. Ono što račun daje jest jedini pošten oblik rečenice o uzorku, u kojem broj jedinica stoji uz učinak koji se njime može uočiti.

STATISTIKA U DIVLJINI

Neuspjeh snage. Skupina istraživača objavila je pregled u kojem tvrdi da je prosječna statistička snaga studija u neuroznanosti vrlo niska, i da posljedice toga uključuju precijenjene veličine učinka i slabu ponovljivost rezultata (Button i sur. 2013.). Rad je naslovljen kao neuspjeh snage i čitan je najčešće kao poziv na veće uzorke.

Ono što se u tom čitanju gubi jest drugi dio tvrdnje. Niska snaga ne smanjuje samo izgleda da se pravi učinak pronađe, nego smanjuje i vjerojatnost da statistički značajan nalaz odgovara stvarnom učinku.

To je ista mehanika koju simulacija u prethodnom odjeljku mjeri, gdje su procjene koje su prešle prag u prosjeku dvostruko veće od istine. Iz toga slijedi da podsnaženo područje ne proizvodi samo manje nalaza nego i lošije, pa preporuka nije čitati takve radove opreznije, nego ne vjerovati veličini učinka koju objavljuju.

PITAJTE MODEL

Asistent pouzdano izračuna standardiziranu razliku i provede analizu snage, a sam ne zna ono što u nju ulazi. Prije poziva mu treba dizajn, očekivana raspršenost ishoda i najmanji učinak koji bi nešto značio, jer bez posljednjega snaga nema referencu. Provjeravamo tri stvari. Prva je koristi li nazivnik koji odgovara dizajnu, budući da se kod uparenih mjerenja dijeli standardnom devijacijom razlika. Druga je uzima li konvencionalne pragove kao sadržajnu činjenicu i naziva li učinak malim prije nego što je pitao o čemu se radi. Treća je računa li snagu iz učinka koji je već opažen, što je najčešća i najskuplja pogreška u ovom području.

Reci mi koji ulaz nedostaje prije nego što izračunaš snagu.
Zatim izračunaj potreban uzorak za nekoliko veličina učinka
i pokaži koliko se odgovor mijenja ako je stvarni učinak
upola manji od pretpostavljenog.

NADITE GREŠKU

Nakon male studije s tridesetero ljudi po skupini asistent je uz nalaz priložio i ovu provjeru.

```
d_opazeni <- (mean(tisak) - mean(portal)) / sd_zdruzena

power.t.test(n = 30, delta = d_opazeni, sd = 1,
             sig.level = 0.05, type = "two.sample")
```

Uz ispis je dodao obrazloženje. Opažena razlika daje standardiziranu razliku oko 0,78, a snaga izračunata za tu vrijednost i trideset ljudi po skupini iznosi 0,84. Budući da je snaga iznad uobičajene granice, zaključuje da je studija bila dovoljno velika i da se procijenjenoj razlici može vjerovati.

Sažetak

Veličina učinka vraća pitanju koliko je razlika velika, a standardizirana mjera čini je usporedivom preko različitih ljestvica. Statistička značajnost i praktična važnost odgovaraju na različita pitanja, pa golem uzorak proizvodi značajnost za razlike koje nikoga ne zanimaju, dok premali uzorak propušta one koje bi promijenile odluku. Snaga povezuje učinak, uzorak, raspršenost i prag, a mjerenje na poznatoj populaciji pokazuje koliko brzo pada kad uzorak popusti. Studije sa slabom snagom pritom ne griješe samo propuštanjem, jer među njihovim objavljenim nalazima procjene su u prosjeku dvostruko veće od istine, a poneka ima i pogrešan predznak. Sljedeće poglavlje pokazuje što se događa kada sustav nagrađuje objavljeni nalaz, a skriva cijeli put koji je do njega doveo.

Pojmovi

veličina učinka (*effect size*), standardizirana razlika (*Cohen's d*), praktična važnost (*practical significance*), statistička snaga (*statistical power*), najmanji važan učinak (*smallest effect size of interest*), planiranje uzorka (*sample size planning*)

Zadaci

Konceptualni

Objasnite u jednom odlomku zašto među objavljenim nalazima podnaženih studija procjene učinka sustavno premašuju istinu, iako nije-

dan pojedinačni istraživač nije napravio ništa nedopušteno. Imenujte korak u kojem nastaje iskrivljenje.

Računski

Dvije skupine imaju sredine 5,4 i 4,6 uz združenu standardnu devijaciju 1,9. Izračunajte razliku i standardiziranu razliku, a zatim ponovite račun uz združenu standardnu devijaciju 3,8. Objasnite koja se od dviju brojki promijenila i zašto. Zatim u widgetu poglavlja pronadite koliko je jedinica po skupini potrebno da se manja od dviju standardiziranih razlika otkrije u četiri od pet pokušaja.

Kritički

Prosudite tvrdnju da niska prosječna snaga nekog područja znači samo da istraživanja propuštaju stvarne učinke (Button i sur. 2013.). Predajte kratku uredničku bilješku i navedite podatak koji bi vam trebao da procijenite koliko je objavljena veličina učinka precijenjena.

Revizija modela

Ocijenite provjeru iz okvira o pogrešci. Imenujte što je u pozivu ispravno, argument u kojem stoji kružnost, redak koda u kojem ona ulazi u račun, i napišite čime bi taj argument trebalo zamijeniti.

Kriza i obnova

Kako se znanstveni zaključci mogu popraviti

Vrijeme čitanja	Widget	Podaci	Preduvjet
6 min	Pješčanik p-hakiranja	simulacija	pogl. 10, 11

VINJETA

Velika suradnja istraživača pokušala je ponoviti niz objavljenih psiholoških studija prema zajedničkom protokolu. Replikacijski rezultati u cjelini bili su slabiji od slike koju je ostavljala izvorna literatura (Open Science Collaboration 2015.). Rasprava koja je slijedila nije se mogla svesti na podjelu između dobrih i loših istraživača. Objavljivanje je dugo nagrađivalo nov, jasan i statistički značajan rezultat. Istraživači su istodobno donosili mnogo

odluka o uzorku, ishodima, podskupinama i modelima. Čak i bez svjesne prevare, fleksibilan put kroz podatke mogao je završiti pričom koja izgleda unaprijed planirana (Simmons i sur. 2011.; Gelman i Loken 2013.).

Kako znanstveni sustav može učiniti vlastite rezultate provjerljivijima bez pretvaranja skepticizma u cinizam?

Putovi koji ostaju nevidljivi

P-hakiranje obuhvaća prilagođavanje analize sve dok se ne pojavi poželjan rezultat. Može uključivati promjenu ishoda, pravila isključivanja, trenutka zaustavljanja ili skupa kontrolnih varijabli. Svaka odluka može imati razumno obrazloženje, ali njihova kombinacija mijenja vjerojatnost konačnog nalaza (Simmons i sur. 2011.).

Vrt račvajućih putova širi problem. Istraživač ne mora isprobati deset analiza i sakriti devet. Podaci mogu usmjeriti jednu odabranu analizu kroz niz odluka koje bi bile drukčije da su podaci izgledali drukčije (Gelman i Loken 2013.). Konačni tekst pokazuje samo put kojim se prošlo, ne sve putove koji su bili mogući.

Publikacijska pristranost zatim djeluje na razini literature. Rezultati koji izgledaju jasni i novi lakše postaju vidljivi, dok neodređeni i neuspjeli pokušaji ostaju u ladicama. Metaanaliza tada može precizno sažeti odabrani dio istraživačkog zapisa i dati varljiv osjećaj stabilnosti.

Reforma kao promjena postupka

Predregistracija vremenski odvaja plan od ishoda. Ona ne jamči dobar plan ni istinito mjerenje, ali čitatelju pokazuje koje su odluke donesene prije gledanja podataka. Registrirani izvještaj ide dalje jer se pitanje i metoda vrednuju prije nego što je rezultat poznat.

Otvoreni podaci, materijali i kod omogućuju provjeru i ponavljanje. Otvorenost ne uklanja etičke i privatnosne granice. Podaci o ljudima ne postaju sigurni samim objavljivanjem, pa transparentnost mora uključiti razloge zbog kojih neki materijali ne mogu biti javni.

Replikacija nije glasanje o tome je li izvorni autor bio u pravu. Rezultati se mogu razlikovati zbog uzoračke varijacije, konteksta, mjerenja ili stvarne heterogenosti učinka. Obnova zato traži kumulativno čitanje procjena i uvjeta, a ne zamjenu jednog spektakularnog nalaza drugim.


Asistent u dvostrukoj ulozi

Generativni modeli mogu ubrzati izradu koda, provjeru tablica i usporedbu izvještaja s analizom. Isti kapacitet može proizvoditi uvjerljive izvore koji ne postoje, sintetičke rukopise i velik broj varijanti iste tvrdnje. Brzina pojačava i provjeru i proizvodnju šuma.

Disciplina rada s asistentom zato mora ostaviti trag. Čuvamo ulazne podatke, upit, kod, verziju alata i ručnu provjeru. Model ne dobiva osjetljive ispitanikove podatke, a njegov tekst ne postaje izvor. Izvor ostaje publikacija, skup podataka ili reproducibilan postupak koji se može otvoriti bez modela.

Interakcija — Pješčanik p-hakiranja

Pješčanik omogućuje biranje ishoda, podskupina i trenutka zaustavljanja na podacima bez stvarnog učinka. Čitatelj promatra kako rast broja odluka povećava priliku za privlačan rezultat i kako korekcija za cijeli postupak mijenja sliku. Radi preglednosti svaki je analitički put u simulaciji neovisan. Stvarni putovi često dijele podatke, ali idealizacija izdvaja cijenu njihova broja.



Slika 1: Vjerojatnost barem jednog rezultata ispod praga raste s brojem neovisnih analitičkih putova.

Što isprobati.

1. Provedite jednu unaprijed određenu analizu.
2. Dodajte ishode, a podskupine i trenutke provjere ostavite jednakima.
3. Dodajte podskupinske inačice i trenutke provjere bez promjene broja ishoda.
4. Usporedite nominalni prag 0,05 s pragom korigiranim za sve putove.

Najmanja p-vrijednost nije sažetak jedne unaprijed određene analize kada je nastala pretraživanjem. Zaključak tada mora opisati cijeli skup mogućnosti ili koristiti postupak koji njihov broj uzima u obzir.

STATISTIKA U DIVLJINI

Replikacija kao zajedničko mjerenje. Open Science Collaboration koristio je zajednički postupak za procjenu reproducibilnosti niza psiholoških nalaza (Open Science Collaboration 2015.). Rezultat nije jednostavna stopa istine jer se izvorne i replikacijske studije razlikuju u preciznosti, kontekstu i mogućim učincima.

Vrijednost projekta leži i u tome što je privatni problem pojedinačnih sumnji pretvorio u podatke o sustavu. Čitatelj može procjenjivati obrasce bez pretpostavke da svaki neuspjeh ima isti uzrok.

PITAJTE MODEL

Asistent može usporediti registrirani plan, kod i rukopis te označiti neslaganja. Ne smije izmišljati nedostajuće datoteke ni procjenjivati reproducibilnost samo prema tonu teksta. Svaki nalaz mora imati put do retka koda, tablice ili dokumenta.

Usporedi istraživački plan, analitički kod i izvještaj. Navedi svako odstupanje s točnim mjestom u dokumentima i odvoji potvrđene razlike od informacija koje nedostaju.

NADITE GREŠKU

Studija je predregistrirala ishod, pravilo isključivanja i model prije prikupljanja podataka. Kod i anonimizirani materijali dostupni su za provjeru. Zbog predregistracije rezultat mora biti istinit.

Razrađeni primjer

Simuliramo podatke bez stvarne grupne razlike, ali s više mogućih ishoda. Analitičar koji prijavi samo najmanju p-vrijednost prikazuje

rezultat jedne odabrane analize, dok je stvarni postupak uključivao mnogo prilika (Simmons i sur. 2011.).

Tablica 1: Najmanja p-vrijednost među simuliranim ishodima bez učinka. Izrada autora prema Simmons i sur. (2011.).

ishod	p
17	0,004
8	0,007
16	0,089
11	0,094
7	0,112
15	0,179

Tablica je jedna realizacija simulacije i ne mora svaki put sadržavati privlačan rezultat. Upravo je to poanta. Kada se cijeli postupak ponavlja, neki će nizovi ponuditi malu p-vrijednost bez učinka. Predregistracija, izvještavanje svih ishoda i korekcija za višestrukost čine tu priliku vidljivom.

Reforma ne traži da prestanemo istraživati neočekivane obrasce. Traži da razlikujemo potvrđujuću analizu od naknadnog istraživanja i da novu hipotezu predstavimo kao početak sljedeće provjere.

Sažetak

Križa reproducibilnosti nastaje iz spoja uzoračke varijacije, analitičke fleksibilnosti i poticaja koji nagrađuju jasan pozitivan nalaz. Predregistracija, registrirani izvještaji i otvoreni materijali povećavaju vidljivost postupka, ali ne jamče istinu. Replikacija procjenjuje stabilnost nalaza kroz nove podatke i uvjete. Asistent može pomoći u provjeri samo kada njegov rad ostaje reproducibilan, provjerljiv i odvojen od izvora.

Pojmovi

p-hakiranje (*p-hacking*), vrt račvajućih putova (*garden of forking paths*), publikacijska pristranost (*publication bias*), predregistracija (*preregistration*), registrirani izvještaj (*registered report*), replikacija (*replication*), otvorena znanost (*open science*)

Zadaci

Konceptualni

Razlikujte p-hakiranje od vrta račvajućih putova. Predajte dva kratka scenarija koja pokazuju razliku (Simmons i sur. 2011.; Gelman i Loken 2013.).

Računski

Ponovite simulaciju `sim_putovi` mnogo puta i predajte raspodjelu najmanjih p-vrijednosti.

Kritički

Prosudite što veliki replikacijski projekt može reći o literaturi, a što ne može o svakoj pojedinačnoj studiji (Open Science Collaboration 2015.). Predajte dva odlomka.

Revizija modela

Ocijenite modelsku analizu iz okvira. Imenujte dvije dobre prakse, jednu pretjeranu tvrdnju i ograničenje koje ostaje nakon predregistracije.

DIO V: MODELI

Kategorički podaci

Od frekvencija u ćelijama do obrazaca povezanosti

Vrijeme čitanja	Widget	Podaci	Preduvjet
24 min	Očekivano i opaženo	simulirana populacija	pogl. 4, 8, 10

VINJETA

Sveučilište u Berkeleyju našlo se sredinom sedamdesetih pred pitanjem na koje je moralo odgovoriti brojkama. Zbirna tablica prijava za poslijediplomski studij pokazivala je da je udio primljenih muškaraca osjetno veći od udjela primljenih žena, a takva se tablica čita brzo i zaključuje još brže (Bickel i sur. 1975.).

Ono što je tablica sadržavala bile su samo frekvencije. Četiri broja u dvije kategorije, bez ijedne informacije o tome kako je do njih došlo. Pitanje pred istraživačima nije bilo je li razlika velika, nego što bi se u tim ćelijama uopće trebalo nalaziti da spol i ishod prijave nemaju nikakve veze.

Kako iz same tablice brojanja prepoznati postoji li veza, gdje se ona nalazi i koliko je snažna?

Brojanje prije testiranja

Kategoričke varijable ne mjere količinu nego pripadnost. Dobna skupina, izvor vijesti, obrazovanje i regija razvrstavaju ljude u kutije, a jedino što se s kutijama može učiniti jest prebrojati ih. Sve što slijedi u ovom poglavlju izvedeno je iz tih brojeva, pa je vrijedno zadržati se na tome koliko se lako prebrojavanje pokvari.

Frekvencija govori koliko je jedinica u nekoj kategoriji. Udio istu tu frekvenciju stavlja u odnos prema nazivniku, i tek s nazivnikom postaje čitljiv. Rečenica da četrdeset posto ispitanika bira društvene mreže znači nešto sasvim drugo ako je nazivnik cijeli uzorak, ako je to samo najmlađa dobna skupina ili ako su to samo oni koji su na pitanje uopće odgovorili. Nazivnik se u izvještajima izostavlja češće nego bilo koji drugi element, a bez njega se udio ne može provjeriti.


Prije nego što se bilo što prebroji, netko je odlučio koje kutije postoje. Dobne skupine mogle su biti podijeljene na drugim granicama, izvori vijesti razvrstani u tri kategorije umjesto u pet, a portal i društvena mreža smješteni zajedno ili razdvojeno. Ta odluka pripada operacionalizaciji iz poglavlja o mjerenju i dizajnu, i donesena je prije podataka. Svaki rezultat u ovom poglavlju vrijedi uz nju, jer test

uspoređuje raspored unutar zadanih kategorija i ne može propitati kategorije same.

Definicija 33. Kontingencijska tablica je tablica frekvencija u kojoj svaka ćelija sadrži broj jedinica koje istovremeno pripadaju jednoj kategoriji retka i jednoj kategoriji stupca.

Za dvije kategoričke varijable takva tablica sadrži cijelu zajedničku raspodjelu. Rubni zbrojevi po retcima daju raspodjelu prve varijable, rubni zbrojevi po stupcima raspodjelu druge, a ćelije govore kako se te dvije raspodjele preklapaju. Poglavlje radi na simuliranoj populaciji iz koje je izvučeno 800 osoba, i sve brojke u njemu potječu iz tog uzorka.

Postoci po retku i postoci po stupcu odgovaraju na različita pitanja i nisu zamjenjivi. Postotak po retku pita kako se unutar jedne dobne skupine dijele izvori vijesti. Postotak po stupcu pita kako je unutar jednog izvora raspoređena dob. Prvi je ovdje pravi jer skupine nisu jednako brojne, pa apsolutne frekvencije ne bi bile usporedive.



Slika 1: Udio pojedinog izvora vijesti unutar svake dobne skupine u simuliranom uzorku od osamsto osoba.

Obrazac je postupan i ide u jednom smjeru. Među osobama od 18 do 29 godina društvene mreže bira 42,1 % ispitanika, a među osobama od 60 i više godina 2,2 %. Televizija ide suprotno, s 12,2 % u najmlađoj i 45,2 % u najstarijoj skupini. Graf je uvjerljiv, ali uvjerljivost nije dokaz, jer bi i uzorak izvučen iz populacije bez ikakve veze proizveo neki obrazac.

Očekivano pod nezavisnošću

Da bismo znali je li opaženi raspored neobičan, treba nam raspored s kojim ga uspoređujemo. Taj se raspored ne pogađa nego izvodi iz same tablice, i to iz onog njezina dijela koji nije sporan. Rubni zbrojevi kažu koliko je ljudi u svakoj dobnoj skupini i koliko ih ukupno bira svaki izvor. Ta dva popisa uzimamo kao zadana i pitamo se kako bi izgledale ćelije kad pripadnost dobnoj skupini ne bi mijenjala ništa u izboru izvora.

Odgovor je jednostavan koliko i sama pretpostavka. Ako televiziju bira petina cijelog uzorka, i ako dob nema nikakve veze s izborom, onda bi televiziju trebala birati petina svake dobne skupine. Očekivani broj za jednu ćeliju zato je udio njezina stupca primijenjen na veličinu njezina retka.

Definicija 34. Očekivana frekvencija ćelije je umnožak zbroja njezina retka i zbroja njezina stupca podijeljen ukupnim brojem jedinica, dakle broj koji bi se u toj ćeliji nalazio kad bi dvije varijable bile nezavisne uz nepromijenjene rubne zbrojeve.

$$E_{ij} = \frac{n_{i.} \times n_{.j}}{n}$$

Oznaka $n_{i.}$ stoji za zbroj i-tog retka, $n_{.j}$ za zbroj j-tog stupca, a n za ukupan broj jedinica u tablici.

Nezavisnost ovdje ima uzak i provjerljiv smisao. Znati nečiju dobnu skupinu ne pomaže u pogađanju njezina izvora vijesti. Model nezavis-


nosti nije tvrdnja o svijetu nego račun koji svijet privremeno pretpostavlja takvim, kako bi se izmjerilo koliko podaci od njega odstupaju.

Najmanja očekivana frekvencija u našoj tablici iznosi 14,3, što je važno zapamtiti za kasniji odjeljak o granicama postupka. Za sada je dovoljno da nijedna ćelija nije toliko rijetka da bi račun postao nepouzdan.

Interakcija — Očekivano i opaženo

Sljedeći prikaz zadržava rubne zbrojeve nepromijenjenima i dopušta pomicanje opaženih frekvencija oko očekivanih. Vidljivo postaje ono što tablica brojeva skriva, a to je da svaka ćelija ima vlastiti doprinos ukupnom odstupanju i da taj doprinos ne raste jednako brzo za velike i za male ćelije. Puni krug označuje opaženu frekvenciju, prazni romb očekivanu, a broj uz njih doprinos te ćelije.

◊ prazni romb: očekivano · ● puni krug: opaženo · broj: doprinos ćelije



Slika 2: Opažene i očekivane frekvencije pri trima odstupanjima uz jednake rubne zbrojeve.

Što isprobati.

1. Postavite opažene frekvencije jednake očekivanima i pogledajte doprinose.
2. Pomaknite opažanja u oba smjera i provjerite ostaju li rubni zbrojevi jednaki.
3. Povećajte pomak i pratite koliko brže raste ukupno odstupanje od pomaka.
4. Zadržite pomak u postocima, a smanjite rubni zbroj na deset.

Posljednji korak pokazuje ono što se u tablici brojeva ne vidi. Isti relativni pomak u maloj ćeliji daje mnogo manji doprinos nego u velikoj, jer se svako odstupanje dijeli očekivanom frekvencijom. Postupak zato ne mjeri koliko je razlika velika u postocima nego koliko je malo vjerojatna uz zadane rubne zbrojeve.

Zbroj odstupanja i njegov raspored

Ono što je widget prikazivao po ćelijama sada dobiva ime. Za svaku ćeliju uzimamo razliku opažene i očekivane frekvencije, kvadriramo je da se odstupanja u dva smjera ne ponište, i dijelimo očekivanom frekvencijom da veliki i mali brojevi budu usporedivi. Zbroj svih tih doprinosa jedna je brojka koja opisuje cijelu tablicu.

Definicija 35. Hi-kvadrat statistika je zbroj kvadriranih odstupanja opaženih od očekivanih frekvencija, pri čemu je svako odstupanje podijeljeno očekivanom frekvencijom svoje ćelije.

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Oznaka O_{ij} stoji za opaženu, a E_{ij} za očekivanu frekvenciju ćelije u i -tom retku i j -tom stupcu.

Za našu tablicu ta statistika iznosi 149,8 uz 12 stupnjeva slobode, gdje se stupnjevi slobode računaju kao umnožak broja redaka umanjenog za jedan i broja stupaca umanjenog za jedan.

Taj se umnožak lako pamti, ali ga vrijedi i razumjeti, jer stoji iza svakog kasnijeg testa u knjizi. Rubni zbrojevi su fiksirani, pa se ćelije ne mogu puniti neovisno jedna o drugoj. U tablici s dva retka i dva stupca dovoljno je odabrati jednu ćeliju, a preostale tri su njome određene. U našoj tablici s četiri retka i pet stupaca slobodno je 12 ćelija, a ostalih osam slijedi iz njih i iz rubova. Stupnjevi slobode zato broje koliko je tablica zaista mogla biti drugačija, i upravo o tome ovisi koliko je veliko odstupanje potrebno da bi bilo neobično.

Sama veličina te brojke ne govori mnogo dok se ne usporedi s onim što bi odstupanje bilo kad veze ne bi bilo. Tu usporedbu obavlja hi-kvadrat raspodjela, i ona vraća p-vrijednost na uobičajen način. Prag koji dijeli obično od neobičnog uz jedan stupanj slobode iznosi 3,84, a raste sa svakim dodatnim stupnjem.

Ukupna brojka ima jedno ozbiljno ograničenje. Ona kaže da tablica nije usklađena s nezavisnošću, ali ne kaže koje su ćelije za to odgovorne. Povratak na ćelije obavlja se dijeljenjem svakog odstupanja korijenom njegove očekivane frekvencije.

Definicija 36. Standardizirani rezidual ćelije je razlika opažene i očekivane frekvencije podijeljena korijenom očekivane frekvencije, pa se očitava na ljestvici sličnoj standardiziranim vrijednostima.

$$e_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}}}$$

Oznaka e ovdje stoji za ostatak, a ne za korelaciju, koju knjiga bilježi slovom r i koja s ovim računom nema veze.

Pozitivan rezidual znači da je u ćeliji više opažanja nego što bi ih bilo bez veze, a negativan da ih je manje. Vrijednosti izvan raspona od minus dva do plus dva uobičajeno se čitaju kao ćelije koje nose odstupanje, uz istu opreznost s kojom se čita svaki prag.

U našoj tablici najveći pozitivni rezidual pripada televiziji u skupini od 60 i više godina i iznosi 5,33. Najveći negativni pripada društvenim mrežama u istoj skupini i iznosi -5,25. U najmlađoj skupini predznaci

su obrnuti, s 4,95 za društvene mreže i -3,19 za televiziju. Reziduali time pretvaraju jednu brojku o cijeloj tablici u tvrdnju o tome tko točno odstupa i u kojem smjeru, što je oblik nalaza koji se uopće može upotrijebiti.

Značajno nije isto što i snažno

Hi-kvadrat statistika raste s veličinom uzorka. Ista tablica postotaka izmjerena na osam tisuća ljudi umjesto na osamsto dat će deset puta veću statistiku i p-vrijednost koja se više ne može ispisati. Iz toga slijedi da p-vrijednost ne može biti mjera jačine veze, jer se mijenja i kad se veza uopće ne mijenja.

Mjera jačine mora zato dijeliti statistiku veličinom uzorka i oblikom tablice. Cramérovo V upravo to čini i vraća broj između nule i jedinice, gdje nula znači potpunu nezavisnost, a jedinica da jedna varijabla u potpunosti određuje drugu.

Definicija 37. Cramérovo V je korijen hi-kvadrat statistike podijeljene umnoškom veličine uzorka i manje dimenzije tablice umanjene za jedan.

$$V = \sqrt{\frac{\chi^2}{n(k-1)}}$$

Oznaka n stoji za ukupan broj jedinica, a k za manji od broja redaka i broja stupaca.

Za našu tablicu V iznosi 0,25. Orijentacijske vrijednosti za takve mjere postoje i najčešće se navode prema Cohenu, ali ih je i sam izvor ponudio kao pomoć u odsutnosti boljeg oslonca, a ne kao ljestvicu za očitavanje (Cohen 1988.). Sadržajno značenje broja dolazi iz usporedbe s drugim vezama u istom području, ne iz tablice pragova.

Korisniji od svakog praga jest prijevod natrag u postotke. Ako televiziju bira 12,2 % najmlađih i 45,2 % najstarijih ispitanika, onda je to razlika koju uredništvo može upotrijebiti pri odluci o rasporedu

resursa. Cramérovo V toj odluci ne dodaje ništa što postoci već ne govore, ali čuva usporedivost među tablicama različitih veličina.

Referentna raspodjela je istraživačka odluka

Do sada je referentna raspodjela dolazila iz same tablice, jer su je odredili rubni zbrojevi. Postoji i drugi oblik istog postupka, u kojem se raspodjela jedne varijable uspoređuje s raspodjelom zadanom izvana. Naziva se testom prilagodbe i računa se istom formulom, s očekivanim frekvencijama koje dolaze iz pretpostavljenih udjela umjesto iz umnoška rubova.

Ovdje se otvara pitanje koje se u nastavi lako previdi. Očekivane frekvencije ovise o tome što smo odabrali za referenciju, pa ista opažena raspodjela može biti u skladu s jednom pretpostavkom i u snažnom neskladu s drugom. Naš uzorak to pokazuje na raspodjeli obrazovanja.

Prva pretpostavka jest da su četiri razine obrazovanja jednako zastupljene. Uz nju statistika iznosi 209,3 i nesklad je golem. Druga pretpostavka koristi stvarne udjele populacije iz koje je uzorak izvučen. Uz nju statistika pada na 1,77, a p -vrijednost iznosi 0,62, što znači da uzorak dobro odražava populacijsku strukturu.

Isti podaci, dva potpuno različita zaključka, i nijedan račun nije pogrešan. Razlika je u tome što tvrdimo. Prvi test odbacuje pretpostavku koju nitko nije imao razloga postaviti, a drugi provjerava tvrdnju koja doista nešto znači. Budući da je populacija u ovom poglavlju simulirana i time poznata, znamo koja je referencija istinita, što je luksuz kakav stvarno istraživanje nema. U njemu izbor referentne raspodjele nosi istraživač, i taj se izbor obrazlaže prije nego što se test provede.

Kad je aproksimacija tanka

Hi-kvadrat postupak ne računa točnu vjerojatnost nego se oslanja na to da se raspodjela njegove statistike dovoljno dobro poklapa s

hi-kvadrat krivuljom. To poklapanje ovisi o tome koliko su ćelije popunjene, i slabi kad su očekivane frekvencije male. Umjesto da se to primi na vjeru, može se izmjeriti.

Postupak je isti kao u poglavlju o uzorkovanju. Konstruiramo situaciju u kojoj veze zaista nema, izvučemo mnogo tablica i pogledamo kako se statistika ponaša. Sve što tada padne ispod praga p-vrijednosti je pogreška, jer po konstrukciji nema što otkriti.

Kad su očekivane frekvencije velike, poklapanje je dobro. Vrijednost ispod koje leži devedeset pet posto simuliranih statistika iznosi 3,77 i praktički se podudara s teorijskom granicom od 3,84, a udio odbacivanja iznosi 4,9 % umjesto očekivanih pet.

Kad su očekivane frekvencije oko dvije, poklapanja više nema. Ista vrijednost pada na 3,45 i time ispod granice, pa test odbacuje samo 3,4 % puta. U ovoj tablici iskrivljenje ide prema opreznosti, ne prema prekomjernom otkrivanju. To je korisno znati jer se pravilo o malim ćelijama često prenosi kao zaštita od lažnih nalaza, a ovdje je zapravo zaštita od nalaza koji se neće pojaviti ni kad postoji.

Za male tablice postoji postupak koji aproksimaciju uopće ne koristi. Fisherov egzaktni test prebroji sve rasporede koji su mogući uz zadane rubne zbrojeve i izračuna koliko je njih barem toliko neuravnoteženo kao opaženi. Njegovo ime ne znači da je svaki drugi test netočan, nego da p-vrijednost dolazi iz prebrojavanja umjesto iz krivulje.

Treći put je preraspodjela samih kategorija. Više rijetkih kategorija često nosi manje informacije od dvije popunjene, pa spajanje istovremeno rješava problem malih ćelija i izoštrava priču. Uvjet je da spajanje ima sadržajno opravdanje i da je odlučeno prije nego što se vidi rezultat. Kategorije se ne spajaju zato da bi nesklad postao veći ili da bi nezgodna skupina nestala.

STATISTIKA U DIVLJINI

Prag pet. Pravilo da svaka očekivana frekvencija mora biti barem pet ponavlja se u udžbenicima, u recenzijama i u izlazu statističkih

programa kao da je riječ o matematičkom uvjetu. Nije. Potječe iz rada koji je pregledao kako se hi-kvadrat postupak ponaša u nezgodnim tablicama i ponudio niz praktičnih preporuka za njihovo ojačavanje (Cochran 1954.).

Razlika između uvjeta i preporuke nije sitničava. Uvjet se provjerava i time je posao gotov, a preporuka traži da se zna od čega štiti. Simulacija u ovom odjeljku pokazuje da iskrivljenje ispod praga ovdje ide prema opreznosti, pa tablica koja prag ne zadovoljava nije automatski tablica s napuhanim nalazom. Analitičar koji je prag provjerio i stao nije doznao ništa o svojim podacima osim da zadovoljavaju konvenciju.

PITAJTE MODEL

Asistent lako izradi kontingencijsku tablicu, očekivane frekvencije i rezidualne, i pritom obično točno pogodi funkcije. Provjeravamo tri stvari koje ne pogađa pouzdano. Prva je nazivnik, jer postoci po retku i po stupcu odgovaraju na različita pitanja, a model bira onaj koji mu je sintaktički bliži. Druga je veličina očekivanih ćelija, koju često preskoči. Treća je jezik zaključka, jer značajnu vezu redovito opisuje kao snažnu i prelazi na uzročnu formulaciju bez ijednog upozorenja.

Izradi kontingencijsku tablicu dobne skupine i izvora vijesti, prikaži postotke po retku i imenuj nazivnik, ispiši očekivane frekvencije i najmanju među njima, a uz test navedi Cramérovo V i standardizirane rezidualne.

NADITE GREŠKU

Analiza je provjerila očekivane frekvencije i sve su iznad pet. Hi-kvadrat test daje vrlo malu p-vrijednost, a standardizirani reziduali pokazuju da najviše odstupaju televizija u najstarijoj skupini i društvene mreže u najmlađoj. Budući da je rezultat značajan na razini ispod jedan promil, veza između dobi i izvora vijesti vrlo je snažna.

Razrađeni primjer

Pet kategorija izvora vijesti daje tablicu koju je teško čitati i o kojoj je još teže odlučivati. Sadržajna podjela na digitalne i tradicionalne izvore zadržava ono što je u podacima nosivo, a uklanja rijetke ćelije. Analiza koja slijedi tu podjelu provodi, ispisuje profile po dobnim skupinama i testira tablicu koja iz njih nastaje.

```
uzorak <- s13_uzorak |>
  mutate(skupina_medija = if_else(
    izvor_vijesti %in% c("portal", "društvene mreže"),
    "digitalni",
    "tradicionalni"
  ))

tablica <- table(uzorak$dobna_skupina, uzorak$skupina_medija)

round(prop.table(tablica, 1) * 100, 1)
```

	digitalni	tradicionalni
18 do 29	75,6	24,4
30 do 44	60,5	39,5
45 do 59	44,2	55,8
60 i više	19,3	80,7

```
chisq.test(tablica)
```

Pearson's Chi-squared test

```
data: tablica
X-squared = 114,27, df = 3, p-value < 0,00000000000000022
```

Funkcija `table` prebrojava kombinacije dviju varijabli, `prop.table` pretvara frekvencije u udjele uz zadani smjer, a `chisq.test` prima gotovu tablicu i vraća statistiku, stupnjeve slobode i p-vrijednost.

Udio digitalnih izvora pada s 75,6 % u najmlađoj skupini na 19,3 % u najstarijoj. Statistika iznosi 114,3 uz 3 stupnja slobode, a Cramérovo V raste na 0,38 s 0,25 u tablici sa svih pet izvora. Sažimanje je ovdje pojačalo mjeru jačine, jer je uklonilo razlike među srodnim kategorijama koje su razrjeđivale glavni obrazac.

Izvrještaj s time ipak nije gotov. Tablica opisuje povezanost dobi i izbora izvora, ali ne kaže zašto ona postoji. Razlika među generacijama može biti posljedica navike stečene u mladosti, dostupnosti uređaja ili samog položaja u životnom ciklusu, a ovi podaci među tim objašnjenjima ne biraju. Odvajanje takvih objašnjenja traži varijable koje tablica ne sadrži i model koji ih može istovremeno uzeti u obzir, o čemu govori poglavlje o regresiji.

Time se zatvara i pitanje s početka poglavlja. Zbirna tablica prijava u Berkeleyju doista nije bila usklađena s modelom nezavisnosti, i svaki bi postupak iz ovog poglavlja to potvrdio (Bickel i sur. 1975.). Ono što nijedan od njih nije mogao dati jest objašnjenje, jer se odgovor nalazio u varijabli koje u tablici nije bilo. Prijave su bile neravnomjerno raspoređene po odjelima, a odjeli su se razlikovali po tome koliko su primali. Kako se takav zbirni obrazac preokrene čim se sloj vrati u račun, pokazuje poglavlje o povezanosti (Simpson 1951.). Ovdje je dovoljna pouka da tablica s dvije varijable odgovara točno na jedno pitanje, a da se pitanje o mehanizmu njome ne može ni postaviti.

Sažetak

Kategorički podaci počinju brojanjem, a brojanje se čita tek uz jasan nazivnik. Model nezavisnosti čuva rubne zbrojeve i iz njih izvodi očekivane frekvencije, a hi-kvadrat statistika zbraja odstupanja opaženog od očekivanog. Ukupna brojka kaže samo da nesklad postoji, pa je reziduali vraćaju u pojedine ćelije, a Cramérovo V odvaja jačinu veze od veličine uzorka. Test prilagodbe pokazuje da referentna raspodjela nije tehnički detalj nego istraživačka odluka. Kad su očekivane frekvencije male, aproksimacija popušta, i tada pomažu Fisherov pos-

tupak ili sadržajno opravdano spajanje kategorija. Sljedeće poglavlje istu logiku usporedbe prenosi na brojčani ishod i dvije skupine.

Pojmovi

kontingencijska tablica (*contingency table*), očekivana frekvencija (*expected frequency*), hi-kvadrat test (*chi-squared test*), test prilagodbe (*goodness-of-fit test*), standardizirani rezidual (*standardized residual*), Cramérovo V (*Cramér's V*), Fisherov egzaktni test (*Fisher's exact test*)

Zadaci

Konceptualni

Objasnite razliku između testa nezavisnosti i mjere jačine veze tako da napišete dvije rečenice koje bi se mogle pojaviti u istom izvještaju, jednu o tome što test kaže i jednu o tome što V kaže.

Računski

Tablica ima dva retka s po sto ispitanika i dva stupca s rubnim zbrojevima stodvadeset i osamdeset. Izračunajte sve četiri očekivane frekvencije, a zatim za opaženu tablicu sa sedamdeset u prvoj ćeliji izračunajte doprinos svake ćelije i njihov zbroj. Usporedite ga s graničnom vrijednošću 3,84.

Kritički

Prosudite što zbirna kontingencijska tablica prijava može reći o upisima, a što gubi kad se odjeli izostave (Bickel i sur. 1975.). Predajte jedan odlomak i imenujte podatak koji bi vam trebao da razlikujete dva ponuđena objašnjenja.

Revizija modela

Ocijenite modelsku analizu iz okvira. Izdvojite dijagnostičke korake koji su provedeni ispravno, imenujte jedan pogrešan zaključak i navedite koju bi veličinu izvještaj morao sadržavati da se taj zaključak ne može izvesti.

Uspoređivanje dviju grupa

Ista razlika, različiti dizajni i zaključci

Vrijeme čitanja	Widget	Podaci	Preduvjet
24 min	Uzorkivač dviju grupa	simulirana populacija	pogl. 10, 11, 13

VINJETA

Cumming je urednicima psihologijskih časopisa predložio promjenu koja izgleda skromno, a mijenja cijeli izvještaj. Umjesto da rad završi oznakom je li rezultat prešao prag, treba dati procjenu razlike i interval koji uz nju ide (Cumming 2014.).

Prijedlog nije bio tehnički. Autor koji piše da razlika postoji rekao je manje nego autor koji piše koliko ona

iznosi i koje su vrijednosti s podacima još uskladive. Prvi izvještaj se ne može ni s čim usporediti, a drugi ulazi u sljedeće istraživanje kao brojka.

Kako jednu usporedbu dviju sredina povezati s dizajnom iz kojeg je nastala, s veličinom koju opisuje i s općim jezikom modela?

Tko nosi dva rezultata

Usporedba dviju sredina izgleda kao jedno pitanje, a zapravo ih je troje. Razlika je u tome odakle dolaze dva broja koja uspoređujemo, i to pitanje nije statističko nego pitanje o dizajnu istraživanja.

U prvom slučaju imamo jednu skupinu i vrijednost izvana. Prosječno povjerenje u našem uzorku uspoređujemo sa službenom vrijednošću iz ranije objavljenog vala istraživanja ili sa sredinom ljestvice. U drugom slučaju imamo dvije odvojene skupine sastavljene od različitih ljudi, recimo one koji se prvenstveno informiraju s televizije i one koji to čine preko društvenih mreža. U trećem slučaju iste jedinice mjerimo dva puta, prije i poslije nekog događaja, pa svaki ispitanik nosi oba rezultata.

Definicija 38. Jedinica neovisnosti je entitet koji se u istraživanju mogao pojaviti ili izostati neovisno o ostalima, pa njegove vrijednosti nisu unaprijed vezane uz vrijednosti bilo koje druge jedinice u istom skupu.

Ta jedinica određuje sve ostalo. U usporedbi dviju skupina to je osoba, jer je svaka osoba u samo jednoj skupini. U ponovljenom mjerenju to je i dalje osoba, ali sada nosi dva rezultata koja su međusobno povezana, pa se analiza ne provodi na četrdeset mjerenja nego na dvadeset razlika. Postupak koji tu vezu previdi računa s dvostruko više podataka nego što ih doista ima.

Prvi korak analize zato nije izbor testa nego rečenica koja imenuje jedinicu. Ako se ta rečenica ne može napisati, podaci još nisu spremni za bilo kakvu usporedbu.

Razlika prije oznake

Poglavlje radi na istoj simuliranoj populaciji kao poglavlja o uzorkovanju i procjeni. Iz nje je izvučeno 120 osoba koje se informiraju s televizije ili preko društvenih mreža, i pitanje glasi razlikuju li se te dvije skupine po povjerenju u medije.

Redoslijed izvještavanja postavljamo prije nego što bilo što izračunamo. Prvo dolazi razlika u izvornim jedinicama, zatim interval koji joj pripada, pa tek onda test i standardizirana veličina. Taj redoslijed nije stvar ukusa. Razlika i njezin interval odgovaraju na pitanje koliko iznosi učinak, a test odgovara na mnogo uže pitanje je li podacima uskladiva i nula.


U našem uzorku prosječno povjerenje iznosi 5,70 među onima koji gledaju televiziju i 4,51 među onima koji se informiraju preko društvenih mreža. Razlika iznosi 1,19 boda uz interval pouzdanosti od 0,45 do 1,92.

Interval je ovdje važniji od svega ostaloga. On kaže da su s ovim uzorkom uskladive i razlike ispod pola boda i razlike blizu dva boda, dakle raspon unutar kojeg bi se praktične odluke mogle razlikovati. Izvještaj koji bi umjesto toga napisao samo da je razlika značajna o toj neizvjesnosti ne bi rekao ništa.

Budući da je populacija simulirana, znamo i točan odgovor. Prava razlika u njoj iznosi 1,30 boda, dakle unutar intervala koji je uzorak proizveo. To je jedna potvrda od mnogo mogućih, a koliko ih se u dugom nizu ponavljanja može očekivati, pokazalo je poglavlje o procjeni.

Interakcija — Uzorkivač dviju grupa

Sljedeći prikaz razdvaja dvije stvari koje se u praksi redovito brkaju. Preklapanje pojedinačnih rezultata dviju skupina jedna je stvar, a preciznost procijenjene razlike druga. Čitatelj odvojeno mijenja stvarnu razliku, raspršenost ishoda i broj jedinica, i može prebaciti dizajn iz neovisnog u upareni uz nepromijenjene ostale postavke.



Slika 1: Raspodjele procijenjene razlike u neovisnom i uparenom dizajnu uz jednake rubne varijabilnosti.

Što isprobati.

1. Povećajte stvarnu razliku uz jednaku raspršenost.
2. Povećajte raspršenost uz jednaku razliku i pogledajte oba panela.
3. Povećajte broj jedinica bez promjene razlike i raspršenosti.
4. Prebacite dizajn u upareni uz sve ostalo nepromijenjeno.

Posljednji korak pomiče samo jednu postavku, a raspodjela procjena vidljivo se sužava. Uparivanje ne mijenja ni stvarnu razliku ni raspršenost ishoda, nego uklanja onaj dio razlike među mjerenjima koji

potječe od razlika među samim jedinicama. Ta dobit postoji samo dok analiza vezu unutar para zadrži.

Ista razlika, dva dizajna

Tvrdnja da dizajn mijenja zaključak zvuči apstraktno dok se ne vidi na jednom skupu brojeva. Zato konstruiramo mjerenje 60 osoba prije i poslije jednog događaja. Skup je izmišljen za ovu svrhu i nije nalaz ni o kome, a jedino što je u njemu namješteno jest da su dva mjerenja iste osobe povezana, kao što u ponovljenim mjerenjima uvijek jesu.

Povezanost dvaju mjerenja iznosi 0,86. Osobe koje su imale visoku vrijednost prije imale su je uglavnom i poslije, pa najveći dio raspršenosti u oba mjerenja potječe od razlika među osobama, a ne od promjene koja nas zanima.

Prosječna promjena iznosi 0,48 uz standardnu devijaciju razlika od 0,90. Analiza koja pare zadrži daje interval od 0,25 do 0,71 i p-vrijednost od 0,0001.

Ista mjerenja, obrađena kao da su dvije neovisne skupine, daju interval od -0,14 do 1,10 i p-vrijednost od 0,126. Isti podaci, ista prosječna promjena, i dva zaključka koja bi u izvještaju izgledala suprotno.

Razlog nije u računu nego u nazivniku. Neovisna analiza mjeri razliku prema raspršenosti među osobama, koja je ovdje velika. Uparena analiza mjeri je prema raspršenosti promjena unutar osoba, koja je mnogo manja jer je razlika među osobama oduzeta. Uparivanje zato nije trik za manju p-vrijednost nego posljedica toga da je promjena unutar osobe druga veličina od razlike među osobama.

Koliko se time dobiva, ovisi isključivo o povezanosti dvaju mjerenja. Uparena raspršenost sadrži faktor koji pada kako povezanost raste, pa je dobitak velik kad se osobe kroz vrijeme drže svojih razina, a nikakav kad se drugo mjerenje ponaša kao da s prvim nema veze. Uz povezanost blizu nule upareni postupak zapravo gubi, jer troši polovicu stupnjeva slobode za ispravak koji nije bio potreban. Uparivanje

se zato planira u dizajnu, gdje se zna hoće li ista osoba sa sobom donijeti stabilnu razinu, a ne bira nakon što se vide podaci.

Jedan model iza triju testova

Tri dizajna iz prvog odjeljka izgledaju kao tri postupka, a mogu se zapisati kao jedan. Pretpostavimo da svaka osoba ima brojčani ishod i pripadnost jednoj od dviju skupina. Model kaže da očekivani ishod ovisi o toj pripadnosti, i to jednim brojem po skupini.

$$\text{povjerenje} = \beta_0 + \beta_1 \cdot \text{skupina} + \varepsilon$$

Oznaka β_0 stoji za očekivani ishod u skupini koja je uzeta kao polazna, β_1 za razliku između druge i te polazne skupine, a ε za ono što model o pojedinoj osobi nije objasnio. Varijabla skupine poprima vrijednost nula za polaznu i jedan za drugu skupinu, pa se sve svodi na dva broja.

Definicija 39. Referentna skupina je kategorija prema kojoj se izražavaju sve ostale kategorije istog prediktora, pa njezina sredina postaje polazna vrijednost modela, a koeficijenti ostalih kategorija odstupanja od nje.

U našem uzorku polazna je skupina onih koji se informiraju preko društvenih mreža, pa β_0 iznosi 4,51 i jednak je njihovoj sredini. Koeficijent β_1 iznosi 1,19 i jednak je razlici koju smo već izračunali. Model dakle nije dao novu brojku nego stari odgovor u novom obliku.

Dobitak od tog oblika pokazat će se kasnije, i to na dva mjesta. Prediktor s više od dviju kategorija donosi poglavlje o više skupina, a prediktor koji nije kategorija nego broj donosi poglavlje o regresiji. Test dviju sredina odatle gledano nije zaseban postupak nego najmanji mogući slučaj jednog jedinog okvira.

Model pritom ne zamjenjuje dizajn. Koeficijent opisuje razliku među skupinama onako kako su one nastale, a uzročno značenje dolazi isključivo iz načina na koji je pripadnost skupini dodijeljena. Ako je

ljudi biraju sami, model o uzroku ne govori ništa, koliko god uredno bio ispisan.

Što razlika sama ne kaže

Razlika u izvornim jedinicama nosi značenje samo dok se zna koliko je ljestvica raspršena. Bod razlike na ljestvici čije su vrijednosti zbijene znači nešto sasvim drugo nego bod razlike na ljestvici na kojoj su ljudi raspoređeni široko. Standardizirana veličina učinka upravo to uzima u obzir.

Standardiziranu razliku uvelo je poglavlje o veličini učinka i snazi, gdje je razlika sredina podijeljena združenom standardnom devijacijom skupina, pa se izražava u standardnim devijacijama umjesto u izvornim jedinicama.

$$d = \frac{\bar{x}_2 - \bar{x}_1}{s_{zdr}}$$

Za naše dvije skupine ta veličina iznosi 0,59. Uobičajene orijentacijske vrijednosti postoje i najčešće se navode prema Cohenu, ali ih je i sam izvor ponudio kao pomoć u odsutnosti boljeg oslonca (Cohen 1988.). Kod uparenog dizajna nazivnik je drugi, jer se dijeli standardnom devijacijom razlika, pa dvije veličine s istim imenom nisu izravno usporedive. Naš upareni skup daje 0,53.

Standardizacija ipak ne rješava ono zbog čega usporedbe dviju skupina najčešće zavaravaju. U našim podacima skupine se ne razlikuju samo po izvoru vijesti. Prosječna dob onih koji se informiraju preko društvenih mreža iznosi 33,4 godine, a onih koji gledaju televiziju 50,2 godine, dok povjerenje u ovoj populaciji raste s dobi.

Budući da je populacija poznata, taj se udio može izmjeriti umjesto pretpostaviti. Ukupna razlika u njoj iznosi 1,30 boda. Ograničimo li je na osobe između trideset i pedeset godina, dakle na raspon unutar kojeg se dob dviju skupina znatno manje razlikuje, razlika pada na 0,90 boda. Otprilike trećina onoga što bi neoprezan izvještaj pripisao izvoru vijesti pripada dobi.

U našem uzorku od 120 osoba u taj uski raspon upada tek 55 njih, i interval razlike proteže se od -0,34 do 1,88, dakle preko nule. Uzorak koji je za ukupnu razliku bio dovoljan za razliku unutar dobnog raspona više nije, a o tome koliko podataka treba da bi se učinak zadane veličine uopće mogao razlučiti govori poglavlje o veličini učinka i snazi.

Pretpostavke i njihove granice

Postupci iz ovog poglavlja počivaju na trima pretpostavkama, i njihova se ozbiljnost razlikuje. Neovisnost opažanja dolazi iz dizajna i ne može se popraviti nikakvim izborom postupka. Približna normalnost odnosi se na raspodjelu ostataka, a kod uparenog dizajna na raspodjelu razlika, ne na raspodjelu pojedinačnih mjerenja. Jednakost varijanci potrebna je samo klasičnoj inačici testa.

Ta se treća pretpostavka rješava izborom postupka. Welchova inačica ne zahtijeva jednake varijance i plaća to prilagođenim stupnjevima slobode, koji zato nisu cijeli broj. U našem uzorku varijance iznose 3,82 i 4,21, dakle vrlo su bliske, pa Welchova inačica troši 102,5 stupnjeva slobode prema 118 koliko ih troši klasična. Kad su varijance slične, razlika je zanemariva, a kad nisu, Welch je točniji. Postupak koji ništa ne gubi kad pretpostavka vrijedi i nešto dobiva kad ne vrijedi razuman je početni izbor.

Normalnost se procjenjuje pogledom na raspodjelu, a tek onda testom. Shapiro-Wilkov test ima istu osjetljivost na veličinu uzorka kao svaki drugi test, pa će na velikom uzorku prijaviti odstupanja bez ikakvih posljedica, a na malom propustiti ozbiljna. Njegov rezultat zato ne može biti prekidač koji sam odlučuje o izboru postupka.

Krajnja opažanja traže pregled, a ne automatsko brisanje. Mogu biti pogreške u unosu, mogu biti rijetki ali stvarni slučajevi, a mogu biti i znak da sredina nije prikladan sažetak te varijable. Analiza provedena s njima i bez njih, uz oba rezultata u izvješčaju, poštenija je od tihe odluke donesene nakon pogleda na p-vrijednost.

Wilcoxonov postupak radi s rangovima umjesto s vrijednostima, pa ga jedno krajnje opažanje ne može pomaknuti. Njegovo pitanje ipak nije isto, jer se ne odnosi na razliku sredina nego na položaje raspodjela. U našem uparenom skupu daje p-vrijednost od 0,0005, dakle isti zaključak, ali ne i istu tvrdnju.

STATISTIKA U DIVLJINI

Preklapanje crtica. Pravilo da razlika nije značajna ako se crtice pogreške na grafu preklapaju kruži znanstvenim tekstovima kao da je egzaktno. Belia i suradnici pozvali su 473 autora radova iz psihologije, bihevioralne neuroznanosti i medicine da na internetskom prikazu pomiču dvije sredine s crticama sve dok razlika ne postane taman značajna (Belia i sur. 2005.).

Odgovori su pokazali da mnogi vodeći istraživači ne razlikuju interval pouzdanosti od standardne pogreške i ne uzimaju u obzir jesu li dvije sredine neovisne ili dolaze iz ponovljenog mjerenja. Upravo to razlikovanje nosi cijelo ovo poglavlje. Nalaz je pritom o čitanju grafova, a ne o crticama, pa iz njega slijedi da graf mora reći koju veličinu prikazuje i iz kojeg dizajna dolazi, a ne da se crtice izbjegavaju.

PITAJTE MODEL

Asistent gotovo uvijek ponudi t-test čim vidi jednu kategoričku i jednu brojčanu varijablu, i obično ne pita ono što bi moralo doći prvo. Prije poziva mu treba opis dizajna i identifikator jedinice, jer iz samog oblika tablice ne može znati jesu li dva stupca dva mjerenja istih osoba. Provjeravamo je li uparivanje sačuvano, koristi li Welchovu inačicu, izvještava li razliku i interval prije testa i je li tiho izbacio retke s praznim vrijednostima.

Opisat ću dizajn i reći koja varijabla identificira jedinicu.

Prvo prikaži raspodjele obiju skupina, zatim procijeni razliku s intervalom u izvornim jedinicama, pa tek onda provedi odgovarajući test i navedi veličinu učinka.

NADITE GREŠKU

Usporedba povjerenja u medije između dviju skupina provedena je Welchovim testom, uz prikazane raspodjele i interval razlike. Analiza je zatim ponovljena unutar dobne skupine od trideset do pedeset godina, gdje interval razlike obuhvaća nulu. Zaključak izvještaja glasi da unutar te dobne skupine izvor vijesti nema veze s povjerenjem.

Razrađeni primjer

Cijela usporedba dviju skupina može se ispisati u nekoliko redaka, i vrijedi je jednom vidjeti u obliku u kojem će se od ovog poglavlja nadalje pojavljivati. Analiza procjenjuje model s binarnim prediktorom, ispisuje njegova dva broja s intervalima i tek zatim provodi test.

```
model <- lm(povjerenje_medijima ~ izvor, data = dvije_skupine)
```

```
coef(model)
```

```
(Intercept)      izvorTV
      4,514286      1,185714
```

```
confint(model)
```

```

                2,5 %   97,5 %
(Intercept) 4,0419213 4,986650
izvorTV      0,4539304 1,917498
```

```
t.test(povjerenje_medijima ~ izvor, data = dvije_skupine)
```

Welch Two Sample t-test

```

data: povjerenje_medijima by izvor
t = -3,1822, df = 102,47, p-value = 0,001935
alternative hypothesis: true difference in means between group društvene mreže
95 percent confidence interval:
  -1,9247421 -0,4466865
sample estimates:
mean in group društvene mreže          mean in group TV
                        4,514286                5,700000

```

Zapis `povjerenje_medijima ~ izvor` čita se kao tvrdnja da ishod ovisi o skupini. Funkcija `lm` procjenjuje takav model, `coef` vraća njegova dva broja, a `confint` intervale koji uz njih idu.

Ispis modela i ispis testa nose istu razliku od 1,19 boda, s istim intervalom, samo drugačije poredanu. To nije podudarnost nego identitet, jer je neovisni t-test upravo test o koeficijentu ovog modela. Kad u sljedećem poglavlju skupina bude pet umjesto dvije, mijenja se samo broj koeficijenata.

Izvještaj koji bi na tome stao još ne bi bio potpun. Treba mu opis kako su skupine nastale, jer ljudi svoj izvor vijesti biraju sami, i napomena da skupine nisu izjednačene po dobi. Bez toga bi ista brojka lako prešla iz rečenice o razlici u rečenicu o učinku, a to su dvije različite tvrdnje.

Sažetak

Usporedba dviju grupa počinje dizajnom i rečenicom koja imenuje jedinicu neovisnosti. Jednouzoračni, neovisni i upareni postupak tri su lica iste procjene razlike, a razlikuju se po tome prema čemu se razlika mjeri. Isti brojevi obrađeni kao upareni i kao neovisni daju suprotne zaključke, pa taj izbor nije tehnički detalj. Linearni model s binarnim prediktorom otkriva zajednički okvir u kojem je test dviju sredina najmanji mogući slučaj. Standardizirana veličina učinka čuva usporedivost, ali ne uklanja razlike među skupinama koje s ishodom dolaze zajedno. Sljedeće poglavlje isti model širi na više skupina i uvodi cijenu mnogih usporedbi.

Pojmovi

jedinica neovisnosti (*unit of independence*), neovisne skupine (*independent groups*), upareni podaci (*paired data*), Welchov t-test (*Welch's t-test*), referentna skupina (*reference category*), standardizirana razlika (*Cohen's d*), Wilcoxonov test (*Wilcoxon test*)

Zadaci

Konceptualni

Za tri istraživačke situacije imenujte jedinicu neovisnosti i odgovarajući dizajn. Prva uspoređuje prosječno povjerenje u uzorku sa službenom vrijednošću iz ranijeg vala istraživanja, druga uspoređuje dvije skupine gledatelja, a treća mjeri iste ispitanike prije i poslije kampanje.

Računski

Dvije skupine imaju po dvadeset pet ispitanika, sredine 5,4 i 4,6 te jednake standardne devijacije od 1,6. Izračunajte razliku i standardiziranu razliku, a zatim ponovite račun uz standardnu devijaciju 3,2. Objasnite zašto se prva brojka nije promijenila, a druga jest.

Kritički

Prosudite koliko izvještaj gubi kad umjesto procjene razlike s intervalom ponudi samo oznaku značajnosti (Cumming 2014.). Predajte kratku bilješku recenzentu i navedite jednu odluku koja bi se bez intervala mogla donijeti pogrešno.

Revizija modela

Ocijenite modelsku analizu iz okvira. Imenujte korake koji su provedeni ispravno, izdvojite tvrdnju koja iz rezultata ne slijedi i napišite rečenicu kojom bi je trebalo zamijeniti.

Uspoređivanje više grupa

Jedan model za razlike među skupinama

Vrijeme čitanja	Widget	Podaci	Preduvjet
22 min	Dekompozicija varijance	simulirana populacija	pogl. 10, 14

VINJETA

Simmons, Nelson i Simonsohn pokazali su da istraživač koji tijekom analize donosi naizgled bezazlene odluke može doći do statistički značajnog rezultata za tvrdnju koja ne može biti istinita (Simmons i sur. 2011.). Odluke su bile obične, poput toga koji će ishod izvijestiti, koju će podskupinu pogledati i kada će prestati prikupljati podatke.

Nijedan pojedinačni test u tom postupku nije bio pogrešno proveden. Problem je nastao od njihova broja, jer je svaka nova usporedba bila nova prilika da slučajnost proizvede rezultat vrijedan objave. Broj prilika nije se nigdje vidio u izvještaju.

Kako više skupina usporediti tako da broj prilika ostane vidljiv, a zatim utvrditi gdje se razlike zapravo nalaze?

Cijena mnogih usporedbi

Pet skupina daje deset parova. Očit postupak jest provesti deset usporedbi iz prethodnog poglavlja i pogledati koje su prošle prag. Prije nego što ga odbacimo, vrijedi izmjeriti koliko taj postupak zapravo košta, i to na način na koji je knjiga to radila i za uzorkovanje i za kategoričke podatke.

Postavljamo situaciju u kojoj razlike po konstrukciji nema. Iz iste simulirane populacije izvučemo pet skupina po četrdeset osoba, dakle skupine koje se ne razlikuju ni po čemu osim po tome koga je slučaj u njih smjestio. Zatim provedemo svih deset usporedbi i zabilježimo je li barem jedna prošla prag. Sve što nađemo je pogreška.

Kroz dvije tisuće ponavljanja barem jedna od deset usporedbi bila je značajna u 27,4 % slučajeva. Postupak koji je zamišljen da griješi u pet posto slučajeva griješi u više od četvrtine njih, a izvještaj bi u svakom od tih slučajeva sadržavao uredno provedenu usporedbu s malom p-vrijednošću.

Definicija 40. Stopa obiteljske pogreške je vjerojatnost da će barem jedan test u unaprijed određenom skupu testova dati lažno pozitivan rezultat, uz uvjet da u tom skupu nijedan učinak zaista ne postoji.

Uobičajena formula za tu stopu množi vjerojatnosti neuspjeha svih testova i za deset testova daje 40,1 %. Naša izmjerena vrijednost osjetno je niža, i razlog je vrijedan pažnje. Formula pretpostavlja da su testovi neovisni, a deset parnih usporedbi među pet skupina dijeli skupine, pa nisu. Ista simulacija s deset zaista neovisnih usporedbi daje 40,4 %, dakle upravo ono što formula predviđa.

Poučak je da formula opisuje gornju granicu, a ne stopu koju parne usporedbe doista imaju. Obje su brojke daleko iznad pet posto i obje vode istom zaključku, ali brojku koja se navodi u izvještaju vrijedi izmjeriti umjesto prepisati.

Postoji i postupak koji cijeli skup pitanja rješava jednim testom. Kad istu simulaciju provedemo tako da svih pet skupina uđe u jedan zajednički model, on griješi u 4,2 % slučajeva, dakle onoliko koliko je i obećao. Taj postupak razvija ostatak poglavlja.

Varijanca između i unutar

Zajednički test za više skupina mora nekako sažeti razlike među njima u jednu brojku. Prva ideja bila bi zbrojiti udaljenosti skupnih sredina od zajedničke sredine, ali takav zbroj sam po sebi ništa ne znači. Tri sredine razmaknute za jedan bod velika su razlika ako su ljudi unutar skupina zbijeni, a gotovo ništa ako su raspršeni preko cijele ljestvice.

Usporedba mora zato ići prema drugoj vrsti raspršenosti. Ukupno rasipanje podataka razlaže se na dio koji potječe od razlika među skupinama i dio koji potječe od razlika među pojedincima unutar iste skupine. Prvi dio je ono što model objašnjava, drugi je ono što ostaje.

Kad se svaki od tih dvaju dijelova podijeli brojem veličina koje su ga mogle proizvesti, dobiju se dvije prosječne raspršenosti koje se mogu staviti u omjer. Ako skupine nemaju nikakvog učinka, obje mjere istu slučajnost i omjer se vrti oko jedinice. Ako skupine imaju učinka, brojnik raste, a nazivnik ne.

Definicija 41. F-statistika je omjer prosječne raspršenosti među skupnim sredinama i prosječne raspršenosti opažanja oko njihovih skupnih sredina.


$$F = \frac{MS_{\text{između}}}{MS_{\text{unutar}}}$$

Oznaka MS stoji za zbroj kvadriranih odstupanja podijeljen pripadnim stupnjevima slobode.

Naziv analiza varijance zbog toga zvuči kao da je riječ o raspršenosti, a pitanje je o sredinama. Raspršenost je ovdje mjerilo, ne predmet. Postupak je i dalje usporedba skupnih sredina, samo izražena u jedinicama koje su za tu usporedbu prikladne.

Interakcija — Dekompozicija varijance

Sljedeći prikaz razdvaja dva izvora rasipanja koje ukupni graf spaja. Okomite trake pokazuju koliko je svaka skupna sredina udaljena od zajedničke, a točke koliko su pojedinci raspršeni oko svoje skupne sredine. Čitatelj pomiče sredine i raspršenost odvojeno, pa se vidi da razmak među skupinama sam po sebi ne određuje ništa.



slika 1: Dekompozicija varijance — razmak sredina povećava F-omjer, a raspršenost unutar skupina smanjuje ga.

Što isprobati.

1. Postavite sve tri sredine na 52 i zadržite standardnu devijaciju 6.
2. Razmaknite sredine na 46, 52 i 58 te usporedite novi omjer s prvim.
3. Zadržite razdvojene sredine i povećajte standardnu devijaciju na 12.

Treći korak ne mijenja nijednu skupnu sredinu, a omjer svejedno pada. Razmak među skupinama nije, dakle, veličina koja odlučuje. Odlučuje njegov odnos prema raspršenosti unutar skupina, jer upravo ona kaže koliko bi razmaka slučaj mogao proizvesti sam od sebe.

Isti model, više koeficijenata

Prethodno poglavlje zapisalo je usporedbu dviju skupina kao model s jednim koeficijentom uz binarni prediktor. Prijelaz na pet skupina ne traži novi okvir nego više koeficijenata u istome. Jedna kategorija ostaje referentna, a svaka od preostalih dobiva svoj broj koji kaže koliko se od nje razlikuje.

$$\text{povjerenje} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \varepsilon$$

Svaka od varijabli x_1 do x_4 poprima vrijednost jedan za jednu od nereferentnih skupina i nulu inače, pa svaka osoba aktivira najviše jedan koeficijent. Oznaka β_0 i dalje je sredina referentne skupine, a ε ono što model o pojedincu nije objasnio. Pet sredina zapisano je s pet brojeva, kao što je i moralo biti.

Ukupni test iz prošlog odjeljka postavlja pitanje o svim tim koeficijentima odjednom. Pita jesu li oni zajedno dovoljno veliki da bi model sa skupinama opisivao podatke bolje nego model koji ima samo zajedničku sredinu. Zato je jedan test, a ne deset.

Naš uzorak od 300 osoba raspoređen je u pet skupina prema izvoru vijesti. Ukupni test daje F od 8,38 uz 4 i 295 stupnjeva slobode. Prosječna raspršenost među skupinama iznosi 28,5, a unutar skupina 3,4, i njihov je omjer upravo ta F-vrijednost.

Model pritom ostaje ono što je bio u prethodnom poglavlju. Ne zna kako su ljudi u skupine dospjeli i ne tvrdi ništa o uzroku. Izvor vijesti u ovoj populaciji ljudi biraju sami, pa razlike među skupinama uključuju i sve ono po čemu se ti ljudi inače razlikuju.

Što ukupni test ne kaže

Značajan ukupni test kaže da model sa skupinama opisuje podatke bolje od modela bez njih. Ne kaže koje se skupine razlikuju, koliko, ni u kojem smjeru. Izvještaj koji na njemu stane predao je jednu bitnu informaciju i nijednu upotrebljivu.

Postupak koji odgovara na to pitanje mora usporediti parove, ali sada uz svijest o njihovom broju. Tukeyjev postupak upravo to radi. Uspoređuje sve parove i pritom širi intervale tako da vjerojatnost barem jedne pogreške u cijelom skupu usporedbi ostane na obećanoj razini.

Način na koji ih širi vrijedi razumjeti, jer objašnjava zašto korekcija nije proizvoljna kazna. Kad se gleda deset razlika, ne odlučuje nijedna pojedinačno nego najveća među njima, a najveća od deset slučajnih veličina sustavno je veća od bilo koje pojedinačne. Postupak zato ne pita koliko je vjerojatna ova razlika, nego koliko je vjerojatan ovako velik raspon među pet sredina. Odgovor na to drugo pitanje daje širi interval, i to točno onoliko širi koliko je bilo prilika.

Od 10 parova u našem uzorku značajno se razlikuju samo oni u kojima sudjeluju društvene mreže. One se odvajaju od sva četiri preostala izvora, a ta četiri međusobno ne. Najveća razlika dijeli televiziju od društvenih mreža i iznosi 1,59 boda. Televizija i tisak ostaju nerazlučivi, s razlikom od 0,04 boda i intervalom od -1,06 do 1,14.

Taj drugi rezultat treba pročitati oprezno. Interval je širok više od dva boda, pa nije riječ o tome da su dva izvora izjednačena, nego o tome da ih ovaj uzorak ne razlučuje. Odsutnost razlike i odsutnost dokaza o razlici dvije su različite tvrdnje, a Tukeyjev ispis ih ne razlikuje umjesto nas.

Postoji i bolji postupak od uspoređivanja svega sa svime. Ako se prije podataka zna koja usporedba nosi istraživačko pitanje, recimo ona između tradicionalnih i digitalnih izvora, ona se može postaviti kao jedna planirana usporedba. Jedno pitanje umjesto deset znači i užu korekciju i veću sposobnost da se razlika uoči. Uvjet je da je pitanje postavljeno prije, a ne odabrano nakon pogleda na sredine.

STATISTIKA U DIVLJINI

Značajno ovdje, neznačajno ondje. Uobičajen način da se dva učinka usporede jest pogledati je li prvi značajan, a drugi nije, i iz toga zaključiti da se razlikuju. Nieuwenhuis, Forstmann i Wagenmakers pregledali su 513 radova iz pet vodećih neuroznanstvenih časopisa i našli 78 radova koji su razliku dvaju učinaka testirali izravno i 79 radova koji su je izveli iz usporedbe dviju oznaka značajnosti (Nieuwenhuis i sur. 2011.).

Postupak je pogrešan jer prag nije linearan. Učinak s p-vrijednošću tik ispod praga i učinak s p-vrijednošću tik iznad njega gotovo su jednaki, a dobivaju suprotne oznake. Usporedba dvaju učinaka zahtijeva test o njihovoj razlici, što je upravo ono što Tukeyjev postupak i planirane usporedbe rade, a čitanje dviju zvjezdica jedne pored druge ne radi.

PITAJTE MODEL

Asistent će na zahtjev za usporedbom više skupina gotovo uvijek ponuditi ukupni test i odmah za njim sve parne usporedbe, jer je to najčešći obrazac u kodu na kojem je učio. Provjeravamo je li referentna skupina ona koju smo htjeli, koliko je usporedbi zapravo provedeno i je li korekcija imenovana. Provjeravamo i opisuje li ispis nesignifikantne parove kao jednake, jer je to najčešća rečenica koju sam doda.

Reci koja je skupina referentna i koliko usporedbi provodiš. Prikaži skupne raspodjele, procijeni zajednički model, navedi veličinu učinka, a parne razlike daj s intervalima i imenovanom korekcijom.

NADITE GREŠKU

Ukupni test pokazuje da model sa skupinama opisuje podatke bolje od modela bez njih, a raspodjela ostataka ne otkriva ozbiljan problem. Veličina učinka izračunata je i iznosi otprilike deset posto objašnjene varijabilnosti. Zaključak izvještaja glasi da se svih pet izvora međusobno razlikuje po percipiranoj vjerodostojnosti.

Koliki je udio objašnjen

Ukupni test opet ovisi o veličini uzorka, pa uz njega ide mjera koja o njoj ne ovisi. Prirodna mjera ovdje već postoji u samoj dekompoziciji. Ako je ukupno rasipanje razloženo na dio među skupinama i dio unutar njih, onda je udio prvoga u ukupnome mjera koliko je skupna pripadnost objasnila.

Definicija 42. Eta-kvadrat je udio ukupne varijabilnosti ishoda koji otpada na razlike među skupnim sredinama.

$$\eta^2 = \frac{SS_{\text{između}}}{SS_{\text{ukupno}}}$$

Za naš uzorak eta-kvadrat iznosi 0,102, dakle izvor vijesti objašnjava oko 10 % varijabilnosti u povjerenju. Preostalih devedeset posto otpada na razlike među ljudima koje ovaj model uopće ne vidi, i ta je asimetrija tipična za istraživanja u društvenim znanostima.

Mjera ima jedan poznat nedostatak. Računa se iz istog uzorka iz kojeg su procijenjene i sredine, pa sustavno precjenjuje udio koji bi se našao u populaciji. **Omega-kvadrat** ispravlja taj pomak oduzimanjem onoga što bi se od razlika među skupinama očekivalo i kad ih ne bi bilo. Za naš uzorak iznosi 0,090, dakle nešto manje od eta-kvadrata, a razlika među njima pada kako skupine rastu.

Ni jedna ni druga mjera ne govori je li udio velik u sadržajnom smislu. Deset posto objašnjene varijabilnosti mnogo je za pojedinačni prediktor stava, a malo za instrument koji bi trebao predviđati pojedinačno ponašanje. Odgovor dolazi iz usporedbe s drugim nalazima u istom području, ne iz tablice pragova.

Kad pretpostavke popuste

Zajednički model počiva na istim trima pretpostavkama kao usporedba dviju skupina, i redoslijed njihove ozbiljnosti je isti. Neovisnost opažanja dolazi iz dizajna. Približna normalnost odnosi se na raspodjelu ostataka, dakle na ono što model nije objasnio, a ne na raspodjelu ishoda unutar svake skupine posebno. Jednakost varijanci potrebna je klasičnoj inačici.

Homogenost se provjerava usporedbom raspršenosti skupina, a najjednostavnija provjera jest omjer najveće i najmanje varijance. U našem uzorku on iznosi 1,43, dakle skupine su dovoljno slične da klasična inačica ne bude sporna.

Kad taj omjer naraste, postoji ista rezerva kao u prethodnom poglavlju. Welchova inačica ukupnog testa ne pretpostavlja jednake varijance i prilagođava stupnjeve slobode. Na našim podacima daje F od 7,32 uz 112,4 stupnjeva slobode u nazivniku, dakle isti zaključak uz nešto opreznije brojke.

Kruskal-Wallisov postupak mijenja pitanje umjesto da popravljati pretpostavku. Rangira sve vrijednosti i uspoređuje prosječne rangove skupina, pa ga jedno krajnje opažanje ne pomiče. Na našim podacima daje statistiku od 29,8 uz jednak broj stupnjeva slobode kao ukupni test. Zaključak je isti, ali tvrdnja nije, jer se odnosi na položaje raspodjela, a ne na sredine.

Nijedan od tih postupaka ne popravljati ovisna opažanja. Ako su ista lica mjerena u više uvjeta ili su ljudi grupirani unutar razreda, škola ili gradova, potreban je model koji tu strukturu uzima u obzir. Takvi modeli izlaze iz opsega ove knjige, a njihov je zajednički korijen upravo okvir iz sljedećeg poglavlja.

Razrađeni primjer

Cijela analiza pet skupina staje u nekoliko redaka, i vrijedi je vidjeti u redoslijedu kojim je poglavlje izgrađeno. Zajednički model dolazi prvi, parne usporedbe tek nakon njega.

```
model <- aov(povjerenje_medijima ~ izvor_vijesti, data = pet_izvora)

summary(model)
```

```

              Df Sum Sq Mean Sq F value    Pr(>F)
izvor_vijesti   4  113,8   28,461    8,382 0,00000204 ***
Residuals      295 1001,7    3,396
---
Signif. codes:  0 '***' 0,001 '**' 0,01 '*' 0,05 '.' 0,1 ' ' 1
```

```
TukeyHSD(model)$izvor_vijesti
```

	diff	lwr	upr	p adj
društvene mreže-portal	-0,97532468	-1,7651549	-0,1854945	0,00707289822
TV-portal	0,61038961	-0,2047400	1,4255192	0,24255614255
radio-portal	0,54292929	-0,4414332	1,5272918	0,55427554251
tisak-portal	0,65056818	-0,3779218	1,6790582	0,41339793230
TV-društvene mreže	1,58571429	0,7073725	2,4640561	0,00001202952
radio-društvene mreže	1,51825397	0,4809413	2,5555666	0,00070927872
tisak-društvene mreže	1,62589286	0,5466154	2,7051703	0,00044313611
radio-TV	-0,06746032	-1,1241637	0,9892430	0,99978806792
tisak-TV	0,04017857	-1,0577486	1,1381058	0,99997689387
tisak-radio	0,10763889	-1,1211725	1,3364503	0,99925834236

Funkcija `aov` procjenjuje isti model kao `lm` iz prethodnog poglavlja, ali ga ispituje u obliku razlaganja varijance. Funkcija `TukeyHSD` prima takav model i vraća sve parne razlike s intervalima i korigiranim p-vrijednostima.

Ispis potvrđuje ono što je poglavlje izgradilo. Redak modela nosi razlaganje 113,8 prema 1 001,7, iz čega slijede F i eta-kvadrat. Tablica parnih usporedbi zatim pokazuje da se društvene mreže odvajaju od svakog preostalog izvora, dok se ta četiri međusobno ne razlučuju.

Rečenica koju bi izvještaj smio sadržavati zato je uža od one koju bi ukupni test sam sugerirao. Razlika među izvorima postoji, nosi je jedna skupina, iznosi oko boda i pol na ljestvici od deset, i objašnjava desetinu ukupne varijabilnosti. Sve što ide dalje od toga traži dizajn koji ovi podaci nemaju.

Sažetak

Deset odvojenih usporedbi među pet skupina griješi mnogo češće nego što obećava, i simulacija to pokazuje bez ijedne formule. Zajednički model rješava isti problem jednim testom tako da razlaže rasipanje na dio među skupinama i dio unutar njih te ih stavlja u omjer. Taj model nije nov nego je prošireni model iz poglavlja o dvjema grupama, s jednim koeficijentom po nereferentnoj skupini. Ukupni test ne imenuje parove, pa nakon njega dolaze planirane usporedbe ili korigirane parne razlike s intervalima. Eta-kvadrat i omega-kvadrat opisuju objašnjeni udio, a pretpostavke se čitaju iz ostataka. Sljedeće poglavlje uklanja i posljednju granicu, jer isti okvir prima prediktor koji uopće nije kategorija.

Pojmovi

analiza varijance (*analysis of variance*), stopa obiteljske pogreške (*familywise error rate*), F-statistika (*F-statistic*), Tukeyjev postupak (*Tukey's HSD*), planirana usporedba (*planned contrast*), eta-kvadrat (*eta squared*), Kruskal-Wallisov test (*Kruskal-Wallis test*)

Zadaci

Konceptualni

Objasnite zašto značajan ukupni test ne znači da se svaki par skupina razlikuje. Skicirajte tri skupne sredine i raspršenosti uz koje bi ukupni test bio značajan, a samo jedan par razlučiv.

Računski

Razlaganje daje 120 na razlike među četirima skupinama i 480 na razlike unutar njih, uz ukupno sto opažanja. Izračunajte obje prosječne raspršenosti, njihov omjer i eta-kvadrat. Objasnite što bi se s omjerom dogodilo da je drugi broj dvostruko veći.

Kritički

Prosudite kako broj analitičkih odluka mijenja čitanje najmanje p-vrijednosti među mnogim skupinama i ishodima (Simmons i sur. 2011.). Predajte jedan odlomak i navedite podatak koji bi u izvještaju taj broj učinio vidljivim.

Revizija modela

Ocijenite modelsku analizu iz okvira. Izdvojite tvrdnju o ukupnom modelu koja stoji, imenujte tvrdnju o parovima koja ne slijedi i napišite rečenicu kojom bi je trebalo zamijeniti.

Regresija, opći okvir

Od pravca do općeg linearnog modela

Vrijeme čitanja	Widget	Podaci	Preduvjet
32 min	Regresijski pravac	simulirana populacija	pogl. 6, 14 i 15

VINJETA


Breiman je 2001. napisao da se statističko modeliranje razdvojilo na dvije kulture koje jedna drugu jedva primjećuju (Breiman 2001.). Jedna pretpostavlja da podatke stvara model koji treba pogoditi i protumačiti, a druga postupak ocjenjuje po tome koliko dobro pogađa ishode koje još nije vidjela.

Prigovor nije bio matematički. Breiman je tvrdio da prva kultura svoje modele ocjenjuje mjerama pristajanja koje ne provjeravaju ono što obećavaju, pa istraživač lako ostane uvjeren da je opisao mehanizam, a zapravo je opisao samo uzorak koji ima pred sobom.

Ista jednadžba pritom služi za sve. Opisati prosječan odnos, predvidjeti ishod za novu osobu i tvrditi da bi promjena jedne varijable promijenila drugu tri su različita zadatka. Kako znati na koji od njih model zapravo odgovara?

Pravac kao tvrdnja o prosjeku

Vraćamo se simuliranoj populaciji od pedeset tisuća odraslih koju su koristila poglavlja o zaključivanju. Povjerenje u medije mjereno je na ljestvici od jedan do deset, a zanima nas kako se ono mijenja s dobi. Poglavlje o povezanosti dalo bi na to pitanje jedan broj o jačini veze. Model daje nešto drugo, jer imenuje očekivano povjerenje za svaku pojedinu dob.



Slika 1: Prosječno povjerenje po godini dobi u simuliranoj populaciji, s pravcem najmanjih kvadrata procijenjenim na svih pedeset tisuća pojedinačnih odgovora.

Pravac na slici nije nacrtan kroz sredinu oblaka po oku. Bira ga pravilo koje za svaku moguću kombinaciju odsječka i nagiba gleda koliko svako pojedino opažanje promašuje, i uzima onu kombinaciju kojoj ti promašaji zajedno najmanje teže.

Definicija 43. Rezidual je razlika između opažene vrijednosti ishoda kod pojedine jedinice i vrijednosti koju za nju predviđa model, dakle onaj dio ishoda koji model nije objasnio.

$$e_i = y_i - \hat{y}_i$$

Oznaka y_i stoji za opaženu vrijednost kod i -te jedinice, a $\hat{y}_i$ za vrijednost koju model za nju predviđa, pri čemu kapica i ovdje označava procjenu.

Zbroj samih reziduala nije upotrebljiv kao mjera promašaja, jer se pozitivna i negativna odstupanja poništavaju, pa bi loš pravac mogao izgledati savršeno. Kvadriranje uklanja predznak i istodobno velika odstupanja košta više nego mala, što je razlog zbog kojeg jedno jako

promašeno opažanje pomiče pravac osjetnije od deset blago promašeni.

Definicija 44. Metoda najmanjih kvadrata bira koeficijente modela tako da zbroj kvadriranih reziduala bude najmanji mogući za zadane podatke.

Model koji taj postupak daje ima oblik koji su poglavlja o dvjema i o više skupina već koristila. Očekivano povjerenje raste od polazne vrijednosti za onoliko koliko nalaže nagib pomnožen s dobi, a ostatak pripada onome što model o pojedinoj osobi ne zna.

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Oznaka β_0 ostaje očekivani ishod kada prediktor ima vrijednost nula, β_1 je promjena očekivanog ishoda po jednoj jedinici prediktora, a ε_i je odstupanje pojedine jedinice od tog očekivanja. Ta se oznaka odnosi na model, a rezidual e_i na ono što od nje vidimo nakon što su koeficijenti procijenjeni, pa je jedno pretpostavka o svijetu, a drugo mjerljiva posljedica procjene. Razlika prema poglavlju o dvjema grupama je jedino u tome što x_i sada nije oznaka skupine nego izmjeren broj.

Procijenjeni nagib iznosi 0,0367, što znači da je deset godina dobi u ovoj populaciji povezano s razlikom od 0,37 boda povjerenja. Odsječak od 3,33 boda odnosio bi se na osobu od nula godina, koje u podacima nema, pa je računski potreban i sadržajno prazan. Kad se prediktor prije procjene umanjuje za svoju sredinu, odsječak postane očekivani ishod kod osobe prosječne dobi, a nagib se ne promijeni. Isti model tada ima jedan broj manje bez značenja.

Pravac je pritom tvrdnja o prosjecima, a ne o pojedincima. Točke na slici su prosjeci nekoliko stotina ljudi po godini dobi i leže blizu pravca, dok pojedinačni odgovori odstupaju od njega za nekoliko bodova u oba smjera. Rečenica da osobe od pedeset godina imaju u prosjeku više povjerenja od osoba od trideset opisuje te prosjeke točno i ne dopušta nikakav zaključak o konkretnoj osobi bilo koje dobi.

Nagib koji nosi tuđu priču

Populacija je simulirana, pa se zna po kojem je pravilu nastala. Povjerenje u njoj raste s dobi za točno 0,028 boda po godini, a procijenjeni nagib iznosi 0,0367. Procjena je za trećinu veća od vrijednosti koju procjenjuje, i to nije pogreška uzorkovanja jer je model procijenjen na cijeloj populaciji.

Razlog je u drugoj varijabli koja se mijenja zajedno s dobi. Izvor vijesti nije jednako raspoređen po dobi, pa prosječna dob ide od 33,4 godine među onima koji se informiraju preko društvenih mreža do 47,9 među slušateljima radija. Kako povjerenje ovisi i o izvoru, a stariji ljudi biraju izvore uz koje ide više povjerenja, nagib uz dob pokupi i tu razliku i pripiše je godinama.

Tvrdnja se može provjeriti bez ijednog novog pojma. Ako nagib doista nosi tuđu priču, onda bi unutar skupine ljudi koji se informiraju iz istoga izvora morao biti manji, jer se ondje izvor više ne mijenja zajedno s dobi.

Tablica 1: Nagib uz dob procijenjen zasebno među korisnicima svakog izvora vijesti, uz zbirni nagib i vrijednost ugrađenu u generator populacije. Izrada autora.

Izvor vijesti	Broj ljudi	Nagib uz dob
portal	15 101	0,0269
društvene mreže	13 378	0,0258
TV	10 827	0,0281
radio	5 839	0,0268
tisak	4 855	0,0255
Svi zajedno	50 000	0,0367
Ugrađeno u populaciju	—	0,028

Nijedna od pet skupina nema nagib blizu zbirnoga. Svi se kreću između 0,0255 i 0,0281, oko vrijednosti koja je u populaciju ugrađena,

dok je zbirni nagib veći od svakoga od njih. Ista pojava kojoj je poglavlje o povezanosti dalo ime pri usporedbi koeficijenata unutar i između skupina ovdje se pojavljuje u modelu, i pokazuje da razlika ne dolazi iz podataka nego iz toga što se pita.

To je konfundiranje iz poglavlja o mjerenju, sada u obliku broja umjesto dijagrama. Koeficijent uz dob odgovara na pitanje koliko se povjerenje razlikuje među ljudima različite dobi, a ne koliko bi se promijenilo kod jedne osobe koja stari. Prvo je pitanje o usporedbi skupina i model na njega odgovara točno. Drugo je pitanje o promjeni i na njega nije ni odgovarao.

Vrijedi zadržati da razlika nema veze s količinom podataka. Model je procijenjen na svih pedeset tisuća ljudi, pa nikakvo povećanje uzorka zbirni nagib ne bi pomaknulo prema vrijednosti koju je generator ugradio. Veći uzorak sužava interval oko krive vrijednosti, i to je razlog zbog kojeg se preciznost i točnost u izvještaju nikada ne mijesaju.

Prilagodba i ono što je čini mogućom

Ako opažena povezanost mijesha dvije priče, izlaz je usporediti ljude koji se u drugoj od njih ne razlikuju. Umjesto da se uzorak reže na skupine iste dobi i istog izvora, model to radi računski, procjenjujući sve koeficijente odjednom.

Definicija 45. Višestruka regresija procjenjuje povezanost svakog prediktora s ishodom pri jednakim vrijednostima svih ostalih prediktora u modelu, pa je svaki koeficijent usporedba jedinica koje se razlikuju po tom prediktoru, a po ostalima ne.

Model s dobi i izvorom vijesti daje uz dob nagib od 0,0269, praktički onu vrijednost koja je u populaciju i ugrađena. Uspoređujući ljude koji se informiraju iz istog izvora, model je oporavio pravilo po kojem su podaci nastali.

Tablica 2: Procijenjeni učinci izvora vijesti uz jednaku dob, uz vrijednosti ugrađene u generator populacije. Portal je referentna skupina. Izrada autora.

Izvor vijesti	Ugrađeno u populaciju	Procjena modela
društvene mreže	-0,55	-0,53
TV	0,35	0,31
radio	0,60	0,60
tisak	0,50	0,49

Procjene su blago manje od ugrađenih vrijednosti, i to nije slučajnost. Povjerenje je u populaciji zaokruženo na cijeli broj i odrezano na krajevima ljestvice, pa mjerenje gubi dio razlika koje generator proizvodi. Isti se učinak javlja u svakom istraživanju s ljestvicom od nekoliko stupnjeva, gdje grubo mjerilo procjene sustavno vuče prema nuli.

Slaganje u tablici izgleda kao potvrda da postupak radi, i jest, ali samo pod uvjetom koji se u stvarnom istraživanju nikada ne može provjeriti. Model je pogodio jer su obje varijable koje su sudjelovale u nastanku povjerenja i izmjerene. Da izvor vijesti nije zabilježen, koeficijent uz dob ostao bi na 0,0367 i ništa u ispisu ne bi upozorilo da je pogrešan.

Izraz „uz kontrolu” zato opisuje račun, a ne postupak. Kontrola u pokusu znači da je istraživač sam dodijelio uvjete, pa se skupine ne razlikuju ni po čemu drugome, uključujući ono što nikome nije palo na pamet izmjeriti. Kontrola u modelu znači da su uspoređene jedinice s jednakim vrijednostima onih varijabli koje su ušle u model.

Iz toga slijedi oblik rečenice koji svaki koeficijent zaslužuje. Uz jednak izvor vijesti, ljudi stariji za deset godina imaju u prosjeku 0,27 boda više povjerenja. Rečenica navodi jedinicu prediktora, jedinicu ishoda i uvjet pod kojim usporedba vrijedi, i bez ijednog od ta tri dijela koeficijent se ne može provjeriti. Ista se disciplina traži i od kategorijskih koeficijenata, gdje uvjet uključuje i referentnu skupinu prema kojoj se svaki od njih mjeri.

Odsječak u takvom modelu ostaje formalno potreban i sadržajno još slabiji nego prije, jer sada opisuje osobu od nula godina koja se informira putem portala. Model se time ne kviri. Kviri se samo pokušaj da se svaki broj iz ispisa protumači kao da nešto opisuje.

Postoji i slučaj u kojem prilagodba ne uspijeva iako su sve varijable izmjerene. Kad dva prediktora nose gotovo istu informaciju, podaci ne sadrže usporedbe u kojima se jedan mijenja a drugi ne, pa se njihovi pojedinačni doprinosi ne mogu razdvojiti i koeficijenti postaju osjetljivi na male promjene uzorka. Zbroj tih prediktora model i dalje koristi jednako dobro, a pitanje o svakome od njih zasebno u tim podacima nema odgovor.

Interakcija — Regresijski pravac

Sljedeći prikaz razdvaja dvije stvari koje su u prethodna tri odjeljka ispisane kao gotov rezultat. Čitatelj sam pomiče pravac i vidi kako zbroj kvadrata reagira na svaki pomak, a zatim uključuje treću varijablu i uspoređuje zbirni nagib s onim koji vrijedi pri njezinoj jednakoj vrijednosti. Podaci su manji i posebno konstruirani za ovaj prikaz, kako bi se pojedini reziduali mogli vidjeti.



Slika 2: Regresijski pravac — reziduali zbirnog modela i blaži prilagođeni nagib pri jednakom prethodnom interesu.

Što isprobati.

1. Mijenjajte odsječak i nagib dok se zbroj kvadrata ne približi prikazanom minimumu.
2. Povećajte samo nagib za jednu jedinicu i pratite koji se reziduali najviše produljuju.
3. Uključite model s prethodnim interesom i usporedite njegov nagib sa zbirnim pravcem.

Zbroj kvadrata oko svojeg minimuma reagira sporo, pa se pravac može osjetno pomaknuti prije nego što se brojka vidljivo pokvari. To je ista

činjenica koju poglavlje o procjeni izražava intervalom, jer sve te bliske vrijednosti nagiba podaci podnose gotovo jednako dobro.

Isti model iza ranijih poglavlja

Poglavlje o dvjema grupama zapisalo je usporedbu dviju sredina kao model s binarnim prediktorom, a poglavlje o više skupina proširilo ga je na četiri koeficijenta. Ovdje je isti model dobio prediktor koji je broj, čime je popis slučajeva zatvoren. Vrijedi provjeriti da to nije bila samo tvrdnja o zapisu.

Uzorak od sto dvadeset ljudi iz poglavlja o dvjema grupama daje razliku sredina od 1,19 boda. Koeficijent uz izvor u modelu iznosi 1,19, a omjer tog koeficijenta i njegove standardne pogreške iznosi 3,21, jednako kao vrijednost koju daje t-test na istim podacima. Riječ je o jednom računu s dva imena.

Uzorak od tristo ljudi iz poglavlja o više skupina daje ukupni test s F-vrijednošću 8,38 uz 4 i 295 stupnja slobode, što je vrijednost koju je to poglavlje ispisalo. Udio objašnjene varijabilnosti u tom modelu iznosi 10,2 %, a to je ista brojka koju je poglavlje o više skupina nazvalo eta-kvadratom.

Iz toga slijedi praktična posljedica za čitanje tuđih radova. Rad koji izvještava o t-testu, rad koji izvještava o analizi varijance i rad koji izvještava o regresiji ne koriste tri različita aparata, pa se mogu čitati istim pitanjima o jedinici analize, o tome što je uspoređeno i uz što je usporedba provedena.

Ista posljedica vrijedi i za odabir postupka. Tablica koja vodi od vrste podataka i pitanja do metode, kakva stoji u dodatku o odabiru testa, pomaže dok se uči, a njezini redovi nisu odvojeni postupci nego različiti oblici jednog istog modela. Pitanje koje ostaje jest što je ishod, što su prediktori i jesu li jedinice neovisne, a ime testa iz tih odgovora slijedi.

Okvir se pritom širi dalje nego što ova knjiga ide. Ishod koji nije broj nego kategorija, mjerenja ponovljena na istim ljudima i podaci

grupirani po razredima ili gradovima traže preinake koje pripadaju literaturi izvan opsega ovog udžbenika. Zajedničko im je da se i dalje piše model, imenuje ishod i imenuju prediktori, pa čitatelj koji je razumio ovo poglavlje takav rad može čitati i kad njegovu procjenu ne bi znao ponoviti.

Pristajanje i njegove granice

Koliko dobro model opisuje podatke mjeri se udjelom varijabilnosti ishoda koji je model uspio objasniti. Ta mjera nosi ime koje obećava više nego što daje, pa je vrijedi definirati oprezno.

Definicija 46. Koeficijent determinacije je udio ukupne varijabilnosti ishoda u promatranom uzorku koji je model objasnio, izračunat kao jedan minus omjer zbroja kvadrata reziduala i zbroja kvadrata odstupanja od zajedničke sredine.

$$R^2 = 1 - \frac{\sum e_i^2}{\sum (y_i - \bar{y})^2}$$


Model samo s dobi objašnjava 8,8 % varijabilnosti povjerenja, a model s dobi i izvorom 12,2 %. Obje su brojke male, a model s izvorom je istodobno onaj koji je oporavio pravilo po kojem su podaci nastali. Ljudi se međusobno razlikuju iz mnoštva razloga koje nijedno istraživanje ne bilježi, pa niska vrijednost ovdje ne znači loš model nego da su ljudi raznoliki.

Vrijednost ima i mehaničko svojstvo koje je čini neupotrebljivom za usporedbu modela. Nikada ne pada kad se doda prediktor, pa i onaj koji s ishodom nema nikakve veze podigne ju za nešto. U uzorku od dvjesto osoba dodavanje pet potpuno slučajnih brojeva podiže udio objašnjene varijabilnosti s 8,1 % na 9,1 %, dok prilagođeni koeficijent determinacije, koji kažnjava svaki dodani prediktor, pada s 5,8 % na 4,3 %. Prvi broj tvrdi da je model bolji, drugi da je gori, i drugi je u pravu.

Postoji i druga strana iste mehanike, po kojoj vrijednost pada iako se odnos ne mijenja. Ograničimo li populaciju na ljude između trideset i pedeset godina, nagib uz dob ostaje 0,0385, praktički kao prije, a udio objašnjene varijabilnosti pada s 8,8 % na 1,4 % na 24 282 ljudi. Ograničenje raspona iz poglavlja o povezanosti radi i ovdje, jer je udio objašnjenoga svojstvo uzorka koji je ušao u analizu, a ne odnosa među varijablama.

Zbog toga usporedba te mjere među radovima gotovo nikada ništa ne znači. Istraživanje na cijeloj populaciji i istraživanje na uskoj dobnoj skupini mogu naći potpuno isti odnos i izvijestiti o vrijednostima koje se razlikuju šest puta. Broj koji se uspoređuje jest procijenjeni koeficijent sa svojim intervalom, jer je jedini izražen u jedinicama koje su u oba rada iste.

Pristajanje pritom ništa ne govori o tome gdje model griješi, a to se vidi tek kad se reziduali pogledaju nasuprot vrijednostima koje model predviđa. Vrijeme provedeno uz medije u ovoj populaciji raste s dobi za 1,05 minute po godini, i taj je pravac sasvim razuman, ali njegovi reziduali nisu jednako raspršeni po cijelom rasponu.



Slika 3: Reziduali modela za dnevno vrijeme uz medije nasuprot vrijednostima koje model predviđa, na slučajnom podskupu od dvije tisuće osoba.

Raspršenost reziduala raste sa 57 minuta u šestini s najnižim predviđanjima na 77 u šestini s najvišima. Model je time u jednom dijelu raspona precizniji nego u drugome, pa jedna zajednička mjera nesigurnosti za sve vrijedi u prosjeku i ni za koga posebno. Prikaz reziduala kaže gdje model ne pristaje, a ne što s tim učiniti, i ta razlika između nalaza i odluke ostaje na istraživaču.

Objašnjenje i predviđanje

Dva zadatka koje ista jednadžba obavlja razlikuju se po tome što od modela traže. Objašnjenje traži koeficijent koji odgovara nekom stvarnom odnosu, a predviđanje traži malu pogrešku na jedinicama koje model nije vidio. Shmueli je pokazala da se ta dva cilja razilaze već u izboru varijabli i mjera, pa model koji je bolji za jedno može biti lošiji za drugo (Shmueli 2010.).

Razilaženje počinje već kod izbora varijabli. Spremnost na plaćanje vijesti u ovoj populaciji nastaje pod utjecajem povjerenja, dakle nakon ishoda koji se modelira. Kao prediktor povjerenja ipak radi, jer podiže udio objašnjene varijabilnosti s 12,2 % na 13,2 % i smanjuje preostalu raspršenost. Za predviđanje je to dobitak, a za objašnjenje besmislica, budući da nitko ne može znati koliko će netko platiti prije nego što ta osoba to i odluči.

Razlika se dalje ne vidi dok se model ocjenjuje na podacima na kojima je procijenjen. Vidi se čim se podaci razdvoje na skup na kojem model uči i skup koji je odvojen prije nego što je model postavljen.

Tablica 3: Prosječna pogreška predviđanja dvaju modela na podacima na kojima su procijenjeni i na odvojenom skupu, u bodovima povjerenja. Izrada autora.

Model	Na skupu za učenje	Na odvojenom skupu
Dob i izvor vijesti	1,78	1,88
Dob, izvor i 25 slučajnih brojeva	1,65	2,06

Tablica 3: Prosječna pogreška predviđanja dvaju modela na podacima na kojima su procijenjeni i na odvojenom skupu, u bodovima povjerenja. Izrada autora.

Model	Na skupu za učenje	Na odvojenom skupu
Sama sredina učenja	—	1,99

Bogatiji model objašnjava 25,4 % varijabilnosti u 150 osoba na kojima je procijenjen, prema 13,1 % kod skromnijeg, i na tim podacima griješi manje. Na 2000 osoba koje nije vidio griješi više od skromnijeg modela i više nego postupak koji svakome pripiše prosjek skupa za učenje. Model je naučio raspored slučajnih brojeva u svojem uzorku i taj raspored u novim podacima ne postoji.

Skromniji model pritom nije samo bolji od bogatijeg nego je blizu najboljega što je na ovim podacima uopće moguće. Povjerenje se u populaciji raspršuje sa standardnom devijacijom 1,98 boda, a nakon što model uzme u obzir dob i izvor ostaje raspršenost od 1,86. Ta je preostala raspršenost u populaciju ugrađena kao slučajni dio ishoda i nijedan je model ne može ukloniti, pa je pogreška predviđanja odozdo ograničena bez obzira na to koliko se varijabli doda.

Za istraživanje iz toga slijedi jedno pravilo. Tvrdnja o predviđanju provjerava se na podacima koji u procjeni nisu sudjelovali, jer se pristajanje uvijek može podići dodavanjem varijabli. Poglavlje o algoritmima na toj razlici gradi cijeli argument, budući da postupci koji odlučuju o kreditima, sadržaju i rangiranju svoju vrijednost mjere isključivo uspješnošću na jedinicama koje još nisu viđene.

Granica prema uzroku

Poglavlje o mjerenju uvelo je konfundirajuću varijablu kao razlog zbog kojeg opažena veza ne dokazuje uzrok, i obećalo da će se pitanje vratiti kad za njega bude postojao račun. Račun sada postoji i vrijedi biti precizan o tome što je njime dobiveno.

Uz izvor vijesti u modelu, koeficijent uz dob poklopio se s pravilom po kojem je populacija nastala. Uspjeh nije proizašao iz postupka nego iz toga što je generator poznat, pa se znalo koje dvije varijable treba uključiti. Stvarno istraživanje tu informaciju nema, i nijedan ispis modela ne razlikuje slučaj u kojem su svi važni čimbenici izmjereni od slučaja u kojem nisu.

Prilagođena povezanost zato nije uzročni učinak nego usporedba pod uvjetom uključenih varijabli. Da bi postala uzročna tvrdnja, potrebno je znati da je uzrok prethodio ishodu, da su svi čimbenici koji djeluju na oboje izmjereni i da nijedna uključena varijabla nije posljedica pretpostavljenog uzroka. Posljednji uvjet je najmanje poznat, jer prilagodba za posljedicu uzroka može uvesti pristranost ondje gdje je prije nije bilo.

Ta tri uvjeta nisu statistička nego sadržajna, pa se o njima raspravlja prije podataka. Za pitanje o dobi i povjerenju prvi je uvjet trivijalno zadovoljen, drugi ovisi o tome je li išta osim izvora vijesti povezano i s dobi i s povjerenjem, a treći traži provjeru da izvor vijesti nije nešto što ljudi biraju zbog razine povjerenja koju već imaju. Ovdje je i taj posljednji odgovor poznat, jer generator izvor određuje prije povjerenja. U stvarnom istraživanju o tom bi se redoslijedu raspravljalo, a ne računalo.

Odatle slijedi i skromnost u jeziku. Model daje razliku između usporedivih skupina, i tu rečenicu treba napisati doslovno tako. Rečenica o tome što bi se dogodilo da se nešto promijeni pripada dizajnu koji tu promjenu doista provodi ili opravdava, a to je pitanje poglavlja o mjerenju i dizajnu, ne poglavlja o modelima.

Postoji koristan test koji ne traži nikakav račun. Prije nego što se koeficijent opiše kao učinak, napiše se rečenica o tome što bi se moralo dogoditi da tvrdnja bude pogrešna, i provjeri se može li ijedan podatak iz istraživanja tu rečenicu opovrgnuti. Ako odgovor ovisi isključivo o pretpostavci koju podaci ne dodiruju, tvrdnja je pretpostavka napisana kao nalaz.

STATISTIKA U DIVLJINI

Druga tablica. Westreich i Greenland opisali su uobičajen postupak u kojem autor u jednoj tablici prikaže sve koeficijente višestrukog modela, s koeficijentom glavne varijable i koeficijentima kontrola jedan ispod drugoga (Westreich i Greenland 2013.). Tvrde da takva tablica potiče čitatelja da svaki redak protumači kao učinak varijable iz tog retka, iako uvjeti pod kojima to vrijedi ne mogu biti ispunjeni za sve retke istodobno.

Razlog je u tome što je model postavljen s obzirom na jednu varijablu. Skup kontrola izabran je tako da usporedba po njoj bude poštena, a za neku od tih kontrola isti skup u pravilu nije prikladan, jer među preostalim varijablama može biti i posljedica te kontrole. Tablica pritom izgleda jednako uredno u oba slučaja. Rad koji uz nju napiše da su svi navedeni čimbenici povezani s ishodom ostaje točan, a rad koji svaki redak pretvori u učinak izrekao je nekoliko tvrdnji za koje njegov dizajn jamči samo jednu.

PITAJTE MODEL

Asistent pouzdano prilagodi model, izradi dijagnostičke prikaze i prevede koeficijente u prozu. Prije poziva treba mu zadati ulogu svake varijable, referentne kategorije i cilj analize, jer isti podaci uz isti kod daju različit model ovisno o tome je li pitanje opisno, prediktivno ili uzročno. Provjeravamo tri stvari. Prva je tumači li koeficijent u izvornim jedinicama i uz uvjet ostalih varijabli, umjesto da ga opiše kao učinak. Druga je predlaže li skup kontrola prema tome koje su varijable dostupne, umjesto prema tome koje bi pitanje tražilo. Treća je ocjenjuje li predikciju na podacima koji su sudjelovali u procjeni, što je najčešća pogreška u ovom zadatku.

Prilagodi model i protumači koeficijent glavne varijable u izvornim jedinicama, s intervalom. Za svaku kontrolu napiši zašto je u modelu i može li biti posljedica glavne varijable. Predikciju ocijeni na odvojenom skupu.

NADITE GREŠKU

Na traženje da procijeni koliko dobro model predviđa povjerenje kod novih korisnika asistent je priložio ovaj račun.

```
model <- lm(povjerenje_medijima ~ dob + izvor_vijesti + obrazovanje +
            minute_medija + spol, data = uzorak)

pogreska <- sqrt(mean((uzorak$povjerenje_medijima - fitted(model))^2))
c(r2 = summary(model)$r.squared, pogreska = pogreska)
```

Uz ispis je napisao obrazloženje. Model objašnjava osjetno veći udio varijabilnosti nego prethodni, a prosječna pogreška iznosi manje od dva boda na ljestvici od jedan do deset. Iz toga zaključuje da model dovoljno pouzdano predviđa povjerenje kod korisnika koje nije vidio i preporučuje ga za primjenu na novim podacima.

Razrađeni primjer

Ponavljamo cijeli argument na jednom mjestu i u obliku u kojem bi se pojavio u izvještaju. Pitanje je kako se povjerenje u medije mijenja s dobi, a analiza daje dva odgovora ovisno o tome uspoređuju li se svi ljudi ili samo oni koji se informiraju iz istog izvora.

```
zbirni <- lm(povjerenje_medijima ~ dob, data = populacija_medija)
prilagodeni <- lm(
  povjerenje_medijima ~ dob + izvor_vijesti,
  data = populacija_medija
)

usporedba <- rbind(
  confint(zbirni)["dob", ],
  confint(prilagodeni)["dob", ]
```

```
)
cbind(nagib = c(coef(zbirni)[["dob"]], coef(prilagodeni)[["dob"]]), t
```

```

           nagib      2,5 %      97,5 %
[1,] 0,03672382 0,03568752 0,03776012
[2,] 0,02688517 0,02576553 0,02800481
```

Funkcija `confint` uz procjenu vraća i granice intervala pouzdanosti iz poglavlja o procjeni, pa svaki nagib dolazi s rasponom vrijednosti koje su s podacima uskladive. Funkcija `rbind` slaže dva takva raspona jedan ispod drugoga.

Tablica 4: Nagib uz dob u dvama modelima, s intervalom pouzdanosti, uz vrijednost ugrađenu u generator populacije. Izrada autora.

Model	Nagib		Interval	Ugrađeno
Samo dob	0,0367	0,0357 do 0,0378		0,028
Dob i izvor vijesti	0,0269	0,0258 do 0,0280		0,028

Intervali dvaju modela se ne preklapaju, pa razlika među njima nije stvar nepreciznosti. Zbirni nagib je za trećinu veći od vrijednosti koju procjenjuje, dok prilagođeni tu vrijednost dohvaća na gornjem rubu svojeg intervala, uz malo zaostajanje koje dolazi od zaokruživanja ljestvice. Izvještaj koji bi naveo samo prvi broj ne bi sadržavao nijednu netočnu rečenicu o podacima, i svejedno bi ostavio dojam da dob s povjerenjem ima jaču vezu nego što je ima.

Zaključak se zato piše u dva dijela. Ljudi različite dobi razlikuju se u povjerenju za 0,37 boda po desetljeću, a među ljudima koji se informiraju iz istog izvora ta razlika iznosi 0,27 boda. Prva rečenica opisuje populaciju kakva jest, druga izdvaja dob od izbora izvora, i tek zajedno kažu ono što je model doista našao.

Izvještaj uz to mora reći što je izostavljeno. Model sadrži dvije varijable, a povjerenje u medije ovisi i o obrazovanju, iskustvu s pojedinim

redakcijama i političkim sklonostima, koje ovdje nisu ni izmjerene. Nijedna od njih ne bi promijenila to da je opisana usporedba točna, i svaka od njih mogla bi promijeniti veličinu razlike koja ostaje kad se izjednače.

Ostaje i pitanje na koje ova analiza uopće nije odgovarala. Nijedna od dviju rečenica ne kaže da bi se povjerenje neke osobe promijenilo time što ona ostari, ni da bi se promijenilo time što promijeni izvor vijesti. Analiza opisuje kako izgleda populacija u jednom trenutku, a promjena kod iste osobe kroz vrijeme zahtijeva podatke koji istu osobu prate, kojih ovdje nema.

Sažetak

Linearni model povezuje ishod s prediktorima kroz očekivane vrijednosti i rezidualne, a metoda najmanjih kvadrata bira koeficijente po jasnem kriteriju koji se u widgetu može vidjeti kako radi. Više prediktora daje povezanosti pri jednakim vrijednostima ostalih varijabli, i na poznatoj populaciji to je dovoljno da se pravilo po kojem su podaci nastali oporavi, ali samo zato što se znalo što treba izmjeriti. Udio objašnjene varijabilnosti raste i kad se doda čista buka, pa pristajanje nije ocjena, dok reziduali pokazuju gdje model ne odgovara podacima. Objašnjenje i predviđanje odatle se razdvajaju, jer se drugo provjerava isključivo na jedinicama koje model nije vidio. Sljedeće poglavlje uzima taj kriterij ozbiljno i pita što se događa kad postupci koji ga zadovoljavaju počnu odlučivati o ljudima.

Pojmovi

linearna regresija (*linear regression*), rezidual (*residual*), metoda najmanjih kvadrata (*least squares*), koeficijent determinacije (*R-squared*), višestruka regresija (*multiple regression*), prilagođena povezanost (*adjusted association*), predviđanje izvan uzorka (*out-of-sample prediction*)

Zadaci

Konceptualni

Objasnite u jednom odlomku zašto se nagib uz dob mijenja kada u model uđe izvor vijesti, a nijedan podatak o dobi pritom nije promijenjen. Imenujte pitanje na koje odgovara svaki od dvaju nagiba.

Računski

Poglavlje navodi da je zbirni nagib 0,0367 boda po godini. Izračunajte očekivanu razliku u povjerenju između osobe od 25 i osobe od 55 godina prema tom modelu, a zatim isti račun ponovite s prilagođenim nagibom 0,0269. Predajte obje brojke i jednu rečenicu o tome koja od njih odgovara na pitanje o dvjema stvarnim osobama iz ove populacije.

Kritički

Pronađite objavljeni rad ili novinski članak koji uz koeficijent iz višestrukog modela navodi da je nešto „utjecalo” na ishod. Prosudite ga prema pitanju koje tablica koeficijenata potiče, a dizajn ne pokriva (Westreich i Greenland 2013.). Predajte kratku bilješku s popisom varijabli za koje bi taj koeficijent bio ispravno protumačen i onih za koje ne bi.

Revizija modela

Ocijenite račun i zaključak iz okvira o pogrešci. Imenujte što je u kodu ispravno, redak u kojem se pogreška događa, razlog zbog kojeg obje priložene brojke izgledaju uvjerljivo, i napišite zaključak koji bi isti ispis podnio.

Statistika u doba algoritama

Kako predviđanja postaju društvene odluke

Vrijeme čitanja	Widget	Podaci	Preduvjet
6 min	Istraživač pravednosti	simulacija	pogl. 7 i 16

VINJETA

Chouldechova je analizirala instrumente za predviđanje povratka u kriminal i pokazala da se poželjna mjerila pravednosti mogu sukobiti kada se temeljne stope razlikuju među skupinama (Chouldechova 2017.). Jednako tumačenje predviđenog rizika, jednake stope lažno pozitivnih odluka i jednaka ukupna točnost ne mogu se uvijek postići istodobno.

To nije samo matematička neugodnost. Prag modela odlučuje tko će biti zaustavljen, provjeren, preporučen ili uskraćen. Pogreške imaju različite posljedice, a zbirna ocjena skriva na koga padaju.

Kako statistički čitati algoritam koji ne opisuje samo društvo, nego sudjeluje u raspodjeli pažnje, prilika i rizika?

Predikcija na novim podacima

Algoritamski model uči obrazac na skupu za treniranje i provjerava ga na odvojenom skupu za testiranje. Razdvajanje postoji zato što model može naučiti slučajnu posebnost podataka koje je već vidio. **Preprilagodba** nastaje kada pristajanje treningu raste, a sposobnost generalizacije na nove slučajeve slabi.

Predikcija i objašnjenje postavljaju različite kriterije dobrog modela (Breiman 2001.). Predikcijski model vrednuje pogrešku na novim podacima. Objašnjavajući model traži koeficijente i strukturu koje možemo povezati s teorijom. Visoka prediktivna uspješnost ne pretvara korištene varijable u uzroke.

Klasifikacija prevodi rezultat modela u kategoriju pomoću praga. Pomicanje praga mijenja odnos lažno pozitivnih i lažno negativnih odluka. Ne postoji prag koji minimizira svaku vrstu pogreške bez odluke o njihovoj cijeni.

Algoritam kao društvena infrastruktura

Sustav preporuke ne predviđa samo što će osoba možda odabrati. Rangiranjem sadržaja mijenja ono što osoba uopće može vidjeti. Podaci o prethodnom ponašanju tako postaju ulaz u okruženje koje proizvodi

sljedeće ponašanje. Promatrač i predmet promatranja ulaze u povratnu petlju.

Metrika poput vremena zadržavanja nije neutralna zamjena za zadovoljstvo, informiranost ili javnu vrijednost. Ona operacionalizira cilj sustava. Optimizacija zatim vrlo učinkovito povećava ono što je izmjereno, uključujući slučajeve u kojima mjera slabo predstavlja društvenu svrhu.

Društvenoznanstveno pitanje zato uključuje vlasništvo nad podacima, institucionalni cilj, mogućnost žalbe i skupine koje nose pogreške. Tehnička dokumentacija modela nije potpuna bez opisa konteksta njegove uporabe.

Pravednost i temeljne stope

Mjere pravednosti promatraju različite dijelove tablice odluka. Jednaka stopa lažno pozitivnih odluka usredotočuje se na osobe bez ishoda. Jednaka prediktivna vrijednost pita koliko je pozitivnih odluka doista pozitivno. Kada se temeljne stope razlikuju, ta se mjerila mogu matematički razići (Chouldechova 2017.; Barocas i sur. 2023.).

Izbor mjerila nije samo tehnički. On određuje koju vrstu pogreške i koju populaciju sustav štiti. Poštena analiza zato prikazuje više mjerila po skupini, objašnjava prag i navodi institucionalnu posljedicu svake pogreške.

Jezični modeli kao distribucije


Veliki jezični model proizvodi tekst predviđanjem sljedećih dijelova niza iz raspodjele naučene na velikom korpusu. Tečnost je rezultat uspješnog modeliranja jezičnih obrazaca. Nije ugrađena provjera da tvrdnja odgovara stvarnom izvoru.

Model može dati korisnu strukturu, kod ili alternativno objašnjenje, ali činjenice moraju ostati vezane uz provjerljive dokumente i podatke.

Kada izvor nije dostupan, odgovoran odgovor označava prazninu. Samouvjerena rečenica bez podrijetla samo je predikcija koja zvuči kao znanje.

Interakcija — Istraživač pravednosti

Istraživač pravednosti mijenja klasifikacijski prag za dvije skupine s različitim temeljnim stopama, ali jednakom kvalitetom rezultata uvjetno na stvarni ishod. Tako se vidi kako zajednički prag može izjednačiti neke stope pogreške, a ipak proizvesti različitu prediktivnu vrijednost i točnost.



Slika 1: Istraživač pravednosti — jednake uvjetne stope pogreške ne daju jednaku prediktivnu vrijednost kada se temeljne stope razlikuju.

Što isprobati.

1. Postavite obje temeljne stope na 20 % i usporedite sva četiri mjerila.
2. Vratite skupinu B na 45 % te pronađite mjerila koja se razilaze iako je prag zajednički.

3. Pomaknite prag prema 0,30 pa prema 0,70 i provjerite može li jedno podešenje istodobno smanjiti obje vrste pogreške.

STATISTIKA U DIVLJINI

Jednaka ocjena, različite pogreške. Analiza instrumenata za procjenu rizika pokazala je sukob između kalibracije i jednakosti određenih stopa pogreške kada se temeljne stope razlikuju (Chouldechova 2017.). Tvrdnja da je model „pravedan” zato nije potpuna bez imenovanja mjerila, skupina, praga i posljedica. Agregatna točnost može ostati jednaka dok se vrste pogrešaka vrlo nejednako raspoređuju.

PITAJTE MODEL

Asistent može izračunati tablice zabune i mjerila po skupinama. Treba mu dati stvarne ishode, predviđene rezultate i prag, bez osobnih identifikatora. Provjeravamo nazivnike svake stope i tražimo da sukob mjerila ne riješi neobrazloženom tvrdnjom da je jedno „najpoštenije”.

Izračunaj tablicu zabune i stope pogrešaka zasebno po skupinama. Objasni kako prag i temeljne stope mijenjaju mjerila, a vrijednosni izbor ostavi jasno označenim.

NADITE GREŠKU

Model ima jednaku ukupnu točnost u dvjema skupinama, a prag je za obje jednak. Zato je algoritam pravedan i nije potrebno pregledavati zasebne stope pogreške.

Razrađeni primjer

Simuliramo dvije skupine s različitim temeljnim stopama i isti bučni prediktivni rezultat. Jedan zajednički prag pretvara rezultat u odluku. Izračun ne tvrdi da je neka stvarna skupina takva. Pokazuje kako nazivnici stvaraju različita mjerila.

Tablica 1: Stope pogrešaka u simuliranom klasifikacijskom primjeru. Izrada autora prema Barocas i sur. (2023.).

Mjera	Skupina A	Skupina B
Temeljna stopa	19,7 %	45,8 %
Lažno pozitivni	8,1 %	7,7 %
Lažno negativni	12,4 %	11,7 %
Točnost	91,0 %	90,5 %

Tablica pokazuje da jedno mjerilo ne opisuje cijelu raspodjelu odluka. Promjena praga može smanjiti jednu pogrešku i povećati drugu. Odluka o prihvatljivom odnosu zahtijeva znanje o posljedicama, mogućnosti žalbe i instituciji koja model primjenjuje.

Ista disciplina vrijedi za sustave preporuke i jezične modele. Prije procjene rezultata moramo znati koji je cilj optimiziran, na kojim je podacima sustav učen i kako njegove pogreške ulaze u društvenu praksu.

Sažetak

Algoritamski model procjenjujemo na novim podacima i prema cilju koji je doista optimiziran. Klasifikacijski prag raspoređuje vrste pogrešaka, a različite temeljne stope mogu dovesti mjerila pravednosti u sukob. Sustavi preporuke mijenjaju okruženje koje mjere, dok jezični modeli proizvode tečan tekst bez ugrađenog jamstva istinitosti. Statistička pismenost zato ostaje odgovornost za izvor, nazivnik, cilj i posljedice odluke.

Pojmovi

skup za treniranje (*training set*), skup za testiranje (*test set*), preprilagodba (*overfitting*), klasifikacijski prag (*classification threshold*), tablica zabune (*confusion matrix*), temeljna stopa (*base rate*), algoritamska pravednost (*algorithmic fairness*)

Zadaci

Konceptualni

Objasnite zašto jednaka ukupna točnost ne jamči jednake posljedice za dvije skupine. Predajte dvije moguće tablice zabune.

Računski

Promijenite prag u objektu `sim_klasifikacija` i predajte graf dviju stopa pogreške po skupini.

Kritički

Prosudite zašto se mjerila pravednosti mogu sukobiti kada se temeljne stope razlikuju (Chouldechova 2017.; Barocas i sur. 2023.). Predajte odlomak bez proglašenja jednog mjerila univerzalno najboljim.

Revizija modela

Ocijenite modelsku analizu iz okvira. Imenujte dvije stvarne provjere, jednu neopravdanu tvrdnju o pravednosti i mjerila koja još treba prikazati.

ZAVRŠNICA

Vaše prvo istraživanje

Od pitanja do provjerljivog zaključka

Vrijeme čitanja	Widget	Podaci	Preduvjet
26 min	bez widgeta	simulirana anketa	pogl. 2, 6 i 16

VINJETA

Istraživački tim na kraju kolegija ima rok od tri tjedna, temu koja ga zanima i datoteku koja još nije spremna za analizu. Jedan član predlaže da odmah otvore model, drugi da najprije poprave mjerenje, a treći da cijelu datoteku pošalju javnom asistentu i uštede vikend.

Sve tri ideje imaju svoju logiku i nijedna ne odgovara na pitanje koje dolazi prvo. Nije poznato koja je jedinica analize, odakle su podaci došli, koja je tvrdnja postavljena

prije gledanja ishoda i koje varijable opisuju ljude koji se mogu prepoznati.

Kako dovesti prvo istraživanje do kraja tako da svaki zaključak može provjeriti netko tko nije bio u sobi?

Pitanje prije podataka

Praktični rad počinje odabirom teme, a tema nije pitanje. Zanimanje za medijske navike, za angažman na društvenim mrežama ili za usporedbu dvaju formata naslova opisuje područje, dok istraživačko pitanje mora imenovati populaciju, jedinicu analize, mjere i usporedbu koja se izvodi.

Tri smjera pokrivaju gotovo sve što se u jednom semestru može izvesti, i razlikuju se po tome odakle podaci dolaze i koliko dizajn dopušta zaključivanju.

Tablica 1: Tri izvediva smjera prvog istraživanja, prema izvoru podataka i granici zaključka. Izrada autora.

Smjer rada	Odakle podaci	Što dizajn dopušta
Anketa među kolegama	vlastito prikupljanje	opis skupine i povezanosti unutar nje
Analiza javno dostupnih objava	postojeći zapis	opis i predviđanje, bez uzročne tvrdnje
Usporedba dviju verzija poruke	vlastita dodjela uvjeta	usporedba koja podnosi uzročni jezik

Odabir smjera unaprijed određuje koje rečenice smijemo napisati na kraju, i to je jedina odluka u projektu koju kasnija analiza ne može popraviti. Prva dva smjera opisuju svijet kakav zatječemo, a treći ga

dodirujemo tako što uvjete dodjeljujemo sami, i tek zbog te dodjele usporedba skupina nosi uzročno značenje.

Za ovo poglavlje biramo prvi smjer i pitanje koje studenti komunikologije, sociologije i psihologije redovito postavljaju. Zanima nas jesu li ljudi koji provode više vremena na društvenim mrežama skloniji vjerovati sadržaju koji ondje vide. Jedinica analize je osoba, ishod je izjavljeno povjerenje na ljestvici od jedan do deset, a prediktor je procijenjeno dnevno vrijeme u minutama.

Prije bilo čega drugoga zapisujemo i kojoj vrsti pitanje pripada. Opisno pitanje traži kako izgleda populacija, prediktivno traži koliko dobro pogađamo ishod kod nekoga koga nismo vidjeli, a uzročno traži što bi se dogodilo kad bismo nešto promijenili. Naše je opisno, i ostaje takvo bez obzira na to kako rezultati ispadnu.

Uz pitanje odmah zapisujemo i što će na kraju biti predano, jer se rad planira unatrag od toga. Nastaju izvještaj koji se čita bez pristupa podacima, skripta koja iz podataka proizvodi svaku tablicu i svaki graf, sami podaci ako ih smijemo dijeliti, kratko usmeno izlaganje i osvrt na ono što bismo napravili drukčije. Posljednja dva dijela nisu formalnost, jer izlaganje otkriva koje rečenice ne možemo obraniti naglas.

Dizajn određuje granicu zaključka

Anketa presjeka mjeri sve u jednom trenutku, pa vrijeme i povjerenje zatječe zajedno i ne može reći što je čemu prethodilo. Ista brojka bila bi u skladu s tvrdnjom da izloženost gradi povjerenje i s tvrdnjom da povjerenje vodi većoj izloženosti, a i s tvrdnjom da oboje ovisi o nečem trećem.

Uzorak dodatno određuje o kome uopće govorimo. Anketa provedena među kolegama s istog studija opisuje njih, a ne mlade ljude, ne studente i ne populaciju. Poglavlje o uzorkovanju pokazuje zašto ta granica ne ovisi o broju ispitanika, pa ni tisuću prikupljenih odgovora iz iste dvorane ne proširuje zaključak izvan te dvorane.

Mjere biramo prije prikupljanja i o njima ovisi više nego o modelu. Dnevno vrijeme na mrežama možemo pitati izravno, tražiti iz zaslonskog izvještaja uređaja ili procijeniti iz broja otvaranja aplikacije, i te tri mjere ne daju iste brojke. Samoprocjena je najjeftinija i najmanje točna, a njezina pogreška nije slučajna, jer ljudi koji su na mrežama najduže svoje vrijeme u prosjeku podcjenjuju. Poglavlje o mjerenju i dizajnu objašnjava zašto se takva pogreška prenosi u svaki kasniji rezultat, pa način mjerenja mora stajati u izvještaju uz svaku brojku koja iz njega nastaje.

Veličinu uzorka planiramo prema preciznosti koju trebamo, a ne prema tome koliko ljudi možemo dobiti. Poglavlje o veličini učinka i snazi pokazuje kako se iz željene širine intervala dobiva broj jedinica, i taj račun radimo prije prikupljanja. Ako izlazi da je potreban uzorak izvan dosega, to je nalaz koji mijenja pitanje, i bolje ga je imati na početku nego u raspravi na kraju.

Plan analize pišemo prije nego što vidimo ishod, i u njemu razdvajamo dvije vrste odluka. Potvrđujuće odluke donesene su unaprijed i obuhvaćaju glavno pitanje, glavni model i način postupanja s nedostajućim odgovorima. Istraživačke odluke nastaju iz onoga što u podacima zateknemo, i one su dopuštene sve dok se u izvještaju tako i imenuju.

Poglavlje o krizi i obnovi opisuje što se događa kada ta razlika nestane, jer skup podataka u kojem je smjelo biti analiziran samo jedan način gotovo uvijek sadrži i drugi način koji daje zanimljiviji rezultat. Zapisan plan ne sprječava nikoga da pogleda i drugo, nego sprječava da se drugo poslije predstavi kao prvo.

Podaci i zapis odluka

Podatke pribavljamo ili prikupljamo, i u oba slučaja nastaje zapis koji putuje uz njih. Bilježimo odakle su došli, pod kojom licencom, kada su preuzeti ili prikupljeni i po kojem su postupku ljudi ušli u uzorak. Bez tog zapisa nijedan kasniji broj ne može se provjeriti, jer se ne zna ni na koga se odnosi.

Izvornu datoteku ne mijenjamo nikada. Svaki popravak, svako preimenovanje i svako isključivanje događa se u koraku koji se može ponovno izvesti nad netaknutim izvornikom, pa se rezultat u svakom trenutku može vratiti na početak. Datoteka u koju se ručno upisivalo prestala je biti podatak i postala je tvrdnja bez izvora.

Osjetljive varijable prepoznajemo na početku, a ne kad ureba. Ime, kontakt, točna adresa, otvoreni odgovori u kojima se netko opisuje i kombinacije obilježja po kojima se pojedinac može prepoznati u maloj skupini traže odluku o tome hoće li uopće ući u analizu. Poglavlje o mjerenju i dizajnu obrazlaže zašto minimizacija nije formalnost, a Dodatak F daje pravila koja knjiga primjenjuje.

Čišćenje je zatim niz odluka od kojih svaka mora imati razlog koji netko drugi može pregledati.

1. Provjeravamo nedostajuće vrijednosti i bilježimo koliko ih je i gdje su.
2. Tražimo nemoguće vrijednosti, dakle dob od dvjesto godina ili udio veći od sto posto.
3. Za svaku izvedenu varijablu zapisujemo iz čega je nastala i po kojem pravilu.
4. Za svako isključeno opažanje zapisujemo razlog, prije nego što smo vidjeli kako to isključenje mijenja rezultat.

Naša simulirana anketa obuhvaća 300 ispitanika, nema nijednu nedostajuću vrijednost i sve vrijednosti leže unutar mogućih raspona, pri čemu se dnevno vrijeme kreće od 3 do 248 minuta. Stvarna datoteka gotovo nikada nije tako uredna, pa korak provjere ostaje dio analize i onda kad ništa ne pronađe.

Nedostajući odgovori u stvarnom radu traže odluku koja se donosi prije nego što se vidi kako utječe na rezultat. Isključivanje svakog ispitanika koji je preskočio jedno pitanje smanjuje uzorak i mijenja njegov sastav, jer ljudi ne preskaču pitanja nasumce. Najskromniji pošten postupak jest izvijestiti koliko odgovora nedostaje po varijabli, provesti glavnu analizu na potpunim odgovorima i navesti da je to učinjeno.

Opis prije modela

Prvi rezultat svakog izvještaja opisuje tko je u uzorku, jer bez toga čitatelj ne može procijeniti ni jednu kasniju brojku. Prosječna dob je 34,5 godina, prosječno dnevno vrijeme 50,1 minuta uz medijan od 39, a prosječno povjerenje 5,45 boda uz standardnu devijaciju 1,79.

Razlika između prosjeka i medijana vremena nije sitnica nego nalaz. Raspodjela je desno asimetrična, kao gotovo svaka mjera vremena provedenog uz sadržaj, pa prosjek povlači manjina ispitanika s vrlo visokim vrijednostima. Poglavlje o sažimanju podataka na tome inzistira, i posljedica za izvještaj je da uz prosjek uvijek stoji i medijan.


Tablica 2: Opis simuliranog uzorka po dobnim skupinama, s prosječnim dnevnim vremenom i prosječnim povjerenjem. Izrada autora.

Dobna skupina	Ispitanika	Minuta dnevno	Povjerenje
18 do 24	90	81,5	6,38
25 do 34	84	54,4	5,56
35 do 44	66	32,4	4,89
45 i više	60	16,2	4,50

Tablica po skupinama nosi više informacije od bilo kojeg zbirnog prosjeka. Dnevno vrijeme pada s 81,5 minuta u najmlađoj skupini na 16,2 u najstarijoj, a povjerenje s 6,38 na 4,50 boda. Obje se mjere kreću u istom smjeru s dobi, i tu činjenicu zapisujemo prije nego što smo izračunali ijednu povezanost.

Graf prije modela

Graf ne služi ukrasu izvještaja nego provjeri pretpostavki koje bi model inače uzeo bez pitanja. Gledamo ima li odnos oblik koji pravac može opisati, postoje li opažanja koja same povlače nagib i mijenja li se raspršenost duž raspona.



Slika 1: Dnevno vrijeme na mrežama i izjavljeno povjerenje u simuliranom uzorku, s pravcem najmanjih kvadrata i točkama razdvojenima po dobnoj skupini.

Pravac blago raste, i da smo stali ovdje, imali bismo nalaz. Oznake po dobnim skupinama pokazuju odakle taj rast dolazi, jer skupine zauzimaju različite dijelove grafa, mlađi desno i visoko, stariji lijevo i nisko. Unutar pojedine skupine oblak nema uzlazan oblik, a povezanost mjerena zasebno po skupinama kreće se od $-0,21$ do $0,15$.

Poglavlje o povezanosti isti je obrazac pokazalo na koeficijentu korelacije, a poglavlje o regresiji na nagibu. Ovdje smo ga vidjeli prije nego što je bilo koji od tih brojeva izračunat, i to je razlog zbog kojeg graf ide ispred modela a ne iza njega.

Model i ono što se dogodilo s nalazom

Model postavljamo prema pitanju, ne prema onome što je dostupno. Ishod je povjerenje, prediktor je dnevno vrijeme, a dob ulazi kao varijabla za koju poglavlje o mjerenju daje razlog da bude povezana i s vremenom i s povjerenjem.

```

zbirni <- lm(povjerenje ~ minute_dnevno, data = anketa_mreze)
uz_dob <- lm(povjerenje ~ minute_dnevno + dob, data = anketa_mreze)

rbind(
  zbirni = c(coef(zbirni)[["minute_dnevno"]], confint(zbirni)[["minute_dnevno"]]),
  uz_dob = c(coef(uz_dob)[["minute_dnevno"]], confint(uz_dob)[["minute_dnevno"]])
)

```

```

                                2,5 %      97,5 %
zbirni  0,0082048533  0,003088870  0,013320837
uz_dob  -0,0002774402 -0,006211828  0,005656947

```

Funkcija `rbind` slaže dva reda jedan ispod drugoga, a `confint` uz svaku procjenu vraća granice intervala pouzdanosti iz poglavlja o procjeni. Ispis namjerno ne sadrži p-vrijednosti, jer procjena i njezin raspon dolaze prvi.

Tablica 3: Procijenjena razlika u povjerenju uz trideset minuta više dnevnog vremena, u dvama modelima, s intervalom pouzdanosti. Izrada autora.

Model	Razlika u bodovima		Interval	Objašnjeno
Samo vrijeme	0,25	0,09 do 0,40		3,2 %
Vrijeme uz jednaku dob	-0,01	-0,19 do 0,17		10,8 %

Prvi model daje razliku od 0,25 boda uz trideset minuta više dnevnog vremena, s intervalom od 0,09 do 0,40, koji nulu ne obuhvaća. Kad se uspoređuju ljudi jednake dobi, ista razlika iznosi -0,01 boda uz interval od -0,19 do 0,17, koji je oko nule.

Nalaz se time promijenio iz jasne povezanosti u odsutnost povezanosti, i taj se prijelaz mora naći u izvještaju. Rad koji bi objavio samo prvi red tablice ne bi sadržavao nijednu netočnu brojku, a čitatelj bi iz njega izašao s uvjerenjem koje podaci ne podupiru.

Zaključak koji uzorak podnosi

Zaključak pišemo tako da svaka rečenica ima pokriće u broju koji smo ispisali. Među simuliranim ispitanicima veće dnevno vrijeme na mrežama povezano je s višim povjerenjem, a ta povezanost nestaje kad se uspoređuju ispitanici jednake dobi. Obje su rečenice točne i tek zajedno opisuju ono što smo našli.

Nesigurnost navodimo uz procjenu, a ne u zasebnom odlomku o ograničenjima. Razlika uz jednaku dob leži između -0,19 i 0,17 boda, što znači da smo isključili velike učinke u oba smjera, a mali učinak bilo kojeg predznaka i dalje je s podacima uskladiv. Rečenica da veze nema jača je od onoga što uzorak od 300 ljudi može ponuditi.

Izbjegavamo i suprotnu pogrešku, koja se lako pomiješa s oprežnošću. Nizanje uvjetnih izraza o tome kako bi možda moglo postojati nešto što bi eventualno upućivalo na nekakvu vezu ne čini izvještaj poštenijim nego neodređenijim. Jasna tvrdnja sa svojim rasponom nosi više informacije od svakog omekšavanja.

Rezultat koji ne pokazuje razliku pritom nije neuspjeh projekta. Studija koja je isključila velike učinke odgovorila je na svoje pitanje, a studija koja nije isključila ništa jer je uzorak bio premalen odgovorila je o svojoj preciznosti i to treba napisati. Poglavlje o logici testiranja i poglavlje o veličini učinka razdvajaju ta dva slučaja, i razlika među njima vidi se u širini intervala, ne u p-vrijednosti.

Poglavlje k tome ima prednost koju stvarno istraživanje nema. Anketa je simulirana, pa se zna po kojem je pravilu nastala, a u tom pravilu izravne veze između vremena i povjerenja doista nema. Oboje ovisi o dobi, i oprezni je zaključak zato bio točan, dok bi onaj iz prvog reda tablice bio pogrešan.

Ta prednost istodobno pokazuje što u stvarnom radu nedostaje. Nikakva analiza nije mogla utvrditi da veze nema, jer je i najbolji model dao samo raspon vrijednosti koje su s podacima uskladive. Znanje o generatoru došlo je izvana, a u istraživanju tu ulogu preuzimaju dizajn, teorija i ranija mjerenja, i to je razlog zbog kojeg se o njima raspravlja koliko i o rezultatu.

Izvještaj koji se može provjeriti

Izvještaj slijedi redoslijed koji čitatelju omogućuje da u svakom trenutku prekine i zna gdje je stao. Pitanje i njegova vrsta, opis uzorka i postupka prikupljanja, mjere i njihova operacionalizacija, opis podataka, analiza s procjenama i intervalima, i tek onda tumačenje s granicom generalizacije.

Svaka tablica i svaki graf nose oznake, jedinice i izvor. Broj ispitanika stoji uz svaku brojku koja se na njih odnosi, a ne samo u odjeljku o uzorku. Nijedan graf nema skraćenu os bez izričite napomene, jer poglavlje o vizualizaciji pokazuje da je skraćivanje osi tvrdnja o podacima.

Uz izvještaj predajemo ono što je potrebno da netko drugi ponovi račun, dakle podatke ako ih smijemo dijeliti, opis njihova podrijetla, skriptu koja iz njih proizvodi svaku tablicu i svaki graf, i bilješku o uporabi asistenta. Provjera je jednostavna, jer skripta mora proći u čistoj sesiji na tuđem računalu.

Usmeno izlaganje traži drukčiji izbor od pisanog rada. U petnaest minuta stane pitanje, način prikupljanja, jedan graf, jedna procjena s rasponom i jedna rečenica o tome što studija ne može reći, dok tablica koeficijenata i opis čišćenja ostaju u izvještaju. Sadržaj koji se ne može objasniti bez čitanja s projekcije obično nije razumljiv ni u pisanom obliku.

Na kraju pišemo kratak osvrt na ono što bismo napravili drukčije. Nije riječ o uljudnosti prema nastavniku nego o najkorisnijem dijelu prvog istraživanja, jer se odluke koje su se pokazale skupima pamte samo ako se zapišu. Najčešće se na tom popisu nađu mjera koja je izabrana prebrzo i uzorak o kojem se razmišljalo prekasno.

STATISTIKA U DIVLJINI

Izvještaj koji vodi procjenom. Cumming je predložio da se rezultati izvještavaju veličinom učinka i intervalom, a ne odlukom o pragu, i taj

je pristup nazvao novom statistikom (Cumming 2014.). Prijedlog je bio uređivački koliko i statistički, jer traži promjenu u tome što se u radu piše, a ne u tome što se računa.

Ono što se u prihvaćanju te preporuke često izgubi jest da interval ne rješava pitanje na koje test nije odgovarao. Naša druga procjena ima uzak interval oko nule i time isključuje velike učinke, ali o smjeru i uzroku ne govori ništa više nego test. Izvještaj koji vodi procjenom čitatelju daje materijal za prosudbu, dok samu prosudbu i dalje mora napisati autor.

Rad s asistentom

Asistent je u ovom projektu koristan na svakom koraku, i na svakom koraku odgovornost ostaje na osobi koja predaje rad. Protokol se svodi na četiri koraka koje Dodatak F razrađuje.

1. **Upitaj** tako da zadamo pitanje, dizajn, jedinicu analize, varijable, dopušten zaključak i željeni oblik izlaza.
2. **Provjeri** svaki broj prema izlazu koji smo sami proizveli i svaki izvor otvaranjem, jer i uvjerljiv odgovor može biti izmišljen.
3. **Reproduciraj** kod u čistoj lokalnoj sesiji, od učitavanja podataka do posljednje tablice.
4. **Objavi** gdje je asistent korišten, prema pravilima kolegija ili časopisa.

Objava uporabe ima sadržaj koji se može provjeriti, a ne rečenicu o tome da je alat korišten. Navodimo koji je sustav korišten, kada, za koji dio posla i što je od predloženoga preživjelo provjeru. Bilješka od tri retka dovoljna je i čini razliku između rada koji se može ocijeniti i rada o čijem nastanku čitatelj mora nagađati.

Jedno pravilo nema iznimke. Odgovori ispitanika ne odlaze u javni model, a uklanjanje imena nije dovoljno kad kombinacija dobi, studija i mjesta može osobu vratiti u prepoznatljivost. Asistentu dajemo strukturu tablice, opis varijabli ili potpuno simulirani primjer, i time

gubimo vrlo malo, jer pomoć koju trebamo tiče se postupka a ne pojedinačnih odgovora.

PITAJTE MODEL

Asistent može predložiti analizu, napisati kod, pronaći nedosljednost u izvještaju i kritizirati nacrt zaključka. Prije toga treba mu zadati vrstu pitanja, dizajn i jedinicu analize, jer bez toga bira postupak prema obliku podataka i redovito ponudi model koji odgovara na pitanje koje nismo postavili. Provjeravamo tri stvari. Prva je odgovara li predloženi zaključak dizajnu, budući da modeli uzročni jezik nude i za presjek. Druga je jesu li sve brojke iz odgovora prisutne u izlazu koji smo sami pokrenuli. Treća je traži li podatke koje mu ne smijemo dati, što se često pojavi kao usputna molba za cijelu datoteku.

Evo pitanja, dizajna i opisa varijabli, bez podataka. Predložiti analizu i napiši zaključak koji ovaj dizajn podnosi. Zatim navedi što moramo ručno provjeriti prije nego što tvoj kod pokrenemo.

NADITE GREŠKU

Tim je sačuvao izvornu datoteku, dokumentirao čišćenje i pokrenuo sav kod lokalno. Za opis uzorka zatražio je pomoć asistenta i priložio mu podatke ovako.

```
# cijela datoteka s odgovorima, imenima i kontaktima
podaci <- read.csv("anketa_odgovori_2026.csv")

cat(paste(capture.output(print(podaci)), collapse = "\n"))
```

Uz to je napisao da datoteku šalje asistentu u cijelosti kako bi opis uzorka bio što precizniji, uz obrazloženje da će rezultate ionako provjeriti sam i da podatke nakon predaje rada briše.

Sažetak

Prvo istraživanje završava tragom odluka koji vodi od pitanja do zaključka i koji netko drugi može proći bez našeg razgovora s asistentom. Vrsta pitanja i dizajn određuju granicu koju kasnija analiza ne može pomaknuti, pa se biraju prije podataka i zapisuju. Opis i graf dolaze prije modela, jer u ovom primjeru graf pokazuje odakle povezanost dolazi prije nego što ju je model izmjerio, a model onda potvrđuje da nestaje kad se uspoređuju ljudi jednake dobi. Zaključak nosi procjenu s intervalom i imenuje ono što uzorak ne može odlučiti, dok asistent ubrzava svaki korak bez ijednog osobnog podatka i bez preuzimanja odgovornosti. Time je knjiga na kraju, i ono što ostaje nije popis postupaka nego navika da se svaka brojka veže uz način na koji je nastala.

Pojmovi

istraživački plan (*research plan*), trag odluka (*decision trail*), potvrđujuća analiza (*confirmatory analysis*), istraživačka analiza (*exploratory analysis*), reproducibilan tijek rada (*reproducible workflow*), minimizacija podataka (*data minimization*), objava uporabe umjetne inteligencije (*AI disclosure*)

Zadaci

Konceptualni

Napišite jedno istraživačko pitanje iz svojeg područja i razložite ga na opisni, prediktivni i uzročni oblik. Uz svaki oblik navedite dizajn koji bi ga podnio i rečenicu koju taj dizajn ne bi dopustio. Predajte tri para rečenica.

Računski

Iz tablice opisa po dobnim skupinama izračunajte razliku u prosječnom dnevnom vremenu i razliku u prosječnom povjerenju između najmlađe i najstarije skupine. Zatim iz nagiba 0,0082 boda po minuti izračunajte koliko bi razlike u povjerenju prvi model pripisao razlici u vremenu koju ste dobili. Usporedite taj broj sa stvarnom razlikom u povjerenju među skupinama i predajte oba rezultata s jednom rečenicom objašnjenja.

Kritički

Pronađite studentski ili novinski izvještaj o anketi koji navodi postotke bez broja ispitanika ili bez opisa načina prikupljanja. Prosudite ga prema redoslijedu izvještavanja koji vodi procjenom i njezinim rasponom (Cumming 2014.). Predajte popis podataka koji nedostaju i jednu rečenicu o tome koji je zaključak zbog toga neprovjerljiv.

Revizija modela

Ocijenite postupak i kod iz okvira o pogrešci. Imenujte reproducibilne odluke koje su ispravne, redak koda u kojem nastaje povreda, argument kojim je opravdana a koji ne stoji, i napišite upit koji bi dao isti opis uzorka bez ijednog osobnog podatka.

Literatura

Anscombe, F. J. 1973. „Graphs in Statistical Analysis“. *The American Statistician* 27 (1): 17–21.

Barocas, Solon, Moritz Hardt, i Arvind Narayanan. 2023. *Fairness and Machine Learning: Limitations and Opportunities*. MIT Press.

Belia, Sarah, Fiona Fidler, Jennifer Williams, i Geoff Cumming. 2005. „Researchers Misunderstand Confidence Intervals and Standard Error Bars“. *Psychological Methods* 10 (4): 389–96. <https://doi.org/10.1037/1082-989X.10.4.389>.

Bickel, P. J., E. A. Hammel, i J. W. O’Connell. 1975. „Sex Bias in Graduate Admissions: Data from Berkeley“. *Science* 187 (4175): 398–404. <https://doi.org/10.1126/science.187.4175.398>.

Breiman, Leo. 2001. „Statistical Modeling: The Two Cultures“. *Statistical Science* 16 (3): 199–231.

Button, Katherine S., John P. A. Ioannidis, Claire Mokrysz, i sur. 2013. „Power Failure: Why Small Sample Size Undermines the

- Reliability of Neuroscience“. *Nature Reviews Neuroscience* 14 (5): 365–76. <https://doi.org/10.1038/nrn3475>.
- Chouldechova, Alexandra. 2017. „Fair Prediction with Disparate Impact: A Study of Bias in Recidivism Prediction Instruments“. *Big Data* 5 (2): 153–63.
- Cleveland, William S., i Robert McGill. 1984. „Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods“. *Journal of the American Statistical Association* 79 (387): 531–54. <https://doi.org/10.1080/01621459.1984.10478080>.
- Cochran, William G. 1954. „Some Methods for Strengthening the Common χ^2 Tests“. *Biometrics* 10 (4). <https://doi.org/10.2307/3001616>.
- Cohen, Jacob. 1988. *Statistical Power Analysis for the Behavioral Sciences*. 2. izd. Lawrence Erlbaum Associates.
- Cohen, Jacob. 1994. „The Earth Is Round ($p < .05$)“. *American Psychologist* 49 (12): 997–1003.
- Cumming, Geoff. 2014. „The New Statistics: Why and How“. *Psychological Science* 25 (1): 7–29.
- Efron, B. 1979. „Bootstrap Methods: Another Look at the Jackknife“. *The Annals of Statistics* 7 (1): 1–26.
- Gelman, Andrew, i Eric Loken. 2013. „The Garden of Forking Paths: Why Multiple Comparisons Can Be a Problem, Even When There Is No ‚Fishing Expedition‘ or ‚p-Hacking‘ and the Research Hypothesis Was Posited Ahead of Time“. Manuscript.
- Gilovich, Thomas, Robert Vallone, i Amos Tversky. 1985. „The Hot Hand in Basketball: On the Misperception of Random Sequences“.

Cognitive Psychology 17 (3): 295–314. [https://doi.org/10.1016/0010-0285\(85\)90010-6](https://doi.org/10.1016/0010-0285(85)90010-6).

Greenland, Sander, Stephen J. Senn, Kenneth J. Rothman, i sur. 2016. „Statistical Tests, P Values, Confidence Intervals, and Power: A Guide to Misinterpretations“. *European Journal of Epidemiology* 31 (4): 337–50. <https://doi.org/10.1007/s10654-016-0149-3>.

Hoekstra, Rink, Richard D. Morey, Jeffrey N. Rouder, i Eric-Jan Wagenmakers. 2014. „Robust Misinterpretation of Confidence Intervals“. *Psychonomic Bulletin & Review* 21 (5): 1157–64. <https://doi.org/10.3758/s13423-013-0572-3>.

Ioannidis, John P. A. 2005. „Why Most Published Research Findings Are False“. *PLoS Medicine* 2 (8): e124.

Ismay, Chester, i Albert Y. Kim. 2019. *Statistical Inference via Data Science: A Modern Dive into R and the Tidyverse*. Chapman; Hall/CRC. <https://doi.org/10.1201/9780367409913>.

Matejka, Justin, i George Fitzmaurice. 2017. „Same Stats, Different Graphs“. *Proceedings of the 2017 CHI Conference on Human Factors in Computing Systems*, 1290–94. <https://doi.org/10.1145/3025453.3025912>.

Miller, Joshua B., i Adam Sanjurjo. 2018. „Surprised by the Hot Hand Fallacy? A Truth in the Law of Small Numbers“. *Econometrica* 86 (6): 2019–47. <https://doi.org/10.3982/ECTA14943>.

Navarro, Danielle. 2019. *Learning Statistics with R*. <https://learningstatisticswithr.com/>.

Nieuwenhuis, Sander, Birte U. Forstmann, i Eric-Jan Wagenmakers. 2011. „Erroneous Analyses of Interactions in Neuroscience: A Problem of Significance“. *Nature Neuroscience* 14 (9): 1105–7. <https://doi.org/10.1038/nn.2886>.

- Open Science Collaboration. 2015. „Estimating the Reproducibility of Psychological Science“. *Science* 349 (6251): aac4716.
- Shmueli, Galit. 2010. „To Explain or to Predict?“. *Statistical Science* 25 (3). <https://doi.org/10.1214/10-STS330>.
- Simmons, Joseph P., Leif D. Nelson, i Uri Simonsohn. 2011. „False-Positive Psychology: Undisclosed Flexibility in Data Collection and Analysis Allows Presenting Anything as Significant“. *Psychological Science* 22 (11): 1359–66.
- Simpson, E. H. 1951. „The Interpretation of Interaction in Contingency Tables“. *Journal of the Royal Statistical Society, Series B* 13 (2): 238–41.
- Squire, Peverill. 1988. „Why the 1936 Literary Digest Poll Failed“. *Public Opinion Quarterly* 52 (1). <https://doi.org/10.1086/269085>.
- Stevens, S. S. 1946. „On the Theory of Scales of Measurement“. *Science* 103 (2684): 677–80. <https://doi.org/10.1126/science.103.2684.677>.
- Tufte, Edward R. 2001. *The Visual Display of Quantitative Information*. 2. izd. Graphics Press.
- Tukey, John W. 1977. *Exploratory Data Analysis*. Addison-Wesley.
- Tversky, Amos, i Daniel Kahneman. 1973. „Availability: A Heuristic for Judging Frequency and Probability“. *Cognitive Psychology* 5 (2): 207–32. [https://doi.org/10.1016/0010-0285\(73\)90033-9](https://doi.org/10.1016/0010-0285(73)90033-9).
- Wasserstein, Ronald L., i Nicole A. Lazar. 2016. „The ASA’s Statement on p-Values: Context, Process, and Purpose“. *The American Statistician* 70 (2): 129–33.

- Westreich, Daniel, i Sander Greenland. 2013. „The Table 2 Fallacy: Presenting and Interpreting Confounder and Modifier Coefficients“. *American Journal of Epidemiology* 177 (4): 292–98. <https://doi.org/10.1093/aje/kws412>.
- Wickham, Hadley. 2016. *ggplot2: Elegant Graphics for Data Analysis*. 2. izd. Springer.
- Wickham, Hadley, Mine Çetinkaya-Rundel, i Garrett Grolemund. 2023. *R for Data Science*. 2. izd. O'Reilly Media. <https://r4ds.hadley.nz/>.
- Wilkinson, Leland. 2005. *The Grammar of Graphics*. 2. izd. Springer. <https://doi.org/10.1007/0-387-28695-0>.

R praktikum

Praktikum je radni pratitelj knjige. Poglavlja se mogu čitati bez otvaranja koda, a ovaj dodatak pokazuje kako se iste analize izvode u R-u. Napisan je tako da se može čitati samostalno, od prve naredbe do gotove skripte, i ne pretpostavlja nikakvo prethodno iskustvo s programiranjem.

Kako čitati ovaj dodatak

Knjiga i praktikum imaju različite zadatke i vrijedi ih držati odvojenima. Poglavlja uče čitanje koda, jer je čitanje način na koji tvrdnja postaje provjerljiva. Praktikum uči pisanje, za čitatelja koji želi analizu ponoviti sam. Nijedan zadatak u knjizi ne pretpostavlja da ste prošli kroz ovaj dodatak, pa je on ponuda, a ne uvjet.

Primjeri idu od malih objekata prema tablicama, zatim prema čišćenju, grupiranju, preoblikovanju i grafovima, i završavaju skriptom koju možete predati zajedno s rezultatima. Gotovo svi rade na simuliranoj anketi `anketa_mreze`, koju knjiga koristi u poglavljima o opisanju podataka. Skup ima 300 ispitanika i pet varijabli, a proizveden je kodom uz fiksno sjeme, pa nije nalaz o stvarnoj populaciji.

Preporučeni način čitanja je uz otvoren R. Kod nemojte samo gledati nego ga prepisite i pokrenite, a zatim promijenite neki broj ili ime stupca i pogledajte što se dogodi. Razlika između čitanja i pisanja

koda upravo je u tome što se pisanje uči jedino kroz pogreške koje sami napravite i popravite.

Za dublji rad s podacima izvan opsega ovog dodatka najkorisniji je slobodno dostupan priručnik *R for Data Science*, koji cijeli pristup tidyversea razrađuje sustavnije nego što je ovdje moguće (Wickham i sur. 2023.). Čitatelju koji uopće ne želi pisati kod Dodatak B nudi put kroz softver s izbornicima.

Alat i radni prostor

Za rad su potrebna dva programa koja se instaliraju odvojeno. R je sam jezik i sustav za statističko računanje, dakle motor koji izvršava naredbe. Njegovo je vlastito sučelje vrlo štedljivo, pa se u praksi ne koristi izravno. Uređivačko okruženje daje uređivač teksta s bojanjem sintakse, konzolu u kojoj se kod izvršava, prozor za grafove i pregled objekata koje ste stvorili. Uobičajeni izbori su Positron i RStudio, oba iz istog razvojnog tima i oba besplatna.

Radni tok je u svakom od njih isti. Kod se piše u uređivaču, označi se redak ili više njih, a kombinacija tipki **Ctrl** i **Enter** šalje označeno u konzolu. Rezultat se ispisuje odmah ispod. Taj se postupak tijekom jedne analize ponovi stotinama puta i vrlo brzo postane automatski.

Prije prvog koda vrijedi urediti mjesto na kojem će analiza živjeti. Analiza se piše u skripti, a ne kao niz naredbi koje ostaju samo u konzoli, jer se skripta može ponovno pokrenuti, poslati kolegi i priložiti uz rad. Projektna mapa drži podatke, kod i rezultate na predvidljivim mjestima.

```
# Jednom po novom projektu
dir.create("data", showWarnings = FALSE)
dir.create("outputs", showWarnings = FALSE)
```

Funkcija `dir.create()` stvara mapu, a argument `showWarnings = FALSE` sprečava upozorenje ako mapa već postoji.

Mapa u kojoj R traži datoteke naziva se radnim direktorijem i može se provjeriti funkcijom `getwd()`. Uređivačka okruženja ga postavljaju na mapu projekta kada projekt otvorite kao projekt, a ne kao pojedinačnu datoteku. Odatle slijedi pravilo koje štedi mnogo živaca. Putanje pišite relativno prema mapi projekta, dakle `"data/anketa.csv"`, a nikada apsolutno, dakle nikada `"C:/Users/ime/Dokumenti/faks/data/anketa.csv"`. Apsolutna putanja radi samo na vašem računalu, jer na tuđem ne postoji mapa s vašim imenom. Relativna radi svugdje gdje se prenese cijela mapa projekta.

Preostaje učitati alate. Sav kod u ovom dodatku pretpostavlja da je na početku sesije izvršen sljedeći redak, koji učitava zbirku paketa opisanu niže u odjeljku o paketima. Ovo je jedini redak koji morate pokrenuti prije svih ostalih primjera.

```
library(tidyverse)
```

Prve naredbe i objekti

Najjednostavniji način da počnete jest da R tretirate kao kalkulator.

```
10 + 25
```

```
[1] 35
```

```
144 / 12
```

```
[1] 12
```

```
2^10
```

```
[1] 1024
```

Redak koji počinje znakom `#` komentar je i R ga potpuno zanemaruje. Komentari služe vama i vašim čitateljima da objasnite zašto nešto radite, a ne što radite, jer se ovo drugo ionako vidi iz koda.

R poštuje uobičajeni redoslijed računskih operacija, pa se množenje i dijeljenje izvode prije zbrajanja i oduzimanja. Zgrade taj redoslijed mijenjaju i vrijedi ih pisati uvijek kada izraz nije očit na prvi pogled.

```
5 + 3 * 2
```

```
[1] 11
```

```
(5 + 3) * 2
```

```
[1] 16
```

Nekoliko računskih funkcija pojavljuje se stalno.

```
sqrt(144)
```

```
[1] 12
```

```
abs(-42)
```

```
[1] 42
```

```
round(3.14159, 2)
```

```
[1] 3,14
```

```
log(100)
```

```
[1] 4,60517
```

Funkcija `sqrt()` računa drugi korijen, `abs()` apsolutnu vrijednost, `round()` zaokružuje na zadani broj decimala, a `log()` bez drugog argumenta računa prirodni logaritam. Logaritam se u knjizi pojavljuje u poglavlju o sažimanju podataka, gdje raspodjelu s dugim desnim repom pretvara u simetričniju.

Prava snaga počinje kada rezultat pohranimo i upotrijebimo poslije. Pohranjena vrijednost naziva se objektom, a stvara se operatorom pridruživanja `<-`, koji se čita kao „spremi desnu stranu pod imenom s lijeve strane”.

```
n_ispitanika <- 300
prosjek_minuta <- 87.3

ukupno_minuta <- n_ispitanika * prosjek_minuta
ukupno_minuta
```

```
[1] 26190
```

Stvaranje objekta ne ispisuje ništa. Da biste vidjeli sadržaj, upišite njegovo ime samo za sebe.

Imena imaju stroga pravila i mekše navike. Ime mora počinjati slovom, ne smije sadržavati razmake ni posebne znakove osim točke i podvlake, a velika i mala slova razlikuju se, pa su `prosjek` i `Prosjek` dva različita objekta. Navika koju knjiga slijedi jest da su riječi odvojene podvlakom i sve je malim slovima, kao u `prosjek_minuta`. Ta je konvencija standard u zajednici oko tidyversea i čini kod čitljivijim od zgusnutih ili miješanih oblika.

Imena birajte opisno. Objekt nazvan `x` radi jednako dobro kao objekt nazvan `prosjek_minuta`, ali za dva tjedna nećete znati što je bio. Izbjegavajte i imena koja se poklapaju s postojećim funkcijama, poput `mean`, `sum` ili `data`, jer objekt tada zaklanja funkciju i proizvodi poruke o greškama koje je teško razumjeti. Rezervirane riječi jezika, među kojima su `TRUE`, `FALSE`, `NULL`, `NA`, `if`, `else` i `function`, uopće se ne mogu upotrijebiti kao imena.

Jedna osobina zaslužuje oprez. Nova dodjela postojećem imenu briše staru vrijednost bez ikakva upozorenja.

```
temperatura <- 22
temperatura <- 35
temperatura
```

```
[1] 35
```

R vas neće pitati jeste li sigurni. Zbog toga isti objekt ne treba upotrebljavati za različite svrhe unutar iste analize. Ako trebate temperaturu zraka i temperaturu vode, napravite `temp_zraka` i `temp_vode`.

Vektori

U statistici gotovo nikada ne radimo s jednim brojem. Najjednostavnija struktura za više vrijednosti jest vektor, uređeni niz vrijednosti istog tipa, koji se stvara funkcijom `c()`.

```
minute <- c(95, 22, 112, 45, 78, 8, 135, 55)
minute
```

```
[1] 95 22 112 45 78 8 135 55
```

```
skupine <- c("mlađi", "stariji", "mlađi", "srednji",
             "mlađi", "stariji", "mlađi", "srednji")
skupine
```

```
[1] "mlađi" "stariji" "mlađi" "srednji" "mlađi" "stariji" "mlađi" "srednji"
[8] "srednji"
```

Tekstualne vrijednosti pišu se u navodnicima, brojčane ne.

Najvažnije svojstvo vektora jest to što se operacija automatski primjenjuje na svaki element. To se naziva vektorizacijom.

```
minute / 60
```

```
[1] 1,5833333 0,3666667 1,8666667 0,7500000 1,3000000 0,1333333 2,2500000
[8] 0,9166667
```

```
minute * 7
```

```
[1] 665 154 784 315 546 56 945 385
```

```
minute - mean(minute)
```

```
[1] 26,25 -46,75 43,25 -23,75 9,25 -60,75 66,25 -13,75
```

Kada napišete `minute / 60`, R ne dijeli vektor kao cjelinu nego svaki njegov element, i vraća novi vektor iste duljine. Zahvaljujući tome jedna naredba preoblikuje tisuće vrijednosti jednako lako kao osam.

Druga skupina funkcija radi obrnuto i cijeli vektor sažima u jedan broj.

```
length(minute)
```

```
[1] 8
```

```
mean(minute)
```

```
[1] 68,75
```

```
median(minute)
```

```
[1] 66,5
```

```
sd(minute)
```

```
[1] 44,18064
```

```
range(minute)
```

```
[1] 8 135
```

```
sum(minute)
```

```
[1] 550
```

Funkcija `length()` vraća broj elemenata, `mean()` aritmetičku sredinu, `median()` medijan, `sd()` standardnu devijaciju, `range()` najmanju i najveću vrijednost, a `sum()` zbroj. Značenje svake od tih mjera razrađuje poglavlje o sažimanju podataka.

Pojedinim elementima pristupa se uglatim zagradama.

```
minute[3]
```

```
[1] 112
```

```
minute[2:5]
```

```
[1] 22 112 45 78
```

```
minute[minute > 100]
```

```
[1] 112 135
```

```
sum(minute > 100)
```

```
[1] 2
```


Posljednja dva retka zaslužuju objašnjenje jer se obrazac ponavlja kroz cijeli R. Izraz `minute > 100` proizvodi logički vektor, dakle niz vrijednosti `TRUE` i `FALSE`. Stavljene u uglate zagrade, taj vektor bira samo elemente za koje vrijedi `TRUE`. Predan funkciji `sum()`, on se prebrojava, jer R vrijednost `TRUE` računa kao jedinicu, a `FALSE` kao nulu. Zbrajanje logičkog vektora zato je najkraći način da odgovorite na pitanje koliko ih zadovoljava uvjet.

Brojanje počinje od jedinice. Prvi element je `minute[1]`, ne `minute[0]`. Ako ste ranije radili u jezicima koji broje od nule, ovo je najčešći izvor zabune.

Za stvaranje nizova i ponavljanja korisne su dvije funkcije.

```
seq(from = 0, to = 100, by = 25)
```

```
[1] 0 25 50 75 100
```

```
rep(c("A", "B"), times = 3)
```

```
[1] "A" "B" "A" "B" "A" "B"
```

```
rep(c("A", "B"), each = 3)
```

```
[1] "A" "A" "A" "B" "B" "B"
```

Argument `times` ponavlja cijeli vektor, a `each` svaki element zasebno.

Tipovi podataka

Svaka vrijednost ima tip koji određuje što se s njom smije raditi. Četiri su tipa u praksi važna.

Brojčani tip obuhvaća sve brojeve. Tekstualni tip označava se navodnicima i s njim se ne može računati, pa se tekstovi spajaju funkcijom

`paste()` umjesto zbrajanja. Logički tip ima samo vrijednosti `TRUE` i `FALSE` i nastaje usporedbama. Faktorski tip služi za kategorijalne varijable i pamti popis dopuštenih razina.

```
class(42)
```

```
[1] "numeric"
```

```
class("TikTok")
```

```
[1] "character"
```

```
class(TRUE)
```

```
[1] "logical"
```

```
paste0("n = ", 300)
```

```
[1] "n = 300"
```

Usporedbe proizvode logičke vrijednosti i koriste vlastite operatore.

```
10 > 5
```

```
[1] TRUE
```

```
10 == 10
```

```
[1] TRUE
```

```
10 != 5
```

```
[1] TRUE
```

Razlika između jednog i dva znaka jednakosti izvor je vrlo čestih pogrešaka. Jedan znak = pridružuje vrijednost, dva znaka == provjeravaju jednakost i vraćaju TRUE ili FALSE.

Faktor je način na koji R prikazuje kategorijalne varijable, dakle nominalne i ordinalne mjere iz poglavlja o mjerenju. Uz vrijednosti pamti i popis razina, pa kategorije mogu imati zadani redoslijed koji nije abecedni.

```
obrazovanje <- factor(
  c("srednja", "prvostupnik", "magistar", "srednja", "magistar"),
  levels = c("srednja", "prvostupnik", "magistar", "doktor"),
  ordered = TRUE
)
obrazovanje
```

```
[1] srednja    prvostupnik magistar    srednja    magistar
Levels: srednja < prvostupnik < magistar < doktor
```

```
levels(obrazovanje)
```

```
[1] "srednja"      "prvostupnik" "magistar"     "doktor"
```

Razina doktor postoji u popisu iako je nitko nema. To nije greška nego korisno svojstvo, jer tablica frekvencija tada pokazuje i praznu kategoriju, umjesto da se pravi da ne postoji.

Tipove je moguće provjeriti i pretvarati.

```
tekst_broj <- "42"
class(tekst_broj)
```

```
[1] "character"
```

```
pravi_broj <- as.numeric(tekst_broj)
pravi_broj + 10
```

```
[1] 52
```

Pretvorba je važna pri uvozu podataka. Stupac s brojevima u kojem se negdje pojavljuje riječ umjesto prazne ćelije bit će učitao kao tekst, pa se s njim neće moći računati dok ga ne pretvorite.

Nedostajuće vrijednosti

Stvarni podaci gotovo nikada nisu potpuni. Ispitanik preskoči pitanje, uređaj ne zabilježi mjerenje, datoteka dođe s praznom ćelijom. R za to ima posebnu oznaku **NA**, koja se ponaša drukčije od svega ostaloga i zaslužuje pažnju od prvog dana.

Pravilo je jednostavno i nemilosrdno, jer svaka operacija koja uključuje **NA** vraća **NA**.

```
ocjene <- c(4, 5, NA, 3, 4)
mean(ocjene)
```

```
[1] NA
```

Rezultat nije broj. R ne pretpostavlja da nedostajuću vrijednost smijete zanemariti, jer ne zna kolika bi bila, a prosjek s njom i bez nje nije isti. Prisiljava vas da odluku donesete svjesno. Najčešća odluka izriče se argumentom `na.rm = TRUE`, koji nedostajuće vrijednosti izbacuje iz izračuna.

```
mean(ocjene, na.rm = TRUE)
```

```
[1] 4
```

```
sd(ocjene, na.rm = TRUE)
```

```
[1] 0,8164966
```

Postojanje nedostajućih vrijednosti provjerava se funkcijom `is.na()`, nikada usporedbom.

```
is.na(ocjene)
```

```
[1] FALSE FALSE TRUE FALSE FALSE
```

```
sum(is.na(ocjene))
```

```
[1] 1
```

```
ocjene == NA
```

```
[1] NA NA NA NA NA
```

Posljednji redak vraća sam `NA`, a ne `TRUE` ili `FALSE`. Razlog je logičan kada se izrekne riječima. Ako ne znate koliko je netko visok i ne znate koliko je netko drugi visok, ne možete reći jesu li jednako visoki, pa je odgovor „ne znam”, a ne „ne”.

U tablici se nedostajuće vrijednosti prebrojavaju po svim stupcima odjednom, što je prvi korak pri svakom novom skupu podataka.

```
anketa_mreze |>
  summarise(across(everything(), \(x) sum(is.na(x))))
```

```
# A tibble: 1 x 5
  ispitanik   dob dobna_skupina minute_dnevno povjerenje
  <int> <int>          <int>          <int>          <int>
1         0     0              0              0              0
```

Simulirani skup nema nedostajućih vrijednosti, a stvarni podaci gotovo uvijek imaju. Nikada nemojte pretpostaviti da ih nema, jer i uredna datoteka nakon uvoza zna proizvesti **NA** na neočekivanim mjestima, primjerice ondje gdje je netko upisao razmak umjesto broja.

Za uklanjanje redaka s nedostajućim vrijednostima služi `drop_na()`, koja bez argumenata briše svaki redak s bilo kojim **NA**, a s imenom stupca samo one kojima nedostaje ta vrijednost.

```
primjer_na <- tibble(
  id = 1:5,
  minute = c(60, NA, 120, 45, NA),
  povjerenje = c(7, 6, NA, 5, 8)
)

drop_na(primjer_na, minute)
```

```
# A tibble: 3 x 3
      id minute povjerenje
  <int> <dbl>     <dbl>
1     1     60         7
2     3    120        NA
3     4     45         5
```

```
drop_na(primjer_na)
```

```
# A tibble: 2 x 3
      id minute povjerenje
  <int> <dbl>     <dbl>
1     1     60         7
2     4     45         5
```

Razlika među ta dva poziva veća je nego što izgleda. Prvi zadržava tri retka, drugi samo dva, jer briše i onaj kojemu nedostaje druga varijabla. Brisanje po cijeloj tablici zato lako odbaci mnogo više podataka nego što ste namjeravali, osobito kada tablica ima mnogo stupaca.

Obrnut postupak pretvara posebne oznake u NA, što treba svaki put kada je nedostatak podatka zapisan kao vrijednost.

```
sirovo <- c(60, 120, -99, 45, -99)
na_if(sirovo, -99)
```

```
[1] 60 120 NA 45 NA
```

Odluka o postupanju s nedostajućim vrijednostima nije tehnička. Izbacivanje ispitanika koji nisu odgovorili mijenja sastav uzorka, a razlozi zbog kojih netko nije odgovorio obično su povezani s onim što se ispituje, kako pokazuje poglavlje o mjerenju i istraživačkom dizajnu. Argument `na.rm = TRUE` rješava računski problem i ostavlja sadržajni otvorenim, pa uz svaki rezultat vrijedi zabilježiti koliko je opažanja u njega ušlo.

Tablica i cjevovod

Vektor sadrži vrijednosti istog tipa, a stvarni podaci imaju i brojeve i tekst i kategorije za istog ispitanika. Za njih služi tablica, koju u tidyverseu predstavlja tibble. Svaki redak je jedno opažanje, svaki stupac jedna varijabla, a stupci mogu biti različitih tipova.

```
anketa <- tibble(
  id = 1:6,
  dob = c(19, 52, 21, 35, 23, 61),
  skupina = c("mlađi", "stariji", "mlađi", "srednji", "mlađi", "stariji"),
  minute = c(95, 22, 112, 45, 78, 8)
)
```

```
anketa
```

```
# A tibble: 6 x 4
  id    dob skupina minute
<int> <dbl> <chr>    <dbl>
```

1	1	19 mlađi	95
2	2	52 stariji	22
3	3	21 mlađi	112
4	4	35 srednji	45
5	5	23 mlađi	78
6	6	61 stariji	8

Ispis tibblea odmah pokazuje tip svakog stupca ispod njegova imena, gdje `<int>` označava cijele brojeve, `<dbl>` decimalne, a `<chr>` tekst. Uz to ispisuje samo prvih deset redaka, pa vam velika tablica ne poplavi konzolu.

Pojedinom stupcu pristupa se znakom `$`.

```
anketa$minute
```

```
[1] 95 22 112 45 78 8
```

```
mean(anketa$minute)
```

```
[1] 60
```

Time dolazimo do jednog od najvažnijih obrazaca u cijelom pristupu. Operator `|>`, koji se naziva cjevovodom, uzima rezultat lijeve strane i predaje ga kao prvi argument funkciji s desne strane. Čita se kao „pa onda”.

Zamislite da trebate uzeti tablicu, zadržati ispitanike mlađe od 30 godina i izračunati njihovo prosječno vrijeme. Bez cjevovoda to se piše na dva načina i oba su nezgrapna.

```
# Ugniježđeno, čita se iznutra prema van
mean(filter(anketa, dob < 30)$minute)
```

```
[1] 95
```



```
# S međuobjektom koji zapravo ne treba
mladi <- filter(anketa, dob < 30)
mean(mladi$minute)
```

```
[1] 95
```

Cjevovod rješava oboje.

```
anketa |>
  filter(dob < 30) |>
  pull(minute) |>
  mean()
```

```
[1] 95
```

Ovaj se kod čita odozgo prema dolje kao rečenica. Uzmi anketu, pa onda zadrži retke u kojima je dob manja od 30, pa onda izvuci stupac s minutama, pa onda izračunaj prosjek. Redoslijed pisanja odgovara redoslijedu razmišljanja, što je razlog zbog kojeg knjiga taj oblik koristi svugdje.

Funkcija `pull()` izvlači jedan stupac kao vektor, čime radi isto što i `$`, ali se uklapa u cjevovod.

Paketi

R sam po sebi dolazi s temeljnim funkcijama, a najveći dio korisnog rada obavlja se pomoću paketa koje je razvila zajednica. Paket je zbirka funkcija, podataka i dokumentacije koju je netko napisao i objavio.

Ovaj se dodatak oslanja na tidyverse, koji nije jedan paket nego skup paketa sa zajedničkom filozofijom. Među njima su `ggplot2` za grafove, `dplyr` za obradu podataka, `tidyr` za preoblikovanje, `readr` za uvoz, `tibble` za tablice, `stringr` za tekst i `forcats` za faktore.

Paket se instalira jednom, a učitava pri svakom pokretanju R-a. Instalacija je poput kupnje knjige, a učitavanje poput njezina otvaranja.

```
# Jednom, u konzoli
install.packages("tidyverse")

# Na početku svake skripte
library(tidyverse)
```

Naredbu `install.packages()` pokrećite u konzoli, a ne u skripti, jer ne želite da se paket iznova instalira pri svakom pokretanju analize. Naredba `library()` pripada vrhu skripte, jer R mora znati koje pakete koristite prije nego što naiđe na njihove funkcije.

Prva instalacija tidyversea traje nekoliko minuta jer povlači mnogo paketa odjednom. To je uobičajeno i ponavlja se samo pri nadogradnji.

Uvoz i prvi pogled

Najčešći format za podatke je CSV, obična tekstualna datoteka u kojoj su vrijednosti odvojene zarezima. Za uvoz služi funkcija `read_csv()` iz paketa `readr`.

```
anketa <- read_csv("data/anketa.csv")
```

Obratite pozornost na podvlaku. Funkcija `read_csv()` s podvlakom brža je od starije `read.csv()` s točkom, vraća tibble i informativnije javlja kako je protumačila stupce. Spremanje ide obrnutim putem funkcijom `write_csv()`, pri čemu ciljna mapa mora postojati unaprijed.

```
write_csv(sazetak, "outputs/sazetak.csv")
```

Skup na kojem radi ostatak ovog dodatka ne dolazi iz datoteke nego iz skripte `R/podaci-nastavni.R`, koja ga proizvodi uz fiksno sjeme.

	<chr>	<dbl>	<fct>		<dbl>	<dbl>
1	I001	22	18 do 24		69	6
2	I002	22	18 do 24		53	8
3	I003	24	18 do 24		83	10

Za brzi pregled raspodjele brojčane varijable korisna je `summary()`, a za kategorijalnu `count()`.

```
summary(anketa_mreze$minute_dnevno)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
3,00	22,00	39,00	50,06	68,25	248,00

```
anketa_mreze |>
  count(dobna_skupina)
```

```
# A tibble: 4 x 2
  dobna_skupina      n
  <fct>          <int>
1 18 do 24         90
2 25 do 34         84
3 35 do 44         66
4 45 i više        60
```

Funkcija `count()` prebrojava retke po kategorijama i vraća tibble. Argument `sort = TRUE` poreda rezultat od najčešće kategorije prema najrjeđoj.

Već iz ovog ispisa vidi se oblik koji poglavlje o sažimanju podataka razrađuje. Prosjek dnevnih minuta veći je od medijana, što je znak raspodjele s dugim desnim repom, u kojoj manjina vrlo intenzivnih korisnika povlači sredinu prema gore.

Za vektore izvan tablice korisne su još tri funkcije. Funkcija `sort()` vraća poredane vrijednosti, `unique()` različite vrijednosti, a `table()` tablicu učestalosti.

```
platforme_sirovo <- c("TikTok", "Instagram", "TikTok",
                      "YouTube", "Instagram", "TikTok")
```

```
unique(platforme_sirovo)
```

```
[1] "TikTok"      "Instagram" "YouTube"
```

```
length(unique(platforme_sirovo))
```

```
[1] 3
```

```
table(platforme_sirovo)
```

```
platforme_sirovo
Instagram    TikTok    YouTube
          2         3         1
```

Funkcija `count()` radi isto što i `table()`, samo vraća tibble koji se uklapa u cjevovod, pa je u ovom pristupu češći izbor. Funkcija `unique()` ipak ostaje nezamjenjiva pri provjeri podataka, jer najbrže otkriva neočekivane vrijednosti u kategorijalnom stupcu, poput iste kategorije napisane na tri načina.

Glagoli obrade podataka

Obrada podataka u dpljru svodi se na nekoliko glagola koji se slažu cjevovodom. Svaki uzima tablicu i vraća tablicu, zbog čega se mogu nizati bez ograničenja.

Glagol `filter()` bira retke koji zadovoljavaju uvjet.

```
anketa_mreze |>
  filter(dob < 25) |>
  head(3)
```

```
# A tibble: 3 x 5
  ispitanik   dob dobna_skupina minute_dnevno povjerenje
  <chr>       <dbl> <fct>                <dbl>      <dbl>
1 I001        22 18 do 24             69         6
2 I002        22 18 do 24             53         8
3 I003        24 18 do 24             83        10
```

Uvjeti se kombiniraju logičkim operatorima. Znak & znači „i”, znak | znači „ili”, a znak ! preokreće uvjet. Zarez među uvjetima unutar `filter()` radi isto što i &.

```
anketa_mreze |>
  filter(dob < 25, minute_dnevno > 100) |>
  nrow()
```

```
[1] 22
```

```
anketa_mreze |>
  filter(povjerenje <= 3 | povjerenje >= 9) |>
  nrow()
```

```
[1] 53
```

Kada provjeravate pripada li vrijednost jednoj od više kategorija, umjesto niza uvjeta spojenih znakom | upotrijebite operator `%in%`.

```
anketa_mreze |>
  filter(dobna_skupina %in% c("18 do 24", "25 do 34")) |>
  nrow()
```

```
[1] 174
```

Čest početnički promašaj jest pisanje `dobna_skupina == "18 do 24" | "25 do 34"`. Takav izraz ne javlja grešku, a ne radi ono što

se očekuje, jer R drugi dio tumači kao samostalnu vrijednost koja je uvijek istinita. Operator `%in%` uklanja tu zamku i uz to je čitljiviji.

Za raspone postoji `between()`.

```
anketa_mreze |>
  filter(between(minute_dnevno, 60, 180)) |>
  nrow()
```

```
[1] 90
```

Glagol `select()` bira stupce, a znak minus ih uklanja.

```
anketa_mreze |>
  select(ispitanik, dob, minute_dnevno) |>
  head(3)
```

```
# A tibble: 3 x 3
  ispitanik  dob minute_dnevno
  <chr>      <dbl>      <dbl>
1 I001      22         69
2 I002      22         53
3 I003      24         83
```

```
anketa_mreze |>
  select(-ispitanik) |>
  head(3)
```

```
# A tibble: 3 x 4
  dob dobna_skupina minute_dnevno povjerenje
  <dbl> <fct>          <dbl>      <dbl>
1    22 18 do 24      69         6
2    22 18 do 24      53         8
3    24 18 do 24      83        10
```

Uz imena, stupce je moguće birati pomoćnim funkcijama poput `starts_with()`, `ends_with()`, `contains()` i `where()`.

```
anketa_mreze |>
  select(where(is.numeric)) |>
  head(3)
```

```
# A tibble: 3 x 3
      dob minute_dnevno povjerenje
  <dbl>      <dbl>      <dbl>
1    22          69           6
2    22          53           8
3    24          83          10
```

Glagol `rename()` mijenja imena bez odbacivanja stupaca, a `relocate()` mijenja njihov redoslijed.

```
anketa_mreze |>
  rename(minute = minute_dnevno) |>
  names()
```

```
[1] "ispitanik"      "dob"              "dobna_skupina" "minute"
[5] "povjerenje"
```

Glagol `mutate()` stvara nove stupce ili mijenja postojeće.

```
anketa_mreze |>
  mutate(sati_dnevno = minute_dnevno / 60) |>
  select(ispitanik, minute_dnevno, sati_dnevno) |>
  head(3)
```

```
# A tibble: 3 x 3
  ispitanik minute_dnevno sati_dnevno
  <chr>      <dbl>      <dbl>
1 I001          69          1.15
2 I002          53          0.883
3 I003          83          1.38
```


Za rekodiranje u kategorije služe dvije funkcije. Kada su ishodi dva, dovoljan je `if_else()`. Kada ih je više, koristi se `case_when()`, koji uvjete provjerava redom i prvi istiniti određuje rezultat.

```
anketa_mreze |>
  mutate(
    intenzitet = case_when(
      minute_dnevno < 30 ~ "rijetko",
      minute_dnevno < 90 ~ "umjereno",
      .default = "često"
    ),
    visoko_povjerenje = if_else(povjerenje >= 7, "da", "ne")
  ) |>
  count(intenzitet, visoko_povjerenje)
```

```
# A tibble: 6 x 3
  intenzitet visoko_povjerenje     n
  <chr>      <chr>             <int>
1 rijetko    da                20
2 rijetko    ne                96
3 umjereno   da                52
4 umjereno   ne                96
5 često      da                15
6 često      ne                21
```

Redoslijed uvjeta u `case_when()` je bitan. Drugi uvjet hvata samo one koji nisu uhvaćeni prvim, pa se granice ne moraju pisati dvos-
truko. Grana `.default` pokriva sve preostale slučajeve, uključujući nedostajuće vrijednosti, pa je vrijedi napisati čak i kada mislite da je nemoguća.

Glagol `arrange()` sortira retke, a `desc()` obrće smjer.

```
anketa_mreze |>
  arrange(desc(minute_dnevno)) |>
  select(ispitanik, dobna_skupina, minute_dnevno) |>
  head(3)
```

```
# A tibble: 3 x 3
  ispitanik dobna_skupina minute_dnevno
  <chr>      <fct>                <dbl>
1 I053      18 do 24                    248
2 I048      18 do 24                    203
3 I019      18 do 24                    190
```

Nedostajuće vrijednosti pri sortiranju uvijek završavaju na kraju tablice, bez obzira na smjer. To je namjerno, jer se za njih ne zna kamo pripadaju.

Grupiranje i sažimanje

Najvažniji obrazac u cijeloj obradi podataka spaja dva glagola. Funkcija `group_by()` dijeli tablicu u skupine, a `summarise()` za svaku skupinu računa sažetak.

```
anketa_mreze |>
  group_by(dobna_skupina) |>
  summarise(
    n = n(),
    prosjek = mean(minute_dnevno),
    medijan = median(minute_dnevno),
    sd = sd(minute_dnevno),
    .groups = "drop"
  )
```

```
# A tibble: 4 x 5
  dobna_skupina      n prosjek medijan    sd
  <fct>          <int>   <dbl>   <dbl> <dbl>
1 18 do 24         90    81.5    68.5 44.6
2 25 do 34         84    54.4     46 29.0
3 35 do 44         66    32.4     26 20.3
4 45 i više        60    16.2     15  9.47
```

Funkcija `n()` unutar `summarise()` vraća broj opažanja u skupini. Vrijedi je uključiti u svaki sažetak, jer prosjek izračunat na pet ispitanika i prosjek izračunat na petsto izgledaju jednako, a nisu jednako pouzdani. Argument `.groups = "drop"` uklanja grupiranje nakon sažimanja, čime sprečava da se ono tiho prenese u sljedeći korak.

Grupirati se može po više varijabli odjednom, čime nastaje redak za svaku kombinaciju.

```
anketa_mreze |>
  mutate(visoko = if_else(povjerenje >= 7, "visoko", "nisko")) |>
  group_by(dobna_skupina, visoko) |>
  summarise(n = n(), prosjek = mean(minute_dnevno), .groups = "drop") |>
  head(4)
```

```
# A tibble: 4 x 4
  dobna_skupina visoko      n prosjek
  <fct>          <chr> <int>   <dbl>
1 18 do 24      nisko    45    80.9
2 18 do 24      visoko    45    82.2
3 25 do 34      nisko    58    56.9
4 25 do 34      visoko    26    48.8
```

Kada trebate samo prebrojavanje, `count()` je kratica za `group_by()` i `summarise(n = n())` zajedno.

Grupiranje se može spojiti i s `mutate()`, čime se dobiva stupac izračunat unutar skupine, a broj redaka ostaje nepromijenjen. Time se, primjerice, svaka vrijednost može usporediti s prosjekom vlastite skupine umjesto s ukupnim prosjekom.

```
anketa_mreze |>
  group_by(dobna_skupina) |>
  mutate(odstupanje = minute_dnevno - mean(minute_dnevno)) |>
  ungroup() |>
  select(ispitanik, dobna_skupina, minute_dnevno, odstupanje) |>
  head(4)
```

```
# A tibble: 4 x 4
  ispitanik dobna_skupina minute_dnevno odstupanje
  <chr>      <fct>                <dbl>      <dbl>
1 I001      18 do 24                69        -12.5
2 I002      18 do 24                53        -28.5
3 I003      18 do 24                83         1.46
4 I004      18 do 24                67        -14.5
```

Funkcija `ungroup()` uklanja grupiranje. Zaboravljeno grupiranje je jedan je od najčešćih uzroka rezultata koji izgledaju neobjašnjivo, jer se svaki sljedeći korak tiho izvodi po skupinama.

Kada istu operaciju treba primijeniti na više stupaca, umjesto ponavljanja služi `across()`.

```
anketa_mreze |>
  group_by(dobna_skupina) |>
  summarise(
    across(c(minute_dnevno, povjerenje), mean),
    .groups = "drop"
  )
```

```
# A tibble: 4 x 3
  dobna_skupina minute_dnevno povjerenje
  <fct>                <dbl>      <dbl>
1 18 do 24            81.5        6.38
2 25 do 34            54.4        5.56
3 35 do 44            32.4        4.89
4 45 i više           16.2        4.5
```

Prvi argument bira stupce, a drugi zadaje funkciju. Za više funkcija odjednom predaje se imenovani popis, a imena novih stupaca nastaju spajanjem imena stupca i imena funkcije.

```
anketa_mreze |>
  summarise(
    across(c(minute_dnevno, povjerenje), list(prosjek = mean, sd = sd))
  )
```

```
# A tibble: 1 x 4
```

	minute_dnevno_prosjek	minute_dnevno_sd	povjerenje_prosjek	povjerenje_sd
	<dbl>	<dbl>	<dbl>	<dbl>
1	50.1	39.2	5.45	1.79

Preoblikovanje tablica

Ista se tablica može zapisati u širem ili užem obliku, a analize i grafovi najčešće traže užu. Načelo urednih podataka traži da svaka varijabla bude stupac, svako opažanje redak, a svaka vrijednost jedna ćelija.

Funkcija `pivot_longer()` pretvara više stupaca u dva, jedan s imenom nekadašnjeg stupca i jedan s vrijednošću.

```
sazetak_sirok <- anketa_mreze |>
  group_by(dobna_skupina) |>
  summarise(
    minute = mean(minute_dnevno),
    povjerenje = mean(povjerenje),
    .groups = "drop"
  )
```

```
sazetak_sirok
```

```
# A tibble: 4 x 3
```

	dobna_skupina	minute	povjerenje
	<fct>	<dbl>	<dbl>
1	18 do 24	81.5	6.38
2	25 do 34	54.4	5.56
3	35 do 44	32.4	4.89
4	45 i više	16.2	4.5

```
sazetak_dug <- sazetak_sirok |>
  pivot_longer(
    cols = c(minute, povjerenje),
    names_to = "mjera",
    values_to = "vrijednost"
  )

sazetak_dug
```

```
# A tibble: 8 x 3
  dobna_skupina mjera      vrijednost
  <fct>          <chr>          <dbl>
1 18 do 24      minute          81.5
2 18 do 24      povjerenje         6.38
3 25 do 34      minute          54.4
4 25 do 34      povjerenje         5.56
5 35 do 44      minute          32.4
6 35 do 44      povjerenje         4.89
7 45 i više     minute          16.2
8 45 i više     povjerenje         4.5
```

Argument `cols` bira stupce koji se preoblikuju, `names_to` imenuje novi stupac s njihovim imenima, a `values_to` novi stupac s vrijednostima. Ovaj oblik traže gotovo svi grafovi u kojima se više mjera prikazuje jedna do druge.

Funkcija `pivot_wider()` radi obrnuto.

```
sazetak_dug |>
  pivot_wider(names_from = mjera, values_from = vrijednost)
```

```
# A tibble: 4 x 3
  dobna_skupina minute povjerenje
  <fct>          <dbl>    <dbl>
1 18 do 24      81.5      6.38
```

2 25 do 34	54.4	5.56
3 35 do 44	32.4	4.89
4 45 i više	16.2	4.5

Široki oblik lakše se čita u ispisu, uski se lakše obrađuje. Uobičajen tijek rada podatke drži uskima tijekom analize i širi ih tek za konačnu tablicu.

Spajanje tablica

Podaci često dolaze u više tablica koje treba povezati. Funkcija `left_join()` zadržava sve retke lijeve tablice i dodaje im stupce iz desne, ondje gdje se ključ podudara.

```
opisi <- tibble(
  dobna_skupina = factor(
    c("18 do 24", "25 do 34", "35 do 44", "45 i više"),
    levels = levels(anketa_mreze$dobna_skupina)
  ),
  naraštaj = c("najmlađi", "mlađi", "srednji", "stariji")
)

anketa_mreze |>
  left_join(opisi, by = "dobna_skupina") |>
  select(ispitanik, dobna_skupina, naraštaj) |>
  head(3)
```

```
# A tibble: 3 x 3
  ispitanik dobna_skupina naraštaj
  <chr>      <fct>      <chr>
1 I001      18 do 24    najmlađi
2 I002      18 do 24    najmlađi
3 I003      18 do 24    najmlađi
```

Argument `by` imenuje stupac po kojem se tablice povezuju. Postoje i druge vrste spajanja, među kojima `inner_join()` zadržava samo retke koji postoje u objema tablicama, a `full_join()` sve retke iz obiju.

Nakon svakog spajanja provjerite broj redaka. Ako se povećao, ključ u desnoj tablici nije jedinstven, pa se svaki lijevi redak umnožio. To je najčešća i najtiša pogreška pri spajanju, jer tablica i dalje izgleda ispravno.

```
nrow(anketa_mreze)
```

```
[1] 300
```

```
nrow(left_join(anketa_mreze, opisi, by = "dobna_skupina"))
```

```
[1] 300
```

Rad s tekstom

Anketni podaci često sadrže slobodan tekst koji treba očistiti prije analize. Paket `stringr` nudi funkcije s dosljednim imenima, koje sve počinju s `str_`.

```
platforme <- c("Instagram, TikTok", "TikTok", "YouTube, Instagram",  
               "Facebook", "TikTok, YouTube, Instagram")
```

```
str_detect(platforme, "TikTok")
```

```
[1] TRUE TRUE FALSE FALSE TRUE
```

```
sum(str_detect(platforme, "TikTok"))
```

```
[1] 3
```



```
str_count(platforme, ",") + 1
```

```
[1] 2 1 2 1 3
```

Funkcija `str_detect()` provjerava sadrži li tekst zadani niz i vraća logički vektor, `str_count()` broji pojavljivanja. Broj navedenih platformi ovdje se dobiva brojanjem zareza uvećanim za jedan, što je jednostavan i pouzdan postupak za uredno unesene odgovore.

Za čišćenje služe `str_to_lower()`, koja sve pretvara u mala slova, i `str_replace_all()`, koja zamjenjuje dijelove teksta.

```
spol_sirovo <- c("Ženski", "muški", "ŽENSKI", "M", "ž")

spol_malim <- str_to_lower(spol_sirovo)
spol_malim
```

```
[1] "ženski" "muški"  "ženski" "m"      "ž"
```

```
spol_cisto <- if_else(spol_malim %in% c("ženski", "ž"), "ženski", "muški")
spol_cisto
```

```
[1] "ženski" "muški"  "ženski" "muški"  "ženski"
```

Ujednačavanje velikih i malih slova prvi je korak pri svakom čišćenju kategorijalnog stupca, jer se `Ženski` i `ženski` inače broje kao dvije kategorije. Nakon toga preostale se inačice svode na zajedničke oznake funkcijama `if_else()` ili `case_when()`.

Faktori i redoslijed kategorija

Kategorijalne varijable po zadanom se poredaju abecedno, što gotovo nikada nije redoslijed koji želite. Dobne skupine, razine obrazovanja i ljestvice slaganja imaju vlastiti poredak koji abeceda ne poznaje.

Paket `forcats` nudi funkcije s prefiksom `fct_` koje taj poredak namještaju.

```
ocjene <- factor(
  c("srednja", "niska", "visoka", "visoka", "srednja", "niska", "visoka")
)
levels(ocjene)
```

```
[1] "niska"    "srednja"  "visoka"
```

```
ocjene_uredene <- fct_relevel(ocjene, "niska", "srednja", "visoka")
levels(ocjene_uredene)
```

```
[1] "niska"    "srednja"  "visoka"
```

Funkcija `fct_relevel()` postavlja razine u zadani redoslijed. Kada kategorije treba poredati prema nekoj brojčanoj veličini, a ne prema unaprijed poznatom poretku, posao obavlja `fct_reorder()`.

```
anketa_mreze |>
  mutate(skupina_po_minutama = fct_reorder(dobna_skupina, minute_dnevno)) |>
  pull(skupina_po_minutama) |>
  levels()
```

```
[1] "45 i više" "35 do 44"  "25 do 34"  "18 do 24"
```

Ovaj poredak nastaje iz podataka, prema medijanu minuta u svakoj skupini, i najčešće se koristi neposredno prije crtanja, jer graf s poredanim kategorijama gotovo uvijek čita se lakše od grafa s abecednim.

Kada kategorija ima previše, rijetke se mogu spojiti u zajedničku.

```
platforme <- factor(c("TikTok", "Instagram", "TikTok", "YouTube",
                      "Instagram", "TikTok", "Reddit", "Snapchat"))

fct_lump_n(platforme, n = 2) |>
  table()
```

Instagram	TikTok	Other
2	3	3

Funkcija `fct_lump_n()` zadržava najčešće kategorije i sve ostale spaja u kategoriju `Other`. Spajanje je odluka o prikazu, a ne o podacima, pa je vrijedi zabilježiti u tekstu uz tablicu ili graf, jer čitatelj inače ne zna što je u toj zajedničkoj kategoriji završilo.

Čišćenje neurednih podataka

Podaci iz stvarnih anketa rijetko dolaze spremni za analizu. Imena stupaca sadrže razmake i zagrade, kategorije su upisane na nekoliko načina, a brožčani stupci sadrže riječi. Ovaj odjeljak prolazi kroz tipične probleme redom kojim se obično pojavljuju.

Prvi je problem imena stupaca. Ime s razmakom ili zagradom mora se u kodu pisati unutar obrnutih navodnika, što je nezgodno, pa se imena obično odmah srede.

```
sirova <- tibble(
  `ID ispitanika` = 1:4,
  `TV (min/dan)` = c("90", "ne gledam", "45", ""),
  `Grad stanovanja` = c("Zagreb", "zagreb", "Split", "ZAGREB"),
  `Spol` = c("Ženski", "M", "muški", "ž")
)

names(sirova)
```

```
[1] "ID ispitanika"    "TV (min/dan)"    "Grad stanovanja" "Spol"
```

```
cista <- sirova |>
  rename(
    id = `ID ispitanika`,
    tv_min = `TV (min/dan)`,
    grad = `Grad stanovanja`,
```

```
    spol = `Spol`
  )

names(cista)
```

```
[1] "id"      "tv_min" "grad"    "spol"
```

Drugi je problem brojčani stupac koji je pri uvozu postao tekstualni, jer sadrži riječ ili praznu vrijednost. Takav stupac treba pretvoriti svjesno, tako da se odluči što znači svaka nebrojčana vrijednost.

```
cista <- cista |>
  mutate(
    tv_min = case_when(
      tv_min == "ne gledam" ~ "0",
      tv_min == "" ~ NA_character_,
      .default = tv_min
    ),
    tv_min = as.numeric(tv_min)
  )

cista$tv_min
```

```
[1] 90  0 45 NA
```

Odluka da „ne gledam” znači nulu, a prazna vrijednost nedostajući podatak sadržajna je, a ne tehnička. Netko tko ne gleda televiziju doista je gledao nula minuta, dok netko tko nije odgovorio možda gleda mnogo. Pretvorba bez te odluke, dakle izravan poziv `as.numeric()`, obje bi vrijednosti pretvorila u `NA` i uz put ispisala upozorenje.

Treći je problem ista kategorija napisana na više načina. Ujednačavanje počinje svodenjem na mala slova, a zatim se preostale inačice svode na zajedničku oznaku.

```
cista <- cista |>
  mutate(
    grad = str_to_title(str_to_lower(grad)),
    spol = str_to_lower(spol),
    spol = case_when(
      spol %in% c("ženski", "ž", "z") ~ "ženski",
      spol %in% c("muški", "m") ~ "muški",
      .default = NA_character_
    )
  )

cista
```

```
# A tibble: 4 x 4
      id tv_min grad   spol
<int> <dbl> <chr> <chr>
1     1     90 Zagreb ženski
2     2      0 Zagreb muški
3     3     45 Split  muški
4     4     NA Zagreb ženski
```

Funkcija `str_to_title()` postavlja prvo slovo svake riječi na veliko, čime se `ZAGREB` i `zagreb` svode na isti `Zagreb`. Grana `.default` ovdje namjerno vraća `NA`, jer je bolje da neprepoznata vrijednost postane vidljivo nedostajuća nego da se tiho svrsta u jednu od kategorija.

Provjera nakon čišćenja obavezna je i sastoji se od dva koraka.

```
count(cista, grad)
```

```
# A tibble: 2 x 2
  grad      n
<chr> <int>
1 Split      1
2 Zagreb     3
```

```
count(cista, spol)
```

```
# A tibble: 2 x 2
  spol      n
  <chr> <int>
1 muški    2
2 ženski    2
```

Ako se u ispisu pojavi kategorija koju niste očekivali ili NA ondje gdje ne biste smjeli imati nedostajuću vrijednost, čišćenje nije gotovo. Ovaj kratki ispis otkriva više problema od svakog drugog pojedinačnog postupka.

Cijelo čišćenje na kraju pripada jednom cjevovodu, koji od sirove tablice do uporabljive vodi bez međuobjekata i može se pročitati kao popis odluka.

```
cista_odjednom <- sirova |>
  rename(
    id = `ID ispitanika`,
    tv_min = `TV (min/dan)`,
    grad = `Grad stanovanja`,
    spol = `Spol`
  ) |>
  mutate(
    tv_min = case_when(
      tv_min == "ne gledam" ~ "0",
      tv_min == "" ~ NA_character_,
      .default = tv_min
    ),
    tv_min = as.numeric(tv_min),
    grad = str_to_title(str_to_lower(grad)),
    spol = str_to_lower(spol),
    spol = case_when(
      spol %in% c("ženski", "ž", "z") ~ "ženski",
      spol %in% c("muški", "m") ~ "muški",
```

```

      .default = NA_character_
    )
  )

identical(cista, cista_odjednom)

```

```
[1] TRUE
```

Funkcija `identical()` potvrđuje da postupak po koracima i postupak u jednom cjevovodu daju isti rezultat. Takva provjera vrijedi kad god analizu preoblikujete, jer je najlakše pogriješiti upravo pri sređivanju koda koji je dotad radio.


Ovaj cjevovod nikada ne prepisuje `sirova`. Izvorna tablica ostaje netaknuta, pa se svaki korak može ponoviti i preispitati. Čišćenje koje prepisuje izvor briše dokaz o tome što je zapravo bilo u podacima.

Grafovi

Zašto je graf skup odluka, a ne vrsta slike, razrađuje poglavlje o vizualizaciji. Ovaj odjeljak uči kako se te odluke zapisuju u paketu `ggplot2`. Redoslijed izlaganja slijedi redoslijed odluka, pa se najprije gradi kostur, a zatim se dodaju geometrija, polja, ljestvice i oznake.

Svaki graf ima tri obavezna dijela. Funkcija `ggplot()` prima tablicu, `aes()` pridružuje varijable svojstvima grafa, a sloj `geom_` određuje oblik prikaza. Slojevi se spajaju znakom `+`, a ne cjevovodom, i to je razlika koju vrijedi zapamtiti odmah, jer je zamjena tih dvaju znakova najčešća pogreška početnika.

```
ggplot(anketa_mreze, aes(x = minute_dnevno))
```



Poziv bez geometrije nacрта osi i ništa više. To nije greška nego točan prikaz onoga što je zatraženo, jer podaci i pridruživanje postoje, a odluka o obliku oznake nije donesena.


Geometrija prema vrsti podataka

Sljedeća četiri izbora pokrivaju gotovo sve što opisna analiza treba. Redoslijed prati tablicu iz poglavlja o vizualizaciji, dakle jednu brojčanu varijablu, jednu kategorijalnu, brojčanu po skupinama i dvije brojčane.

Jedna brojčana varijabla

Histogram dijeli raspon varijable na jednako široke razrede i broji opažanja u svakom.


```
ggplot(anketa_mreze, aes(x = minute_dnevno)) +
  geom_histogram(bins = 30) +
  labs(x = "Minute dnevno", y = "Broj ispitanika")
```

Argument `bins` zadaje broj razreda, a `binwidth` njihovu širinu, i navodi se jedan ili drugi. Zadanih trideset razreda gotovo nikada nije pravi izbor, pa vrijedi isprobati nekoliko vrijednosti i vidjeti mijenja li se oblik. Ako se mijenja jako, oblik nije svojstvo podataka nego izbora razreda.

Krivulja gustoće daje glađu inačicu istog prikaza i ne ovisi o razredima.

```
ggplot(anketa_mreze, aes(x = minute_dnevno)) +
  geom_density(fill = "grey70", alpha = 0.4) +
  labs(x = "Minute dnevno", y = "Gustoća")
```




Argument **alpha** zadaje prozirnost, gdje nula znači posve prozirno, a jedinica posve neprozirno. Prozirnost je nužna kada se prikazi preklapaju, jer bez nje gornji sloj skriva donji.


Jedna kategorijalna varijabla

Za kategorije postoje dva sloja i razlika među njima je u tome tko broji. Funkcija `geom_bar()` prebrojava retke sama, dok `geom_col()` crta vrijednosti koje ste već izračunali.

```
ggplot(anketa_mreze, aes(x = dobna_skupina)) +
  geom_bar() +
  labs(x = NULL, y = "Broj ispitanika")
```




```
anketa_mreze |>
  group_by(dobna_skupina) |>
  summarise(prosjek = mean(minute_dnevno), .groups = "drop") |>
  mutate(dobna_skupina = fct_reorder(dobna_skupina, prosjek)) |>
  ggplot(aes(x = prosjek, y = dobna_skupina)) +
  geom_col() +
  labs(x = "Prosječne minute dnevno", y = NULL)
```



Drugi primjer pokazuje tri navike odjednom. Cjevovod vodi do `ggplot()`, gdje se prelazi na znak `+`. Funkcija `fct_reorder()` iz odjeljka o faktorima poreda kategorije po brojčanoj veličini umjesto po abecedi. I kategorijalna varijabla stavljena je na okomitu os, čime se dobiva vodoravni prikaz, koji duga imena kategorija podnosi bez zakretanja teksta.

Kada kategorija ima dvije, druga ulazi kroz ispunu.

```
anketa_mreze |>
  mutate(razina = if_else(povjerenje >= 7, "visoko", "nisko")) |>
  ggplot(aes(x = dobna_skupina, fill = razina)) +
  geom_bar(position = "dodge") +
  labs(x = NULL, y = "Broj ispitanika", fill = NULL)
```




Argument `position` određuje raspored stupaca. Vrijednost `"dodge"` stavlja ih jedan uz drugi i čuva apsolutne brojeve, `"stack"` ih slaže jedan na drugi, a `"fill"` svaki stupac rastegne na punu visinu i time prikazuje udjele umjesto brojeva. Izbor među njima je izbor pitanja, jer prvi prikazuje koliko ih ima, a treći kako su raspoređeni.

Brojčana varijabla po skupinama

Kutijasti dijagram prije crtanja izračunava medijan i kvartile.


```
ggplot(anketa_mreze, aes(x = dobna_skupina, y = minute_dnevno)) +
  geom_boxplot() +
  labs(x = NULL, y = "Minute dnevno")
```



Razlika prema histogramu nije kozmetička. Histogram čuva oblik cijele raspodjele i ne računa ništa prije crtanja. Kutijasti dijagram oblik unutar kutije više ne pokazuje, ali skupine uspoređuje bez napore. Svaki prikaz nešto čuva i nešto odbacuje, što je argument koji poglavlje o vizualizaciji razrađuje.

Ono što je kutija odbacila može se vratiti dodavanjem sloja s opažanjima.


```
ggplot(anketa_mreze, aes(x = dobna_skupina, y = minute_dnevno)) +
  geom_jitter(width = 0.15, alpha = 0.25) +
  geom_boxplot(fill = NA, outlier.shape = NA) +
  labs(x = NULL, y = "Minute dnevno")
```



Funkcija `geom_jitter()` točkama dodaje mali slučajni pomak, jer bi inače sve opažanja iste skupine pala na isti okomiti pravac. Argument `width` zadaje koliko se smije pomaknuti, a vrijednost veća od polovine razmaka među kategorijama počinje miješati skupine. Argument `outlier.shape = NA` uklanja točke koje kutija sama crta, jer bi se inače udvostručile. Redoslijed slojeva je bitan, jer se svaki sljedeći crta preko prethodnog.

Violinski prikaz radi obrnuto od kutije i pokazuje oblik umjesto kvartila.


```
ggplot(anketa_mreze, aes(x = dobna_skupina, y = minute_dnevno)) +
  geom_violin() +
  labs(x = NULL, y = "Minute dnevno")
```



Dvije brojčane varijable

Raspršeni dijagram jedini je prikaz koji ne mora ništa izračunati.


```
ggplot(anketa_mreze, aes(x = dob, y = minute_dnevno)) +
  geom_point(alpha = 0.3) +
  labs(x = "Dob", y = "Minute dnevno")
```



Prozirnost je ovdje nužna, a ne ukrasna. Bez nje se preklopljene točke ne razlikuju od pojedinačnih, pa se gustoća oblaka ne vidi.

Sloj `geom_smooth()` provlači kroz oblak procijenjeni prosječni odnos.

```
ggplot(anketa_mreze, aes(x = dob, y = minute_dnevno)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm") +
  labs(x = "Dob", y = "Minute dnevno")
```




Argument `method = "lm"` traži pravac najmanjih kvadrata, a bez njega se crta prilagodljiva krivulja koja slijedi oblik podataka. Siva vrpca oko linije je interval pouzdanosti, i uklanja se argumentom `se = FALSE`. Ta linija je model, a ne podatak, pa se čita zajedno s oblakom iz kojega je izvučena. Poglavlje o regresiji pokazuje kako nastaje.

Pridruživanje, polja i oznake


Pridruživanje unutar i izvan aes()

Ovo je mjesto na kojem se griješi najčešće i na kojem poruka o grešci najmanje pomaže. Pravilo ima jednu rečenicu. Unutar `aes()` ide ime varijable, izvan `aes()` ide zadana vrijednost.

```
ggplot(anketa_mreze, aes(x = dob, y = minute_dnevno)) +
  geom_point(colour = "grey40", alpha = 0.4) +
  labs(x = "Dob", y = "Minute dnevno")
```



```
anketa_mreze |>
  mutate(razina = if_else(povjerenje >= 7, "visoko", "nisko")) |>
  ggplot(aes(x = dob, y = minute_dnevno)) +
  geom_point(aes(shape = razina), alpha = 0.5) +
  labs(x = "Dob", y = "Minute dnevno", shape = NULL)
```




U prvom pozivu boja je zadana vrijednost i vrijedi za sve oznake, pa legende nema. U drugom je oblik pridružen varijabli, pa ggplot2 le-
gendu izradi sam. Kada se ime boje zabunom stavi unutar `aes()`,
paket ga protumači kao jednočlanu kategorijalnu varijablu, sve oz-
nake oboji jednako i doda beskorisnu legendu s jednim unosom. Graf
pritom ne javlja nikakvu grešku.

Polja

Funkcija `facet_wrap()` ponavlja isti graf za svaku razinu varijable.
Tilda ispred imena čita se kao „po”.

```
ggplot(anketa_mreze, aes(x = minute_dnevno)) +
  geom_histogram(bins = 24) +
  facet_wrap(~ dobna_skupina, nrow = 1) +
  labs(x = "Minute dnevno", y = "Broj ispitanika")
```



Argument `nrow` ili `ncol` određuje raspored polja. Po zadanom sva polja dijele istu os, što je i svrha postupka, jer se položaji smiju uspoređivati između polja. Argument `scales = "free_y"` to napušta i svakom polju daje vlastiti raspon, čime usporedba razina prestaje biti moguća. Vrijedi ga upotrijebiti samo kada se uspoređuje oblik, i tada to reći u tekstu uz graf.

Za dvije kategorijalne varijable odjednom služi `facet_grid()`, koja polja slaže u matricu, s varijablom za retke lijevo i varijablom za stupce desno od tilde.

Oznake


Funkcija `labs()` imenuje sve što se na grafu vidi.

```
ggplot(anketa_mreze, aes(x = dob, y = minute_dnevno)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    title = "Vrijeme korištenja opada s dobi",
    subtitle = "Simulirana anketa, 300 ispitanika",
    x = "Dob",
    y = "Minute dnevno",
```

```
caption = "Izrada autora. Podaci su simulirani i nisu mjerenje."
)
```

Vrijeme korištenja opada s dobi

Simulirana anketa, 300 ispitanika



Izrada autora. Podaci su simulirani i nisu mjerenje.

Naslov koji izriče nalaz čitatelju kaže više od naslova koji opisuje sadržaj, pa je „Vrijeme korištenja opada s dobi” korisnije od „Odnos dobi i vremena korištenja”. Potpis nosi izvor podataka i napomenu o postupku, i u ovoj knjizi nikada ne izostaje.


Izgled, ljestvice i spremanje

Teme i ljestvice

Tema određuje sve što nije podatak, dakle pozadinu, mrežu, pisma i položaj legende. Ugrađene teme uključuju `theme_minimal()`, `theme_bw()`, `theme_classic()` i `theme_void()`, a postavljaju se po grafu ili jednom za cijelu sesiju pozivom `theme_set()`.

```
ggplot(anketa_mreze, aes(x = dobna_skupina)) +
  geom_bar() +
  labs(x = NULL, y = "Broj ispitanika") +
```

```
theme_minimal() +
theme(
  panel.grid.minor = element_blank(),
  legend.position = "none"
)
```




Funkcija `theme()` mijenja pojedinačne elemente, pri čemu `element_blank()` element uklanja, a `element_text()` mu mijenja pismo i veličinu. Poziv `theme()` dolazi nakon gotove teme, jer bi ga inače gotova tema pregazila.

Boje kategorija zadaju se ljestvicama. Ručni izbor traži `scale_fill_manual()` uz popis vrijednosti, a gotove skupove nude `scale_fill_brewer()` i `scale_fill_viridis_d()`. Skup `viridis` vrijedi poznavati jer je izrađen tako da jednakim koracima u podacima odgovaraju jednaki koraci u boji, ostaje razlučiv u sivim tonovima i čitljiv osobama koje boje razlikuju drukčije. Nastavak `_d` označava kategorijalnu varijablu, a `_c` neprekinutu.

Ova knjiga vlastite boje ne bira u poglavljima nego ih uzima iz svoje palete, pa se u njezinim izvorima ne pojavljuje nijedan zapis boje. Razlog je u tome što paleta mora ostati razlučiva i u crno-bijelom tisku, što se postiže poretком po svjetlini, a ne po tonu.


Oznake na osima uređuju se funkcijama `scale_x_continuous()` i `scale_y_continuous()`, gdje `breaks` zadaje položaje oznaka, a `labels` njihov zapis.

```
anketa_mreze |>
  group_by(dobna_skupina) |>
  summarise(prosjek = mean(minute_dnevno), .groups = "drop") |>
  ggplot(aes(x = dobna_skupina, y = prosjek)) +
  geom_col() +
  scale_y_continuous(breaks = seq(0, 100, by = 25)) +
  labs(x = NULL, y = "Prosječne minute dnevno")
```



Jedan par argumenata zaslužuje posebnu pozornost, jer izgledaju zamjenjivo, a nisu. Argument `limits` unutar ljestvice odbacuje opažanja izvan raspona prije crtanja, pa se s njima gubi i sve što se iz njih računa, uključujući pravce i prosjeke. Funkcija `coord_cartesian()` mijenja samo prikazani izrez i sva opažanja zadržava u izračunu.

```
ggplot(anketa_mreze, aes(x = dob, y = minute_dnevno)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = FALSE) +
  coord_cartesian(ylim = c(0, 150)) +
  labs(x = "Dob", y = "Minute dnevno")
```



Kada isti raspon zadate preko `limits`, pravac se promijeni, jer je izračunat bez odbačenih opažanja. To je tiha pogreška koja graf ne ruši, pa za sužavanje pogleda uvijek koristite `coord_cartesian()`.

Spremanje

Gotov se graf sprema funkcijom `ggsave()`.

```
ggsave("outputs/dob-minute.png", width = 6, height = 3.6, dpi = 300)
```

Bez imenovanog grafa sprema se posljednji nacrtani. Dimenzije se zadaju u inčima, a `dpi` određuje razlučivost, pri čemu je 300 uobičajeno za tisak, a 150 dovoljno za prezentaciju. Nastavak u imenu datoteke određuje format, gdje `.png` daje rastersku sliku prikladnu za zaslon, a `.pdf` i `.svg` vektorsku, koja se može povećati bez gubitka oštine.

Četiri česte pogreške

Prva je znak `|>` umjesto `+` između slojeva. Cjevovod vodi do `ggplot()`, a unutar grafa slojevi se zbrajaju.

Druga je brojčana varijabla pridružena ispuni stupčastog prikaza, čime nastaje neprekinuta ljestvica boja ondje gdje su potrebne kategorije. Popravak je pretvoriti varijablu u faktor.

Treća je previše skupina u jednom prikazu. Preko tri ili četiri boje legenda prestaje pomagati, pa je bolje prijeći na polja.

Četvrta je nedostajuća vrijednost koja tiho postane vlastita kategorija ili vlastito polje. Prikaz izgleda ispravno, a sadrži skupinu koja ne postoji. Provjera funkcijom `count()` prije crtanja to otkriva odmah.

Pisanje funkcija

Kada se isti postupak ponavlja nad različitim varijablama, vrijedi mu dati ime. Funkcija se sastoji od imena, popisa argumenata i tijela, a vraća vrijednost posljednjeg izraza.

```

opis <- function(x) {
  tibble(
    n = sum(!is.na(x)),
    sredina = mean(x, na.rm = TRUE),
    medijan = median(x, na.rm = TRUE),
    sd = sd(x, na.rm = TRUE)
  )
}

```

```
opis(anketa_mreze$minute_dnevno)
```

```

# A tibble: 1 x 4
      n sredina medijan    sd
  <int>   <dbl>   <dbl> <dbl>
1   300    50.1     39  39.2

```

```
opis(anketa_mreze$povjerenje)
```



```
# A tibble: 1 x 4
      n sredina medijan    sd
  <int>   <dbl>   <dbl> <dbl>
1   300    5.45     5  1.79
```

Argumenti mogu imati zadane vrijednosti, koje se koriste kada ih pozivatelj ne navede.

```
opis_zaokruzeno <- function(x, decimala = 1) {
  opis(x) |>
    mutate(across(c(sredina, medijan, sd), \(v) round(v, decimala)))
}

opis_zaokruzeno(anketa_mreze$minute_dnevno)
```

```
# A tibble: 1 x 4
      n sredina medijan    sd
  <int>   <dbl>   <dbl> <dbl>
1   300   50.1    39  39.2
```

```
opis_zaokruzeno(anketa_mreze$minute_dnevno, decimala = 3)
```

```
# A tibble: 1 x 4
      n sredina medijan    sd
  <int>   <dbl>   <dbl> <dbl>
1   300   50.1    39  39.2
```

Zapis `\(v)` skraćeni je oblik za `function(v)` i koristan je za kratke funkcije koje se predaju drugim funkcijama.

U funkciju je korisno ugraditi provjeru ulaza, kako bi pogreška bila prijavljena na mjestu gdje je nastala, a ne nekoliko koraka poslije.

```
udio_iznad <- function(x, granica) {
  if (!is.numeric(x)) {
    stop("Varijabla mora biti brojčana.")
  }
  100 * mean(x > granica, na.rm = TRUE)
}

udio_iznad(anketa_mreze$minute_dnevno, 120)
```

```
[1] 6,333333
```

Funkcija `stop()` prekida izvršavanje i ispisuje poruku. Poruka treba reći što je pošlo po zlu i što se očekivalo, jer ćete je čitati vi sami za nekoliko mjeseci.

Skripta, Quarto i ponovljivost

Analiza se piše u datoteci, a ne u konzoli. Uredna skripta ima zaglavlje s opisom, zatim učitavanje paketa, zatim učitavanje podataka, pa pregled, obradu i tek onda rezultate.

```
# =====
# Analiza korištenja društvenih mreža
# Autor: Ime Prezime
# Datum: 2026-07-30
# =====

# 1. Paketi ----
library(tidyverse)

# 2. Podaci ----
anketa <- read_csv("data/anketa.csv")

# 3. Pregled ----
glimpse(anketa)
```

```
colSums(is.na(anketa))

# 4. Obrada ----
anketa_cista <- anketa |>
  filter(!is.na(minute_dnevno)) |>
  mutate(sati_dnevno = minute_dnevno / 60)

# 5. Rezultati ----
sazetak <- anketa_cista |>
  group_by(dobna_skupina) |>
  summarise(n = n(), prosjek = mean(minute_dnevno), .groups = "drop")

# 6. Izvoz ----
write_csv(sazetak, "outputs/sazetak.csv")
```

Komentar koji završava s četiri crtice R-ova okruženja prepoznaju kao naslov odjeljka i prikazuju ga u navigaciji, što u dugoj skripti znatno olakšava snalaženje.

Čišćenje nikada ne prepisuje izvornu datoteku. Stvara novi objekt ili novu datoteku, a svaka promjena ostaje zapisana u skripti. Ručna izmjena ćelije u tablici prekida ponovljivost, jer nakon nje nitko, uključujući vas, ne može rekonstruirati put od sirovih podataka do rezultata.

Kada uz kod treba i tekst, umjesto skripte koristi se Quarto dokument, isti alat kojim je izrađena ova knjiga. Takav dokument ima tri dijela, i to zaglavlje u kojem se zadaju naslov i format, tekst pisan u Markdownu i blokove koda čiji se rezultati ugrađuju u dokument pri izradi. Ponašanje svakog bloka podešava se opcijama, među kojima `echo` odlučuje hoće li se kod vidjeti, `eval` hoće li se izvršiti, a `warning` i `message` hoće li se poruke prikazati. Izvještaj za naručitelja tako može sakriti kod, a isti izvor za kolegicu analitičarku može ga pokazati.

Quarto uz to omogućuje da broj u rečenici dođe izravno iz izračuna, umjesto da se prepisuje rukom. Takav se umetnuti kod piše unutar obrnutih navodnika s oznakom jezika, u obliku prikazanom niže.

```
U uzorku je \text{300} ispitanika, a prosječno dnevno
vrijeme iznosi \text{50,1} minuta.
```

Pri izradi dokumenta na mjestu svakog takvog izraza pojavljuje se njegov rezultat, dakle brojevi koje daju sljedeći pozivi.

```
nrow(anketa_mreze)
```

```
[1] 300
```

```
round(mean(anketa_mreze$minute_dnevno), 1)
```

```
[1] 50,1
```

Ovo je više od udobnosti. Broj prepisan rukom razilazi se s podacima čim se podaci promijene, a nitko to ne primijeti jer rečenica i dalje izgleda uredno. Broj koji dolazi iz koda ne može se raziću s tablicom iz koje je izračunat. Poglavlja ove knjige pisana su tako da svaka brojka u prozi dolazi iz izračuna, upravo zbog toga.

Prije predaje analizu pokrenite iz čiste sesije, dakle nakon što ste obrisali sve objekte i ponovno pokrenuli R. Rezultati moraju nastati iz skripte, a ne iz objekata koji su slučajno ostali u memoriji. Ako analiza uključuje slučajne brojeve, sjeme generatora postavite funkcijom `set.seed()` na početku, jer bez toga isti kod pri svakom pokretanju daje malo drukčije brojeve.

```
set.seed(2026)
mean(sample(anketa_mreze$minute_dnevno, 30))
```

```
[1] 53,8
```

```
set.seed(2026)
mean(sample(anketa_mreze$minute_dnevno, 30))
```

```
[1] 53,8
```

Ista vrijednost pri oba pokretanja pokazuje da je izvlačenje ponovljivo. Uz sjeme, u reproduksijski zapis pripadaju i verzije paketa te izvor podataka.

Greške i dijagnostika

Greške su uobičajen dio rada s kodom. Razlika između početnika i iskusnog korisnika nije u tome koliko ih rade nego u tome koliko brzo ih prepoznaju. Prvi i najvažniji korak jest pročitati poruku, jer je gotovo uvijek informativna.

Poruka `object 'x' not found` znači da objekt s tim imenom ne postoji. Uzrok je najčešće tipfeler u imenu, nepokrenut raniji redak ili pokretanje koda izvan redosljeda. Poruka `unexpected symbol` označava sintaktičku pogrešku, obično zaboravljeni zarez, operator ili zatvorenu zagradu. Poruka `does not exist in current working directory` znači da R ne nalazi datoteku, pa provjerite ime, veliko i malo slovo te putanju, a `getwd()` će vam reći gdje R uopće traži. Poruka `could not find function` znači da paket nije učitao, pa provjerite je li `library()` na vrhu skripte pokrenut.

Upozorenja se razlikuju od grešaka. Greška zaustavlja izvršavanje, a upozorenje ga ne zaustavlja nego javlja da se dogodilo nešto neobično.

```
as.numeric(c("10", "20", "trideset"))
```

Warning: NAs introduced by coercion

```
[1] 10 20 NA
```

R je prva dva teksta pretvorio u brojeve, treći nije mogao i na njegovo je mjesto stavio NA. Kod se izvršio do kraja, a rezultat je tiho izgubio jednu vrijednost. Upozorenja zato treba čitati jednako pažljivo kao greške, jer najčešće govore o problemu s podacima, a ne s kodom.

Kada dugačak cjevovod ne radi, ne tražite grešku u cjelini. Pokrenite ga korak po korak i nakon svakog koraka pogledajte rezultat.

```
anketa_mreze |>
  filter(dob < 30) |>
  nrow()
```

```
[1] 139
```

```
anketa_mreze |>
  filter(dob < 30) |>
  group_by(dobna_skupina) |>
  summarise(n = n(), .groups = "drop")
```

```
# A tibble: 2 x 2
  dobna_skupina      n
  <fct>          <int>
1 18 do 24         90
2 25 do 34         49
```

Prvi korak potvrđuje da filtriranje uopće nešto zadržava, drugi da grupiranje daje očekivane skupine. Postupno građenje cjevovoda uz provjeru nakon svakog koraka najbrži je način da se pronađe mjesto na kojem se nešto raspalo.

Za pomoć oko pojedine funkcije služi upitnik ispred njezina imena. Stranica pomoći opisuje argumente i završava primjerima, koji su gotovo uvijek korisniji od opisa.

```
?mean
vignette("dplyr")
```

Kada pomoć ne pomogne, potraga na internetu gotovo uvijek uspije, uz jedan savjet. Pretraži dodajte riječ `tidyverse` ili ime paketa, jer ćete inače dobiti odgovore u drukčijoj sintaksi od one koju ovdje koristimo.

Postupci iz poglavlja

Ovaj odjeljak okuplja postupke na koje poglavlja upućuju kada zadatak traži izračun nad cijelim skupom podataka. Svaki je zaokružen i može se pokrenuti samostalno.

Zbirne i skupne stope iz poglavlja 1

Poglavlje o statističkom mišljenju uspoređuje zbirnu stopu sa stopama po podskupinama. Postupak ima tri koraka. Najprije se izračunaju stope unutar skupina, zatim zbirna stopa, i naposljetku se usporede.

```
upisi <- as.data.frame(UCBAdmissions)

# Stope po odjelu i spolu
po_odjelu <- upisi |>
  group_by(Dept, Gender) |>
  summarise(
    prijave = sum(Freq),
    primljeni = sum(Freq[Admit == "Admitted"]),
    stopa = primljeni / prijave,
    .groups = "drop"
  )

# Zbirna stopa, bez odjela
zbirno <- upisi |>
  group_by(Gender) |>
  summarise(
    prijave = sum(Freq),
    primljeni = sum(Freq[Admit == "Admitted"]),
```

```

    stopa = primljeni / prijave,
    .groups = "drop"
  )

zbirno

```

```

# A tibble: 2 x 4
  Gender prijave primljeni stopa
  <fct>    <dbl>    <dbl> <dbl>
1 Male      2691      1198 0.445
2 Female    1835       557 0.304

```

Zbirna tablica pokazuje razliku u korist muškaraca. Usporedba po odjelima pokazuje drukčiju sliku, a broj odjela u kojima žene prolaze barem jednako dobro dobiva se preoblikovanjem u široki oblik.

```

po_odjelu |>
  select(Dept, Gender, stopa) |>
  pivot_wider(names_from = Gender, values_from = stopa) |>
  mutate(zene_bolje = Female >= Male)

```

```

# A tibble: 6 x 4
  Dept    Male Female zene_bolje
  <fct>  <dbl>  <dbl> <lgl>
1 A      0.621 0.824 TRUE
2 B      0.630 0.68  TRUE
3 C      0.369 0.341 FALSE
4 D      0.331 0.349 TRUE
5 E      0.277 0.239 FALSE
6 F      0.0590 0.0704 TRUE

```

Ključ mehanizma leži u raspodjeli prijave, jer zbirna stopa svakom odjelu daje težinu prema broju prijave iz te skupine.


```
po_odjelu |>
  group_by(Gender) |>
  mutate(udio_prijava = 100 * prijave / sum(prijave)) |>
  ungroup() |>
  select(Dept, Gender, stopa, udio_prijava) |>
  pivot_wider(names_from = Gender, values_from = c(stopa, udio_prijava))
```

```
# A tibble: 6 x 5
  Dept stopa_Male stopa_Female udio_prijava_Male udio_prijava_Female
  <fct>      <dbl>      <dbl>      <dbl>      <dbl>
1 A         0.621        0.824        30.7        5.89
2 B         0.630        0.68         20.8        1.36
3 C         0.369        0.341        12.1       32.3
4 D         0.331        0.349        15.5       20.4
5 E         0.277        0.239         7.10       21.4
6 F         0.0590        0.0704       13.9       18.6
```

Provjera instrumenta iz poglavlja 2

Poglavljje o mjerenju okreće ljestvicu niječno formulirane tvrdnje i provjerava slaže li se svaka tvrdnja s ostatkom instrumenta. Postupak se lako primjenjuje na bilo koji upitnik.

```
odgovori <- tribble(
  ~ispitanik, ~t1, ~t2, ~t3, ~t4,
  "I01", 4, 5, 4, 2,
  "I02", 5, 4, 5, 1,
  "I03", 3, 3, 3, 3,
  "I04", 2, 1, 2, 5,
  "I05", 1, 2, 1, 4,
  "I06", 3, 4, 3, 3
)

stavke <- c("t1", "t2", "t3", "t4")
```

```
# Korelacija svake tvrdnje sa zbrojem preostalih
stavka_ukupno <- function(podaci, stavke) {
  sapply(stavke, function(s) {
    ostatak <- rowSums(podaci[setdiff(stavke, s)])
    cor(podaci[[s]], ostatak)
  })
}

round(stavka_ukupno(odgovori, stavke), 2)
```

t1	t2	t3	t4
0,86	0,57	0,86	-0,94

Negativna vrijednost kod četvrte tvrdnje znak je niječne formulacije. Ljestvica se okreće tako da se odgovor oduzme od najveće moguće vrijednosti uvećane za jedan, dakle od šest za ljestvicu od 1 do 5.

```
okrenuto <- odgovori |>
  mutate(t4 = 6 - t4)

round(stavka_ukupno(okrenuto, stavke), 2)
```

t1	t2	t3	t4
0,94	0,82	0,94	0,94

```
okrenuto |>
  mutate(povjerenje = rowMeans(pick(all_of(stavke)))) |>
  select(ispitanik, povjerenje)
```

```
# A tibble: 6 x 2
  ispitanik povjerenje
  <chr>      <dbl>
1 I01      4.25
2 I02      4.75
```

3 I03	3
4 I04	1.5
5 I05	1.5
6 I06	3.25

Nakon okretanja sve četiri tvrdnje idu u istu stranu i zbrajanje ima smisla.

Mjere središta i raspršenosti iz poglavlja 4

Poglavlje o sažimanju podataka traži usporedbu mjera središta i raspršenosti te njihovu osjetljivost na ekstremnu vrijednost. Sve se dobiva jednim sažetkom.

```
minute <- anketa_mreze$minute_dnevno

tibble(
  n = length(minute),
  sredina = mean(minute),
  medijan = median(minute),
  skracena10 = mean(minute, trim = 0.10),
  sd = sd(minute),
  iqr = IQR(minute),
  raspon = diff(range(minute))
) |>
  mutate(across(everything(), \(v) round(v, 1)))
```

```
# A tibble: 1 x 7
```

	n	sredina	medijan	skracena10	sd	iqr	raspon
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	300	50.1	39	44.1	39.2	46.2	245

Osjetljivost se pokazuje tako da se najveća vrijednost zamijeni znatno većom, a zatim se isti sažetak ponovi. Medijan i međukvartilni raspon jedva se pomaknu, dok sredina i standardna devijacija reagiraju snažno.

```

minute_izmijenjeno <- minute
minute_izmijenjeno[which.max(minute)] <- 10 * max(minute)

tibble(
  verzija = c("izvorno", "s ekstremom"),
  sredina = c(mean(minute), mean(minute_izmijenjeno)),
  medijan = c(median(minute), median(minute_izmijenjeno)),
  sd = c(sd(minute), sd(minute_izmijenjeno)),
  iqr = c(IQR(minute), IQR(minute_izmijenjeno))
) |>
  mutate(across(where(is.numeric), \(v) round(v, 1)))

```

```

# A tibble: 2 x 5
  verzija      sredina medijan    sd    iqr
  <chr>        <dbl>   <dbl> <dbl> <dbl>
1 izvorno      50.1      39  39.2  46.2
2 s ekstremom  57.5      39 145.  46.2

```

Poglavlje uspoređuje i položaj sredine i medijana na izvornoj te na logaritamskoj ljestvici.

```

tibble(
  ljestvica = c("izvorna", "logaritamska"),
  sredina = c(mean(minute), mean(log(minute))),
  medijan = c(median(minute), median(log(minute)))
) |>
  mutate(razlika = round(sredina - medijan, 2))

```

```

# A tibble: 2 x 4
  ljestvica      sredina medijan razlika
  <chr>        <dbl>   <dbl>   <dbl>
1 izvorna      50.1      39    11.1
2 logaritamska  3.61     3.66   -0.05

```

Na izvornoj ljestvici sredina znatno nadmašuje medijan, a nakon logaritamske pretvorbe razlika se gotovo gubi, jer pretvorba stiše dugi desni rep.

Izračuni iza četiriju prikaza iz poglavlja 5

Poglavlje o vizualizaciji pita što svaki prikaz čuva i što izračunava prije crtanja. Odgovor se najlakše vidi tako da se isti izračuni naprave izravno.

```
# Što računa kutijasti dijagram
anketa_mreze |>
  group_by(dobna_skupina) |>
  summarise(
    q1 = quantile(minute_dnevno, 0.25),
    medijan = median(minute_dnevno),
    q3 = quantile(minute_dnevno, 0.75),
    .groups = "drop"
  )
```

```
# A tibble: 4 x 4
  dobna_skupina    q1 medijan    q3
  <fct>          <dbl>   <dbl> <dbl>
1 18 do 24       53     68.5  99.2
2 25 do 34      30.8     46   72.5
3 35 do 44      18.2     26   44.5
4 45 i više       9     15   24.5
```

```
# Što računa stupičasti prikaz prosjeka
anketa_mreze |>
  group_by(dobna_skupina) |>
  summarise(prosjek = round(mean(minute_dnevno), 1), .groups = "drop")
```

```
# A tibble: 4 x 2
  dobna_skupina prosjek
```

	<fct>	<dbl>
1	18 do 24	81.5
2	25 do 34	54.4
3	35 do 44	32.4
4	45 i više	16.2

Histogram i raspršeni prikaz ne računaju ništa od toga, jer crtaju pojedinačna opažanja ili njihove razrede. Usporedba pokazuje koliko se informacije gubi na putu od svih opažanja do jednog stupca po skupini.

Isti se postupak primjenjuje i na Anscombeov kvartet, koji je ugrađen u R.

```
anscombe |>
  pivot_longer(
    everything(),
    names_to = c(".value", "skup"),
    names_pattern = "(.)(. )"
  ) |>
  group_by(skup) |>
  summarise(
    sredina_x = mean(x),
    sredina_y = round(mean(y), 2),
    sd_y = round(sd(y), 2),
    korelacija = round(cor(x, y), 2),
    .groups = "drop"
  )
```

```
# A tibble: 4 x 5
  skup sredina_x sredina_y sd_y korelacija
  <chr>      <dbl>      <dbl> <dbl>      <dbl>
1 1          9        7.5  2.03      0.82
2 2          9        7.5  2.03      0.82
3 3          9        7.5  2.03      0.82
4 4          9        7.5  2.03      0.82
```

Sva četiri skupa imaju gotovo jednake sažetke i posve različite oblike, što je argument koji poglavlje razrađuje.

Kamo dalje

Ovdje prikazano dovoljno je za opisnu analizu, čišćenje podataka i pripremu tablica koje knjiga koristi. Za sve dalje najkorisniji je *R for Data Science*, koji je slobodno dostupan i pisan u istom pristupu (Wickham i sur. 2023.).

Tri navike vrijede više od svakog dodatnog paketa. Podatke pogledajte prije nego što ih obradite. Cjevovod gradite korak po korak i provjeravajte rezultat nakon svakog koraka. Analizu na kraju pokrenite iz čiste sesije. Time se uklanja većina problema s kojima se početnici susreću, a rad ostaje ponovljiv, što je jedini oblik u kojem tuđa analiza uopće može biti provjerena.

Put bez koda

Ovaj dodatak prati analize iz knjige u jamoviju. Namjerno se oslanja na nazive analiza i očekivane izlaze, a ne na snimke zaslona koje se mijenjaju s verzijom sučelja. Čitatelj bez programiranja tako može reproducirati statistički postupak, dok iste provjere dizajna i interpretacije ostaju obvezne.

Priprema podataka

Svaki redak predstavlja jedinicu analize, a svaki stupac varijablu. Prije odabira analize provjeravamo razinu mjerenja koju jamovi prikazuje ikonom uz ime stupca. Pogrešno postavljena razina može sakriti postupak ili ponuditi račun koji nema sadržajno značenje.

U opisnom modulu najprije tražimo broj valjanih opažanja, nedostajuće vrijednosti, prikladnu mjeru središta i raspršenosti te graf raspodjele. Izlaz spremamo uz datoteku podataka i bilježimo verziju programa.

Povezanost i skupine

Za dvije brojčane varijable biramo korelacijsku matricu i uključujemo raspršeni prikaz. Pearsonov i Spearmanov koeficijent uspoređujemo tek nakon pregleda oblika. Za dvije skupine odabiremo neovisni ili upareni t-test prema jedinici analize, a ne prema rasporedu stupaca.

Kod više skupina koristimo ANOVA-u, uključujemo prikaz reziduala, veličinu učinka i unaprijed obrazložene usporedbe. Hi-kvadrat analiza pripada kontingencijskim tablicama i uz test treba pokazati očekivane frekvencije, reziduala i Cramérovo V .

Izvoz koji se može provjeriti

Tablica iz jamovija nije samostalan zaključak. Uz nju čuvamo opis varijabli, dizajna, svih uključenih opcija i razloga odabira. U izvještaj prenosimo procjenu i interval prije testa, a graf preuređujemo samo ako promjena ne skriva ljestvicu, skupine ili pojedinačna opažanja.

Katalog podataka

Katalog povezuje svaki skup podataka s izvorom, licencom, jedinicom analize i poglavljima koja ga koriste. Skup bez provjerljivog podrijetla i uvjeta uporabe ne ulazi u knjigu. Simulacije nastale u kodu nisu empirijski skupovi i navode se odvojeno.

Ugrađeni skupovi

Trenutačni djelomični rukopis koristi dva ugrađena skupa iz distribucije R-a. Prije konačnog izdanja provjerit će se uvjeti zasebne redistribucije svakog skupa. Knjiga ih sada poziva iz lokalne instalacije i ne pohranjuje njihove kopije u `data/`.

Tablica 1: Ugrađeni skupovi u djelomičnom rukopisu. Izrada autora.

Skup	Podrijetlo, jedinica i uporaba
UCBAdmissions	Berkeleyjski podaci o prijavama (Bickel i sur. 1975.). Jedinica je ćelija tablice frekvencija, a skup se koristi u poglavljima o statističkom mišljenju i kategoričkim podacima.

Skup	Podrijetlo, jedinica i uporaba
<code>anscombe</code>	Anscombeov kvartet (Anscombe 1973.). Jedinica je par brojčanih opažanja, a skup se koristi u poglavljima o vizualizaciji i povezanosti.

Simulirani nastavni podaci

Poglavlja o vjerojatnosti, uzorkovanju, procjeni, testiranju, snazi, modelima i algoritmima stvaraju podatke kodom uz fiksirano sjeme iz `R/setup.R`. Simulacije služe učenju mehanizma i nikada se ne opisuju kao nalaz o stvarnoj populaciji. Svaki rezultat može se ponovno proizvesti iz koda u poglavlju.

Dva simulirana skupa nisu lokalna za pojedino poglavlje nego prolaze kroz više njih, pa imaju vlastite unose. Njihovi generatori žive u `R/podaci-nastavni.R` i pozivaju se iz `R/setup.R`, tako da su skupovi dostupni svakom poglavlju pod imenima `anketa_mreze` i `populacija_medija` bez dodatnog učitavanja. Svaki generator nosi vlastito sjeme i vraća zatečeno stanje generatora slučajnih brojeva, pa učitavanje skupa ne pomiče nijednu kasniju simulaciju u poglavlju.

Tablica 2: Simulirana anketa o korištenju društvenih mreža. Izrada autora.

Svojstvo	Opis
Ime	<code>anketa_mreze</code>
Podrijetlo	simulacija, <code>R/podaci-nastavni.R</code> , sjeme 4001
Jedinica analize	ispitanik
Veličina	300 opažanja

Svojstvo	Opis
Varijable	<code>ispitanik</code> , <code>dob</code> , <code>dobna_skupina</code> , <code>minute_dnevno</code> , <code>povjerenje</code>
Oblik	dnevno vrijeme korištenja je lognormalno po dobnoj skupini, pa je zbirna raspodjela nagnuta prema većim vrijednostima
Uporaba	poglavlja o sažimanju podataka, vizualizaciji i povezanosti
Licenca	nije primjenjiva, skup nastaje kodom u ovom repozitoriju

Skup je nastavno pomagalo i nije mjerenje. Nijedna brojka izvedena iz njega ne smije se navesti kao tvrdnja o korištenju društvenih mreža u Hrvatskoj ni igdje drugdje, a poglavlja koja ga koriste to kažu na prvom mjestu na kojem se pojavi. Postoji zato da poglavlja o opisanju podataka rade na istim ispitanicima, pa čitatelj isti uzorak prepozna u sažecima, grafovima i koeficijentima.

Drugi skup rješava suprotan problem. Poglavlja o uzorkovanju i procjeni moraju pokazati koliko dobro procjena pogađa cilj, a to je moguće samo ako je cilj poznat. Nijedno stvarno istraživanje ne raspolaže takvom populacijom, jer kad bi je imalo, ne bi mu trebala statistika. Zato knjiga populaciju stvara kodom i zatim iz nje uzorkuje pred čitateljem.

Tablica 3: Simulirana populacija poznatih parametara. Izrada autora.

Svojstvo	Opis
Ime	<code>populacija_medija</code>
Podrijetlo	simulacija, <code>R/podaci-nastavni.R</code> , sjeme 8001

Svojstvo	Opis
Jedinica analize	odrasla osoba izmišljenoga grada
Veličina	50 000 opažanja
Varijable	osoba, dob, spol, obrazovanje, izvor_vijesti, povjerenje_medijima, minute_medija, spremnost_platiti
Poznati parametri	prosječno povjerenje 4,88 uz standardnu devijaciju 1,98, prosječnih 174,5 minuta dnevno, udio korisnika portala 0,302
Oblik	spremnost na plaćanje ima oko 76 % nula i dugačak desni rep, pa služi kao izrazito asimetrična varijabla u demonstraciji središnjega graničnog teorema
Uporaba	poglavlja o uzorkovanju, procjeni, kategoričkim podacima, dvjema grupama i više grupa
Licenca	nije primjenjiva, skup nastaje kodom u ovom repozitoriju

Ni ovaj skup nije mjerenje. Grad iz kojeg dolazi ne postoji, a povjerenje u medije, dnevne minute i spremnost na plaćanje vrijednosti su koje je proizveo generator slučajnih brojeva. Njegova nastavna vrijednost leži upravo u tome što je izmišljen, jer se samo za izmišljenu populaciju smije reći koliki joj je prosjek prije nego što se uzme i jedan uzorak. Poglavlja koja ga koriste tu razliku navode prije prve brojke.

Sljedeći podatkovni val

Plan knjige predviđa provjerene društvenoznanstvene skupove iz Europskoga društvenog istraživanja, DZS-a i Eurostata. Za svaki budući unos katalog mora navesti izdanje ili val, trajnu poveznicu, licencu, datum preuzimanja, jedinicu analize, varijable korištene u knjizi i sve korake obrade.

Koji test kada

Odabir postupka počinje istraživačkim pitanjem, dizajnom i vrstom ishoda. Stablo ne može popraviti loše mjerenje ni stvoriti neovisna opažanja. Ono samo povezuje dobro postavljeno pitanje s poglavljem i početnim modelom.

Put od pitanja do modela

Za opis jedne brojčane varijable koristimo raspodjelu, mjeru središta i raspršenosti. Za dvije brojčane varijable polazimo od raspršenog dijagrama i korelacije, a prema potrebi prelazimo na regresiju. Za kategoričke varijable polazimo od frekvencija, udjela i kontingencijske tablice.

Brojčani ishod i dvije neovisne skupine vode prema Welchovu t-testu ili linearnom modelu s binarnim prediktorom. Iste jedinice mjerene dvaput vode prema uparenom postupku. Više skupina vodi prema ANOVA-i kao linearnom modelu s kategoričkim prediktorom.

Tablica 1: Početni izbor postupka prema pitanju i dizajnu. Izrada autora.

Pitanje, ishod i dizajn	Početni postupak
Opis raspodjele brojčanog ishoda u jednom uzorku	sažeci i graf

Pitanje, ishod i dizajn	Početni postupak
Povezanost dviju brojčanih varijabli u opažajnom dizajnu	korelacija i regresija
Razlika brojčanog ishoda između dviju neovisnih skupina	Welchov t-test
Promjena brojčanog ishoda na istim uparenim jedinicama	upareni t-test
Razlika brojčanog ishoda između više neovisnih skupina	ANOVA
Povezanost kategoričkih varijabli u tablici frekvencija	hi-kvadrat ili Fisherov test

Provjere nakon odabira

Nakon izbora pregledavamo neovisnost, oblik raspodjele, rezidualne, veličinu uzorka i očekivane frekvencije. Izvještavamo procjenu, interval i veličinu učinka prije odluke o testu. Ako pretpostavka ne pristaje, mijenjamo pitanje, model ili način izvještavanja uz sadržajno obrazloženje.

Rječnik pojmova

Rječnik uparuje hrvatske nazive s engleskim terminima pod kojima će ih čitatelj najčešće pronaći u međunarodnoj literaturi. Kanonske definicije nastat će iz definicijskih blokova u poglavljima nakon ratifikacije kraljevnice pojmova. Ovaj početni registar zasad služi snalaženju.

Temeljni pojmovi

statistika *statistics* Poglavlje · Zašto statistika

operacionalizacija *operationalization* Poglavlje · Mjerenje i istraživački dizajn

pristranost *bias* Poglavlje · Kako brojke zavode

aritmetička sredina *mean* Poglavlje · Sažimanje podataka

standardna devijacija *standard deviation* Poglavlje · Sažimanje podataka

korelacija *correlation* Poglavlje · Povezanost

vjerojatnost *probability* Poglavlje · Vjerojatnost koliko treba

distribucija uzorkovanja *sampling distribution* Poglavlje · Uzorkovanje

standardna pogreška *standard error* Poglavlje · Uzorkovanje

interval pouzdanosti *confidence interval* Poglavlje · Procjena

p-vrijednost *p-value* Poglavlje · Logika testiranja

veličina učinka *effect size* Poglavlje · Veličina učinka i snaga

predregistracija *preregistration* Poglavlje · Kriza i obnova

kontingencijska tablica *contingency table* Poglavlje · Kategorički podaci

rezidual *residual* Poglavlje · Regresija, opći okvir

preprilagodba *overfitting* Poglavlje · Statistika u doba algoritama

Pravilo uporabe

Hrvatski naziv vodi u prozi, a engleski se pojavljuje u bloku pojmova i pri prvom susretu samo kada je potreban za čitanje literature. Jedan pojam ima jedno kanonsko ime kroz cijelu knjigu. Sinonimi se mogu navesti kao uputnice, ali ne smiju stvarati dvije definicije iste ideje.

Protokol za rad s asistentom

Asistent ubrzava rad kada dobije jasno ograničen zadatak i kada se svaki njegov rezultat provjerava izvan razgovora. Ovaj protokol primjenjuje se na kod, interpretaciju, izvore i pisanje. Odgovornost ostaje na osobi koja predaje, objavljuje ili donosi odluku.

Privatnost prije praktičnosti

Podaci koji opisuju ljude ne šalju se javnom modelu. Uklanjanje imena nije dovoljno ako kombinacija varijabli može ponovno identificirati osobu. Koristimo strukturu tablice, sintetički primjer ili lokalno odobren alat prema pravilima ustanove i istraživačkog odobrenja.

Modelu dajemo najmanju količinu informacija potrebnu za zadatak. Kontakti, otvoreni odgovori, identifikatori i osjetljiva obilježja ostaju izvan razgovora.

Upit, provjera i reprodukcija

Dobar upit navodi pitanje, dizajn, jedinicu analize, varijable, dopušteni zaključak i željeni oblik izlaza. Od modela tražimo kod ili račun,

pretpostavke i popis ručnih provjera. Ne tražimo samo „analiziraj podatke”.

Svaki broj povezujemo s izlazom koji možemo ponovno proizvesti. Svaki izvor otvaramo i provjeravamo podupire li tvrdnju. Kod pokrećemo u čistoj lokalnoj sesiji, pregledavamo pogreške i spremamo konačnu verziju uz podatke.

Objavljivanje uporabe

U studentskom radu i publikaciji navodimo gdje je asistent korišten prema pravilima kolegija, časopisa ili ustanove. Objavljujemo ulogu alata, a ne prebacujemo na njega autorstvo ili odgovornost. Kada je važan za reproducibilnost, bilježimo naziv sustava, datum, verziju ako je dostupna i sažetak zadatka.

Kriteriji za prvo istraživanje

Poglavlje o prvom istraživanju vodi kroz faze rada, a ovdje stoji mjerilo po kojem se gotov rad procjenjuje. Kriteriji su isti bez obzira na to je li rad nastao uz asistenta ili bez njega, jer se svi tiču onoga što se u predanom radu može provjeriti.

Tablica 1: Mjerilo za procjenu prvog istraživanja. Izrada autora.

Kriterij	Zadovoljava kada	Ne zadovoljava kada
Istraživačko pitanje	imenuje populaciju, jedinicu analize, mjere i usporedbu	ostaje na temi ili se mijenja nakon što su rezultati viđeni
Dizajn i granica zaključka	zaključak ostaje unutar onoga što dizajn dopušta	opisni nacrt nosi uzročni jezik
Podaci i trag odluka	podrijetlo, čišćenje i isključenja zapisani su i pregledni	brojke se ne mogu vratiti na izvornik

Kriterij	Zadovoljava kada	Ne zadovoljava kada
Opis i prikaz	tablice i grafovi nose jedinice, broj jedinica i izvor	prikaz skriva raspršenost ili skraćuje os bez napomene
Analiza	postupak odgovara pitanju, a procjena dolazi s intervalom	izvještaj vodi golom p-vrijednošću
Tumačenje	nesigurnost i granica generalizacije stoje uz nalaz	zaključak je širi od uzorka ili od dizajna
Reproducibilnost	tuda čista sesija daje iste tablice i grafove	rezultat ovisi o koracima kojih nema u zapisu
Objava uporabe asistenta	navodi sustav, dio posla i provedene provjere	izostaje ili tvrdi više nego što je provjereno

Kriteriji nisu jednako teški i ne nose jednaku težinu u svakom radu. Pitanje, dizajn i tumačenje nose najviše, jer su to odluke koje kasniji rad ne može popraviti. Reproducibilnost i objava uporabe binarne su, budući da rad ili jest ili nije moguće ponoviti.

Procjena znanja uz asistenta

Zadaci ostaju smisleni kada traže prosudbu, provjeru i reviziju. Student treba objasniti zašto je model prikladan, pronaći pogrešku u uvjerljivom rješenju, reproducirati broj i ograničiti zaključak. Lokalni podaci, usmena obrana i simulacijske igre dodatno pokazuju razumije li postupak osoba koja je koristila alat.

Kolofon

Osnove statistike za društvene znanosti

Luka Šikić

`example.github.io/Statistika`